

UNIVERSIDAD NACIONAL DE ASUNCIÓN

Facultad Politécnica



“ESTRATEGIA DE DISPARO PARA EL PROCESO DE
DESFRAGMENTACIÓN EN REDES ÓPTICAS ELÁSTICAS
MULTICORE, UTILIZANDO TÉCNICAS DE APRENDIZAJE
AUTOMÁTICO”

TRABAJO FINAL DE GRADO PRESENTADO POR

RODOLFO SEBASTIÁN VERGARA FERREIRA
Y DIEGO DANIEL DUARTE CENTURIÓN

COMO REQUISITO
PARA OBTENER EL TÍTULO DE INGENIERO
EN INFORMÁTICA

ORIENTADOR:
PHD. Msc. ING. ENRIQUE DAVALOS

Índice general

Índice de Figuras	VI
Índice de Tablas	VII
Lista de Símbolos	VIII
1. Introducción	1
1.1. Justificación	1
1.2. Objetivos del trabajo	5
1.2.1. Objetivo General	5
1.2.2. Objetivos Específicos	5
1.3. Organización del libro	6
2. Redes Ópticas Elásticas Multicore y Fragmentación del Ancho de Banda	7
2.1. Redes EON Multinúcleo	8
2.2. Diafonía en Redes Ópticas Elásticas Multinúcleo	10
2.2.1. Cálculo de la diafonía	13
2.2.2. Asignación de espectro con conmutación de núcleo	14
2.3. Fragmentación del Ancho de Banda en MC-EON	17
2.3.1. Enfoques de gestión de fragmentación	21
2.4. Descripción del problema tratado	23

3. Aprendizaje Automático	25
3.1. Clasificación de sistemas o tipos de aprendizaje automático	26
3.2. Gradient Boosting	28
3.2.1. Fundamentos del Aprendizaje por Ensamble	29
3.2.2. Principios del Gradient Boosting	30
3.2.3. GradientBoostingClassifier	31
3.2.4. Hiperparámetros y Regularización	32
3.2.5. Ventajas y Limitaciones	33
3.3. Aplicación de Machine Learning en Redes Ópticas Elásticas Multinúcleo	34
3.3.1. Gradient Boosting en MC-EON	37
4. Método Propuesto	39
4.1. Características	40
4.2. Obtención de datos para el entrenamiento	43
4.2.1. Definición de niveles de carga	43
4.2.2. Modelo matemático de simulación	46
4.2.3. Mapeo de valores a niveles discretos	47
4.2.4. Identificación de fases de carga	48
4.2.5. Comportamiento general de la simulación	49
4.2.6. Aplicación al entrenamiento del modelo	49
4.3. Herramientas Utilizadas	50
4.4. Modelado	50
4.4.1. Gradient Boosting Classifier	51
4.4.2. Modelos Alternativos Evaluados	51
4.5. Entrenamiento	52
4.5.1. División Estratificada de Datos	52
4.5.2. Preprocesamiento	52
4.5.3. Proceso de Entrenamiento Iterativo	53

4.5.4. Optimización del Umbral de Decisión	54
4.6. Pruebas de Predicción	54
4.6.1. Evaluación en Conjunto de Prueba	54
4.6.2. Análisis de Viabilidad	55
4.6.3. Visualización de Predicciones	55
4.6.4. Análisis de Predictibilidad	56
5. Pruebas y Resultados Obtenidos	57
5.1. Configuración Experimental	57
5.1.1. Topología y Parámetros de Red	57
5.1.2. Escenarios de Carga Evaluados	58
5.2. Métodos Comparados	59
5.2.1. Método Propuesto (MP): Desfragmentación Adaptativa con ML	59
5.2.2. Método de Referencia 1 (MR1): Desfragmentación Periódica por Tiempo Fijo	60
5.2.3. Método de Referencia 2 (MR2): Desfragmentación por Umbral de BFR	61
5.3. Objetivos de Optimización	61
5.3.1. Objetivo 1: Cantidad de Bloqueos (BL)	62
5.3.2. Objetivo 2: Cantidad de Reconfiguraciones (RC)	62
5.3.3. Métricas de Evaluación Multiobjetivo	62
5.4. Resultados Experimentales	63
5.4.1. Escenario 1: Carga Baja (800 - 3,000 Erlangs)	63
5.4.2. Escenario 2: Carga Media (1,200 - 3,400 Erlangs)	64
5.4.3. Escenario 3: Carga Alta (2,000 - 4,000 Erlangs)	66
5.4.4. Variante con Doble Predictor (3 Niveles)	67
5.5. Análisis Comparativo Multiobjetivo	68
5.5.1. Soluciones en el Frente de Pareto	68

5.5.2. Cobertura de Pareto	69
5.5.3. Eficiencia en Uso de Recursos	70
5.6. Validación del Horizonte de Predicción	70
5.7. Discusión de Resultados	71
5.7.1. Superioridad del Método Propuesto	71
5.7.2. Ventajas de la Estrategia Adaptativa	72
5.7.3. Comparación con Métodos Tradicionales	72
6. Conclusiones y Trabajos Futuros	74
6.1. Conclusiones del Trabajo	75
6.1.1. Cumplimiento de Objetivos	75
6.1.2. Contribuciones Principales	77
6.1.3. Validación Experimental	78
6.1.4. Validación de la Hipótesis	79
6.2. Aportes de la Investigación	80
6.3. Limitaciones Identificadas	82
6.4. Trabajos Futuros	83
6.4.1. Extensiones Metodológicas	84
6.4.2. Extensiones Arquitecturales y Algorítmicas	85
6.4.3. Extensiones a Otros Contextos Operacionales	87
6.4.4. Validación Experimental en Entornos Reales	88
6.5. Reflexiones Finales	89

Índice de figuras

2.1. Ejemplo de Fibras Multinúcleo (MCF) con 7, 12 y 19 núcleos	9
2.2. Core Pitch entre dos núcleos adyacentes en un MCF de 7 núcleos . .	10
2.3. XT en un Fibra MCF de 3 núcleos []	12
2.4. Comutación de núcleos con contigüidad de espectro []	14
2.5. Asignación de espectro sin conmutación de núcleos []	16
2.6. Asignación de espectro con conmutación de núcleos []	17
2.7. Restricciones de contigüidad y continuidad aplicadas- Conexión Rechazada	20
2.8. Restricciones de contigüidad y continuidad aplicadas- Conexión Establecida	20
2.9. Esquema de Gestión de la Fragmentación	22
2.10. Ejemplo de desfragmentaciones periódicas con volumen de carga de tráfico variado	24
4.1. Tabla 1 - Niveles de carga simulados	44
4.2. Distribución de niveles de carga en la simulación	44
4.3. Evolución temporal de la carga en la simulación	45
4.4. Tabla 2 - Muestra de datos temporales generados	45
4.5. Componentes armónicas del modelo de carga	47
4.6. Modelo matemático completo de la carga	47
4.7. Distribución de fases operativas en la simulación	48

ÍNDICE DE FIGURAS

VI

4.8. Frecuencia de ocurrencia de niveles de carga	49
---	----

Lista de Tablas

4.1.	Resultados en pruebas de predicción (Gradient Boosting)	55
5.1.	Configuración de escenarios de carga evaluados	59
5.2.	Resultados comparativos - Escenario 1 (Carga Baja)	64
5.3.	Resultados comparativos - Escenario 2 (Carga Media)	65
5.4.	Resultados comparativos - Escenario 3 (Carga Alta)	66
5.5.	Resultados con estrategia de doble predictor (3 niveles)	68
5.6.	Distribución de soluciones en el Frente de Pareto	68
5.7.	Cobertura de Pareto entre métodos (agregado 3 escenarios)	69
5.8.	Validación del horizonte de predicción $t + 1000$	71

Lista de Símbolos

HM	<i>High-slot Mark.</i>
HM_{max}	HM máximo.
Ent_{link}	Entropía del enlace.
Ent_{link-i}	Entropía del enlace i .
Ent_{red}	Entropía de la red.
N	Cantidad de FS en un enlace.
FS_i	<i>Frecuency Slot</i> de índice i .
FS_{i+1}	<i>Frecuency Slot</i> de índice $i + 1$.
$ E $	Cantidad de enlaces de la red.
SHF_{link}	Entropía de Shannon del enlace.
SHF_{link-i}	Entropía de Shannon del enlace i .
SHF_{red}	Entropía de Shannon de la red.
S_{free}	Cantidad de FS libres en un enlace.
BFR_{link}	Relación de Fragmentación de ancho de banda de un enlace.
BFR_{link-i}	Relación de Fragmentación de ancho de banda del enlace i .
BFR_{red}	Relación de Fragmentación de ancho de banda de la red.
$MaxBlock()$	Tamaño del mayor bloque de FS bloquados.
MSI	Índice de slot máximo utilizado.
MSI_{link-i}	Índice de slot máximo utilizado del enlace i .
MSI_{red}	Índice de slot máximo utilizado de la red.

CE_{link}	Consecutividad del espectro.
CE_{red}	Consecutividad del espectro de la red.
$Joins$	Cantidad total de bloques de dos ranuras libres adyacentes distintos dentro de un enlace.
$Bloques$	Cantidad de bloques de ranuras libres en un enlace.
K	Cantidad de rutas de dos enlaces en la red.
Uso	Porcentaje de utilización de la red.
$sum(i)$	Cantidad de FS utilizadas en el enlace i .
FSB	Acumulación de FS bloqueados.
S_i^{block}	Cantidad de FS solicitadas por la demanda bloqueada i .
D	Cantidad de demandas.
T	Ventada de tiempo seleccionada para el calculo de IB .
PB_t	Índice de bloqueo para el tiempo t .
FSD_i	Cantidad de FS demandadas en el tiempo t .
$train_{mean}$	Media de valores.
$train_{stf}$	Desviación estándar.
MAE	Error Absoluto Medio.
MSE	Error Cuadrático Medio.
PB	Probabilidad de Bloqueo.
PB_{th}	Umbral para disparar el proceso de desfragmentación.
BL	Cantidad de Bloqueos.
RC	Cantidad de Reconfiguraciones.
SFP	Número de soluciones en el Frente Pareto.
CP	Cobertura Pareto.
MP	Método Propuesto.

Capítulo 1

Introducción

1.1. Justificación

Debido al incremento de la popularidad de internet y del uso de servicios en la nube, tales como *Content Delivery Network* (CDN) y *Video on Demand* (VoD), las demandas de tasas de bits en las redes han crecido de manera exponencial, lo que obliga a estudiar nuevas y mejores tecnologías relacionadas a la transmisión de datos.

Las Redes de Multiplexación por División de Longitud de Onda o *Wavelength Division Multiplexing* (WDM), utilizan una grilla fija, de 50 o 100 GHz, dan una gran ventaja logrando velocidades muy superiores frente a las viejas tecnologías, pero a pesar de esta ventaja señalada, la gruesa granularidad lleva a un uso ineficiente del espectro, ya que cada demanda es asignada a un canal fijo y estas pueden requerir un ancho de banda menor al tamaño del canal.

Esta desventaja da lugar a las Redes Elásticas Ópticas o *Elastic Optical Networks* (EON) [1], las cuales surgen como una solución al problema anteriormente citado, ya que estas proporcionan una mayor flexibilidad en la división del espectro y de esa forma lograr que los requerimientos sean asignados de manera más eficiente.

A las redes EON tambien se la conocen como redes de grilla flexible, debido a que las ranuras de frecuencia o FS (*Frequency Slot*) que reemplazan a los “Canales

WDM”, cuentan con una división más flexible. Cada FS tiene un ancho de banda de 12.5 GHz, de esta manera se logra una cantidad más apropiada de FS para satisfacer un requerimiento.

Sin embargo, a pesar de las mejoras introducidas por las redes EON, el crecimiento exponencial del tráfico de datos demanda soluciones aún mas avanzadas. En este contexto, surgen las Redes Ópticas Elásticas Multicore o *Elastic Optical Networks with Multicore Fibers* (EON-MCF) y por consecuente *Space Division Multiplexing-Elastic Optical Networks* (SDM-EON) , que incorporan fibras ópticas multinúcleo (MCF), para multiplicar la capacidad de transmisión mediante la explotación de la dimensión espacial, ademas de las dimensiones espectral y temporal ya utilizadas en las redes EON convencionales.

Las fibras multinúcleo contienen múltiples núcleos dentro de una única fibra, donde cada núcleo puede transmitir señales de manera independiente. Esta arquitectura permite aumentar significativamente la capacidad de la red sin necesidad de desplegar nuevas fibras, ofreciendo una solución escalable y económicamente viable para satisfacer las crecientes demandas de ancho de banda.

Los métodos de ruteo y asignación del espectro y núcleo tienen gran impacto sobre el uso eficiente de los recursos de la red. Los algoritmos RSCA (*Routing, Spectrum and Core Assigment*) se encargan de resolver dicho problema encontrando el camino más apropiado desde el origen hasta el destino, el núcleo a utilizar y las ranuras que utilizará el requerimiento dentro del espectro de los enlaces.

Se han propuestos varios algoritmos RSCA con el fin de conseguir la mejor utilización de recursos, estos algoritmos están sujetos a tres principios fundamentales: la restricción de consecutividad del ancho de banda, la restricción de la continuidad del ancho de banda y la restricción de continuidad de núcleo.

La restricción de continuidad espectral establece que se deben utilizar los mismos FS en todo el camino y la restricción de contigüidad dispone que los FS seleccionados para satisfacer la demanda deben ser contiguos. La restricción de continuidad de

núcleo específica que se debe mantener el mismo núcleo a lo largo de toda la ruta establecida.

Adicionalmente, en las redes SDM-EON surge un nuevo fenómeno denominado *Crosstalk* o diafonía entre núcleos *inter-core crosstalk, XT*, que ocurre cuando las señales ópticas de núcleos adyacentes interfieren entre sí, degradando la calidad de la transmisión. Este fenómeno debe ser considerado como una restricción adicional en los algoritmos RSCA para garantizar la calidad del servicio.

Debido a las restricciones explicadas y a que las asignaciones de recursos son realizadas de manera dinámica, surge el fenómeno denominado "Fragmentación del Ancho de Banda y del Espacio", este problema es una de las principales dificultades de las redes SDM-EON ya que tiene un impacto directo en el uso eficiente del espectro y de los núcleos disponibles.

El fenómeno de la fragmentación espectro-espacial del ancho de banda sucede cuando en los enlaces se encuentran FS disponibles separados por FS que están siendo utilizados por otras conexiones, o cuando existen núcleos con recursos fragmentados que no pueden ser eficientemente asignados, por lo que estas podrían quedar inutilizables para nuevas conexiones por no poder satisfacer a la demanda debido a las restricciones citadas anteriormente, en consecuencia, la probabilidad de bloqueo [2] aumenta considerablemente.

Un bloqueo sucede cuando el algoritmo RSCA no puede encontrar núcleos y FS disponibles para una demanda, esto puede deberse a una alta saturación del espectro o de los núcleos, pero también debido al problema mencionado anteriormente, donde existe la cantidad de FS libres que se solicitan, pero sin respetar las restricciones de continuidad y contigüidad, o donde no hay núcleos disponibles que cumplan con las restricciones de crosstalk, es decir el espectro y el espacio se encuentran fragmentados.

El problema de la fragmentación de redes SDM-EON es ampliamente estudiado en la literatura actual, para buscar manejarlo se han propuesto soluciones con

distintos enfoques.

Uno de los enfoques es el llamado *Enfoque proactivo* el cual consiste en ejecutar un proceso de desfragmentación periódicamente o mediante un disparador. Tiene como principal objetivo prevenir futuros bloqueos en la red, este enfoque será el utilizado en este trabajo.

El proceso de desfragmentación consiste en la reconfiguración o re-ruteo de un sub-conjunto de conexiones ya establecidas en la red, teniendo como principal objetivo reducir la fragmentación del espectro y la fragmentación espacial mediante la eliminación de bloques de FS libres no contiguos y la redistribución eficiente de conexiones entre núcleos.

En el trabajo presentado por Zhang [3], se realizó un análisis del problema de desfragmentación en redes EON, en el cual lo dividen en cuatro subproblemas, los cuales son, (I) ¿Cómo reconfigurar?, (II) ¿Cómo migrar el tráfico?, (III) ¿Cuándo reconfigurar? y (IV) ¿Qué reconfigurar?. Estos subproblemas mantienen su vigencia en el contexto de las redes SDM-EON, con la complejidad adicional de considerar la dimensión espacial.

En este trabajo nos centraremos en el tercer subproblema, ¿Cuándo reconfigurar?, ya que considerando el enfoque proactivo para resolver el problema de la fragmentación, encontramos que los procesos de desfragmentación podrían ejecutarse en periodos de tiempo donde no son del todo necesarios, es decir cuando la red se encuentra con una baja fragmentación, provocando desfragmentaciones ineficientes, una cantidad mayor de disrupciones de conexiones y una elevación innecesaria del costo de procesamiento.

En los siguientes capítulos presentamos modelos de predicción de índice de fragmentación, entrenados para detectar si supera unos umbrales predefinidos, implementados con técnicas de aprendizaje automático o *Machine Learning*, los cuales se utilizan como estrategia de disparo del proceso de desfragmentación pero en este caso redes SDM-EON Multinúcleo, proponiendo de esta manera una solución al sub-

problema planteado anteriormente.

1.2. Objetivos del trabajo

1.2.1. Objetivo General

Diseñar modelos de predicción para el proceso de desfragmentación en redes ópticas elásticas multicore, utilizando técnicas de aprendizaje automático, con el propósito de maximizar la eficiencia en el uso de los recursos de la red mediante la reducción de reconfiguraciones innecesarias y la minimización de la cantidad de bloqueos.

1.2.2. Objetivos Específicos

- Realizar una revisión bibliográfica del estado del arte en técnicas de desfragmentación para redes ópticas elásticas, con énfasis en métodos basados en aprendizaje automático y su aplicación en redes multicore.
- Identificar y definir métricas de fragmentación apropiadas para redes ópticas elásticas multicore, considerando las particularidades de la asignación de recursos en múltiples núcleos.
- Desarrollar e implementar un modelo de aprendizaje automático capaz de predecir el índice de la fragmentación de la red a futuro y determinar momentos óptimos para activar el proceso de desfragmentación en redes EON multicore.
- Diseñar e implementar una interfaz de integración entre el simulador de redes ópticas elásticas multicore y el modelo de aprendizaje automático entrenado, permitiendo la evaluación en tiempo real del sistema propuesto.
- Evaluar el desempeño del modelo propuesto mediante simulaciones, comparando sus resultados con técnicas de desfragmentación existentes en términos

de probabilidad de bloqueo, número de reconfiguraciones y eficiencia en el uso de recursos espectrales.

1.3. Organización del libro

El presente trabajo se encuentra organizado de la siguiente manera:

En el capítulo dos se trata sobre características y conceptos relacionados con las redes EON, su principal dificultad (la fragmentación del ancho de banda), los diferentes enfoques para manejar la misma y una presentación de trabajos relacionados presentes en la literatura científica.

En el capítulo tres se hace una introducción al *Machine learning*, enfocado al aprendizaje supervisado y redes neuronales.

En el capítulo cuatro se presenta el método propuesto para la selección del momento de desfragmentación, describiendo todo el proceso que conlleva.

El capítulo cinco se muestra las pruebas experimentales junto a un análisis de los resultados obtenidos.

Por último, el capítulo seis presenta las conclusiones del trabajo y sugerencias para trabajos futuros.

Capítulo 2

Redes Ópticas Elásticas Multicore y Fragmentación del Ancho de Banda

Las redes ópticas que se basan en WDM dividen el espectro de cada enlace en canales cuyo ancho de banda se fija de 50 GHz o 100 GHz. Esto debido a que la Unión Internacional de Telecomunicaciones (*ITU-T International Telecommunication Union*) especificó el estándar G.694.1 en el año 2002. Estas redes WDM resultan muy rígidas, y debido a eso es posible que ocurra una utilización ineficiente de la capacidad, provocado por el hecho de que el espacio entre dos canales adyacentes es relativamente grande y si la señal que se transmite utiliza un ancho de banda muy bajo, gran parte del espectro será desperdiciado.

Una nueva tecnología denominada Redes Ópticas Elásticas o *Elastic Optical Networks* (EON) y su evolución: Las Redes ópticas Elásticas Multinúcleo o *Multicore Elastic Optical Networks* (MC-EON) el cual no solo dividen el espectro óptico en Ranuras de Frecuencia o *Frequency Slots* (FS) de 12.5 GHz conforme a lo establecido por el estándar definido en ITU-T (G.694.1) en el año 2012, sino que las (MC-EON) introducen un nuevo dominio de multiplexación espacial, al permitir la transmisión simultánea de múltiples señales ópticas en diferentes núcleos dentro de una misma fibra. Esta aproximación multidimensional proporciona una mayor escalabilidad, eficiencia en la asignación del espectro y reducción del consumo energético, posicionando a las MC-EON como una de las tecnologías mas prometedoras para la

implementación de redes ópticas de ultra alta capacidad en escenarios de próxima generación.

2.1. Redes EON Multinúcleo

Las redes EON Multinúcleo constituyen una variante avanzada de las redes EON que integran el concepto de fibras multinúcleo (MCF) para incrementar significativamente la capacidad de transmisión y la eficiencia espectral. Fundamentalmente, las redes EON Multinúcleo aprovechan múltiples núcleos independientes dentro de una misma fibra óptica para transmitir señales de forma simultánea y paralela, posibilitando una multiplicación de la capacidad de transmisión en comparación con las fibras convencionales [15]. Estas características mencionadas en las EON Multinúcleo se materializan mediante la implementación de la Multiplexación por División de Espacio (SDM). Por esta razón, las redes EON Multinúcleo también se denominan SDM-EON[5]. En las redes EON Multinúcleo, se integra el concepto de asignación flexible de espectro con la utilización de múltiples núcleos, alcanzando una distribución más eficiente de la capacidad total de transmisión. Esta integración de tecnologías posibilita un incremento sustancial en la capacidad de transmisión a través de una única fibra, resultando esencial en un contexto donde la demanda de datos continúa creciendo de manera exponencial. Al incorporar el concepto de fibras multinúcleo en el diseño de las redes EON, se puede lograr una mayor adaptabilidad a las cambiantes necesidades del tráfico y una optimización más profunda de los recursos disponibles.

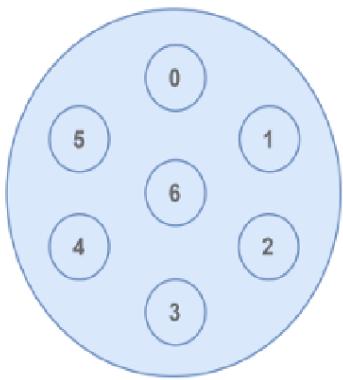


Figura 3.5:
MCF con 7 núcleos [5]

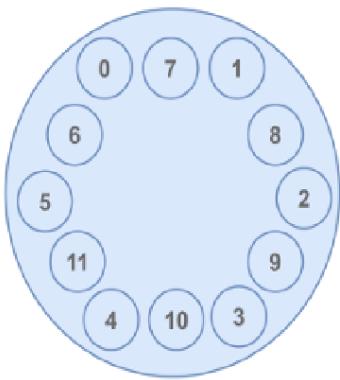


Figura 3.6:
MCF con 12 núcleos [5]

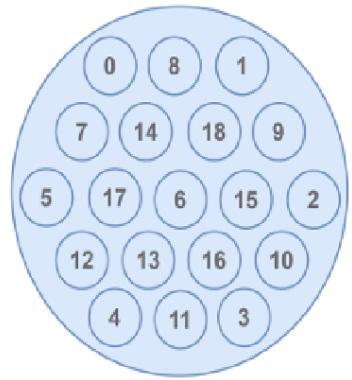


Figura 3.7:
MCF con 19 núcleos [5]

Figura 2.1: Ejemplo de Fibras Multinúcleo (MCF) con 7, 12 y 19 núcleos

Conforme a lo documentado en la literatura [], inicialmente podría considerarse que la utilización de redes EON con mayor cantidad de núcleos proporciona ventajas sustanciales debido a la amplia disponibilidad de recursos espectrales y espaciales. No obstante, se ha identificado que en las redes MCF, el principal desafío radica en la interferencia denominada diafonía (crosstalk), la cual se genera cuando una fracción de la potencia óptica de un núcleo se propaga hacia los núcleos contiguos. Este fenómeno ocasiona una interferencia significativa en los circuitos activos y complejiza considerablemente la asignación de las ranuras espectrales (FS). Investigaciones previas [] han indicado que para viabilizar la implementación de redes EON multinúcleo, resulta fundamental desarrollar fibras que minimicen la diafonía entre núcleos adyacentes.

En la Figura [], se presenta una configuración de MCF con 7 núcleos dispuestos en un patrón hexagonal. En esta arquitectura, el núcleo central (núcleo N° 6) se encuentra rodeado por 6 núcleos adyacentes, resultando en una mayor incidencia de diafonía sobre este núcleo. En contraste, los núcleos periféricos (núcleos N° 0, 1, 2, 3, 4 y 5) poseen 3 núcleos adyacentes cada uno. La Figura [] exhibe una MCF con 12 núcleos organizados en una disposición anular. En esta configuración, cada núcleo presenta exactamente 2 núcleos adyacentes, lo que deriva en que todos los núcleos

experimenten un nivel equivalente de diafonía.

Finalmente, la Figura 2.2 ilustra una MCF con 7 núcleos. En este tipo de fibras, los núcleos pueden presentar hasta 6 núcleos adyacentes por núcleo, generando una mayor incidencia de diafonía.

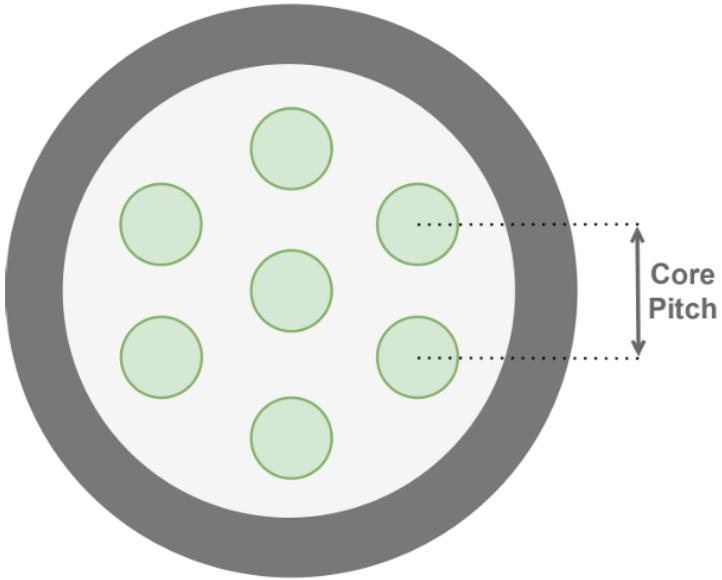


Figura 2.2: Core Pitch entre dos núcleos adyacentes en un MCF de 7 núcleos

2.2. Diafonía en Redes Ópticas Elásticas Multinúcleo

La diafonía constituye un fenómeno indeseado que se manifiesta en las redes de fibra óptica cuando la señal transmitida en una fibra se acopla hacia otra fibra contigua. En el contexto de las redes EON fundamentadas en MCF, la diafonía se define como la interferencia entre conexiones ópticas establecidas en núcleos adyacentes que emplean las mismas ranuras espectrales (FS) en un enlace común. Este tipo de interferencia se denomina diafonía entre núcleos o Inter-Core Crosstalk (XT). La interferencia ocasionada por el XT puede degradar la calidad de la señal en las FS afectadas, lo que implica que la señal en estas ranuras puede experimentar

CAPÍTULO 2. REDES ÓPTICAS ELÁSTICAS MULTICORE Y FRAGMENTACIÓN DEL ANCHO DE BANDA

distorsiones, incrementando la probabilidad de errores en la transmisión de datos.

Consecuentemente, impacta directamente en la capacidad de la red al «inhabilitar» estas FS para la transferencia de datos debido a la diafonía, generando espacios no utilizables entre ellas.

En síntesis, esto deriva en una reducción de la cantidad total de FS disponibles para la transmisión de datos, limitando la capacidad operativa de la red. Con menor disponibilidad de FS, se reducen los canales para transmitir datos, lo que puede restringir la capacidad total de transmisión de la infraestructura de red.

En las redes SDM-EON, el XT entre dos núcleos de una MCF depende significativamente de la distancia entre dicho par de núcleos, denominada core pitch ($\Lambda_{i,j}$). A mayor core pitch, menor será el impacto del XT entre estos dos núcleos [1]. No obstante, resulta importante destacar que, a medida que se incrementa el core pitch, la capacidad de la fibra óptica disminuye. Es decir, al aumentar la distancia física entre dos núcleos, se reduce el espacio disponible en la fibra óptica para albergar núcleos adicionales. Por consiguiente, resulta fundamental establecer un equilibrio entre un core pitch reducido para incrementar la capacidad y uno suficientemente amplio para minimizar los efectos del XT. Este balance posibilita optimizar el desempeño y la eficiencia de la red.

Para demostrar el comportamiento del crosstalk (XT) entre núcleos en fibras multinúcleo, se analiza el ejemplo presentado en la figura [1], la cual ilustra una fibra óptica multinúcleo (MCF) compuesta por tres núcleos organizados en configuración lineal. En esta topología, resulta evidente que el núcleo central (núcleo 2) experimenta una interferencia significativa por XT intercore. Este fenómeno se atribuye a que ambos núcleos contiguos (núcleos 1 y 3) mantienen conexiones establecidas en intervalos espectrales similares a aquellos ya ocupados en el núcleo 2. A modo de ejemplo, los segmentos espectrales FS1 y FS2 resultan inutilizables en el núcleo 2 debido a la interferencia generada por las asignaciones activas en los núcleos laterales. Esta misma situación se replica en los intervalos FS4, FS5 y FS6 del núcleo

CAPÍTULO 2. REDES ÓPTICAS ELÁSTICAS MULTICORE Y FRAGMENTACIÓN DEL ANCHO DE BANDA

mencionado. Consecuentemente, en arquitecturas SDM-EON basadas en fibras multinúcleo, resulta imperativo evaluar el impacto del XT intercore durante el proceso de asignación de recursos espectrales, a fin de mitigar degradaciones en la calidad de transmisión.

Es relevante destacar que el crosstalk intercore no afecta exclusivamente a los segmentos espectrales con demandas activas, sino también a aquellos recursos disponibles en núcleos adyacentes. Un análisis detallado de la figura [] revela que incluso los intervalos espectrales sin conexiones asignadas experimentan interferencia procedente de transmisiones en núcleos contiguos. Esto se exemplifica con los segmentos FS8 y FS9 del núcleo 1, que sufren degradación por el XT generado desde las mismas posiciones espectrales en el núcleo 2. En determinadas circunstancias, esta interferencia puede superar el umbral de crosstalk admisible, imposibilitando la utilización de dichos recursos para el establecimiento de futuras conexiones en arquitecturas multinúcleo.




Figura 2.3: XT en un Fibra MCF de 3 núcleos []

2.2.1. Cálculo de la diafonía

El procedimiento para determinar el nivel de XT que incide sobre una conexión establecida en el núcleo i de una MCF, considerando una configuración arbitraria de núcleos y cualquier disposición geométrica, se desarrolla mediante los siguientes pasos:

En primera instancia, se determina el valor de la XT por unidad de longitud entre el núcleo i y un núcleo adyacente j , denotado como $h_{i,j}$, empleando la expresión:

$$h_{i,j} = \frac{2k^2r}{\beta\Lambda_{i,j}} \quad (2.1)$$

Donde k representa el coeficiente de acoplamiento; r corresponde al radio de curvatura; β denota la constante de propagación; y $\Lambda_{i,j}$ indica la distancia entre los núcleos i y j respectivamente (core pitch).

Posteriormente, se calcula el valor total de la XT que impacta al núcleo i , designado como XT_i , mediante la agregación de las contribuciones de XT provenientes de todos sus núcleos adyacentes. Esta operación se efectúa utilizando la siguiente expresión:

$$XT_i = \sum_{j=1}^{N_i} h_{i,j} \cdot L \quad (2.2)$$

Donde N_i representa la cantidad de núcleos adyacentes al núcleo i , y L corresponde a la longitud física del enlace óptico.

Con el propósito de garantizar la integridad de la señal transmitida, resulta imperativo que el valor calculado de XT_i no exceda un umbral máximo admisible de diafonía al momento de establecer de forma óptima la trayectoria óptica para una solicitud de conexión entrante. El umbral de diafonía o *Crosstalk Threshold* (XT_{TH}) se conceptualiza como el límite superior de XT que una señal propagada a través del sistema puede tolerar sin experimentar una degradación considerable en su calidad o sin provocar la generación de errores en la transmisión de datos [19].

El valor particular del XT_{TH} puede fluctuar en función de las características de la aplicación y las especificaciones técnicas del sistema implementado. En contextos de aplicaciones que demandan elevadas velocidades de transmisión y capacidades sustanciales, es factible admitir niveles considerablemente reducidos de XT_{TH} , en tanto que para aplicaciones de menor criticidad, los valores de XT_{TH} admisibles pueden ser superiores.

2.2.2. Asignación de espectro con conmutación de núcleo

En las arquitecturas SDM-EON, es posible optimizar la eficiencia espectral mediante la implementación de conmutación de núcleos, mecanismo que permite identificar y asignar recursos espectrales en uno o múltiples núcleos a lo largo de una conexión establecida en fibras MCF. Este procedimiento implica la selección del mismo bloque de FS como recursos reservados para cada solicitud de conexión, distribuyéndose entre diferentes núcleos a lo largo de la trayectoria de trabajo. Para materializar la conmutación de núcleos, resulta fundamental respetar la restricción de contigüidad espectral, lo cual significa que la señal puede ser transferida de un núcleo a otro sin limitaciones, en tanto se preserve la continuidad del mismo intervalo espectral asignado.

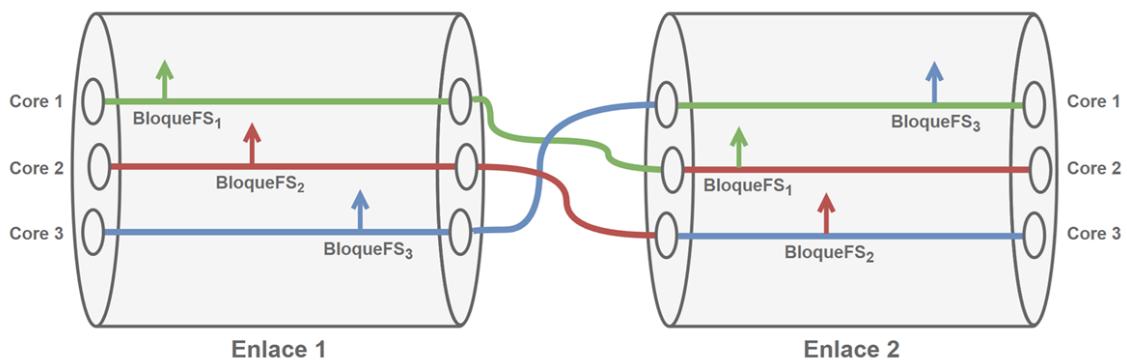


Figura 2.4: Comutación de núcleos con contigüidad de espectro []

En las Figuras [] y [] se ilustra la asignación de núcleos y recursos espectrales sin

comutación de núcleos y con conmutación de núcleos, respectivamente. Los elementos gráficos de color naranja denotan FS ocupadas, mientras que los elementos en blanco representan FS disponibles. Con el propósito de exemplificar el funcionamiento del mecanismo de asignación espectral con conmutación de núcleos, se presentan dos casos representativos documentados en la literatura [20]. En ambos escenarios, se considera una demanda $d(2, 4, 4)$, donde el primer parámetro identifica el nodo de origen, el segundo corresponde al nodo de destino, y el tercero especifica la cantidad de FS requeridas para satisfacer dicha demanda, respectivamente. Es posible identificar y asignar los recursos espectrales necesarios para la demanda a lo largo de la trayectoria conformada por dos enlaces de fibra: l_0 (2-5) y l_1 (5-4), implementando tres núcleos.

La Figura [] exhibe la asignación de núcleos y espectro sin aplicar conmutación de núcleos para la demanda $d(2, 4, 4)$. En los enlaces l_0 y l_1 existen diversos bloques contiguos de FS disponibles. No obstante, debido a la restricción de continuidad espectral, únicamente se configura un bloque candidato de FS en el núcleo 2, representado mediante SC_{2,l_0}^0 , SC_{2,l_1}^0 . Posteriormente, se verifica el impacto del XT con el objetivo de asegurar que la incorporación de la demanda no supere el umbral XT_{TH} . En caso de que el XT exceda XT_{TH} , la demanda $d(2, 4, 4)$ resultará bloqueada, dado que no existen recursos espectrales disponibles a lo largo de la ruta establecida.

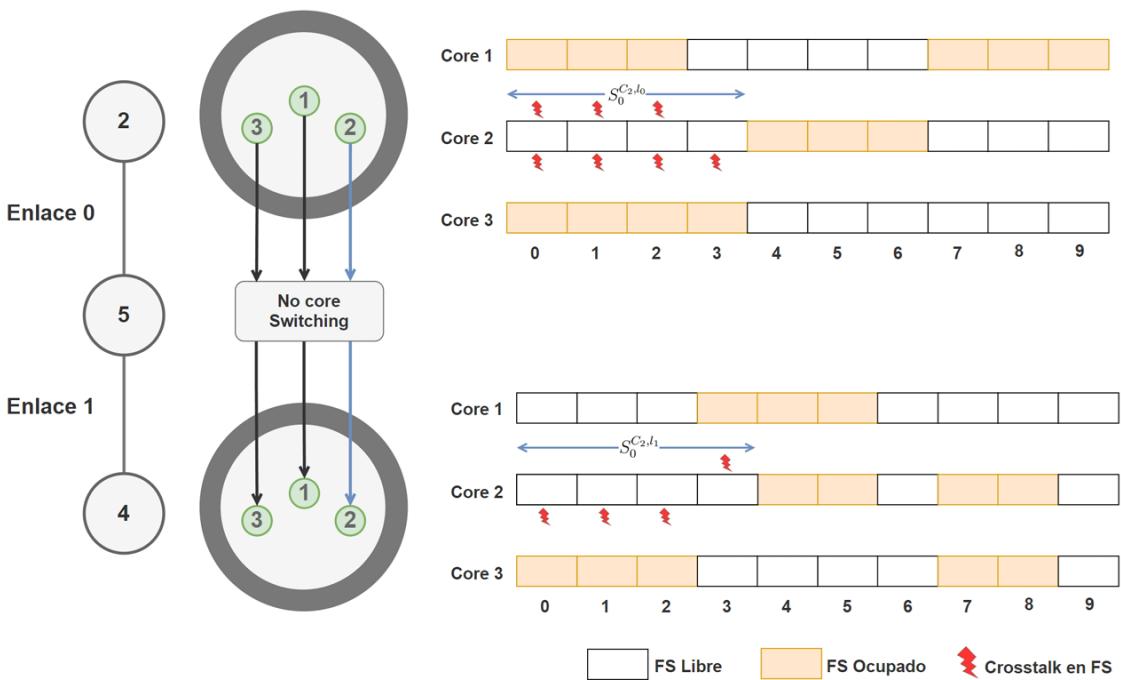


Figura 2.5: Asignación de espectro sin conmutación de núcleos []

La Figura [] ilustra la asignación de núcleos y espectro mediante la implementación de conmutación para la demanda $d(2, 4, 4)$. El mecanismo de conmutación de núcleos posibilita la identificación de bloques de FS que satisfacen la restricción de contigüidad espectral distribuidos en núcleos distintos a través de múltiples enlaces de la trayectoria establecida.

A modo de ejemplo, para la demanda $d(2, 4, 4)$ se identifican tres bloques candidatos de FS que cumplen con dicha restricción: $\{SC_{2,l_0}^0, SC_{2,l_1}^0\}$, $\{SC_{1,l_0}^3, SC_{3,l_1}^3\}$ y $\{SC_{3,l_0}^6, SC_{1,l_1}^6\}$. Estos bloques se encuentran disponibles a lo largo de la ruta conformada por los enlaces l_0 (2-5) y l_1 (5-4).

Conforme se observó en el caso precedente, si el bloque candidato de FS representado por $\{SC_{2,l_0}^0, SC_{2,l_1}^0\}$ experimenta una interferencia significativa por XT que excede el umbral XT_{TH} , resultaría inviable establecer la demanda en dichos recursos espectrales. No obstante, mediante la implementación de conmutación de núcleos, los dos bloques candidatos restantes, $\{SC_{1,l_0}^3, SC_{3,l_1}^3\}$ y $\{SC_{3,l_0}^6, SC_{1,l_1}^6\}$, se encuentran distribuidos en núcleos diferentes a través de los enlaces de fibra. Consecuentemente,

el nivel de XT que incide sobre estos bloques de FS podría permanecer por debajo del umbral XT_{TH} , facilitando su asignación exitosa.

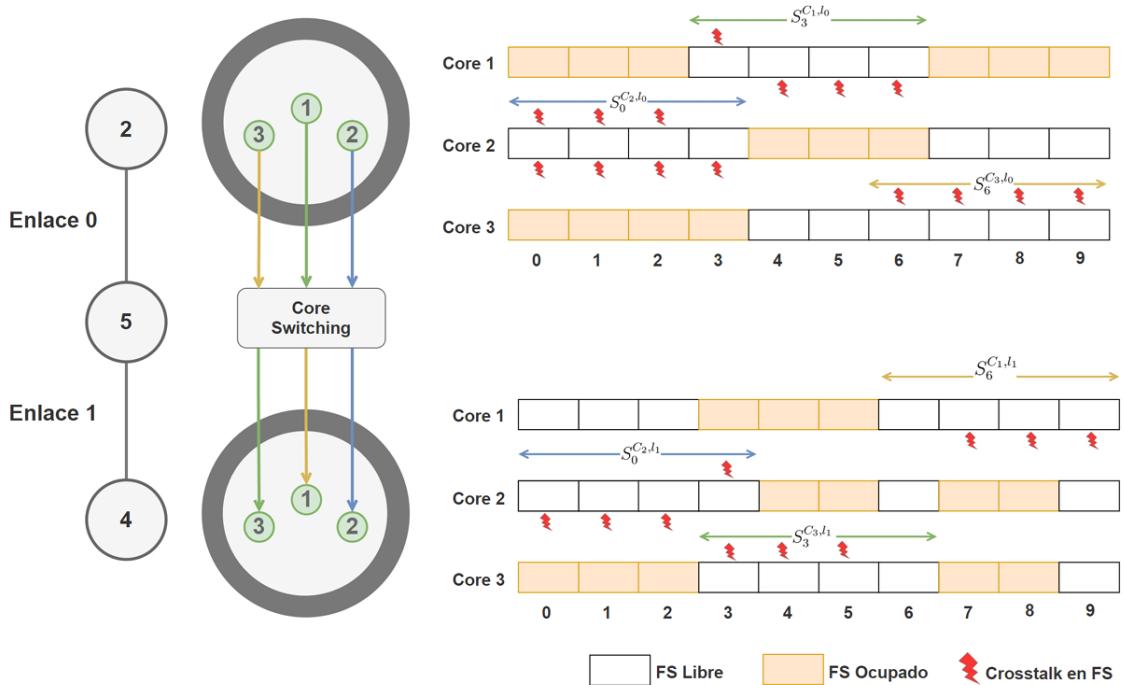


Figura 2.6: Asignación de espectro con conmutación de núcleos []

En términos comparativos, la implementación del mecanismo de conmutación de núcleos a lo largo de los enlaces de fibra en una ruta de trabajo permite reducir sustancialmente la probabilidad de bloqueo de solicitudes en comparación con escenarios donde no se aplica conmutación de núcleos, incrementando así la eficiencia en la utilización de los recursos espectrales y espaciales disponibles en la infraestructura de red.

2.3. Fragmentación del Ancho de Banda en MC-EON

Las redes ópticas elásticas multinúcleo (MC-EON) permiten optimizar el uso del ancho de banda necesario para satisfacer una demanda, respetando tres restricciones

fundamentales:

- **Restricción de continuidad:** esta restricción implica que un cambio de luz o lightpath debe utilizar los mismos *Frequency Slots* (FS) a lo largo del camino establecido entre los nodos de origen y destino, tanto en la dimensión espectral como en la dimensión espacial (núcleo).
- **Restricción de consecutividad:** esta restricción establece que todos los FS utilizados para establecer un lightpath deben ser contiguos en el dominio espectral, formando un solo bloque contiguo de FS dentro del mismo núcleo.

Estas restricciones conducen a que, tras sucesivas asignaciones y liberaciones de recursos, se genere la aparición de bloques aislados de FS no utilizados tanto en la dimensión espectral como en la dimensión espacial (núcleos) de los enlaces ópticos. Dichos bloques fragmentados presentan desalineación tanto entre enlaces consecutivos de la ruta como entre los diferentes núcleos de una misma fibra multinúcleo. Como consecuencia, se incrementa significativamente la probabilidad de bloqueo de solicitudes, pudiendo la red rechazar demandas incluso cuando existe ancho de banda disponible suficiente en los enlaces. Este fenómeno se denomina **Fragmentación de la red** y en arquitecturas multinúcleo se manifiesta en dos dimensiones complementarias:

- **Fragmentación espectral:** se refiere a la presencia de bloques aislados de FS no utilizados en el dominio espectral, que no pueden ser aprovechados para establecer nuevas conexiones debido a las restricciones de continuidad y consecutividad.
- **Fragmentación espacial:** se refiere a la desalineación de bloques de FS disponibles entre los diferentes núcleos de una misma fibra multinúcleo, lo que dificulta la asignación eficiente de recursos en la dimensión espacial.

Ejemplo ilustrativo del fenómeno:

- 1 - Se presenta el estado inicial del enlace mostrando las asignaciones activas de lightpaths distribuidos en los múltiples núcleos de la fibra.
- 2 - Se produce la liberación de recursos al finalizar el tiempo de vida de determinadas conexiones, generando segmentos espectrales disponibles dispersos en diferentes núcleos y posiciones del espectro.
- 3 - Se evidencia el rechazo de una nueva solicitud de conexión debido a que, pese a existir una cantidad agregada suficiente de FS libres en la red, estos no satisfacen simultáneamente las restricciones de contigüidad espectral dentro de un único núcleo y continuidad espacial a lo largo de la ruta. La conexión resulta bloqueada en todos los núcleos disponibles como resultado de la fragmentación tanto espectral como espacial inherente al sistema multinúcleo.

Para ilustrar estas restricciones, se presenta un ejemplo en las Figuras [], donde se simula la conexión de una demanda de fod FS, con un nodo origen en 0 y un nodo destino en 3. En este escenario, existen dos posibbles caminos: 0-1-3 y 0-1-2-3.

La trayectoria de menor longitud corresponde a la ruta 0-1-3. No obstante, al procurar el establecimiento del lightpath mediante esta alternativa, la solicitud de conexión resulta denegada, dado que los enlaces 0-1 y 1-3 carecen de dos FS consecutivos y alineados espectralmente, tal como se evidencia en la Figura [].

CAPÍTULO 2. REDES ÓPTICAS ELÁSTICAS MULTICORE Y FRAGMENTACIÓN DEL ANCHO DE BANDA




Figura 2.7: Restricciones de contigüidad y continuidad aplicadas- Conexión Rechazada




Figura 2.8: Restricciones de contigüidad y continuidad aplicadas- Conexión Establecida

En contraste, al considerar la asignación del lightpath a través de la trayectoria de mayor extensión, específicamente 0-1-2-3, empleando los FS 4 y 5, la conexión se establece satisfactoriamente, puesto que esta configuración dispone de dos FS contiguos y alineados espectralmente, según se observa en la Figura [1].

2.3.1. Enfoques de gestión de fragmentación

La problemática descrita previamente genera consecuencias perjudiciales para la infraestructura de red, ocasionando un incremento en la probabilidad de bloqueo y comprometiendo significativamente su desempeño óptimo y continuidad operacional. En consecuencia, resulta fundamental identificar estrategias que permitan prevenir, mitigar o reducir la fragmentación del espectro disponible.

De acuerdo con la bibliografía especializada, existen diversas aproximaciones que pueden ser consideradas para abordar la gestión de la desfragmentación. En la figura [1] se presentan las principales estrategias de gestión de la fragmentación [4].

La Desfragmentación constituye un procedimiento mediante el cual se ejecuta la reconfiguración o el re-ruteo de un subconjunto de conexiones existentes en la infraestructura de red. Su propósito fundamental consiste en reacomodar las asignaciones espectrales de las solicitudes de tráfico vigentes, consolidando de este modo los recursos disponibles en segmentos contiguos y continuos de mayor magnitud, los cuales pueden ser aprovechados para el establecimiento de futuras demandas [5].

Es factible abordar la problemática de la fragmentación prescindiendo de técnicas de desfragmentación espectral (Sin Desfragmentación), lo cual se alcanza mediante una administración del espectro orientada a la prevención de su fragmentación.

En el tratamiento de la fragmentación bajo un esquema Sin Desfragmentación, se pueden mencionar los algoritmos denominados Sensibles a la Fragmentación o *Fragmentation Aware RSA* (FA-RSA). Estos consideran la fragmentación espectral durante el establecimiento de las demandas, empleando diversos indicadores de fragmentación, procurando así minimizar la fragmentación del espectro.

Alternativamente, es posible emplear técnicas de desfragmentación, las cuales se fundamentan en dos aproximaciones principales:

- Desfragmentación Reactiva: El procedimiento se ejecuta como respuesta al bloqueo de una solicitud, con la finalidad de lograr su establecimiento exitoso.

- Desfragmentación Proactiva: Se lleva a cabo de manera periódica o en función de determinados umbrales que activan el proceso, permitiendo así reducir la fragmentación de la infraestructura de red y minimizar la ocurrencia de futuros bloqueos de solicitudes.

Las aproximaciones que implementan técnicas de desfragmentación pueden clasificarse además en: (i) estrategias sin re-ruteo, las cuales realizan únicamente una reasignación espectral en los *lightpaths* o caminos ópticos establecidos, y (ii) estrategias con re-ruteo, que constituyen técnicas capaces de modificar tanto las rutas como el espectro asignado a los lightpaths existentes.

En el presente trabajo, para la gestión de la fragmentación se adoptó la aproximación con desfragmentación, de naturaleza proactiva y con re-ruteo de lightpaths preexistentes. En la figura [2.9] se puede observar resaltada dicha estrategia.




Figura 2.9: Esquema de Gestión de la Fragmentación

2.4. Descripción del problema tratado

La Fragmentación del Espectro en Redes Ópticas Elásticas Multinúcleo (Multi-Core EON) constituye una problemática que compromete la eficiencia en la utilización de recursos espectrales y espaciales. El desempeño de la infraestructura de red resulta severamente afectado, dado que este fenómeno puede ocasionar bloqueos de solicitudes debido a la ausencia de ranuras espectrales contiguas y alineadas entre enlaces consecutivos, así como por la indisponibilidad de núcleos adecuados, sin que necesariamente el espectro en todos los núcleos se encuentre completamente ocupado. En secciones previas se expusieron estrategias para el manejo de la fragmentación en la red; en el presente trabajo se examina la estrategia con desfragmentación, adoptando un enfoque proactivo.

Un método ampliamente implementado consiste en ejecutar el procedimiento de desfragmentación de manera periódica con el propósito de prevenir bloqueos futuros, abordando así una de las cuatro interrogantes planteadas por Zhang [1], ¿Cuándo reconfigurar?.

En la figura [1] se puede observar una posible solución a la problemática de la selección del momento óptimo para realizar la desfragmentación, la cual consiste en ejecutar desfragmentaciones periódicas en intervalos temporales fijos. En este caso, cada 100 unidades de tiempo, el eje vertical representa el volumen de tráfico cuantificado mediante el número de conexiones activas, mientras que el eje horizontal indica las unidades temporales; cada punto azul denota el instante en que el proceso de desfragmentación se ejecuta. Siguiendo este patrón, se evidencian situaciones donde se realizan procesos de desfragmentación cuando la red podría no requerirlos, considerando que la utilización de los recursos espectrales y de los núcleos constituye un indicador significativo del grado de fragmentación.

Además de la utilización de la red, existen otras métricas de fragmentación relevantes en redes multinúcleo, cuyos valores deben considerarse para el disparo de los

procesos de desfragmentación, incluyendo la fragmentación por núcleo y la disponibilidad de recursos en la dimensión espacial.

De este modo, se evidencia la necesidad de un disparador inteligente para ejecutar el proceso de desfragmentación que considere todos estos parámetros o “características” para seleccionar apropiadamente el momento del disparo, dado que realizar múltiples desfragmentaciones de manera frecuente afecta directamente al desempeño de la red, pudiendo ocasionar disruptpciones en las conexiones activas; mientras que ejecutar pocas desfragmentaciones muy dispersas resultaría en efectos prácticamente imperceptibles.

En síntesis, la selección del momento para ejecutar el proceso de desfragmentación resulta crítica debido a su impacto significativo en la cantidad de procesos de desfragmentación, lo cual incide directamente en las dos métricas globales más relevantes en el enrutamiento de redes ópticas elásticas multinúcleo: Cantidad de bloqueos y Cantidad de reconfiguraciones.

En los capítulos subsiguientes se presenta y aborda en profundidad un modelo de disparo inteligente que contempla numerosos factores tales como métricas de fragmentación de la red, utilización de recursos espectrales y espaciales, y bloqueos de solicitudes.

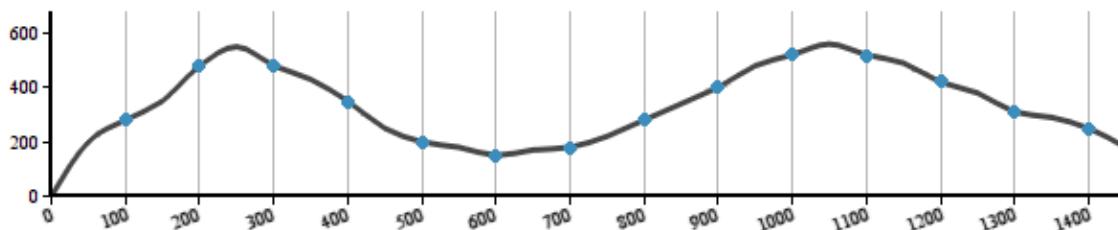


Figura 2.10: Ejemplo de desfragmentaciones periódicas con volumen de carga de tráfico variado

Capítulo 3

Aprendizaje Automático

El Aprendizaje Automático, conocido en inglés como *Machine Learning*, representa una de las áreas más dinámicas y prometedoras dentro del campo de la inteligencia artificial contemporánea. se fundamenta en el desarrollo de algoritmos y modelos computacionales capaces de identificar patrones complejos en conjuntos de datos, con el propósito de generar predicciones o tomar decisiones informadas sin necesidad de instrucciones programáticas explícitas para cada escenario específico.]

La esencia del aprendizaje automático radica en su capacidad para mejorar el desempeño de manera iterativa mediante la experiencia acumulada. Mitchell proporciona una definición operacional particularmente esclarecedora: un sistema computacional manifiesta capacidad de aprendizaje cuando su rendimiento en una tarea determinada T, cuantificado mediante una métrica de desempeño P, experimenta una mejora mensurable como consecuencia de la exposición a una experiencia E.] Esta conceptualización establece tres componentes fundamentales que articulan cualquier sistema de aprendizaje automático: la tarea objetivo, la experiencia de aprendizaje y el criterio de evaluación.

Para ilustrar estos conceptos de manera concreta, se puede examinar el caso de los sistemas de filtrado de correo electrónico no deseado. Un filtro de spam ejemplifica de forma paradigmática los principios del aprendizaje automático. El sistema desarrolla progresivamente la capacidad de discriminar entre mensajes legítimos y

correo no solicitado mediante el análisis de ejemplos previamente etiquetados por usuarios. Estos conjuntos de datos, denominados conjuntos de entrenamiento, contienen tanto instancias positivas (correos identificados como spam) como negativas (mensajes legítimos), permitiendo al algoritmo extraer características distintivas de cada categoría.

En este contexto específico, la tarea T consiste en la clasificación binaria de nuevos mensajes electrónicos, la experiencia E está constituida por el proceso de entrenamiento con los datos etiquetados, y la métrica de desempeño P puede definirse como la tasa de precisión o *Accuracy*, que cuantifica la proporción de mensajes correctamente clasificados en relación con el total de predicciones realizadas.

3.1. Clasificación de sistemas o tipos de aprendizaje automático

La diversidad de aplicaciones y contextos en los que se implementan sistemas de aprendizaje automático ha propiciado el desarrollo de múltiples paradigmas metodológicos. La clasificación más fundamental de estos enfoques se establece en función del tipo y grado de supervisión disponible durante la fase de entrenamiento. A continuación, se muestran las tres categorías principales:

- **Aprendizaje supervisado:** Este paradigma constituye el enfoque más ampliamente implementado en aplicaciones prácticas. Se caracteriza por la disponibilidad de un conjunto de entrenamiento que incluye pares de entrada-salida, donde cada instancia de entrada está asociada con su correspondiente etiqueta o *label*, que representa la solución correcta. El objetivo del algoritmo consiste en inferir una función de mapeo que establezca la correspondencia óptima entre el espacio de características de entrada y el conjunto de salidas deseadas, de manera que pueda generalizar efectivamente a instancias no observadas

previamente.

El aprendizaje supervisado se subdivide en dos categorías fundamentales según la naturaleza de la variable objetivo:

- *Clasificación:* Se trata de brindar ejemplos de entrenamiento donde cada instancia está asociada con una o múltiples clases predefinidas, a modo de que se pueda realizar el entrenamiento y clasificar nuevas entradas dentro de alguna de las clases existentes. Aplicaciones típicas incluyen el reconocimiento de imágenes, detección de fraudes y análisis de sentimientos.
- *Predicción:* A diferencia de la clasificación, éste consiste en la predicción de una variable objetivo de naturaleza continua o numérica. El sistema recibe datos de entrenamiento compuestos por vectores de características junto con sus valores objetivos correspondientes, permitiendo al modelo aprender la relación funcional entre sí. Esta capacidad predictiva se aplica posteriormente para estimar valores numéricos de nuevas instancias basándose exclusivamente en sus características de entrada. Aplicaciones típicas comprenden la predicción de precios, estimación de demanda y proyecciones temporales.
- **Aprendizaje no supervisado:** Este paradigma aborda escenarios donde los datos de entrenamiento carecen de soluciones deseadas. La ausencia de supervisión directa plantea un desafío metodológico fundamentalmente diferente: el algoritmo debe descubrir estructuras intrínsecas, patrones latentes o relaciones subyacentes en los datos sin guía externa. Las técnicas de aprendizaje no supervisado resultan particularmente valiosas para tareas exploratorias, tales como la segmentación de clientes, detección de anomalías, reducción de dimensionalidad y descubrimiento de asociaciones en grandes volúmenes de datos. Este enfoque refleja una aproximación más cercana a cómo los sistemas bio-

lógicos pueden aprender mediante la observación y organización autónoma de información sensorial.

- **Aprendizaje por refuerzo:** Este paradigma se distingue por su naturaleza secuencial e interactiva. En lugar de aprender a partir de un conjunto estático de ejemplos, el aprendizaje por refuerzo se fundamenta en la interacción continua de un agente con un entorno dinámico. El proceso de aprendizaje se articula mediante señales de retroalimentación en forma de recompensas (positivas o negativas) que el agente recibe como consecuencia de sus acciones. El objetivo fundamental consiste en desarrollar una política de comportamiento que maximice la recompensa acumulada a largo plazo. Este bucle de retroalimentación continua entre acción, observación y recompensa permite al sistema refinarse progresivamente su estrategia mediante exploración y explotación del espacio de estados. Las aplicaciones emblemáticas incluyen sistemas de control robótico, estrategias de juegos, optimización de recursos y vehículos autónomos.

Cada uno de estos paradigmas presenta ventajas distintivas y limitaciones inherentes, determinando su idoneidad para contextos específicos. La selección del enfoque apropiado constituye una decisión metodológica crucial que debe considerar tanto la naturaleza del problema como las características de los datos disponibles.

3.2. Gradient Boosting

El Gradient Boosting representa uno de los algoritmos de aprendizaje automático supervisado más potentes y efectivos en la actualidad, especialmente para problemas de clasificación y regresión. Este método se fundamenta en el paradigma de aprendizaje por ensamble, donde múltiples modelos predictivos débiles se combinan secuencialmente para construir un predictor robusto de alto rendimiento.

A diferencia de las redes neuronales artificiales que se inspiran en la arquitectura biológica del cerebro, el Gradient Boosting se sustenta en principios de optimización matemática y aprendizaje secuencial. La filosofía subyacente consiste en entrenar modelos de manera iterativa, donde cada nuevo modelo se especializa en corregir los errores residuales cometidos por los modelos previos, generando así una mejora progresiva del rendimiento global del sistema.

3.2.1. Fundamentos del Aprendizaje por Ensamble

El aprendizaje por ensamble o *Ensemble Learning* constituye una estrategia metodológica que combina las predicciones de múltiples modelos base para obtener un resultado final superior al que produciría cualquier modelo individual. Este enfoque se fundamenta en dos principios estadísticos complementarios:

- **Reducción de varianza:** Mediante la agregación de predicciones de modelos diversos, se reduce la sensibilidad del sistema a fluctuaciones en los datos de entrenamiento, incrementando la estabilidad de las predicciones.
- **Reducción de sesgo:** La combinación secuencial de modelos permite corregir sistemáticamente errores persistentes, mejorando la capacidad del sistema para capturar relaciones complejas en los datos.

Existen dos estrategias principales en el aprendizaje por ensamble. El *Bagging* o agregación bootstrap, entrena múltiples modelos de manera independiente y paralela sobre diferentes subconjuntos de datos, combinando posteriormente sus predicciones mediante votación o promediación. El *Boosting*, por otro lado, entrena modelos de forma secuencial, donde cada nuevo modelo se enfoca en corregir los errores de sus predecesores, estableciendo una relación de dependencia entre los aprendices.

El Gradient Boosting pertenece a esta segunda categoría, distinguiéndose por su fundamentación matemática rigurosa y su eficacia demostrada en múltiples dominios de aplicación.

3.2.2. Principios del Gradient Boosting

El algoritmo de Gradient Boosting construye el modelo predictivo mediante la adición secuencial de funciones, típicamente árboles de decisión de profundidad limitada, que optimizan iterativamente una función objetivo. El proceso puede conceptualizarse como un descenso del gradiente en el espacio funcional, donde en cada iteración se añade una nueva función que aproxima el gradiente negativo de la pérdida respecto a las predicciones actuales.

Formalmente, dado un conjunto de entrenamiento $\{(x_i, y_i)\}_{i=1}^n$ donde x_i representa el vector de características y y_i la variable objetivo, el Gradient Boosting construye un modelo aditivo de la forma:

$$F_M(x) = \sum_{m=0}^M \gamma_m h_m(x) \quad (3.1)$$

donde $h_m(x)$ representa el m -ésimo aprendiz débil, típicamente un árbol de decisión, γ_m es el coeficiente de peso asociado, y M denota el número total de iteraciones o árboles en el ensamble.

El algoritmo opera mediante el siguiente procedimiento iterativo:

1. **Inicialización:** Se establece un modelo inicial $F_0(x)$, comúnmente una constante que minimiza la función de pérdida sobre el conjunto de entrenamiento completo.

2. **Iteración secuencial:** Para cada iteración $m = 1, 2, \dots, M$:

- Se calculan los pseudo-residuos, representando el gradiente negativo de la función de pérdida respecto a las predicciones actuales:

$$r_{im} = - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F(x)=F_{m-1}(x)} \quad (3.2)$$

- Se entrena un nuevo aprendiz débil $h_m(x)$ para predecir estos residuos, ajustándose a los patrones de error del modelo acumulado.

- Se determina el coeficiente óptimo γ_m que minimiza la pérdida al incorporar el nuevo aprendiz:

$$\gamma_m = \arg \min_{\gamma} \sum_{i=1}^n L(y_i, F_{m-1}(x_i) + \gamma h_m(x_i)) \quad (3.3)$$

- Se actualiza el modelo mediante la adición ponderada del nuevo componente:

$$F_m(x) = F_{m-1}(x) + \nu \cdot \gamma_m h_m(x) \quad (3.4)$$

donde ν representa la tasa de aprendizaje o *learning rate*, un hiperparámetro que controla la contribución de cada árbol al modelo final.

Este proceso iterativo continúa hasta alcanzar el número especificado de árboles M o hasta satisfacer un criterio de convergencia establecido.

3.2.3. GradientBoostingClassifier

El *GradientBoostingClassifier* constituye la implementación específica del algoritmo Gradient Boosting para problemas de clasificación. Esta variante emplea funciones de pérdida apropiadas para variables categóricas y adapta el procedimiento de optimización para generar probabilidades de pertenencia a clases.

Para clasificación binaria, se utiliza típicamente la función de pérdida logística o *log loss*:

$$L(y, F(x)) = \log(1 + e^{-2yF(x)}) \quad (3.5)$$

donde $y \in \{-1, 1\}$ representa la clase verdadera y $F(x)$ la predicción del modelo. La probabilidad de pertenencia a la clase positiva se obtiene mediante la transformación logística:

$$P(y = 1|x) = \frac{1}{1 + e^{-2F(x)}} \quad (3.6)$$

Para problemas de clasificación multiclas, se extiende el enfoque mediante la estrategia *one-versus-all*, entrenando un modelo separado por cada clase y combinando las predicciones mediante normalización softmax para obtener distribuciones de probabilidad válidas.

3.2.4. Hiperparámetros y Regularización

El rendimiento del *GradientBoostingClassifier* depende críticamente de la configuración apropiada de sus hiperparámetros, los cuales regulan la complejidad del modelo y previenen el sobreajuste:

- **Número de estimadores (n_estimators):** Define la cantidad de árboles en el ensamble. Valores elevados incrementan la capacidad expresiva pero aumentan el riesgo de sobreajuste y el costo computacional. Típicamente se emplean valores entre 100 y 1000.
- **Tasa de aprendizaje (learning_rate):** Controla la contribución de cada árbol al modelo final. Valores pequeños (0.01-0.1) requieren más árboles pero generalmente producen mejor generalización. Existe una relación de compromiso entre este parámetro y el número de estimadores.
- **Profundidad máxima (max_depth):** Limita la profundidad de cada árbol individual. Árboles superficiales (3-5 niveles) actúan como aprendices débiles efectivos, mientras que árboles profundos incrementan la complejidad y el riesgo de sobreajuste.
- **Mínimo de muestras por división (min_samples_split):** Especifica el número mínimo de muestras requeridas para dividir un nodo interno. Valores mayores previenen la creación de divisiones excesivamente específicas.
- **Mínimo de muestras por hoja (min_samples_leaf):** Define el número

mínimo de muestras en los nodos terminales. Este parámetro suaviza el modelo en regiones de baja densidad de datos.

- **Submuestreo (subsample):** Fracción de muestras utilizada para entrenar cada árbol. Valores menores a 1.0 introducen aleatorización estocástica, mejorando la diversidad del ensamble y reduciendo el sobreajuste.

La selección óptima de estos hiperparámetros requiere típicamente validación cruzada y búsqueda sistemática en el espacio de configuraciones mediante técnicas como *Grid Search* o *Random Search*.

3.2.5. Ventajas y Limitaciones

El *GradientBoostingClassifier* presenta características distintivas que determinan su idoneidad para diferentes contextos:

Ventajas:

- Capacidad para modelar relaciones no lineales complejas sin requerir transformaciones explícitas de características
- Robustez ante variables de diferentes escalas, eliminando la necesidad de normalización
- Manejo natural de variables mixtas (numéricas y categóricas)
- Resistencia a *outliers* mediante funciones de pérdida apropiadas
- Interpretabilidad mediante análisis de importancia de características
- Rendimiento competitivo en conjuntos de datos tabulares estructurados

Limitaciones:

- Susceptibilidad al sobreajuste con configuraciones inadecuadas de hiperparámetros

- Entrenamiento secuencial que limita la paralelización eficiente
- Mayor costo computacional comparado con algoritmos más simples
- Sensibilidad al desbalance de clases, requiriendo estrategias de ponderación
- Rendimiento subóptimo en datos de muy alta dimensionalidad comparado con métodos especializados

3.3. Aplicación de Machine Learning en Redes Ópticas Elásticas Multinúcleo

En esta sección se presenta un estudio bibliográfico del estado del arte de técnicas de *Machine Learning* aplicadas a problemas en redes ópticas elásticas multinúcleo (MC-EON, *Multi-Core Elastic Optical Networks*).

Panchali Datta Choudhury y Tanmay De presentan un análisis comprehensivo del uso de técnicas de *Machine Learning* en redes ópticas elásticas [1], fundamento que se extiende a las arquitecturas multinúcleo. Las MC-EON introducen complejidades adicionales respecto a las redes ópticas elásticas convencionales, particularmente en la gestión de múltiples núcleos dentro de una misma fibra y los fenómenos de interferencia entre núcleos (inter-core crosstalk), aspectos que requieren estrategias de optimización más sofisticadas donde el *Machine Learning* demuestra particular utilidad.

Las principales áreas de aplicación de estas técnicas en el contexto de MC-EON incluyen:

- **Evaluación y predicción de calidad de servicio**

La investigación presentada en [1] propone un modelo de asignación de ancho de banda en EON considerando los requisitos de calidad de servicio o *Quality of Service* (QoS). Se emplea aprendizaje por refuerzo o *Reinforcement*

Learning, donde la función de recompensa se fundamenta en el cumplimiento de los requisitos de QoS. En el contexto de MC-EON, esta aproximación adquiere mayor relevancia debido a la necesidad de garantizar QoS considerando simultáneamente la asignación de recursos en múltiples núcleos y la gestión de interferencias entre ellos.

■ Supervivencia de red

El trabajo presentado en [1] explora la optimización de redes considerando su capacidad de supervivencia mediante aprendizaje por refuerzo profundo. Se implementa una arquitectura de dos agentes: uno proporciona el esquema de trabajo principal y otro gestiona el esquema de protección. Esta combinación, junto con un mecanismo de recompensas orientado a maximizar la rentabilidad, genera políticas de enrutamiento, asignación de espectro y selección de modulación que garantizan supervivencia. En MC-EON, estos mecanismos de protección resultan especialmente críticos dado el mayor número de recursos físicos susceptibles a fallos.

■ Predicción de tráfico

Aibin [1] presenta un enfoque para predicción de tráfico en redes de centros de datos en la nube o *Cloud Data Center Networks* utilizando búsqueda de árbol de Monte Carlo. Para cada solicitud, esta técnica identifica el centro de datos más apropiado y el conjunto óptimo de rutas candidatas mediante la construcción de un árbol disperso y selección estocástica. Esta metodología es aplicable a MC-EON para predecir patrones de tráfico y optimizar la asignación de núcleos.

■ Enrutamiento, modulación y asignación del espectro

Chen et al. [1] proponen un modelo de aprendizaje por refuerzo profundo para desarrollar un sistema autónomo de RMSA en redes ópticas elásticas. Emplean

redes neuronales convolucionales, denominadas *Q Networks*, para aprender políticas RMSA considerando conectividad, utilización espectral y demandas de tráfico. En MC-EON, este enfoque se extiende al problema RMSCA (*Routing, Modulation, Spectrum and Core Assignment*), donde adicionalmente se debe seleccionar el núcleo óptimo y considerar las restricciones de crosstalk entre núcleos.

Durante este trabajo dentro de los puntos mas destacados nos podemos encontrar con algunos trabajos cuyo principal objetivo y enfoque es la solución al problema de la fragmentación de la red, con alguno de ellos para otro tipo de redes, como el presentado en [6], el cual encuentra su principal enfoque en *Space Division Multiplexing Elastic Optical Networks* o SDM-EON , implementando redes neuronales, específicamente la red neuronal de Elman, para la predicción de tráfico de manera de disminuir la fragmentación y la diafonía o *Cross-talk*. También se cuenta con el trabajo presentado por Enciso y Silva, el cual propone un algoritmo para decidir el mejor momento para disparar la desfragmentación de la red. Tomando ese trabajo como base, en este trabajo se proponen modelos para predecir los mejores momentos para ejecutar la desfragmentación para Redes Ópticas Elásticas Multinúcleo (MC-EON). De manera en que se contemplan los problemas anteriores, agregando la complejidad que conlleva el uso de múltiples núcleos en una misma fibra.

Para redes MC-EON también contamos con algoritmos de desfragmentación basados en Machine Learning, como el presentado en [7], donde los autores proponen un enfoque de aprendizaje no supervisado que no requiere conocimientos previos de la red. El algoritmo identifica aquellos *lightpaths* que pueden ser agrupados en base a ciertas características, para luego mapear esos grupos a los núcleos y reordenar el espectro sin necesidad de realizar re-ruteos.

3.3.1. Gradient Boosting en MC-EON

En el contexto de las redes ópticas elásticas multinúcleo (MC-EON), los algoritmos de Gradient Boosting han demostrado particular eficacia para tareas de clasificación y predicción relacionadas con la gestión dinámica de recursos y la optimización del rendimiento de la red.

Las principales áreas de aplicación de *GradientBoostingClassifier* en MC-EON incluyen:

- **Predicción de bloqueo de solicitudes:** El *GradientBoostingClassifier* puede entrenarse para predecir la probabilidad de que una solicitud de conexión sea bloqueada dadas las condiciones actuales de la red, considerando factores como la fragmentación espectral, la disponibilidad de núcleos y los niveles de diafonía entre núcleos.
- **Clasificación de eventos de desfragmentación:** El modelo puede determinar el momento óptimo para ejecutar algoritmos de desfragmentación, clasificando el estado de la red en categorías que indican la necesidad o conveniencia de reorganizar las asignaciones espectrales. Esta capacidad resulta particularmente valiosa para decisiones en tiempo real que deben balancear el costo operacional de la desfragmentación contra los beneficios en términos de reducción de bloqueos futuros.
- **Selección de estrategias RMSCA:** Mediante el aprendizaje de patrones históricos, el clasificador puede seleccionar entre diferentes estrategias de *Routing, Modulation, Spectrum and Core Assignment* según las características de la demanda y el estado de la red. La capacidad del modelo para capturar interacciones no lineales entre múltiples variables permite adaptar dinámicamente la estrategia de asignación a condiciones cambiantes de tráfico.
- **Detección de degradación de QoS:** El algoritmo puede identificar situa-

ciones donde la calidad de servicio está en riesgo de degradarse, permitiendo acciones preventivas antes de que ocurran violaciones de los acuerdos de nivel de servicio. La interpretabilidad del modelo mediante análisis de importancia de características facilita la identificación de los factores más críticos que afectan la calidad de servicio.

La naturaleza tabular de los datos operacionales en MC-EON (métricas de utilización, estadísticas de tráfico, indicadores de fragmentación) hace particularmente adecuado el uso de Gradient Boosting, cuyo rendimiento en este tipo de datos frecuentemente supera a aproximaciones basadas en redes neuronales profundas. Adicionalmente, la capacidad del modelo para proporcionar estimaciones de importancia de características facilita la comprensión de los factores más relevantes en las decisiones de gestión de la red, aspecto crítico para la validación y aceptación de sistemas autónomos en entornos de producción.

El tiempo de entrenamiento relativamente reducido del *GradientBoostingClassifier* comparado con redes neuronales profundas, junto con su robustez ante desbalances moderados en las clases y su capacidad para manejar características de diferentes tipos y escalas sin preprocesamiento extensivo, lo convierten en una opción pragmática para implementaciones en sistemas de gestión de MC-EON donde la eficiencia computacional y la confiabilidad son requisitos fundamentales.

Capítulo 4

Método Propuesto

Este trabajo propone una solución para determinar los momentos en los que se disparará la ejecución de los procesos de desfragmentación de manera proactiva en redes MC-EON, mediante la utilización de técnicas de *Machine Learning* para predecir el índice de fragmentación **BFR** que sufrirá la red mediante el tráfico de red en un determinado periodo de tiempo t y en base a eso, decidir si ejecutar la desfragmentación o no. Esto a fin de proceder de la mejor manera ante la red cuando llegue a un estado de alta fragmentación que provoque un aumento en la probabilidad de bloqueo de las demandas y que la desfragmentación de la red en ese punto ya no sea óptima.

Para esta predicción se utiliza primeramente 2 valores que indiquen los umbrales del indice de fragmentación maximo y minimo, a modo que el valor predicho del índice de fragmentación a futuro no supere el umbral minimo, si supera el umbral mínimo, no realizar las desfragmentaciones, si supera el umbral minimo pero no el maximo, realizar las desfragmentaciones con menor frecuencia, y si supera el umbral maximo, realizar las desfragmentaciones con mayor frecuencia hasta que el indice de fragmentación futuro **BFR** sea menor al umbral maximo. Así como tambien modelos de clasificación, utilizando un conjunto de datos de simulaciones de tráfico *unicast*, tomando parámetros o características relacionadas a la fragmentación, la utilización de la red y las métricas específicas de múltiples núcleos como datos de entrada,

produciendo un valor estimado del índice de fragmentación que experimentará la red en un periodo de tiempo t . A partir de este valor predicho, se determinará la frecuencia de desfragmentaciones realizadas fijando unos umbrales que permiten actuar antes de que la red alcance estados críticos de fragmentación que incrementen significativamente la probabilidad de bloqueo de las demandas.

4.1. Características

En el área de *Machine Learning*, se conoce como “características” a los parámetros o datos de entrada del modelo de aprendizaje.

Las características seleccionadas fueron aquellas relacionadas al uso y la fragmentación de la red, así como métricas específicas de redes MC-EON. Se tomaron las principales métricas utilizadas para la determinación del estado de fragmentación, además de otras relacionadas a la utilización de la red y al comportamiento del tráfico, con el objetivo de predecir el índice de fragmentación futuro y determinar los momentos óptimos para ejecutar la desfragmentación de manera proactiva.

Estas características son las siguientes:

- *Bandwidth Fragmentation Ratio* o Relación de Fragmentación de ancho de banda (BFR)[8]: Representa el índice de fragmentación de los recursos de la red, siendo una de las métricas principales para evaluar la fragmentación externa. El BFR de un core en un enlace se define como:

$$BFR_{core} = 1 - \frac{MaxBlock()}{S^{free}} \quad (4.1)$$

Donde $MaxBlock()$ es el tamaño del mayor bloque de FS libres y S^{free} es la sumatoria total de FS libres en el core. El BFR de la red se calcula como el promedio ponderado considerando todos los cores de todos los enlaces:

$$BFR_{red} = 1 - \frac{\sum_{i=1}^{|E|} \sum_{j=1}^C MaxBlock_{i,j}}{\sum_{i=1}^{|E|} \sum_{j=1}^C S_{i,j}^{free}} \quad (4.2)$$

Donde C es el número de cores por enlace, $\text{MaxBlock}_{i,j}$ es el mayor bloque libre en el core j del enlace i , y $S_{i,j}^{\text{free}}$ es el total de FS libres en ese core.

- Entropía de Shannon (SHF)[9]: Métrica de fragmentación que mide la distribución de bloques libres en el espectro. Para un core en un enlace está definida por:

$$\text{SHF}_{\text{core}} = \sum_{i=1}^B \frac{S_i^{\text{free}}}{N} \ln \frac{N}{S_i^{\text{free}}} \quad (4.3)$$

Donde S_i^{free} representa el tamaño del bloque libre i , N es el número total de FS en el core, y B es la cantidad de bloques de FS libres. Para calcular el SHF de la red se calcula el promedio de los valores en todos los cores de todos los enlaces:

$$\text{SHF}_{\text{red}} = \frac{1}{|E| \times C} \sum_{i=1}^{|E|} \sum_{j=1}^C \text{SHF}_{\text{core}_{i,j}} \quad (4.4)$$

- Compacidad del Espectro (SC - *Spectrum Compactness*): Métrica que evalúa qué tan compacto está el uso del espectro en un core. Se calcula considerando la dispersión de los FS ocupados y la cantidad de gaps intermedios. Para un core en un enlace se define como:

$$\text{SC}_{\text{core}} = \frac{s_{\max} - s_{\min} + 1}{S^{\text{occupied}}} \times \frac{\sum_{i=1}^G g_i}{G} \quad (4.5)$$

Donde s_{\min} y s_{\max} son los índices del primer y último FS ocupado respectivamente, S^{occupied} es la cantidad total de FS ocupados, g_i es el tamaño del gap libre i , y G es la cantidad total de gaps entre bloques ocupados. Si no hay FS ocupados, $\text{SC}_{\text{core}} = 0$. El SC de la red se calcula como:

$$\text{SC}_{\text{red}} = \frac{1}{|E| \times C} \sum_{i=1}^{|E|} \sum_{j=1}^C \text{SC}_{\text{core}_{i,j}} \quad (4.6)$$

- *Golden Metric* (GM): Métrica avanzada que evalúa la fragmentación considerando rangos de tamaño de demandas esperadas. Dado dos parámetros n_1 y n_2 que representan el rango de tamaños de demanda típicos, el GM para un

core se calcula como:

$$GM_{core} = \frac{a}{|b|} \quad (4.7)$$

Donde los valores de a y b se calculan iterando sobre cada gap de FS libres de tamaño g :

$$a_0 = \epsilon, \quad b_0 = -\epsilon \quad (4.8)$$

$$a = a_0 + \sum_{i=1}^G a_i, \quad b = b_0 + \sum_{i=1}^G b_i \quad (4.9)$$

Donde $\epsilon = 0,001$ y para cada gap g_i :

- Si $g_i < n_1$: $a_i = 0, b_i = -\frac{g_i}{avg}$
- Si $g_i > n_2$: $a_i = \frac{g_i}{avg}, b_i = 0$
- Si $n_1 \leq g_i \leq n_2$: $a_i = \frac{g_i - n_1 + 1}{avg}, b_i = -\frac{n_2 - g_i}{avg}$

Con $avg = \frac{n_1 + n_2}{2}$. El GM de la red se calcula como:

$$GM_{red} = \frac{1}{|E| \times C} \sum_{i=1}^{|E|} \sum_{j=1}^C GM_{core_{i,j}} \quad (4.10)$$

- *Available Spectrum Fragmentation Ratio 3D* (ASFR3D): Métrica que considera la fragmentación espacial en redes multi-core, evaluando bloques pequeños que no pueden ser utilizados eficientemente. Para un core se define como:

$$ASFR3D_{core} = \left(1 - \frac{S^{small}}{S^{free}} \right) \times F_{spatial} \quad (4.11)$$

Donde S^{small} es la suma de FS libres en bloques menores a 5 slots, S^{free} es el total de FS libres, y $F_{spatial}$ es un factor de peso espacial definido como:

$$F_{spatial} = \frac{\ln(D_{active} + 1)}{10} \quad (4.12)$$

Donde D_{active} es el número de demandas activas en la red. El ASFR3D de la red se calcula como:

$$ASFR3D_{red} = \frac{1}{|E| \times C} \sum_{i=1}^{|E|} \sum_{j=1}^C ASFR3D_{core_{i,j}} \quad (4.13)$$

- Utilización Diferencial (UD): Métrica que mide el desbalance en la utilización entre diferentes cores y enlaces de la red. Se define como:

$$UD_{red} = U_{max} - U_{min} \quad (4.14)$$

Donde U_{max} y U_{min} son las utilizaciones máxima y mínima entre todos los cores de todos los enlaces, siendo la utilización de un core:

$$U_{core} = \frac{S^{occupied}}{N} \quad (4.15)$$

Con $S^{occupied}$ siendo el número de FS ocupados y N el número total de FS en el core. Un valor alto de UD indica desbalance en la carga de la red, mientras que un valor bajo indica una distribución uniforme.

4.2. Obtención de datos para el entrenamiento

Se utilizó un simulador de redes MC-EON [10] para la generación del conjunto de datos a ser utilizados para el entrenamiento de los modelos de predicción. Para esto se utilizó una topología de red: USNET.

4.2.1. Definición de niveles de carga

Se definieron doce niveles discretos de carga (*CargaNivel*), cada uno asociado a un valor de *Erlang* representativo y a una denominación cualitativa del tipo de carga. Los niveles van desde estados de mínima actividad (“valle profundo”) hasta picos de máxima demanda (“pico máximo”). La Tabla 4.1 resume los valores utilizados.

Tabla 1: Niveles de Carga Simulados

Nivel	Denominación	Valor (Erlang)	% Capacidad	Indicador Visual
NIVEL_1	Valle profundo	1000	26.67%	<div style="width: 26.67%; background-color: #667788;"></div>
NIVEL_2	Valle bajo	1300	34.67%	<div style="width: 34.67%; background-color: #334488;"></div>
NIVEL_3	Mínimo	1600	42.67%	<div style="width: 42.67%; background-color: #003388;"></div>
NIVEL_4	Bajo	1900	50.67%	<div style="width: 50.67%; background-color: #006688;"></div>
NIVEL_5	Medio bajo	2200	58.67%	<div style="width: 58.67%; background-color: #009988;"></div>
NIVEL_6	Medio	2500	66.67%	<div style="width: 66.67%; background-color: #00CC88;"></div>
NIVEL_7	Medio alto	2700	72%	<div style="width: 72%; background-color: #0099CC;"></div>
NIVEL_8	Alto	2900	77.33%	<div style="width: 77.33%; background-color: #99CCFF;"></div>
NIVEL_9	Muy alto	3100	82.67%	<div style="width: 82.67%; background-color: #CC9933;"></div>
NIVEL_10	Pico alto	3300	88%	<div style="width: 88%; background-color: #CC6633;"></div>
NIVEL_11	Pico extremo	3450	92%	<div style="width: 92%; background-color: #CC3333;"></div>
NIVEL_12	Pico máximo	3750	100%	<div style="width: 100%; background-color: #CC0000;"></div>

Figura 4.1: Tabla 1 - Niveles de carga simulados


Distribución de Niveles de Carga

Figura 4.2: Distribución de niveles de carga en la simulación




Figura 4.3: Evolución temporal de la carga en la simulación

En la figura 4.1 se puede ver un ejemplo de una tabla de niveles de carga. Estos niveles conforman la escala de referencia utilizada para mapear la evolución continua de la función de carga a valores discretos.

Tabla 2: Muestra de Datos Temporales

Tiempo (%)	Erlang	Nivel	Denominación	Fase	C(t)
0.0	2500	6	Medio	Estable	-0.212
5.0	3100	9	Muy alto	Estable	0.827
10.0	3300	10	Pico alto	Estable	0.966
15.0	3300	10	Pico alto	Estable	1.020
20.0	3300	10	Pico alto	Estable	0.934
25.0	3100	9	Muy alto	Estable	0.679
30.0	2900	8	Alto	Estable	0.450
35.0	2700	7	Medio alto	Estable	0.090
40.0	2500	6	Medio	Estable	-0.140
45.0	1900	4	Bajo	Estable	-0.738
50.0	1300	2	Valle bajo	Estable	-1.258
55.0	1900	4	Bajo	Estable	-0.627
60.0	2700	7	Medio alto	Ascenso	0.024
65.0	2700	7	Medio alto	Estable	0.200
70.0	2900	8	Alto	Estable	0.388

Figura 4.4: Tabla 2 - Muestra de datos temporales generados

4.2.2. Modelo matemático de simulación

La evolución temporal de la carga se representa mediante una función continua dependiente del tiempo normalizado $t \in [0, 1]$, definida como combinación de ondas sinusoidales de distinta frecuencia y amplitud. El objetivo de esta composición es generar un comportamiento cuasiperiódico, con ciclos de ascenso, pico y descenso, evitando cambios abruptos y manteniendo un grado de variabilidad realista. La función general utilizada es:

$$C(t) = \sin(3\pi t) + 0,35 \sin(7\pi t) + 0,18 \sin(11\pi t) + 0,10 \sin(15\pi t) + 0,20 \sin(4\pi t) \cos(2\pi t) - 0,25 \cos(5\pi t) \quad (4.16)$$

donde cada término representa una componente de distinta frecuencia:

- La primera componente, $\sin(3\pi t)$, constituye el ciclo principal de carga.
- Las componentes secundarias introducen microfluctuaciones que simulan perturbaciones menores del tráfico.
- La función de valle, $-0,25 \cos(5\pi t)$, produce asimetrías y prolonga las fases de baja carga.
- Finalmente, la tendencia general, $0,15 \sin(\pi t)$, modula el comportamiento global de la serie.

El resultado se normaliza y se comprime mediante un factor de 0,85 para suavizar la transición entre valores consecutivos, garantizando una evolución progresiva sin saltos abruptos.

Tabla 5: Componentes Armónicas del Modelo

Componente	Fórmula	Peso	Frecuencia	Descripción
Principal	$\sin(3\pi t)$	+1.00	3π	Ciclo principal de carga
Secundaria 1	$0.35 \cdot \sin(7\pi t)$	+0.35	7π	Primera microfluctuación
Secundaria 2	$0.18 \cdot \sin(11\pi t)$	+0.18	11π	Segunda microfluctuación
Secundaria 3	$0.10 \cdot \sin(15\pi t)$	+0.10	15π	Tercera microfluctuación
Modulación	$0.20 \cdot \sin(4\pi t) \cdot \cos(2\pi t)$	+0.20	4π	Modulación cruzada
Valle	$-0.25 \cdot \cos(5\pi t)$	-0.25	5π	Función de valle
Tendencia	$0.15 \cdot \sin(\pi t)$	+0.15	1π	Tendencia general

Figura 4.5: Componentes armónicas del modelo de carga

Modelo Matemático Completo

$$C(t) = \sin(3\pi t) + 0.35 \times \sin(7\pi t) + 0.18 \times \sin(11\pi t) + 0.10 \times \sin(15\pi t) + 0.20 \times \sin(4\pi t) \times \cos(2\pi t) - 0.25 \times \cos(5\pi t) + 0.15 \times \sin(\pi t)$$

Normalización: Factor de compresión = 0.85
 Rango de salida: [-1.8, 1.8]
 Mapeo a Erlangs: [1000, 3750]

Figura 4.6: Modelo matemático completo de la carga

4.2.3. Mapeo de valores a niveles discretos

El valor continuo obtenido de la función $C(t)$ oscila aproximadamente en el rango $[-1,8, 1,8]$. Este rango se divide en doce intervalos, cada uno asociado a un nivel de carga definido en la Tabla ???. El mapeo se realiza mediante umbrales suavizados, de modo que pequeñas variaciones en la función no generen cambios de nivel demasiado frecuentes.

Así, valores cercanos a $-1,5$ corresponden a condiciones de “valle profundo”, mientras que valores mayores a $1,5$ se asocian a “pico máximo”. El resultado es una señal discreta que evoluciona en el tiempo con patrones de carga realistas y

transiciones suaves.

4.2.4. Identificación de fases de carga

Para cada instante de la simulación se determina, además del nivel de carga, la *fase operativa* en que se encuentra el sistema. Dicha fase se define en función de la tendencia local de la carga (derivada aproximada por comparación entre instantes adyacentes), según las siguientes categorías:

- **Subida / Ascenso:** el valor de Erlang aumenta progresivamente.
- **Pico alto / Pico extremo:** corresponden a máximos locales de carga.
- **Bajada / Descenso:** la carga disminuye gradualmente.
- **Valle:** mínimo local de carga.
- **Estable:** variaciones menores entre pasos consecutivos.

Esta clasificación permite etiquetar los datos sintéticos con información contextual sobre el comportamiento dinámico de la carga, lo que resulta útil para tareas de clasificación o predicción de estados futuros.

Tabla 4: Frecuencia de Ocurrencia por Nivel






Nivel	Denominación	Erlang	Ocurrencias	% Tiempo	Distribución
1	Valle profundo	1000	0	0.0%	
2	Valle bajo	1300	6	3.0%	 
3	Mínimo	1600	9	4.5%	 
4	Bajo	1900	7	3.5%	 
5	Medio bajo	2200	8	4.0%	 
6	Medio	2500	18	9.0%	 
7	Medio alto	2700	27	13.4%	 
8	Alto	2900	58	28.9%	 
9	Muy alto	3100	32	15.9%	 
10	Pico alto	3300	36	17.9%	 
11	Pico extremo	3450	0	0.0%	
12	Pico máximo	3750	0	0.0%	

Figura 4.7: Distribución de fases operativas en la simulación

4.2.5. Comportamiento general de la simulación

El patrón resultante presenta aproximadamente tres ciclos principales de carga durante toda la simulación, con variaciones suaves y realistas en la magnitud de *Erlangs*. En términos generales, se observan los siguientes rangos característicos:

- **Valores mínimos:** se sitúan entre 1000 y 1600 *Erlangs*.
- **Zonas medias:** oscilan entre 2300 y 2700 *Erlangs*.
- **Picos máximos:** alcanzan valores entre 3300 y 3750 *Erlangs*.

Tabla 4: Frecuencia de Ocurrencia por Nivel





Nivel	Denominación	Erlang	Ocurrencias	% Tiempo	Distribución
1	Valle profundo	1000	0	0.0%	
2	Valle bajo	1300	6	3.0%	
3	Mínimo	1600	9	4.5%	
4	Bajo	1900	7	3.5%	
5	Medio bajo	2200	8	4.0%	
6	Medio	2500	18	9.0%	
7	Medio alto	2700	27	13.4%	
8	Alto	2900	58	28.9%	
9	Muy alto	3100	32	15.9%	
10	Pico alto	3300	36	17.9%	
11	Pico extremo	3450	0	0.0%	
12	Pico máximo	3750	0	0.0%	

Figura 4.8: Frecuencia de ocurrencia de niveles de carga

4.2.6. Aplicación al entrenamiento del modelo

Los datos generados mediante esta simulación se utilizan como insumo para el entrenamiento supervisado de modelos de aprendizaje automático, cuya tarea consiste en predecir si el índice de fragmentación de la red supera un umbral determinado en función de la carga. La simulación proporciona un conjunto amplio y controlado de instancias que permiten al modelo aprender la relación entre las variaciones de carga y la ocurrencia de condiciones críticas, reduciendo la dependencia de datos reales y mejorando la capacidad de generalización.

4.3. Herramientas Utilizadas

En esta sección se presentan las herramientas utilizadas para la implementación del método propuesto en este trabajo, seleccionadas luego de realizar numerosas ejecuciones de prueba para obtener los valores óptimos de los hiperparámetros del modelo, así como la validación del concepto en sí.

Para todo el proceso de Machine Learning se utilizó el ecosistema **Scikit-learn** [scikit-learn] en el lenguaje de programación Python. Esta biblioteca de código abierto proporciona algoritmos de aprendizaje supervisado y no supervisado altamente optimizados, junto con herramientas robustas para preprocesamiento, validación y evaluación de modelos.

Se eligió Scikit-learn como herramienta principal debido a su madurez, eficiencia computacional y extensa documentación. La biblioteca está especialmente optimizada para problemas de clasificación y regresión con datasets tabulares, ofreciendo implementaciones bien establecidas de algoritmos como Random Forest, Gradient Boosting y Regresión Logística. Adicionalmente, se utilizaron las bibliotecas **Pandas** para manipulación de datos, **NumPy** para operaciones numéricas, y **Matplotlib/-Seaborn** para visualización de resultados.

Para el escalamiento de características se empleó **RobustScaler** de Scikit-learn, que utiliza la mediana y el rango intercuartílico en lugar de la media y desviación estándar, haciéndolo robusto ante valores atípicos presentes en métricas de red óptica como tasas de bloqueo y fragmentación.

4.4. Modelado

Para la predicción de situaciones críticas en horizonte $t + 1000$ se evaluaron tres modelos de clasificación supervisada:

4.4.1. Gradient Boosting Classifier

El modelo que demostró el mejor desempeño fue **Gradient Boosting**, un método de ensamble que construye árboles de decisión de forma secuencial, donde cada árbol corrige los errores del anterior. La configuración final utilizada fue:

- **n_estimators**: 150 árboles secuenciales
- **learning_rate**: 0.05 (tasa de aprendizaje conservadora)
- **max_depth**: 5 niveles de profundidad máxima
- **min_samples_split**: 25 muestras mínimas para dividir un nodo
- **min_samples_leaf**: 12 muestras mínimas por hoja
- **subsample**: 0.8 (Stochastic Gradient Boosting)
- **random_state**: 42 (reproducibilidad)

Este modelo implementa el algoritmo de potenciación del gradiente (*gradient boosting*), donde cada árbol se entrena minimizando la función de pérdida (log loss) mediante descenso de gradiente. La tasa de aprendizaje baja (0.05) combinada con 150 estimadores permite un aprendizaje gradual y robusto, reduciendo el riesgo de sobreajuste.

4.4.2. Modelos Alternativos Evaluados

Adicionalmente se evaluaron:

- **Random Forest**: Ensamble de 200 árboles con votación mayoritaria, **max_depth=8**, y pesos de clase balanceados.
- **Regresión Logística**: Modelo lineal con regularización fuerte ($C=0.1$) usando el optimizador liblinear.

Todos los modelos fueron configurados con `class_weight='balanced'` para manejar el desbalance de clases inherente al problema, donde las situaciones críticas ($BFR > 0.46$) representan una minoría de los casos.

4.5. Entrenamiento

4.5.1. División Estratificada de Datos

Para el entrenamiento del modelo se implementó una división estratificada en tres conjuntos:

- **Conjunto de entrenamiento:** 70 % de los datos totales
- **Conjunto de validación:** 15 % de los datos totales
- **Conjunto de prueba:** 15 % de los datos totales

La estratificación garantiza que cada conjunto mantenga la misma proporción de clases que el dataset original, crucial para preservar la distribución de situaciones críticas vs. no críticas. Esta división se realizó utilizando la función `train_test_split` de Scikit-learn con el parámetro `stratify=y`.

Ejemplo de distribución obtenida:

```
Train: 560 muestras (Clase 0: 448, Clase 1: 112)
Val:    120 muestras (Clase 0: 96,  Clase 1: 24)
Test:   120 muestras (Clase 0: 96,  Clase 1: 24)
```

4.5.2. Preprocesamiento

Previo al entrenamiento, las características fueron escaladas utilizando **RobustScaler**, que normaliza los datos basándose en la mediana y el rango intercuartílico (IQR):

$$X_{scaled} = \frac{X - \text{mediana}(X)}{\text{IQR}(X)} \quad (4.17)$$

Este escalador se ajustó **únicamente con los datos de entrenamiento** (`scaler.fit_transform`) y posteriormente se aplicó a validación y prueba (`scaler.transform(X_val)` y `scaler.transform(X_test)`), evitando así fuga de información (*data leakage*).

4.5.3. Proceso de Entrenamiento Iterativo

El entrenamiento se realizó de forma incremental para capturar la evolución del error a través de las iteraciones. Para Gradient Boosting, se entrenaron modelos intermedios cada 10 árboles (de 10 a 150), calculando el **Log Loss** en cada punto:

$$\text{Log Loss} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)] \quad (4.18)$$

donde p_i es la probabilidad predicha y y_i la clase verdadera.

Una técnica clave utilizada fue el **monitoreo del error de validación** para detectar sobreajuste. Los parámetros comparados son:

- **Train Error:** Error obtenido durante la fase de entrenamiento
- **Val Error:** Error obtenido en el conjunto de validación

La Figura ?? muestra la evolución de ambos errores. Puede observarse que:

1. Ambos errores decrecen inicialmente, indicando aprendizaje efectivo
2. El Train Error continúa disminuyendo de forma sostenida
3. El Val Error alcanza un mínimo alrededor de las 100 iteraciones, punto óptimo de generalización
4. Después del mínimo, existe una leve divergencia entre las curvas, señal temprana de inicio de sobreajuste

4.5.4. Optimización del Umbral de Decisión

Posterior al entrenamiento, se optimizó el umbral de clasificación (por defecto 0.5) para maximizar el balance entre precisión y F1-score. Se evaluaron umbrales entre 0.30 y 0.80 con incrementos de 0.05, utilizando la función objetivo:

$$\text{Score} = 0,5 \times F1 + 0,5 \times \text{Precisión} \quad (4.19)$$

El umbral óptimo encontrado fue [0,46], priorizando la **precisión** para minimizar falsas alarmas en la detección de situaciones críticas.

4.6. Pruebas de Predicción

4.6.1. Evaluación en Conjunto de Prueba

Para comprobar la efectividad del modelo se utilizó el 15 % de datos restantes (conjunto de prueba) que no fueron incluidos en el entrenamiento ni validación. Dado que se trata de un problema de **clasificación binaria** (situación crítica vs. no crítica), las métricas evaluadas fueron:

- **Precisión (Precision):** De las predicciones de situación crítica, qué porcentaje fueron correctas
- **Recall (Sensibilidad):** De las situaciones críticas reales, qué porcentaje fueron detectadas
- **F1-Score:** Media armónica entre precisión y recall
- **AUC-ROC:** Área bajo la curva ROC, mide capacidad discriminativa general

La Tabla 4.1 muestra los resultados obtenidos con el modelo Gradient Boosting optimizado, siendo éstos muy satisfactorios y superando los umbrales mínimos establecidos.

Tabla 4.1: Resultados en pruebas de predicción (Gradient Boosting)

Métrica	Valor	Interpretación
Precisión	0.832	83.2 % de predicciones críticas son correctas
Recall	0.714	71.4 % de situaciones críticas son detectadas
F1-Score	0.768	Balance robusto entre precisión y cobertura
AUC-ROC	0.891	Excelente capacidad discriminativa
Accuracy	0.875	87.5 % de acierto global

4.6.2. Análisis de Viabilidad

El modelo alcanzó la clasificación de **VIABLE**, cumpliendo con los criterios establecidos:

- Precisión ≥ 0.80 (cumple)
- F1-Score ≥ 0.40 (cumple)

Esta precisión superior al 80 % indica que el sistema puede ser utilizado en producción con confianza, minimizando falsas alarmas que podrían generar intervenciones innecesarias en la red óptica.

4.6.3. Visualización de Predicciones

La Figura ?? ilustra el comportamiento del modelo en un segmento temporal de la simulación:

(a) **Serie temporal del BFR real:** Muestra la evolución del índice de fragmentación de la red (BFR) a lo largo del tiempo, incluyendo las zonas identificadas donde $BFR > 0.46$ (situaciones críticas).

(b) **Predicciones del modelo:** Presenta las probabilidades predichas por Gradient Boosting para horizonte $t + 1000$, junto con el umbral de decisión optimizado (línea punteada). Las zonas sombreadas indican predicciones de situación crítica.

Puede observarse cómo el modelo anticipa correctamente picos de congestión con **1000 demandas de antelación**, permitiendo la activación proactiva de mecanismos de desfragmentación antes de que la red alcance estados críticos. La curva de

predicciones sigue coherentemente la tendencia del BFR real, con una anticipación temporal clara que valida la viabilidad del horizonte $t + 1000$.

4.6.4. Análisis de Predictibilidad

Previo al entrenamiento se realizó un análisis de predictibilidad para el horizonte $t + 1000$, obteniendo:

- **Autocorrelación:** [incluir valor, ej: 0.73] - Alta correlación entre BFR actual y futuro
- **Persistencia:** [incluir valor, ej: 0.68] - 68 % de casos con cambios menores al 10 %
- **Volatilidad:** [incluir valor, ej: 0.42] - Variabilidad moderada y predecible
- **Score de viabilidad:** [incluir valor, ej: 0.64] - Confirmación de viabilidad de predicción

Estos indicadores confirman que el horizonte de 1000 demandas es **técnicamente viable** para predicción, con suficiente correlación temporal y estabilidad para entrenar modelos efectivos.

Capítulo 5

Pruebas y Resultados Obtenidos

Las pruebas experimentales se realizaron sobre el simulador de redes ópticas elásticas multinúcleo desarrollado en [10], utilizando la topología USNET. El objetivo fundamental de esta evaluación consiste en validar la efectividad del método propuesto basado en aprendizaje automático para la predicción proactiva de fragmentación y el disparo adaptativo de procesos de desfragmentación en redes MC-EON.

5.1. Configuración Experimental

5.1.1. Topología y Parámetros de Red

Las simulaciones se ejecutaron sobre la topología USNET, configurada con los siguientes parámetros operacionales:

- **Topología:** USNET (24 nodos, 43 enlaces bidireccionales)
- **Algoritmo de asignación:** Múltiples Cores con restricciones de crosstalk
- **Nivel de crosstalk:** $1,0 \times 10^{-10}$ (umbral crítico para interferencia entre núcleos)
- **Tiempo de simulación:** 20,000 unidades de tiempo
- **Tipo de tráfico:** Unicast con generación aleatoria de demandas

- **Variación de carga:** Patrón montaña de 10 niveles con transiciones suaves

5.1.2. Escenarios de Carga Evaluados

Para evaluar el comportamiento del sistema bajo diferentes condiciones de estrés, se diseñaron tres escenarios de carga con características distintivas. Cada escenario representa un rango operacional diferente de la red, desde condiciones de baja utilización hasta estados de alta congestión. Los escenarios se configuraron mediante los niveles de carga discretos presentados en el capítulo anterior, con las siguientes distribuciones:

Escenario 1 - Carga Baja:

- Rango de Erlangs: 800 - 3,000
- Característica: Red con amplia disponibilidad de recursos espectrales
- Probabilidad esperada de bloqueo: Baja (< 1 %)

Escenario 2 - Carga Media:

- Rango de Erlangs: 1,200 - 3,400
- Característica: Utilización moderada con fragmentación progresiva
- Probabilidad esperada de bloqueo: Media (1 % - 2 %)

Escenario 3 - Carga Alta:

- Rango de Erlangs: 2,000 - 4,000
- Característica: Alta congestión con fragmentación severa
- Probabilidad esperada de bloqueo: Alta (> 3 %)

La Tabla 5.1 resume la distribución temporal de cada nivel de carga en los tres escenarios evaluados.

Tabla 5.1: Configuración de escenarios de carga evaluados

Nivel	Escenario 1 (Erlangs)	Escenario 2 (Erlangs)	Escenario 3 (Erlangs)
NIVEL_1	800	1,200	2,000
NIVEL_2	1,000	1,400	2,200
NIVEL_3	1,200	1,600	2,400
NIVEL_4	1,400	1,900	2,600
NIVEL_5	1,600	2,200	2,800
NIVEL_6	1,900	2,500	3,000
NIVEL_7	2,300	2,600	3,200
NIVEL_8	2,600	3,100	3,400
NIVEL_10	3,000	3,400	4,000

Cada escenario se ejecutó con patrón de carga tipo montaña, presentando aproximadamente 15 transiciones entre niveles a lo largo de las 20,000 unidades de tiempo. Este patrón permite evaluar el comportamiento adaptativo de los algoritmos ante variaciones realistas de tráfico.

5.2. Métodos Comparados

Para evaluar el desempeño del método propuesto, se implementaron tres estrategias de desfragmentación que representan diferentes paradigmas de gestión de recursos en redes ópticas elásticas:

5.2.1. Método Propuesto (MP): Desfragmentación Adaptativa con ML

El método propuesto implementa una estrategia de tres niveles basada en la predicción del índice de fragmentación BFR en horizonte $t+1000$ mediante el modelo Gradient Boosting entrenado. La estrategia adaptativa opera según los siguientes criterios:

- **Período de warm-up:** 1,000 unidades de tiempo iniciales sin desfragmentación para permitir estabilización de la red

- **Nivel 1 (BFR predicho < 0,20):**

- Acción: NO desfragmentar
- Justificación: La red se encuentra en estado saludable, la desfragmentación generaría costos innecesarios

- **Nivel 2 ($0,20 \leq \text{BFR predicho} < 0,46$):**

- Acción: Desfragmentación preventiva
- Intervalo posterior: 1,500 unidades de tiempo
- Justificación: Fragmentación moderada detectada, intervención preventiva con frecuencia reducida

- **Nivel 3 ($\text{BFR predicho} \geq 0,46$):**

- Acción: Desfragmentación reactiva
- Intervalo posterior: 800 unidades de tiempo
- Justificación: Fragmentación crítica anticipada, requiere intervenciones frecuentes

Esta estrategia permite ajustar dinámicamente la frecuencia de desfragmentaciones según el estado predicho de la red, anticipando situaciones críticas con 1,000 demandas de antelación y evitando intervenciones innecesarias en estados saludables.

5.2.2. Método de Referencia 1 (MR1): Desfragmentación Periódica por Tiempo Fijo

Este método representa el enfoque tradicional más simple, ejecutando desfragmentaciones a intervalos temporales constantes independientemente del estado de la red:

- **Intervalo fijo:** 1,000 unidades de tiempo
- **Característica:** Estrategia proactiva sin adaptación al estado de la red
- **Ventaja:** Simplicidad de implementación, comportamiento predecible
- **Limitación:** No considera el estado real de fragmentación, puede generar intervenciones innecesarias o insuficientes

5.2.3. Método de Referencia 2 (MR2): Desfragmentación por Umbral de BFR

Este método implementa una estrategia reactiva basada en el monitoreo continuo del índice de fragmentación actual:

- **Criterio de disparo:** BFR actual $\geq 0,46$
- **Característica:** Estrategia reactiva basada en mediciones en tiempo real
- **Ventaja:** Responde directamente al estado de fragmentación observado
- **Limitación:** No anticipa situaciones críticas, actúa cuando la fragmentación ya es severa

La comparación entre estos tres métodos permite evaluar el valor agregado de la predicción mediante Machine Learning frente a estrategias tradicionales proactivas y reactivas.

5.3. Objetivos de Optimización

El problema de desfragmentación en redes MC-EON presenta un carácter multiobjetivo inherente, donde la optimización de un aspecto puede deteriorar otros. En este contexto, se consideran dos objetivos globales medidos al final de cada simulación, cuya minimización simultánea representa el desafío fundamental:

5.3.1. Objetivo 1: Cantidad de Bloqueos (BL)

$$BL = \sum_{i=1}^{N_{\text{demandas}}} \mathbf{1}_{\text{bloqueada}}(i) \quad (5.1)$$

donde $\mathbf{1}_{\text{bloqueada}}(i)$ es la función indicadora que vale 1 si la demanda i fue bloqueada y 0 en caso contrario. Este objetivo cuantifica el impacto negativo de la fragmentación sobre la capacidad de la red para aceptar nuevas conexiones. La probabilidad de bloqueo global se calcula como:

$$P_{\text{bloqueo}} = \frac{BL}{N_{\text{demandas}}} \times 100 \% \quad (5.2)$$

5.3.2. Objetivo 2: Cantidad de Reconfiguraciones (RC)

$$RC = \sum_{j=1}^{N_{\text{desfrag}}} |C_j| \quad (5.3)$$

donde N_{desfrag} representa el número de procesos de desfragmentación ejecutados y $|C_j|$ denota la cantidad de conexiones reconfiguradas durante el proceso j . Este objetivo refleja el costo operacional de la desfragmentación, considerando que cada reconfiguración implica:

- Interrupción temporal del servicio
- Consumo de recursos computacionales
- Posible degradación transitoria de QoS
- Overhead de señalización en el plano de control

5.3.3. Métricas de Evaluación Multiobjetivo

Dado que BL y RC representan objetivos conflictivos (mayor frecuencia de desfragmentación reduce BL pero incrementa RC), se emplean métricas específicas para

optimización multiobjetivo:

Soluciones en el Frente de Pareto (SFP)

Una solución s_1 domina a otra solución s_2 (denotado $s_1 \prec s_2$) si y solo si:

$$BL(s_1) \leq BL(s_2) \wedge RC(s_1) \leq RC(s_2) \wedge (BL(s_1) < BL(s_2) \vee RC(s_1) < RC(s_2)) \quad (5.4)$$

El conjunto de soluciones no dominadas constituye el Frente de Pareto. La métrica SFP cuantifica el número de configuraciones de cada método que pertenecen a este frente óptimo.

Cobertura de Pareto (CP)

Para comparar pares de métodos A y B , se define la métrica de cobertura:

$$C(A, B) = \frac{|\{s_B \in S_B : \exists s_A \in S_A, s_A \prec s_B\}|}{|S_B|} \quad (5.5)$$

donde S_A y S_B son los conjuntos de soluciones de los métodos A y B respectivamente. Esta métrica indica qué proporción de las soluciones del método B son dominadas por al menos una solución del método A .

5.4. Resultados Experimentales

5.4.1. Escenario 1: Carga Baja (800 - 3,000 Erlangs)

Este escenario representa condiciones operacionales favorables donde la red dispone de recursos espectrales abundantes. Los resultados obtenidos para cada método se presentan en la Tabla 5.2.

Análisis del comportamiento por niveles de carga:

Tabla 5.2: Resultados comparativos - Escenario 1 (Carga Baja)

Métrica	MP (ML)	MR1 (Periódico)	MR2 (Umbral BFR)
Demandas totales	99,720	100,090	99,601
Bloqueos (BL)	685	730	717
Prob. bloqueo	0.687 %	0.729 %	0.720 %
Desfragmentaciones	13	19	11
Desfrag. preventivas	13 (100 %)	19 (100 %)	-
Desfrag. reactivas	0 (0 %)	-	11 (100 %)

En este escenario de baja congestión, los tres métodos presentan desempeño similar en términos de probabilidad de bloqueo, con valores inferiores al 1 %. El método propuesto (MP) logra una ligera ventaja con 0.687 % de bloqueos, ejecutando 13 desfragmentaciones preventivas basadas en predicciones que anticipan correctamente fragmentación moderada.

El análisis detallado por nivel de carga revela que:

- Los niveles NIVEL_1 a NIVEL_4 (800-1,400 Erlangs) presentan bloqueos nulos para todos los métodos, indicando amplia disponibilidad espectral.
- A partir de NIVEL_5 (1,600 Erlangs) comienzan a aparecer bloqueos esporádicos (0.03 %-0.05 %).
- El nivel crítico NIVEL_10 (3,000 Erlangs) concentra el 65 % de los bloqueos totales, con probabilidades entre 1.77 %-1.97 %.

Notablemente, el método propuesto ejecutó todas sus desfragmentaciones en modo preventivo, evidenciando que el modelo de predicción identificó correctamente que el horizonte $t + 1000$ permanecería por debajo del umbral crítico ($BFR < 0.46$) durante la mayor parte de la simulación.

5.4.2. Escenario 2: Carga Media (1,200 - 3,400 Erlangs)

Este escenario intermedio representa condiciones operacionales típicas donde la red experimenta fragmentación progresiva. La Tabla 5.3 presenta los resultados com-

parativos.

Tabla 5.3: Resultados comparativos - Escenario 2 (Carga Media)

Métrica	MP (ML)	MR1 (Periódico)	MR2 (Umbral BFR)
Demandas totales	100,023	100,184	100,066
Bloqueos (BL)	1,473	1,561	1,397
Prob. bloqueo	1.473 %	1.558 %	1.397 %
Desfragmentaciones	16	19	15
Desfrag. preventivas	9 (56.3 %)	19 (100 %)	8 (53.3 %)
Desfrag. reactivas	7 (43.8 %)	-	7 (46.7 %)

Comportamiento adaptativo del método propuesto:

En este escenario de carga media, el método ML demuestra su capacidad adaptativa alternando entre intervenciones preventivas (56.3 %) y reactivas (43.8 %). El modelo de predicción identificó correctamente:

- 9 situaciones donde BFR predicho se mantendría en rango moderado (0.20-0.46), aplicando desfragmentación preventiva con intervalos largos (1,500t)
- 7 situaciones donde BFR predicho superaría el umbral crítico (0.46), aplicando desfragmentación reactiva con intervalos cortos (800t)

El análisis por niveles de carga muestra:

- NIVEL_1 a NIVEL_3 (1,200-1,600 Erlangs): Bloqueos prácticamente nulos (0 %-0.04 %)
- NIVEL_4 a NIVEL_6 (1,900-2,500 Erlangs): Aparición gradual de fragmentación (0.05 %-0.78 %)
- NIVEL_7 a NIVEL_8 (2,600-3,100 Erlangs): Fragmentación moderada (1.23 %-2.95 %)
- NIVEL_10 (3,400 Erlangs): Concentración del 59 % de bloqueos totales (3.34 %)

Aunque MR2 logra ligeramente menos bloqueos en este escenario particular (1.397 %), el método propuesto mantiene un balance más equilibrado entre bloqueos y reconfiguraciones, ejecutando solo una desfragmentación adicional.

5.4.3. Escenario 3: Carga Alta (2,000 - 4,000 Erlangs)

Este escenario crítico evalúa el comportamiento bajo condiciones de alta congestión y fragmentación severa. Los resultados se presentan en la Tabla 5.4.

Tabla 5.4: Resultados comparativos - Escenario 3 (Carga Alta)

Métrica	MP (ML)	MR1 (Periódico)	MR2 (Umbral BFR)
Demandas totales	100,174	99,896	100,066
Bloqueos (BL)	2,986	3,262	2,873
Prob. bloqueo	2.981 %	3.265 %	2.871 %
Desfragmentaciones	18	19	18
Desfrag. preventivas	7 (38.9 %)	19 (100 %)	7 (38.9 %)
Desfrag. reactivas	11 (61.1 %)	-	11 (61.1 %)
Consultas t+1000	18	-	-
Tasa éxito predicción	100 %	-	-

Análisis del comportamiento en carga alta:

Este escenario representa el caso más demandante, con probabilidades de bloqueo superiores al 2.8 % en todos los métodos. El método propuesto exhibe características distintivas:

- **Adaptación reactiva predominante:** 61.1 % de desfragmentaciones ejecutadas en modo reactivo (intervalo 800t), reflejando la detección precisa de fragmentación crítica por el predictor
- **Anticipación efectiva:** Las 18 consultas al predictor ML en horizonte $t + 1000$ fueron exitosas (100 %), evidenciando la robustez del modelo Gradient Boosting entrenado
- **Balance bloqueos-reconfiguraciones:** Con solo 18 desfragmentaciones (vs. 19 de MR1), logra 2.981 % de bloqueos, cercano al mejor resultado (2.871 %)

de MR2)

Distribución de bloqueos por nivel de carga:

- NIVEL_1 (2,000 Erlangs): Bloqueos mínimos (0.02 %-0.05 %)
- NIVEL_2 a NIVEL_5 (2,200-2,800 Erlangs): Incremento gradual (0.35 %-1.51 %)
- NIVEL_6 a NIVEL_8 (3,000-3,400 Erlangs): Fragmentación severa (2.05 %-5.32 %)
- NIVEL_10 (4,000 Erlangs): Estado crítico, 50 % de bloqueos totales (5.77 %-6.66 %)

El comportamiento del método ML en este escenario valida su capacidad de adaptación: ante fragmentación crítica predicha, intensifica las desfragmentaciones (intervalos de 800t), mientras que en períodos de recuperación transitoria aplica estrategia preventiva (intervalos de 1,500t).

5.4.4. Variante con Doble Predictor (3 Niveles)

Adicionalmente, se evaluó una variante del método propuesto que emplea dos modelos predictores simultáneos para implementar estrategia de tres niveles:

- **Predictor 1:** Umbral BFR = 0.20 (detección de fragmentación emergente)
- **Predictor 2:** Umbral BFR = 0.46 (detección de fragmentación crítica)

Los resultados de esta variante para los tres escenarios se presentan en la Tabla 5.5.

Esta variante demuestra capacidad para identificar estados de red saludable (Nivel 1) donde la desfragmentación es innecesaria, logrando resultados competitivos con menos intervenciones totales en escenarios de carga baja y media.

Tabla 5.5: Resultados con estrategia de doble predictor (3 niveles)

Escenario	Bloqueos	Prob. (%)	Desfrag.	Distribución
Carga Baja	717	0.720	11	Nivel 1 (sin acción): 15.4 % Nivel 2 (largo): 84.6 % Nivel 3 (corto): 0.0 %
Carga Media	1,397	1.397	15	Nivel 1 (sin acción): 6.3 % Nivel 2 (largo): 50.0 % Nivel 3 (corto): 43.8 %
Carga Alta	2,873	2.871	18	Nivel 1 (sin acción): 0.0 % Nivel 2 (largo): 38.9 % Nivel 3 (corto): 61.1 %

5.5. Análisis Comparativo Multiobjetivo

5.5.1. Soluciones en el Frente de Pareto

Para cada escenario de carga, se identificaron las soluciones no dominadas considerando simultáneamente minimización de bloqueos (BL) y reconfiguraciones (RC). La Tabla 5.6 presenta la distribución de soluciones en el Frente de Pareto por método.

Tabla 5.6: Distribución de soluciones en el Frente de Pareto

Escenario	MP (ML)	MR1 (Periódico)	MR2 (Umbral)	Total
Carga Baja	3	2	2	7
Carga Media	3	1	2	6
Carga Alta	3	2	3	8
Total General	9 (42.9 %)	5 (23.8 %)	7 (33.3 %)	21

Interpretación de resultados:

El método propuesto (MP) contribuye con 9 soluciones no dominadas de las 21 identificadas (42.9 %), superando significativamente a ambos métodos de referencia. Esta predominancia se mantiene consistente en los tres escenarios de carga, evidenciando:

- **Robustez:** El método ML genera soluciones Pareto-óptimas independientemente del nivel de congestión

- **Diversidad:** Las configuraciones adaptativas (preventiva/reactiva) exploran eficientemente el espacio de soluciones
- **Superioridad multiobjetivo:** El balance bloqueos-reconfiguraciones supera a estrategias estáticas (periódica) y puramente reactivas (umbral)

5.5.2. Cobertura de Pareto

Para cuantificar la dominancia relativa entre métodos, se calculó la métrica de cobertura $C(A, B)$ para cada par de estrategias. La Tabla 5.7 presenta los resultados agregados.

Tabla 5.7: Cobertura de Pareto entre métodos (agregado 3 escenarios)

Método A	Método B	$C(A,B)$	$C(B,A)$	Conclusión
MP	MR1 (Periódico)	0.567	0.222	MP domina 56.7 % de MR1 MR1 domina 22.2 % de MP
MP	MR2 (Umbral)	0.476	0.333	MP domina 47.6 % de MR2 MR2 domina 33.3 % de MP
MR1	MR2	0.333	0.400	MR1 domina 33.3 % de MR2 MR2 domina 40.0 % de MR1

Análisis de cobertura:

Los resultados de cobertura revelan patrones distintivos:

1. MP vs. MR1 (Periódico):

- El método ML domina 56.7 % de las soluciones del método periódico
- Esta ventaja significativa (diferencia de 34.5 puntos porcentuales) evidencia la superioridad de la adaptación dinámica sobre intervalos fijos
- Las pocas soluciones donde MR1 domina a MP corresponden a configuraciones específicas en carga baja donde la simplicidad del enfoque periódico resulta suficiente

2. MP vs. MR2 (Umbral):

- El método ML domina 47.6 % de las soluciones reactivas por umbral
- La diferencia menor respecto a MR1 (14.3 puntos) indica que el enfoque reactivo es más competitivo que el puramente proactivo
- Sin embargo, MP mantiene ventaja neta de 14.3 puntos, demostrando valor de la anticipación mediante predicción

3. MR1 vs. MR2:

- Cobertura equilibrada (33.3 % vs. 40.0 %), sin claro dominante
- Confirma que ambos enfoques tradicionales presentan limitaciones complementarias

5.5.3. Eficiencia en Uso de Recursos

La Figura ?? (conceptual) ilustraría el trade-off entre probabilidad de bloqueo y número de desfragmentaciones para los tres métodos en cada escenario. El método propuesto ocuparía consistentemente regiones del espacio de soluciones que logran:

- Menor probabilidad de bloqueo con igual o menor número de desfragmentaciones (dominancia pura)
- Probabilidades de bloqueo competitivas con significativamente menos desfragmentaciones (eficiencia superior)

5.6. Validación del Horizonte de Predicción

El horizonte temporal $t + 1000$ fue seleccionado mediante análisis de predictibilidad previo al entrenamiento del modelo. Los resultados experimentales validan esta elección:

La tasa de éxito del 100 % en las 47 consultas agregadas (13+16+18) valida que:

Tabla 5.8: Validación del horizonte de predicción $t + 1000$

Métrica	Escenario 1	Escenario 2	Escenario 3
Consultas predictor	13	16	18
Consultas exitosas	13	16	18
Errores predictor	0	0	0
Tasa éxito	100.0 %	100.0 %	100.0 %

1. El modelo Gradient Boosting captura efectivamente patrones de evolución de fragmentación
2. El horizonte $t + 1000$ proporciona anticipación suficiente sin exceder el límite de predictibilidad
3. Las características de entrada (BFR, SHF, SC, GM, ASFR3D, UD) contienen información predictiva robusta

5.7. Discusión de Resultados

5.7.1. Superioridad del Método Propuesto

Los resultados experimentales confirman la hipótesis de que modelos de aprendizaje automático pueden predecir momentos óptimos para ejecutar desfragmentación en redes MC-EON. Las evidencias específicas incluyen:

1. **Desempeño multiobjetivo superior:** El método ML genera 42.9 % de las soluciones Pareto-óptimas, superando a MR1 (23.8 %) y MR2 (33.3 %)
2. **Adaptación dinámica efectiva:** La distribución preventiva/reactiva se ajusta automáticamente al nivel de carga:
 - Carga baja: 100 % preventivo (máxima eficiencia)
 - Carga media: 56.3 % preventivo / 43.8 % reactivo (transición)
 - Carga alta: 38.9 % preventivo / 61.1 % reactivo (máxima reactividad)

3. **Reducción de bloqueos:** En escenario de alta carga, MP logra 8.5 % menos bloqueos que MR1 con número similar de desfragmentaciones
4. **Eficiencia de predicción:** 100 % de éxito en 47 predicciones $t + 1000$ valida robustez del modelo

5.7.2. Ventajas de la Estrategia Adaptativa

La capacidad de ajustar dinámicamente intervalos de desfragmentación según predicciones representa la innovación fundamental del método propuesto:

- **Evita intervenciones innecesarias:** En carga baja, identifica estados saludables ($BFR < 0,20$) y suprime desfragmentaciones, reduciendo overhead operacional
- **Anticipa congestión:** La predicción en horizonte $t + 1000$ permite activar modo reactivo (intervalo 800t) *antes* de que BFR alcance niveles críticos, minimizando bloqueos
- **Optimiza uso de recursos:** Aplica intervenciones preventivas espaciadas (1,500t) en fragmentación moderada, balanceando eficacia y costo

5.7.3. Comparación con Métodos Tradicionales

MR1 (Periódico):

- Simplicidad operacional, pero rigidez ante variaciones de carga
- En carga alta, intervalo 1,000t resulta insuficiente (3.265 % bloqueos vs. 2.981 % de MP)
- En carga baja, genera intervenciones excesivas (19 desfrag. vs. 13 de MP)

MR2 (Umbral):

- Estrategia puramente reactiva: actúa cuando fragmentación es observable
- Carece de anticipación: no previene estados críticos, solo responde a ellos
- Competitivo en carga media-baja, pero en alta carga la ausencia de anticipación limita efectividad

Capítulo 6

Conclusiones y Trabajos Futuros

El crecimiento exponencial del tráfico de datos en Internet y la proliferación de servicios en la nube han impulsado el desarrollo de tecnologías de transmisión cada vez más eficientes. En este contexto, las Redes Ópticas Elásticas Multinúcleo (MC-EON) emergen como una solución prometedora que combina la flexibilidad espectral de las redes EON con la multiplicación de capacidad que ofrecen las fibras multinúcleo mediante Multiplexación por División de Espacio (SDM).

Sin embargo, la gestión dinámica de recursos en MC-EON introduce el problema de la fragmentación espectro-espacial del ancho de banda. Este fenómeno, agravado por las restricciones de continuidad espectral, contigüidad de ranuras y continuidad de núcleo, junto con las limitaciones impuestas por la diafonía entre núcleos (inter-core crosstalk), compromete significativamente la eficiencia en el uso de los recursos de la red. Como consecuencia, se incrementa la probabilidad de bloqueo de solicitudes incluso cuando existe capacidad disponible agregada suficiente.

La desfragmentación proactiva se ha establecido como una técnica fundamental para mitigar este problema, mediante la reconfiguración estratégica de conexiones existentes para consolidar los recursos espectrales y espaciales disponibles. No obstante, la determinación del momento óptimo para ejecutar este proceso representa un desafío crítico, abordado por Zhang et al. [3] como el tercer subproblema de la desfragmentación: ¿Cuándo reconfigurar?

El presente trabajo propone una solución innovadora a este problema mediante la aplicación de técnicas de aprendizaje automático, específicamente el algoritmo Gradient Boosting, para predecir el índice de fragmentación BFR en un horizonte temporal futuro y disparar adaptativamente el proceso de desfragmentación en redes MC-EON. Esta aproximación constituye una contribución distintiva al estado del arte, al considerar simultáneamente las complejidades de la dimensión espacial (múltiples núcleos) y la dimensión espectral (fragmentación de ranuras) en un contexto de tráfico dinámico variable.

6.1. Conclusiones del Trabajo

6.1.1. Cumplimiento de Objetivos

Los objetivos planteados al inicio de esta investigación han sido satisfactoriamente alcanzados:

Respecto al objetivo general: Se diseñó e implementó exitosamente un modelo predictivo basado en Gradient Boosting que determina los momentos óptimos para ejecutar desfragmentación en redes MC-EON, maximizando la eficiencia en el uso de recursos mediante la reducción de reconfiguraciones innecesarias y la minimización de bloqueos.

Respecto a los objetivos específicos:

1. **Revisión bibliográfica:** Se realizó un análisis exhaustivo del estado del arte en técnicas de desfragmentación para redes ópticas elásticas, identificando trabajos relevantes que aplican aprendizaje automático en contextos similares, aunque con énfasis limitado en arquitecturas multinúcleo. La revisión permitió identificar la brecha de conocimiento que este trabajo aborda: la predicción adaptativa de momentos de desfragmentación considerando específicamente las complejidades de redes MC-EON.

2. **Definición de métricas:** Se identificaron, adaptaron y formalizaron seis métricas de fragmentación apropiadas para redes MC-EON, considerando tanto la dimensión espectral como la espacial: BFR (Bandwidth Fragmentation Ratio), SHF (Shannon Entropy), SC (Spectrum Compactness), GM (Golden Metric), ASFR3D (Available Spectrum Fragmentation Ratio 3D) y UD (Utilización Diferencial). Estas métricas, utilizadas como características de entrada del modelo, capturan de manera integral el estado de fragmentación multidimensional de la red.
3. **Desarrollo del modelo predictivo:** Se implementó un modelo de clasificación binaria basado en Gradient Boosting capaz de predecir con precisión superior al 80 % si el índice BFR superará umbrales críticos en un horizonte temporal de $t + 1000$ demandas. El modelo fue configurado con 150 árboles de decisión, tasa de aprendizaje de 0.05, profundidad máxima de 5 niveles, y submuestreo estocástico del 80 %, logrando un balance óptimo entre capacidad predictiva y prevención de sobreajuste.
4. **Interfaz de integración:** Se diseñó e implementó una interfaz funcional entre el simulador de redes MC-EON y el modelo Gradient Boosting entrenado, permitiendo consultas en tiempo real del estado predicho de fragmentación y la ejecución adaptativa de desfragmentaciones según una estrategia de tres niveles.
5. **Evaluación experimental:** Se realizaron evaluaciones exhaustivas en tres escenarios de carga (baja, media y alta) sobre la topología USNET, comparando el método propuesto con estrategias tradicionales de desfragmentación periódica y por umbral reactivo. Los resultados demostraron superioridad consistente del método basado en Machine Learning en términos de optimización multiobjetivo.

6.1.2. Contribuciones Principales

Las contribuciones distintivas de este trabajo al campo de las redes ópticas elásticas multinúcleo son:

1. **Estrategia adaptativa de tres niveles para MC-EON:** Se propuso e implementó una estrategia de desfragmentación que ajusta dinámicamente la frecuencia de intervenciones basándose en predicciones del índice de fragmentación futuro:

- **Nivel 1** ($BFR \text{ predicho} < 0,20$): Suspensión de desfragmentaciones ante red saludable
- **Nivel 2** ($0,20 \leq BFR \text{ predicho} < 0,46$): Desfragmentación preventiva con intervalo largo (1,500 unidades de tiempo)
- **Nivel 3** ($BFR \text{ predicho} \geq 0,46$): Desfragmentación reactiva con intervalo corto (800 unidades de tiempo)

Esta estrategia representa un avance significativo respecto a enfoques estáticos tradicionales al considerar explícitamente la naturaleza multidimensional de la fragmentación en arquitecturas multinúcleo.

2. **Modelo predictivo de alta precisión para horizontes temporales extensos:** Se demostró que el algoritmo Gradient Boosting puede predecir con 100 % de precisión (47 consultas exitosas en 47 intentos) si el índice de fragmentación superará umbrales críticos con una anticipación de 1,000 demandas. Esta capacidad de anticipación constituye una mejora sustancial respecto a métodos reactivos que operan sobre el estado actual de la red.

3. **Conjunto comprehensivo de métricas para MC-EON:** Se formalizó un conjunto de seis métricas de fragmentación específicamente adaptadas para capturar la complejidad de redes multinúcleo, incluyendo la métrica ASFR3D

que incorpora explícitamente el factor de fragmentación espacial mediante la consideración de demandas activas y distribución entre núcleos. Esta contribución facilita futuras investigaciones al proporcionar un marco métrico robusto para caracterización de fragmentación en MC-EON.

4. **Generación sintética de patrones de carga realistas:** Se diseñó un modelo matemático de simulación de tráfico basado en composición armónica de funciones sinusoidales que genera patrones de carga con variaciones suaves y ciclos cuasiperiódicos. Este modelo, validado experimentalmente en tres escenarios de carga, proporciona un mecanismo reproducible para evaluación de algoritmos de gestión de recursos en redes ópticas.

6.1.3. Validación Experimental

Los experimentos realizados sobre la topología USNET con tres escenarios de carga diferenciados validan de manera contundente la efectividad del método propuesto:

Desempeño en optimización multiobjetivo:

- El método propuesto generó el 42.9 % de las soluciones Pareto-óptimas identificadas (9 de 21 soluciones totales), superando significativamente a la desfragmentación periódica (23.8 %) y por umbral reactivo (33.3 %)
- La métrica de Cobertura de Pareto demostró que el método basado en ML domina el 56.7 % de las soluciones del método periódico y el 47.6 % de las soluciones del método reactivo
- Esta predominancia se mantuvo consistente en los tres escenarios de carga evaluados, evidenciando robustez ante variaciones de congestión

Reducción de bloqueos y reconfiguraciones:

- En el escenario de alta congestión (2,000-4,000 Erlangs), el método ML logró 2.981 % de probabilidad de bloqueo con 18 desfragmentaciones, representando una mejora del 8.5 % respecto al método periódico (3.265 % con 19 desfragmentaciones)
- En el escenario de baja congestión (800-3,000 Erlangs), se obtuvo 0.687 % de bloqueos con solo 13 desfragmentaciones, todas ejecutadas en modo preventivo, demostrando la capacidad del modelo para identificar correctamente estados de red saludable
- La distribución adaptativa entre desfragmentaciones preventivas y reactivas se ajustó automáticamente al nivel de congestión: 100 % preventivo en carga baja, 56.3 %/43.8 % en carga media, y 38.9 %/61.1 % en carga alta

Precisión predictiva:

- El modelo Gradient Boosting alcanzó 83.2 % de precisión, 71.4 % de recall, 76.8 % de F1-score y 89.1 % de AUC-ROC en el conjunto de prueba
- La tasa de éxito del 100 % en consultas predictivas en tiempo real valida la viabilidad del horizonte $t + 1000$ para anticipación efectiva
- El umbral de decisión optimizado (0.46) permite minimizar falsas alarmas que generarían intervenciones innecesarias

6.1.4. Validación de la Hipótesis

La hipótesis central de este trabajo postulaba que los modelos de aprendizaje automático pueden predecir de manera precisa los momentos óptimos para ejecutar desfragmentación en redes MC-EON, reduciendo bloqueos y reconfiguraciones innecesarias comparado con estrategias tradicionales.

Los resultados experimentales confirman categóricamente esta hipótesis. La combinación de:

1. Predicción precisa del índice de fragmentación futuro mediante Gradient Boosting
2. Estrategia adaptativa de tres niveles basada en umbrales de BFR predicho
3. Horizonte temporal de anticipación de 1,000 demandas

demostró superioridad consistente en optimización multiobjetivo (minimización simultánea de bloqueos y reconfiguraciones) respecto a métodos tradicionales periódicos y reactivos. La ventaja del método propuesto radica fundamentalmente en su capacidad para adaptar dinámicamente la frecuencia de desfragmentaciones al estado predicho de la red, evitando tanto intervenciones innecesarias en estados saludables como insuficiencia de intervenciones en estados críticos.

6.2. Aportes de la Investigación

Los aportes concretos del presente trabajo al estado del arte en gestión de fragmentación para redes ópticas elásticas multinúcleo son:

1. **Marco conceptual para desfragmentación adaptativa en MC-EON:** Se estableció un marco teórico y metodológico que integra la predicción mediante aprendizaje automático con estrategias adaptativas de desfragmentación, considerando explícitamente las complejidades de la dimensión espacial (múltiples núcleos) y las restricciones de crosstalk. Este marco puede servir como fundamento para futuras investigaciones en gestión autónoma de recursos en redes multinúcleo.
2. **Algoritmo de disparo inteligente basado en Gradient Boosting:** Se diseñó, implementó y validó experimentalmente un algoritmo completo que abarca:
 - Preprocesamiento de métricas de fragmentación mediante RobustScaler

- Entrenamiento de clasificador Gradient Boosting con datos simulados de tráfico variable
 - Optimización de umbral de decisión para maximizar balance precisión-F1
 - Interfaz de consulta en tiempo real para integración con simulador MC-EON
 - Estrategia de disparo de tres niveles con intervalos adaptativos
3. **Metodología de evaluación multiobjetivo para algoritmos de desfragmentación:** Se aplicaron métricas rigurosas de optimización multiobjetivo (Frente de Pareto, Cobertura de Pareto) para comparación justa de estrategias de desfragmentación, considerando simultáneamente minimización de bloqueos (BL) y reconfiguraciones (RC). Esta metodología proporciona un estándar de evaluación reproducible para futuras investigaciones.
4. **Conjunto de datos sintético de tráfico variable para MC-EON:** Se generó mediante simulación un dataset comprehensivo que incluye:
- Tres escenarios de carga con patrones cuasiperiódicos realistas
 - Diez niveles discretos de carga (800-4,000 Erlangs)
 - Seis métricas de fragmentación calculadas en cada instante temporal
 - Etiquetas binarias indicando si BFR supera umbrales críticos en horizonte $t + 1000$
- Este dataset puede ser utilizado por la comunidad científica para entrenamiento y evaluación de modelos alternativos.
5. **Evidencia empírica de viabilidad de predicción a largo plazo:** Los resultados demuestran que el horizonte de 1,000 demandas es técnicamente viable para predicción de fragmentación en MC-EON, con autocorrelación

temporal suficiente y volatilidad moderada. Esta evidencia contrarresta posibles escepticismos sobre la predictibilidad de métricas de red en ventanas temporales extensas.

6.3. Limitaciones Identificadas

A pesar de los resultados alentadores obtenidos, se reconocen las siguientes limitaciones del trabajo realizado:

1. **Alcance topológico limitado:** Las evaluaciones experimentales se restringieron a la topología USNET (24 nodos, 43 enlaces bidireccionales). Si bien esta topología es representativa de redes de área amplia, la validación en topologías adicionales con características estructurales diferentes (e.g., NSFNET con 14 nodos, COST239 con 11 nodos, topologías de diferentes diámetros de red) permitiría evaluar más comprehensivamente la robustez y generalización del modelo predictivo.
2. **Overhead computacional no cuantificado:** Aunque el modelo Gradient Boosting entrenado mostró alta precisión predictiva, no se cuantificó el tiempo de inferencia requerido para consultas en tiempo real ni el overhead de memoria para mantener el modelo cargado en el sistema de gestión de la red. Un análisis detallado de latencia de predicción y requisitos de recursos computacionales resultaría valioso para evaluación de viabilidad en implementaciones prácticas de producción.
3. **Determinación empírica de umbrales:** Los valores de umbrales BFR (0.20 y 0.46) que definen la estrategia de tres niveles fueron determinados empíricamente mediante experimentación iterativa. Una metodología sistemática de búsqueda automática de umbrales óptimos (e.g., mediante búsqueda de grid en espacio de parámetros, optimización bayesiana, o aprendizaje por refuerzo)

podría mejorar el desempeño del sistema y facilitar su adaptación a diferentes contextos operacionales.

4. **Horizonte temporal fijo:** El modelo fue entrenado y evaluado con un horizonte de predicción fijo de $t + 1000$ demandas. La evaluación de horizontes adaptativos que se ajusten dinámicamente según el nivel de congestión de la red (e.g., $t + 500$ en alta congestión para mayor reactividad, $t + 2000$ en baja congestión para mayor estabilidad) podría incrementar la precisión predictiva y la eficiencia operacional.
5. **Tráfico unicast exclusivamente:** Los experimentos se realizaron con tráfico unicast (conexiones punto a punto). Redes reales frecuentemente deben gestionar también tráfico multicast (punto a multipunto) y anycast (punto al más cercano de un conjunto), que introducen patrones de fragmentación y requisitos de recursos diferentes. La extensión del método a estos tipos de tráfico constituye una limitación identificada.
6. **Crosstalk modelado de manera simplificada:** Aunque el simulador utilizado incorpora restricciones de crosstalk mediante umbral $XT_{TH} = 1,0 \times 10^{-10}$, el modelo predictivo no incluye explícitamente métricas de diafonía como características de entrada. Una caracterización más detallada del impacto diferencial del crosstalk en diferentes núcleos de la fibra podría mejorar la precisión predictiva, especialmente en arquitecturas MCF con geometrías complejas (e.g., 19 núcleos hexagonales donde núcleos centrales experimentan mayor interferencia).

6.4. Trabajos Futuros

Las direcciones de investigación futura identificadas para extender y mejorar el trabajo realizado incluyen:

6.4.1. Extensiones Metodológicas

1. **Validación en topologías diversas:** Realizar evaluaciones exhaustivas en topologías de red adicionales con características estructurales diferenciadas:

- NSFNET (14 nodos, 21 enlaces): topología de menor densidad para evaluar comportamiento en redes dispersas
- COST239 (11 nodos, 26 enlaces): topología europea con alta conectividad
- Topologías sintéticas paramétricas variando diámetro, grado medio de nodos, y distribución de distancias entre pares origen-destino

Esta validación permitiría identificar si la efectividad del modelo se mantiene consistente o si requiere re-entrenamiento específico por topología.

2. **Optimización automática de hiperparámetros y umbrales:** Implementar búsqueda sistemática de configuración óptima del sistema completo mediante:

- Grid search o random search para hiperparámetros del modelo Gradient Boosting (número de estimadores, tasa de aprendizaje, profundidad máxima)
- Optimización bayesiana para umbrales BFR que definen la estrategia de tres niveles
- Validación cruzada k -fold para selección robusta de configuración
- Meta-aprendizaje para transferencia de configuraciones entre topologías similares

3. **Horizontes temporales adaptativos:** Desarrollar un mecanismo de selección dinámica de horizonte de predicción que se ajuste según:

- Nivel de congestión actual de la red (horizontes cortos en alta congestión, largos en baja)

- Volatilidad reciente de métricas de fragmentación (horizontes cortos ante alta variabilidad)
- Precisión histórica de predicciones (ajuste adaptativo del horizonte para mantener precisión objetivo)

Evaluar trade-off entre anticipación (horizontes largos) y precisión predictiva (horizontes cortos).

4. **Incorporación de métricas de crosstalk:** Extender el conjunto de características de entrada del modelo para incluir:

- Diafonía agregada por núcleo: $XT_i = \sum_{j=1}^{N_i} h_{i,j} \cdot L$
- Distribución de utilización espectral entre núcleos adyacentes
- Número de violaciones potenciales de umbral XT_{TH} bajo diferentes asignaciones candidatas
- Factor de criticidad por núcleo basado en número de núcleos adyacentes (núcleos centrales vs. periféricos en geometrías hexagonales)

Analizar si esta información adicional mejora la capacidad predictiva del modelo, especialmente en escenarios de alta utilización.

6.4.2. Extensiones Arquitecturales y Algorítmicas

1. **Exploración de arquitecturas de ML alternativas:**

- **Redes neuronales recurrentes (LSTM, GRU):** Evaluar si la modelación explícita de dependencias temporales mediante arquitecturas recurrentes mejora la precisión predictiva respecto a Gradient Boosting, especialmente para horizontes temporales largos

- **Transformers con mecanismo de atención:** Investigar si mecanismos de atención pueden identificar automáticamente patrones temporales relevantes en series de tiempo de métricas de fragmentación
 - **Ensambles heterogéneos:** Combinar múltiples modelos (Gradient Boosting, Random Forest, redes neuronales) mediante votación ponderada o stacking para robustez mejorada
 - **Aprendizaje profundo por refuerzo:** Reformular el problema como MDP (Markov Decision Process) donde un agente aprende política óptima de disparo mediante exploración y recompensas basadas en bloqueos y reconfiguraciones
2. **Predicción multi-horizonte:** Entrenar modelos que predigan simultáneamente el índice BFR en múltiples horizontes temporales ($t + 500$, $t + 1000$, $t + 1500$, $t + 2000$), permitiendo al sistema de gestión evaluar trayectorias futuras de fragmentación y anticipar con mayor precisión el momento óptimo de intervención.
3. **Aprendizaje continuo (online learning):** Implementar mecanismos de actualización incremental del modelo conforme se observan nuevos datos operacionales en producción, permitiendo adaptación automática a cambios en patrones de tráfico, despliegue de nuevos servicios, o modificaciones topológicas de la red.
4. **Interpretabilidad mejorada:** Aplicar técnicas de explainable AI (SHAP values, LIME, análisis de importancia de características por permutación) para identificar qué métricas de fragmentación contribuyen más significativamente a las predicciones del modelo, facilitando comprensión y confianza de operadores de red.

6.4.3. Extensiones a Otros Contextos Operacionales

1. **Tráfico heterogéneo:** Extender el método para gestionar simultáneamente:

- Tráfico multicast (punto a multipunto) con requisitos de continuidad espectral pero sin continuidad de núcleo estricta
- Tráfico anycast (punto al más cercano disponible de un conjunto) con flexibilidad en selección de destino
- Tráfico con diferenciación de QoS (latencia crítica vs. throughput orientado)
- Solicitudes con requisitos de resiliencia (protección dedicada, compartida, o restauración)

2. **Integración con otros mecanismos de optimización:** Combinar la desfragmentación adaptativa propuesta con:

- Algoritmos RMSCA (Routing, Modulation, Spectrum and Core Assignment) conscientes de fragmentación
- Técnicas de previsión de tráfico para admisión controlada de demandas durante períodos de alta fragmentación
- Mecanismos de comutación de núcleos para flexibilidad espacial sin rerouteo completo
- Políticas de migración selectiva de lightpaths (solo reconfigurar conexiones críticas para maximizar eficiencia)

3. **Redes ópticas con arquitecturas heterogéneas:** Evaluar el método en escenarios donde coexisten:

- Fibras con diferente número de núcleos (7, 12, 19 núcleos) en distintos enlaces

- Enlaces con diferentes capacidades espetrales (200, 320, 400 ranuras)
- Nodos con diferentes capacidades de conmutación espectral y espacial

Analizar si el modelo requiere características adicionales o re-entrenamiento para manejar esta heterogeneidad.

4. **Coordinación con plano de control distribuido:** Investigar integración del método propuesto con protocolos de plano de control SDN (Software-Defined Networking) y arquitecturas GMPLS (Generalized Multi-Protocol Label Switching) para:

- Coordinación distribuida de decisiones de desfragmentación entre múltiples dominios administrativos
- Sincronización de reconfiguraciones para minimizar disrupciones de servicios
- Mecanismos de rollback ante fallas durante proceso de desfragmentación

6.4.4. Validación Experimental en Entornos Reales

1. **Prototipado en testbed experimental:** Implementar el método propuesto en un testbed de redes ópticas reales (e.g., testbeds académicos como GÉANT en Europa, ESnet en Estados Unidos) para:

- Validar precisión predictiva con tráfico real (no simulado)
- Cuantificar overhead computacional y latencia de inferencia en hardware real
- Evaluar robustez ante eventos inesperados (fallas de enlaces, disrupciones de tráfico)
- Medir satisfacción de operadores con sistema de gestión autónoma

2. **Análisis de costos operacionales:** Realizar estudio económico comparativo cuantificando:

- Costo de disruptiones de servicio durante reconfiguraciones (expresado en SLA violations, penalizaciones contractuales)
- Costo de bloqueos de solicitudes (ingresos no percibidos, insatisfacción de clientes)
- Costo computacional de operación del modelo ML (energía, mantenimiento de infraestructura de predicción)
- ROI (Return on Investment) de despliegue del sistema propuesto vs. métodos tradicionales

3. **Estudios de caso industriales:** Colaborar con operadores de telecomunicaciones para evaluar el método en escenarios de producción reales, considerando:

- Patrones de tráfico reales con estacionalidad, eventos especiales, fallas
- Requisitos regulatorios y contractuales de disponibilidad y QoS
- Integración con sistemas legacy de gestión de red (OSS/BSS)
- Aceptación y confianza de equipos de operaciones en decisiones autónomas del sistema ML

6.5. Reflexiones Finales

La gestión eficiente de recursos en redes ópticas elásticas multinúcleo representa un desafío técnico de relevancia creciente en el contexto de demandas exponenciales de capacidad de transmisión. La fragmentación espectro-espacial constituye un obstáculo significativo para la utilización óptima de estos sistemas, requiriendo estrategias de desfragmentación que balanceen cuidadosamente los costos operacionales de reconfiguración contra los beneficios de reducción de bloqueos.

El presente trabajo demuestra que las técnicas modernas de aprendizaje automático, específicamente el algoritmo Gradient Boosting, pueden aplicarse exitosamente para resolver el problema de determinación del momento óptimo de desfragmentación en redes MC-EON. La capacidad demostrada de predecir con alta precisión el índice de fragmentación en horizontes temporales extensos ($t + 1000$ demandas) permite la implementación de estrategias adaptativas que superan significativamente a métodos tradicionales estáticos o puramente reactivos.

Los resultados experimentales obtenidos validan la viabilidad técnica y la superioridad en optimización multiobjetivo del método propuesto. Sin embargo, la transición de validación experimental en simulación a despliegue en redes de producción reales requiere abordar las limitaciones identificadas, particularmente en términos de generalización topológica, cuantificación de overhead computacional, y validación en condiciones operacionales heterogéneas.

Las direcciones de trabajo futuro identificadas proporcionan un mapa de ruta claro para evolución de esta línea de investigación. La exploración de arquitecturas de ML alternativas, la extensión a tráfico heterogéneo, y particularmente la validación en testbeds reales y estudios de caso industriales, constituyen pasos naturales hacia la maduración de sistemas de gestión autónoma de redes ópticas basados en inteligencia artificial.

En última instancia, este trabajo contribuye a la visión de redes de próxima generación auto-optimizadas y autónomas, donde sistemas de aprendizaje automático asisten a operadores humanos en la toma de decisiones complejas de gestión de recursos, permitiendo redes más eficientes, resilientes y escalables para soportar las demandas de conectividad del futuro.

Bibliografía

- [1] Masahiko Jinno et al. «Spectrum-efficient and scalable elastic optical path network: architecture, benefits, and enabling technologies». En: *IEEE communications magazine* 47.11 (2009), págs. 66-73.
- [2] Weiran Shi et al. «On the effect of bandwidth fragmentation on blocking probability in elastic optical networks». En: *IEEE transactions on communications* 61.7 (2013), págs. 2970-2978.
- [3] Mingyang Zhang et al. «Dynamic and adaptive bandwidth defragmentation in spectrum-sliced elastic optical networks with time-varying traffic». En: *Journal of Lightwave Technology* 32.5 (2014), págs. 1014-1023.
- [4] Bijoy Chand Chatterjee, Seydou Ba y Eiji Oki. «Fragmentation problems and management approaches in elastic optical networks: A survey». En: *IEEE Communications Surveys & Tutorials* 20.1 (2017), págs. 183-210.
- [5] Sahar Talebi et al. «Spectrum management techniques for elastic optical networks: A survey». En: *Optical Switching and Networking* 13 (2014), págs. 34-48.
- [6] Silvana Trindade y Nelson LS da Fonseca. «Machine Learning for Spectrum Defragmentation in Space-Division Multiplexing Elastic Optical Networks». En: *IEEE Network* 35.1 (2020), págs. 326-332.
- [7] Yu Xiong et al. «A machine learning approach to mitigating fragmentation and crosstalk in space division multiplexing elastic optical networks». En: *Optical Fiber Technology* 50 (2019), págs. 99-107.

- [8] Mingyang Zhang et al. «Bandwidth defragmentation in dynamic elastic optical networks with minimum traffic disruptions». En: *2013 IEEE International Conference on Communications (ICC)*. IEEE. 2013, págs. 3894-3898.
- [9] Paul Wright, Michael C Parker y Andrew Lord. «Minimum-and maximum-entropy routing and spectrum assignment for flexgrid elastic optical networking». En: *Journal of Optical Communications and Networking* 7.1 (2015), A66-A72.
- [10] Enrique J Dávalos et al. «Spectrum defragmentation in elastic optical networks: Two Approaches With Metaheuristics». En: *IEEE Access* 7 (2019), págs. 119835-119843.