

UNIVERSIDAD NACIONAL DE ASUNCIÓN

Facultad Politécnica



“ESTRATEGIA DE DISPARO PARA EL PROCESO DE
DESFRAGMENTACIÓN EN REDES ÓPTICAS ELÁSTICAS
MULTICORE, UTILIZANDO TÉCNICAS DE APRENDIZAJE
AUTOMÁTICO”

TRABAJO FINAL DE GRADO PRESENTADO POR

RODOLFO SEBASTIÁN VERGARA FERREIRA
Y DIEGO DANIEL DUARTE CENTURIÓN

COMO REQUISITO
PARA OBTENER EL TÍTULO DE INGENIERO
EN INFORMÁTICA

ORIENTADOR:
PROF. DR. ENRIQUE DAVALOS

San Lorenzo - Paraguay.

Diciembre de 2025

Índice general

Índice de Figuras	v
Índice de Tablas	vi
Lista de Símbolos	vii
1. Introducción	1
1.1. Justificación	1
1.2. Objetivos del trabajo	5
1.2.1. Objetivo General	5
1.2.2. Objetivos Específicos	5
1.3. Análisis Bibliográfico	6
1.4. Organización del libro	8
2. Fragmentación en Redes EON Multinúcleo	10
2.1. Redes EON Multinúcleo	11
2.2. Diafonía en Redes Ópticas Elásticas Multinúcleo	13
2.2.1. Cálculo de la diafonía	14
2.2.2. Asignación de espectro con conmutación de núcleo	15
2.3. Fragmentación del Ancho de Banda en MC-EON	17
2.3.1. Enfoques de gestión de fragmentación	20
2.4. Descripción del problema tratado	22

3. Aprendizaje Automático	25
3.1. Clasificación de sistemas o tipos de aprendizaje automático	26
3.2. Gradient Boosting	28
3.2.1. Fundamentos del Aprendizaje por Ensamble	29
3.2.2. Algoritmo de Gradient Boosting	30
3.2.3. Gradient Boosting Classifier	31
3.2.4. Configuración e Hiperparámetros	31
3.2.5. Aplicación en MC-EON	33
4. Método Propuesto	34
4.1. Estrategia de Desfragmentación Adaptativa	34
4.2. Características Utilizadas	36
4.3. Generación de Datos de Entrenamiento	40
4.3.1. Simulador y Topología	40
4.3.2. Modelo de Carga Variable	40
4.3.3. Niveles Discretos de Carga	41
4.3.4. Identificación de Fases Operativas	43
4.4. Herramientas de Implementación	43
4.5. Arquitectura del Sistema de Predicción	44
4.5.1. Modelo para Umbral Mínimo ($BFR_F = 0.20$)	44
4.5.2. Modelo para Umbral Crítico ($BFR_F = 0.46$)	44
4.6. Proceso de Entrenamiento	45
4.6.1. División Estratificada de Datos	45
4.6.2. Preprocesamiento	46
4.6.3. Entrenamiento Iterativo y Monitoreo	46
4.6.4. Optimización de Umbrales de Decisión	47
4.7. Resultados de Predicción	47
4.7.1. Métricas de Evaluación	47

4.7.2.	Metodología de Selección del Horizonte	48
4.7.3.	Análisis de Predictibilidad del Horizonte	48
4.7.4.	Resultados del Modelo de Umbral Crítico ($BFR_F = 0.46$) . . .	49
4.7.5.	Resultados del Modelo de Umbral Mínimo ($BFR_F = 0.20$) . .	50
4.7.6.	Justificación de Gradient Boosting	51
4.7.7.	Validación de la Estrategia de Dos Umbrales	51
4.8.	Implementación del Sistema	52
4.8.1.	Arquitectura de Servicios	52
4.8.2.	Lógica de Control de Desfragmentación	52
5.	Pruebas y Resultados Obtenidos	54
5.1.	Flujo del Algoritmo de Desfragmentación Adaptativa	54
5.2.	Configuración Experimental	56
5.2.1.	Topología y Parámetros de Red	56
5.2.2.	Escenarios de Carga Evaluados	56
5.3.	Métodos Comparados	58
5.3.1.	Línea Base (SD): Sin Desfragmentación	58
5.3.2.	Método de Referencia 1 (MR1): Desfragmentación Periódica por Tiempo Fijo	59
5.3.3.	Método de Referencia 2 (MR2): Desfragmentación por Umbral de BFR	59
5.3.4.	Método Propuesto (MP): Desfragmentación Adaptativa con Doble Umbral	60
5.4.	Objetivos de Optimización	61
5.4.1.	Objetivo 1: Cantidad de Bloqueos (BL)	61
5.4.2.	Objetivo 2: Cantidad de Reconfiguraciones (RC)	62
5.5.	Resultados Experimentales	62
5.5.1.	Escenario 1: Carga Baja (800 - 3,000 Erlangs)	62

5.5.2. Escenario 2: Carga Media (1,200 - 3,400 Erlangs)	64
5.5.3. Escenario 3: Carga Alta (2,000 - 4,000 Erlangs)	65
5.6. Análisis Comparativo Multiobjetivo	67
5.6.1. Cobertura de Pareto	67
5.6.2. Eficiencia en Uso de Recursos	68
5.7. Validación del Horizonte de Predicción	69
5.8. Discusión de Resultados	69
5.8.1. Superioridad del Método Propuesto	69
5.8.2. Valor de la Desfragmentación Activa	70
5.8.3. Ventajas de la Estrategia Adaptativa	71
5.8.4. Comparación con Métodos Tradicionales	71
6. Conclusiones y Trabajos Futuros	73
6.1. Cumplimiento de Objetivos	74
6.2. Contribuciones Principales	75
6.3. Validación Experimental	77
6.4. Validación de la Hipótesis	78
6.5. Aportes de la Investigación	79
6.6. Limitaciones Identificadas	80
6.7. Trabajos Futuros	81
6.7.1. Extensiones Metodológicas	81
6.7.2. Extensiones Arquitecturales y Algorítmicas	82
6.7.3. Extensiones a Otros Contextos Operacionales	82
6.7.4. Validación Experimental en Entornos Reales	83
6.8. Reflexiones Finales	84

Índice de figuras

2.1. Ejemplo de Fibra Multinúcleo (MCF) con 7 núcleos	12
2.2. Conmutación de núcleos con contigüidad de espectro	15
2.3. Asignación de espectro con conmutación de núcleos	17
2.4. Restricciones de contigüidad y continuidad aplicadas- Conexión Re- chazada	19
2.5. Restricciones de contigüidad y continuidad aplicadas- Conexión Es- tablecida	20
2.6. Esquema de Gestión de la Fragmentación	22
2.7. Ejemplo de desfragmentaciones periódicas con volumen de carga de tráfico variado	24
4.1. Distribución de niveles de carga en la simulación	42
4.2. Evolución temporal de la carga	42

Lista de Tablas

4.1. Componentes del modelo matemático de carga	41
4.2. Fases operativas del sistema basadas en tendencia de carga	43
4.3. Resultados del modelo Gradient Boosting para umbral crítico (BFR_F = 0.46)	49
4.4. Resultados del modelo Gradient Boosting para umbral mínimo (BFR_F = 0.20)	50
5.1. Flujo de decisiones del algoritmo de desfragmentación adaptativa . .	55
5.2. Configuración de escenarios de carga evaluados	57
5.3. Resultados comparativos - Escenario 1 (Carga Baja)	62
5.4. Resultados comparativos - Escenario 2 (Carga Media)	64
5.5. Resultados comparativos - Escenario 3 (Carga Alta)	65
5.6. Cobertura de Pareto entre métodos (agregado 3 escenarios)	67
5.7. Validación del horizonte de predicción $t + 1000$	69

Lista de Símbolos

Parámetros de red y espectro

N	Cantidad de FS en un enlace.
FS_i	<i>Frecuency Slot</i> de índice i .
FS_{i+1}	<i>Frecuency Slot</i> de índice $i + 1$.
$ E $	Cantidad de enlaces de la red.
C	Número de núcleos por enlace.
L	Longitud física del enlace óptico.
S_{free}	Cantidad de FS libres en un enlace o núcleo.
$S_{occupied}$	Cantidad de FS ocupados.
S^{small}	Suma de FS libres en bloques menores a 5 slots.
$Bloques$	Cantidad de bloques de ranuras libres en un enlace.
B	Cantidad de bloques libres.
G	Cantidad total de gaps.
g_i	Tamaño del gap libre i .
s_{min}	Índice del primer FS ocupado.
s_{max}	Índice del último FS ocupado.

Parámetros de fibra multinúcleo

$\Lambda_{i,j}$	Core pitch - Distancia entre los núcleos i y j .
N_i	Cantidad de núcleos adyacentes al núcleo i .

k	Coeficiente de acoplamiento.
r	Radio de curvatura.
β	Constante de propagación.
$h_{i,j}$	XT por unidad de longitud entre núcleos i y j .
XT_i	Crosstalk total que impacta al núcleo i .
XT_{TH}	Umbral de crosstalk admisible.

Métricas de fragmentación

BFR_{link}	Relación de Fragmentación de ancho de banda de un enlace.
BFR_{link-i}	Relación de Fragmentación de ancho de banda del enlace i .
BFR_{red}	Relación de Fragmentación de ancho de banda de la red.
BFR_F	BFR futuro predicho.
BFR_{FMIN}	Umbral mínimo de BFR.
BFR_{FMAX}	Umbral crítico de BFR.
$MaxBlock()$	Tamaño del mayor bloque de FS libres.

SHF_{link}	Entropía de Shannon del enlace.
SHF_{link-i}	Entropía de Shannon del enlace i .
SHF_{red}	Entropía de Shannon de la red.

MSI	Índice de slot máximo utilizado.
MSI_{link-i}	Índice de slot máximo utilizado del enlace i .
MSI_{red}	Índice de slot máximo utilizado de la red.

n_1, n_2	Parámetros de tamaños típicos de demanda (Golden Metric).
avg	Promedio en cálculo de Golden Metric.
ϵ	Valor pequeño para evitar división por cero.

a, b	Variables acumulativas en Golden Metric.
$F_{spatial}$	Factor de peso espacial.
D_{active}	Número de demandas activas en la red.

Utilización de red

U_{so}	Porcentaje de utilización de la red.
U_{core}	Utilización de un núcleo.
U_{max}	Utilización máxima entre todos los núcleos.
U_{min}	Utilización mínima entre todos los núcleos.

Métricas de desempeño

PB	Probabilidad de Bloqueo.
PB_{th}	Umbral para disparar el proceso de desfragmentación.
$P_{bloqueo}$	Probabilidad de bloqueo global.
BL	Cantidad de Bloqueos.
B_t	Bloqueos en tiempo t .
RC	Cantidad de Reconfiguraciones.
$N_{demandas}$	Número total de demandas.
$N_{desfrag}$	Número de procesos de desfragmentación.
$ C_j $	Cantidad de conexiones reconfiguradas en proceso j .
$\mathbf{1}_{bloqueada}(i)$	Función indicadora de bloqueo para demanda i .
SFP	Número de soluciones en el Frente Pareto.
CP	Cobertura Pareto.
TBI_t	Tasa de Bloqueo Instantánea en tiempo t .
$D_{processed,t}$	Demandas procesadas hasta tiempo t .

Parámetros de simulación y tiempo

t	Tiempo de simulación.
\widehat{BFR}_{t+1000}	BFR predicho a 1000 demandas futuras.

Parámetros de aprendizaje automático

M	Número total de iteraciones (Gradient Boosting).
$h_m(x)$	m-ésimo aprendiz débil.
γ_m	Coefficiente de peso asociado.
ν	Tasa de aprendizaje.
p_i	Probabilidad predicha para la muestra i .
X_{scaled}	Características escaladas.
IQR	Rango intercuartílico.

Métodos comparados

MP	Método Propuesto.
$MR1$	Método de Referencia 1 (Desfragmentación Periódica).
$MR2$	Método de Referencia 2 (Desfragmentación por Umbral).
SD	Sin Desfragmentación.

Capítulo 1

Introducción

1.1. Justificación

Debido al incremento de la popularidad de internet y del uso de servicios en la nube, tales como *Content Delivery Network* (CDN) y *Video on Demand* (VoD), las demandas de tasas de bits en las redes han crecido de manera exponencial [1], lo que obliga a estudiar nuevas y mejores tecnologías relacionadas a la transmisión de datos.

Las Redes de Multiplexación por División de Longitud de Onda o *Wavelength Division Multiplexing* (WDM), utilizan una grilla fija, de 50 o 100 GHz, dan una gran ventaja logrando velocidades muy superiores frente a las viejas tecnologías, pero a pesar de esta ventaja señalada, la gruesa granularidad lleva a un uso ineficiente del espectro, ya que cada demanda es asignada a un canal fijo y estas pueden requerir un ancho de banda menor al tamaño del canal.

Esta desventaja da lugar a las Redes Elásticas Ópticas o *Elastic Optical Networks* (EON) [2], las cuales surgen como una solución al problema anteriormente citado, ya que estas proporcionan una mayor flexibilidad en la división del espectro y de esa forma lograr que los requerimientos sean asignados de manera más eficiente.

A las redes EON también se las conoce como redes de grilla flexible, debido a que las ranuras de frecuencia o FS (*Frequency Slot*) que reemplazan a los “Canales

WDM”, cuentan con una división más flexible [3]. Cada FS tiene un ancho de banda de 12.5 GHz, de esta manera se logra una cantidad más apropiada de FS para satisfacer un requerimiento.

Sin embargo, a pesar de las mejoras introducidas por las redes EON, el crecimiento exponencial del tráfico de datos demanda soluciones aún más avanzadas. En este contexto, surgen las Redes Ópticas Elásticas Multicore o *Elastic Optical Networks with Multicore Fibers* (EON-MCF) y por consecuente *Space Division Multiplexing-Elastic Optical Networks* (SDM-EON), que incorporan fibras ópticas multinúcleo (MCF) [4], para multiplicar la capacidad de transmisión mediante la explotación de la dimensión espacial, además de las dimensiones espectral y temporal ya utilizadas en las redes EON convencionales.

Las fibras multinúcleo contienen múltiples núcleos dentro de una única fibra, donde cada núcleo puede transmitir señales de manera independiente [5]. Esta arquitectura permite aumentar significativamente la capacidad de la red sin necesidad de desplegar nuevas fibras, ofreciendo una solución escalable y económicamente viable para satisfacer las crecientes demandas de ancho de banda.

Los métodos de ruteo y asignación del espectro y núcleo tienen gran impacto sobre el uso eficiente de los recursos de la red. Los algoritmos RSCA (*Routing, Spectrum and Core Assignment*) [6] se encargan de resolver dicho problema encontrando el camino más apropiado desde el origen hasta el destino, el núcleo a utilizar y las ranuras que utilizará el requerimiento dentro del espectro de los enlaces.

Adicionalmente, en las redes SDM-EON surge un nuevo fenómeno denominado *Crosstalk* o diafonía entre núcleos *inter-core crosstalk*, *XT*, que ocurre cuando las señales ópticas de núcleos adyacentes interfieren entre sí, degradando la calidad de la transmisión [5]. Este fenómeno debe ser considerado como una restricción adicional en los algoritmos RSCA para garantizar la calidad del servicio.

Debido a las restricciones explicadas y a que las asignaciones de recursos son realizadas de manera dinámica, surge el fenómeno denominado "Fragmentación del

Ancho de Banda y del Espacio", este problema es una de las principales dificultades de las redes SDM-EON [7] ya que tiene un impacto directo en el uso eficiente del espectro y de los núcleos disponibles.

El fenómeno de la fragmentación espectro-espacial del ancho de banda sucede cuando en los enlaces se encuentran FS disponibles separados por FS que están siendo utilizados por otras conexiones, o cuando existen núcleos con recursos fragmentados que no pueden ser eficientemente asignados, por lo que estas podrían quedar inutilizables para nuevas conexiones por no poder satisfacer a la demanda debido a las restricciones citadas anteriormente, en consecuencia, la probabilidad de bloqueo [8] aumenta considerablemente.

Un bloqueo sucede cuando el algoritmo RSCA no puede encontrar núcleos y FS disponibles para una demanda, esto puede deberse a una alta saturación del espectro o de los núcleos, pero también debido al problema mencionado anteriormente, donde existe la cantidad de FS libres que se solicitan, pero sin respetar las restricciones de continuidad y contigüidad, o donde no hay núcleos disponibles que cumplan con las restricciones de crosstalk, es decir el espectro y el espacio se encuentran fragmentados.

El problema de la fragmentación de redes SDM-EON es ampliamente estudiado en la literatura actual [9, 7, 10], para buscar manejarlo se han propuesto soluciones con distintos enfoques.

Uno de los enfoques es el llamado *Enfoque proactivo* [11] el cual consiste en ejecutar un proceso de desfragmentación periódicamente o mediante un disparador. Tiene como principal objetivo prevenir futuros bloqueos en la red, este enfoque será el utilizado en este trabajo.

El proceso de desfragmentación consiste en la reconfiguración o re-ruteo de un sub-conjunto de conexiones ya establecidas en la red [12], teniendo como principal objetivo reducir la fragmentación del espectro y la fragmentación espacial mediante la eliminación de bloques de FS libres no contiguos y la redistribución eficiente de

conexiones entre núcleos.

En el trabajo presentado por Zhang [13], se realizó un análisis del problema de desfragmentación en redes EON, en el cual lo dividen en cuatro subproblemas, los cuales son, (I) ¿Cómo reconfigurar?, (II) ¿Cómo migrar el tráfico?, (III) ¿Cuándo reconfigurar? y (IV) ¿Qué reconfigurar?. Estos subproblemas mantienen su vigencia en el contexto de las redes SDM-EON, con la complejidad adicional de considerar la dimensión espacial.

En este trabajo nos centraremos en el tercer subproblema, ¿Cuándo reconfigurar?, ya que considerando el enfoque proactivo para resolver el problema de la fragmentación [14], encontramos que los procesos de desfragmentación podrían ejecutarse en periodos de tiempo donde no son del todo necesarios, es decir cuando la red se encuentra con una baja fragmentación, provocando desfragmentaciones ineficientes, una cantidad mayor de interrupciones de conexiones y una elevación innecesaria del costo de procesamiento.

En los siguientes capítulos presentamos modelos de predicción de índice de fragmentación, entrenados para detectar si supera unos umbrales predefinidos, implementados con técnicas de aprendizaje automático o *Machine Learning* [15], los cuales se utilizan como estrategia de disparo del proceso de desfragmentación pero en este caso redes SDM-EON Multinúcleo, proponiendo de esta manera una solución al subproblema planteado anteriormente.

En este contexto, la Inteligencia Artificial (IA) y específicamente el Aprendizaje Automático o *Machine Learning* (ML) [15], emergen como herramientas fundamentales para abordar estos desafíos de optimización en redes de telecomunicaciones. El ML se fundamenta en el desarrollo de algoritmos capaces de identificar patrones complejos en conjuntos de datos, mejorando su desempeño de manera iterativa mediante la experiencia acumulada, sin necesidad de instrucciones programáticas explícitas para cada escenario específico.

Dentro del paradigma de aprendizaje supervisado, el algoritmo Gradient Boos-

ting [16] ha demostrado ser particularmente efectivo para problemas de clasificación y predicción con datos tabulares. Este método construye secuencialmente múltiples modelos predictivos débiles mediante principios de optimización matemática, corrigiendo iterativamente los errores de sus predecesores. Su capacidad para modelar relaciones no lineales complejas, manejar variables de diferentes escalas, y proporcionar estimaciones de importancia de características lo hacen especialmente adecuado para el análisis de métricas operacionales en redes ópticas.

La aplicación de estas técnicas de ML al problema de la desfragmentación en redes SDM-EON permite desarrollar sistemas predictivos que anticipen el estado futuro de fragmentación de la red, considerando múltiples factores como métricas de fragmentación espectral y espacial, utilización de recursos en los núcleos, y patrones temporales de tráfico. Esta capacidad de anticipación posibilita la implementación de estrategias de desfragmentación adaptativas que optimicen el balance entre la reducción de bloqueos y el costo operacional de las reconfiguraciones.

1.2. Objetivos del trabajo

1.2.1. Objetivo General

Diseñar modelos de predicción para el proceso de desfragmentación en redes ópticas elásticas multicore, utilizando técnicas de aprendizaje automático, con el propósito de maximizar la eficiencia en el uso de los recursos de la red mediante la reducción de reconfiguraciones innecesarias y la minimización de la cantidad de bloqueos.

1.2.2. Objetivos Específicos

- Realizar una revisión bibliográfica del estado del arte en técnicas de desfragmentación para redes ópticas elásticas, con énfasis en métodos basados en

aprendizaje automático y su aplicación en redes multicore.

- Identificar y definir métricas de fragmentación apropiadas para redes ópticas elásticas multicore, considerando las particularidades de la asignación de recursos en múltiples núcleos.
- Desarrollar e implementar un modelo de aprendizaje automático capaz de predecir el índice de la fragmentación de la red a futuro y determinar momentos óptimos para activar el proceso de desfragmentación en redes EON multicore.
- Diseñar e implementar una interfaz de integración entre el simulador de redes ópticas elásticas multicore y el modelo de aprendizaje automático entrenado, permitiendo la evaluación en tiempo real del sistema propuesto.
- Evaluar el desempeño del modelo propuesto mediante simulaciones, comparando sus resultados con técnicas de desfragmentación existentes en términos de probabilidad de bloqueo, número de reconfiguraciones y eficiencia en el uso de recursos espectrales.

1.3. Análisis Bibliográfico

El problema de la fragmentación en redes ópticas elásticas ha sido ampliamente estudiado en la literatura científica, con diversos enfoques propuestos para su gestión. En el trabajo presentado por Enciso y Silva [17], se aborda específicamente el problema del momento de disparo del proceso de desfragmentación en redes EON utilizando técnicas de aprendizaje automático con redes neuronales artificiales. Su enfoque se centra en la predicción de probabilidades de bloqueo para determinar cuándo ejecutar el proceso de desfragmentación de manera proactiva.

Diversos autores han propuesto diferentes estrategias para el disparo de procesos de desfragmentación. Takita y colaboradores [18] proponen un mecanismo basado

en el valor del *High-slot Mark* (HM), que indica el número máximo de una ranura ocupada en la red. El proceso se dispara cuando el HM supera un umbral predefinido. Por su parte, Fávero y colegas [19] combinan enfoques reactivos y proactivos, considerando tanto los bloqueos como las conexiones liberadas para determinar el momento de desfragmentación.

Zhang y colaboradores [20] proponen un disparo basado en la cantidad de conexiones liberadas, ejecutando la desfragmentación cuando este número alcanza un umbral específico. En otro trabajo, Zhang [21] utiliza la métrica de *Spectrum Compactness* (SC) como criterio de disparo, comparando su valor actual con un umbral predefinido para determinar la necesidad de desfragmentación.

El enfoque de desfragmentación periódica, ampliamente utilizado en la literatura, ha sido analizado por Comellas, Vicario y Junyent [14], quienes evaluaron los efectos de diferentes parámetros de desfragmentación en el rendimiento de la red bajo tráfico dinámico. Sus resultados indican que períodos de desfragmentación muy pequeños pueden generar complejidad excesiva, mientras que períodos muy grandes producen efectos insignificantes.

En el contexto del aprendizaje automático aplicado a redes ópticas, el algoritmo Gradient Boosting [16] ha demostrado ser particularmente efectivo para problemas de clasificación y predicción. Friedman introduce este método como una técnica que construye secuencialmente modelos predictivos mediante la optimización de funciones de pérdida, corrigiendo iterativamente los errores de modelos anteriores. La implementación práctica de este algoritmo ha sido facilitada por herramientas como Scikit-learn [22], una biblioteca de código abierto para Python que proporciona implementaciones eficientes de algoritmos de aprendizaje automático.

El estado del arte en desfragmentación de redes ópticas elásticas muestra una tendencia hacia enfoques adaptativos e inteligentes. Chatterjee, Ba y Oki [11] realizaron un análisis exhaustivo de los problemas de fragmentación y los enfoques de gestión, clasificándolos en estrategias sin desfragmentación (mediante algoritmos sensibles

a la fragmentación), desfragmentación reactiva (ante bloqueos) y desfragmentación proactiva (preventiva).

En el contexto de redes SDM-EON, Trindade y da Fonseca [9] proponen un enfoque de aprendizaje no supervisado para la desfragmentación, identificando grupos de *lightpaths* que pueden ser reordenados eficientemente entre núcleos. Xiong y colaboradores [7] utilizan técnicas de ML para mitigar simultáneamente la fragmentación y el *crosstalk* en redes con multiplexación por división de espacio.

El presente trabajo se posiciona en la intersección de estas líneas de investigación, extendiendo los enfoques de disparo inteligente de desfragmentación mediante ML al contexto más complejo de las redes SDM-EON multinúcleo, donde la dimensión espacial adicional introduce nuevos desafíos en la gestión de recursos y la prevención de la fragmentación tanto espectral como espacial.

1.4. Organización del libro

El presente trabajo se encuentra organizado de la siguiente manera:

En el capítulo dos se presentan las características y conceptos fundamentales de las redes ópticas elásticas multinúcleo (MC-EON), incluyendo la multiplexación por división de espacio (SDM), el fenómeno de diafonía entre núcleos (*crosstalk*), y el problema de la fragmentación espectro-espacial del ancho de banda. Se describen los diferentes enfoques para la gestión de la fragmentación, con énfasis en la estrategia de desfragmentación proactiva con re-ruteo adoptada en este trabajo.

En el capítulo tres se introduce el aprendizaje automático, enfocándose en los fundamentos del aprendizaje supervisado y el paradigma de aprendizaje por ensamble. Se presenta en detalle el algoritmo Gradient Boosting, describiendo su funcionamiento, configuración de hiperparámetros, y su aplicación específica a problemas de clasificación en redes MC-EON mediante el GradientBoostingClassifier.

En el capítulo cuatro se describe el método propuesto para la selección del mo-

mento óptimo de desfragmentación mediante predicción con aprendizaje automático. Se presenta la estrategia adaptativa de tres niveles basada en doble umbral, las características utilizadas como entrada al modelo, el proceso de generación de datos sintéticos con carga variable, el entrenamiento de dos modelos Gradient Boosting independientes, y la arquitectura de servicios REST para integración con el simulador de red.

El capítulo cinco presenta las pruebas experimentales realizadas sobre la topología USNET en tres escenarios de carga (baja, media y alta). Se muestran los resultados comparativos del método propuesto frente a estrategias tradicionales de desfragmentación, evaluando objetivos multiobjetivo mediante métricas de bloqueos, reconfiguraciones, soluciones en el Frente de Pareto y Cobertura de Pareto.

Por último, el capítulo seis presenta las conclusiones del trabajo, validando el cumplimiento de objetivos, destacando las contribuciones principales, identificando limitaciones, y proponiendo direcciones para trabajos futuros en extensiones metodológicas, arquitecturales y validación experimental en entornos reales.

Capítulo 2

Fragmentación en Redes EON Multinúcleo

Las redes ópticas que se basan en WDM dividen el espectro de cada enlace en canales cuyo ancho de banda se fija de 50 GHz o 100 GHz. Esto debido a que la Unión Internacional de Telecomunicaciones (*ITU-T International Telecommunication Union*) especificó el estándar G.694.1 en el año 2002 [3].

Estas redes WDM resultan muy rígidas, y debido a eso es posible que ocurra una utilización ineficiente de la capacidad, provocado por el hecho de que el espacio entre dos canales adyacentes es relativamente grande y si la señal que se transmite utiliza un ancho de banda muy bajo, gran parte del espectro será desperdiciado.

Una nueva tecnología denominada Redes Ópticas Elásticas o *Elastic Optical Networks* (EON) [2] y su evolución: Las Redes ópticas Elásticas Multinúcleo o *Multicore Elastic Optical Networks* (MC-EON) el cual no solo dividen el espectro óptico en Ranuras de Frecuencia o *Frequency Slots* (FS) de 12.5 GHz conforme a lo establecido por el estándar definido en ITU-T (G.694.1) en el año 2012 [3], sino que las (MC-EON) introducen un nuevo dominio de multiplexación espacial, al permitir la transmisión simultánea de múltiples señales ópticas en diferentes núcleos dentro de una misma fibra.

Esta aproximación multidimensional proporciona una mayor escalabilidad, eficiencia en la asignación del espectro y reducción del consumo energético, posicio-

nando a las MC-EON como una de las tecnologías más prometedoras para la implementación de redes ópticas de ultra alta capacidad en escenarios de próxima generación.

2.1. Redes EON Multinúcleo

Las redes EON Multinúcleo constituyen una variante avanzada de las redes EON que integran el concepto de fibras multinúcleo (MCF) [4] para incrementar significativamente la capacidad de transmisión y la eficiencia espectral. Fundamentalmente, las redes EON Multinúcleo aprovechan múltiples núcleos independientes dentro de una misma fibra óptica para transmitir señales de forma simultánea y paralela, posibilitando una multiplicación de la capacidad de transmisión en comparación con las fibras convencionales.

Estas características mencionadas en las EON Multinúcleo se materializan mediante la implementación de la Multiplexación por División de Espacio (SDM). Por esta razón, las redes EON Multinúcleo también se denominan SDM-EON. En las redes EON Multinúcleo, se integra el concepto de asignación flexible de espectro con la utilización de múltiples núcleos, alcanzando una distribución más eficiente de la capacidad total de transmisión. Esta integración de tecnologías posibilita un incremento sustancial en la capacidad de transmisión a través de una única fibra, resultando esencial en un contexto donde la demanda de datos continúa creciendo de manera exponencial [1].

Al incorporar el concepto de fibras multinúcleo en el diseño de las redes EON, se puede lograr una mayor adaptabilidad a las cambiantes necesidades del tráfico y una optimización más profunda de los recursos disponibles.

Inicialmente podría considerarse que la utilización de redes EON con mayor cantidad de núcleos proporciona ventajas sustanciales debido a la amplia disponibilidad de recursos espectrales y espaciales. No obstante, se ha identificado que en las redes

MCF, el principal desafío radica en la interferencia denominada diafonía (crosstalk) [5], la cual se genera cuando una fracción de la potencia óptica de un núcleo se propaga hacia los núcleos contiguos.

Este fenómeno ocasiona una interferencia significativa en los circuitos activos y complejiza considerablemente la asignación de las ranuras espectrales (FS). Investigaciones previas [5, 4] han indicado que para viabilizar la implementación de redes EON multinúcleo, resulta fundamental desarrollar fibras que minimicen la diafonía entre núcleos adyacentes.




Figura 2.1: Ejemplo de Fibra Multinúcleo (MCF) con 7 núcleos

En la Figura 2.1, se presenta una configuración de MCF con 7 núcleos dispuestos en un patrón hexagonal. En esta arquitectura, el núcleo central (núcleo N° 6) se encuentra rodeado por 6 núcleos adyacentes, resultando en una mayor incidencia de diafonía sobre este núcleo. En contraste, los núcleos periféricos (núcleos N° 0, 1, 2, 3, 4 y 5) poseen 3 núcleos adyacentes cada uno.

2.2. Diafonía en Redes Ópticas Elásticas Multinúcleo

La diafonía constituye un fenómeno indeseado que se manifiesta en las redes de fibra óptica cuando la señal transmitida en una fibra se acopla hacia otra fibra contigua. En el contexto de las redes EON fundamentadas en MCF, la diafonía se define como la interferencia entre conexiones ópticas establecidas en núcleos adyacentes que emplean las mismas ranuras espectrales (FS) en un enlace común [5].

Este tipo de interferencia se denomina diafonía entre núcleos o Inter-Core Cross-talk (XT). La interferencia ocasionada por el XT puede degradar la calidad de la señal en las FS afectadas, lo que implica que la señal en estas ranuras puede experimentar distorsiones, incrementando la probabilidad de errores en la transmisión de datos.

Consecuentemente, impacta directamente en la capacidad de la red al «inhabilitar» estas FS para la transferencia de datos debido a la diafonía, generando espacios no utilizables entre ellas.

En síntesis, esto deriva en una reducción de la cantidad total de FS disponibles para la transmisión de datos, limitando la capacidad operativa de la red. Con menor disponibilidad de FS, se reducen los canales para transmitir datos, lo que puede restringir la capacidad total de transmisión de la infraestructura de red.

En las redes SDM-EON, el XT entre dos núcleos de una MCF depende significativamente de la distancia entre dicho par de núcleos, denominada core pitch ($\Lambda_{i,j}$). A mayor core pitch, menor será el impacto del XT entre estos dos núcleos 2.1.

No obstante, resulta importante destacar que, a medida que se incrementa el core pitch, la capacidad de la fibra óptica disminuye. Es decir, al aumentar la distancia física entre dos núcleos, se reduce el espacio disponible en la fibra óptica para albergar núcleos adicionales.

Por consiguiente, resulta fundamental establecer un equilibrio entre un core pitch reducido para incrementar la capacidad y uno suficientemente amplio para minimizar los efectos del XT. Este balance posibilita optimizar el desempeño y la eficiencia de la red.

2.2.1. Cálculo de la diafonía

El procedimiento para determinar el nivel de XT que incide sobre una conexión establecida en el núcleo i de una MCF, considerando una configuración arbitraria de núcleos y cualquier disposición geométrica, se desarrolla mediante los siguientes pasos:

En primera instancia, se determina el valor de la XT por unidad de longitud entre el núcleo i y un núcleo adyacente j , denotado como $h_{i,j}$, empleando la expresión:

$$h_{i,j} = \frac{2k^2r}{\beta\Lambda_{i,j}} \quad (2.1)$$

Donde k representa el coeficiente de acoplamiento; r corresponde al radio de curvatura; β denota la constante de propagación; y $\Lambda_{i,j}$ indica la distancia entre los núcleos i y j respectivamente (core pitch).

Posteriormente, se calcula el valor total de la XT que impacta al núcleo i , designado como XT_i , mediante la agregación de las contribuciones de XT provenientes de todos sus núcleos adyacentes. Esta operación se efectúa utilizando la siguiente expresión:

$$XT_i = \sum_{j=1}^{N_i} h_{i,j} \cdot L \quad (2.2)$$

Donde N_i representa la cantidad de núcleos adyacentes al núcleo i , y L corresponde a la longitud física del enlace óptico.

Con el propósito de garantizar la integridad de la señal transmitida, resulta imperativo que el valor calculado de XT_i no exceda un umbral máximo admisible de

diafonía al momento de establecer de forma óptima la trayectoria óptica para una solicitud de conexión entrante. El umbral de diafonía o *Crosstalk Threshold* (XT_{TH}) se conceptualiza como el límite superior de XT que una señal propagada a través del sistema puede tolerar sin experimentar una degradación considerable en su calidad o sin provocar la generación de errores en la transmisión de datos.

2.2.2. Asignación de espectro con conmutación de núcleo

En las arquitecturas SDM-EON, es posible optimizar la eficiencia espectral mediante la implementación de conmutación de núcleos [6], mecanismo que permite identificar y asignar recursos espectrales en uno o múltiples núcleos a lo largo de una conexión establecida en fibras MCF.

Este procedimiento implica la selección del mismo bloque de FS como recursos reservados para cada solicitud de conexión, distribuyéndose entre diferentes núcleos a lo largo de la trayectoria de trabajo.

Para materializar la conmutación de núcleos, resulta fundamental respetar la restricción de contigüidad espectral, lo cual significa que la señal puede ser transferida de un núcleo a otro sin limitaciones, en tanto se preserve la continuidad del mismo intervalo espectral asignado.




Figura 2.2: Conmutación de núcleos con contigüidad de espectro

En la Figura 2.2 se ilustra una fibra óptica multicore de tres núcleos (1, 2 y 3),

en la que el bloque de FS (BloqueFS1) conmuta del core 1 en el Enlace 1 al core 2 en el Enlace 2, manteniendo la continuidad del espectro asignado. Asimismo, el bloque de FS (BloqueFS2) también conmuta, pasando del core 2 en el Enlace 1 al core 3 en el Enlace 2. Por último, el bloque de FS (BloqueFS3) conmuta del core 3 al core 1 entre los enlaces. Este enfoque de conmutación de núcleos permite un uso más eficiente del espectro en redes de fibra óptica multicore, reduciendo notablemente la probabilidad de bloqueo en comparación con los RSA que no implementan conmutación de núcleos.

La Figura 2.3 ilustra la asignación de núcleos y espectro mediante la implementación de conmutación para la demanda $d(2, 4, 4)$. El mecanismo de conmutación de núcleos posibilita la identificación de bloques de FS que satisfacen la restricción de contigüidad espectral distribuidos en núcleos distintos a través de múltiples enlaces de la trayectoria establecida.

A modo de ejemplo, para la demanda $d(2, 4, 4)$ se identifican tres bloques candidatos de FS que cumplen con dicha restricción: $\{SC_{2,l_0}^0, SC_{2,l_1}^0\}$, $\{SC_{1,l_0}^3, SC_{3,l_1}^3\}$ y $\{SC_{3,l_0}^6, SC_{1,l_1}^6\}$. Estos bloques se encuentran disponibles a lo largo de la ruta conformada por los enlaces l_0 (2-5) y l_1 (5-4).

Conforme se observó en el caso precedente, si el bloque candidato de FS representado por $\{SC_{2,l_0}^0, SC_{2,l_1}^0\}$ experimenta una interferencia significativa por XT que excede el umbral XT_{TH} , resultaría inviable establecer la demanda en dichos recursos espectrales. No obstante, mediante la implementación de conmutación de núcleos, los dos bloques candidatos restantes, $\{SC_{1,l_0}^3, SC_{3,l_1}^3\}$ y $\{SC_{3,l_0}^6, SC_{1,l_1}^6\}$, se encuentran distribuidos en núcleos diferentes a través de los enlaces de fibra. Consecuentemente, el nivel de XT que incide sobre estos bloques de FS podría permanecer por debajo del umbral XT_{TH} , facilitando su asignación exitosa.

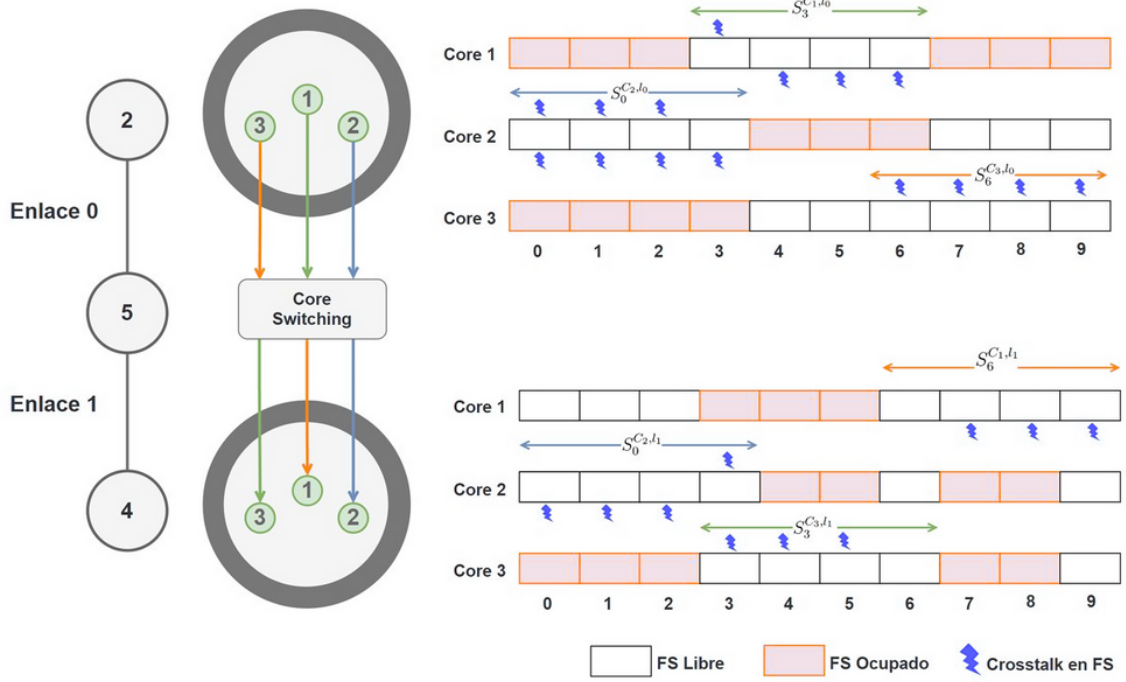


Figura 2.3: Asignación de espectro con conmutación de núcleos

En términos comparativos, la implementación del mecanismo de conmutación de núcleos a lo largo de los enlaces de fibra en una ruta de trabajo permite reducir sustancialmente la probabilidad de bloqueo de solicitudes en comparación con escenarios donde no se aplica conmutación de núcleos [6], incrementando así la eficiencia en la utilización de los recursos espectrales y espaciales disponibles en la infraestructura de red.

2.3. Fragmentación del Ancho de Banda en MC-EON

Las redes ópticas elásticas multinúcleo (MC-EON) permiten optimizar el uso del ancho de banda necesario para satisfacer una demanda, respetando tres restricciones fundamentales [23]:

- **Restricción de continuidad:** esta restricción implica que un cambio de luz

o lightpath debe utilizar los mismos *Frequency Slots* (FS) a lo largo del camino establecido entre los nodos de origen y destino, tanto en la dimensión espectral como en la dimensión espacial (núcleo).

- **Restricción de consecutividad:** esta restricción establece que todos los FS utilizados para establecer un lightpath deben ser contiguos en el dominio espectral, formando un solo bloque contiguo de FS dentro del mismo núcleo.

Estas restricciones conducen a que, tras sucesivas asignaciones y liberaciones de recursos, se genere la aparición de bloques aislados de FS no utilizados tanto en la dimensión espectral como en la dimensión espacial (núcleos) de los enlaces ópticos [8]. Dichos bloques fragmentados presentan desalineación tanto entre enlaces consecutivos de la ruta como entre los diferentes núcleos de una misma fibra multinúcleo. Como consecuencia, se incrementa significativamente la probabilidad de bloqueo de solicitudes [8], pudiendo la red rechazar demandas incluso cuando existe ancho de banda disponible suficiente en los enlaces. Este fenómeno se denomina **Fragmentación de la red** y en arquitecturas multinúcleo se manifiesta en dos dimensiones complementarias [7, 9]:

- **Fragmentación espectral:** se refiere a la presencia de bloques aislados de FS no utilizados en el dominio espectral, que no pueden ser aprovechados para establecer nuevas conexiones debido a las restricciones de continuidad y consecutividad.
- **Fragmentación espacial:** se refiere a la desalineación de bloques de FS disponibles entre los diferentes núcleos de una misma fibra multinúcleo, lo que dificulta la asignación eficiente de recursos en la dimensión espacial.

Ejemplo ilustrativo del fenómeno:

- 1 - Se presenta el estado inicial del enlace mostrando las asignaciones activas de lightpaths distribuidos en los múltiples núcleos de la fibra.

- 2 - Se produce la liberación de recursos al finalizar el tiempo de vida de determinadas conexiones, generando segmentos espectrales disponibles dispersos en diferentes núcleos y posiciones del espectro.
- 3 - Se evidencia el rechazo de una nueva solicitud de conexión debido a que, pese a existir una cantidad agregada suficiente de FS libres en la red, estos no satisfacen simultáneamente las restricciones de contigüidad espectral dentro de un único núcleo y continuidad espacial a lo largo de la ruta. La conexión resulta bloqueada en todos los núcleos disponibles como resultado de la fragmentación tanto espectral como espacial inherente al sistema multinúcleo.

Para ilustrar estas restricciones, se presenta un ejemplo en las Figuras 2.4 y 2.5, donde se simula la conexión de una demanda de dos FS, con un nodo origen en 0 y un nodo destino en 3. En este escenario, existen dos posibles caminos: 0-1-3 y 0-1-2-3.

La trayectoria de menor longitud corresponde a la ruta 0-1-3. No obstante, al procurar el establecimiento del lightpath mediante esta alternativa, la solicitud de conexión resulta denegada, dado que los enlaces 0-1 y 1-3 carecen de dos FS consecutivos y alineados espectralmente, tal como se evidencia en la Figura 2.4.




Figura 2.4: Restricciones de contigüidad y continuidad aplicadas- Conexión Rechazada




Figura 2.5: Restricciones de contigüidad y continuidad aplicadas- Conexión Establecida

En contraste, al considerar la asignación del lightpath a través de la trayectoria de mayor extensión, específicamente 0-1-2-3, empleando los FS 4 y 5, la conexión se establece satisfactoriamente, puesto que esta configuración dispone de dos FS contiguos y alineados espectralmente, según se observa en la Figura 2.5.

2.3.1. Enfoques de gestión de fragmentación

La problemática descrita previamente genera consecuencias perjudiciales para la infraestructura de red, ocasionando un incremento en la probabilidad de bloqueo y comprometiendo significativamente su desempeño óptimo y continuidad operacional. En consecuencia, resulta fundamental identificar estrategias que permitan prevenir, mitigar o reducir la fragmentación del espectro disponible.

De acuerdo con la bibliografía especializada, existen diversas aproximaciones que pueden ser consideradas para abordar la gestión de la desfragmentación. En la figura 2.6 se presentan las principales estrategias de gestión de la fragmentación [11].

La Desfragmentación constituye un procedimiento mediante el cual se ejecuta la reconfiguración o el re-ruteo de un subconjunto de conexiones existentes en la infraestructura de red [12]. Su propósito fundamental consiste en reacomodar las asigna-

ciones espectrales de las solicitudes de tráfico vigentes, consolidando de este modo los recursos disponibles en segmentos contiguos y continuos de mayor magnitud, los cuales pueden ser aprovechados para el establecimiento de futuras demandas.

Es factible abordar la problemática de la fragmentación prescindiendo de técnicas de desfragmentación espectral (Sin Desfragmentación), lo cual se alcanza mediante una administración del espectro orientada a la prevención de su fragmentación.

En el tratamiento de la fragmentación bajo un esquema Sin Desfragmentación, se pueden mencionar los algoritmos denominados Sensibles a la Fragmentación o *Fragmentation Aware RSA* (FA-RSA). Estos consideran la fragmentación espectral durante el establecimiento de las demandas, empleando diversos indicadores de fragmentación [24], procurando así minimizar la fragmentación del espectro.

Alternativamente, es posible emplear técnicas de desfragmentación, las cuales se fundamentan en dos aproximaciones principales [11]:

- Desfragmentación Reactiva: El procedimiento se ejecuta como respuesta al bloqueo de una solicitud, con la finalidad de lograr su establecimiento exitoso.
- Desfragmentación Proactiva: Se lleva a cabo de manera periódica [14] o en función de determinados umbrales que activan el proceso, permitiendo así reducir la fragmentación de la infraestructura de red y minimizar la ocurrencia de futuros bloqueos de solicitudes.

Las aproximaciones que implementan técnicas de desfragmentación pueden clasificarse además en: (i) estrategias sin re-ruteo, las cuales realizan únicamente una reasignación espectral en los *lightpaths* o caminos ópticos establecidos, y (ii) estrategias con re-ruteo, que constituyen técnicas capaces de modificar tanto las rutas como el espectro asignado a los *lightpaths* existentes [25].

En el presente trabajo, para la gestión de la fragmentación se adoptó la aproximación con desfragmentación, de naturaleza proactiva y con re-ruteo de *lightpaths* preexistentes. En la figura 2.6 se puede observar resaltada dicha estrategia.

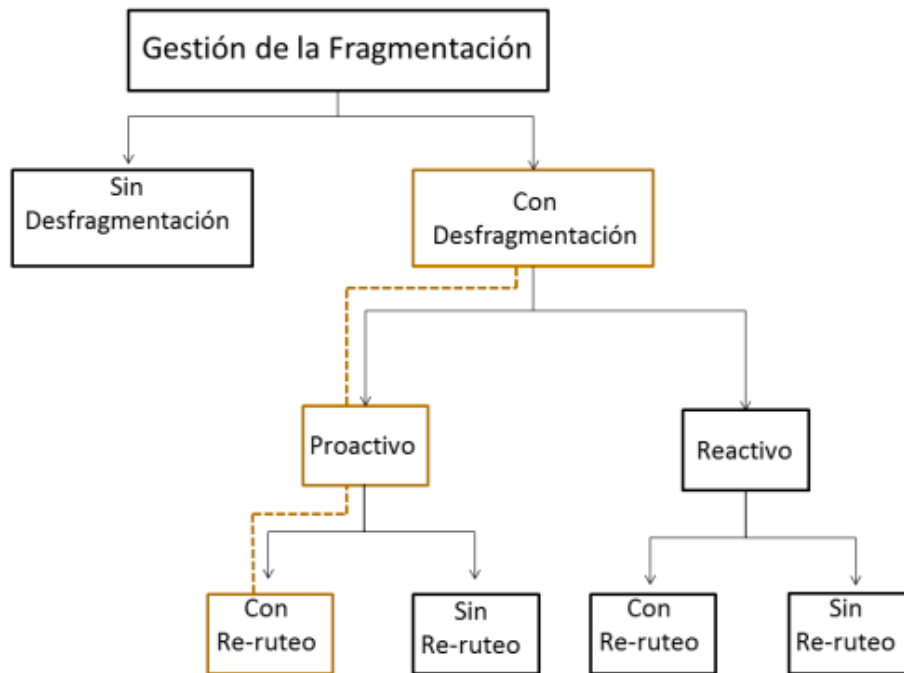


Figura 2.6: Esquema de Gestión de la Fragmentación

2.4. Descripción del problema tratado

La Fragmentación del Espectro en Redes Ópticas Elásticas Multinúcleo (Multi-Core EON) constituye una problemática que compromete la eficiencia en la utilización de recursos espectrales y espaciales. El desempeño de la infraestructura de red resulta severamente afectado, dado que este fenómeno puede ocasionar bloqueos de solicitudes debido a la ausencia de ranuras espectrales contiguas y alineadas entre enlaces consecutivos, así como por la indisponibilidad de núcleos adecuados, sin que necesariamente el espectro en todos los núcleos se encuentre completamente ocupado. En secciones previas se expusieron estrategias para el manejo de la fragmentación en la red; en el presente trabajo se examina la estrategia con desfragmentación, adoptando un enfoque proactivo.

Un método ampliamente implementado consiste en ejecutar el procedimiento de desfragmentación de manera periódica [14] con el propósito de prevenir bloqueos

futuros, abordando así una de las cuatro interrogantes planteadas por Zhang [13], ¿Cuándo reconfigurar?.

En la figura 2.7 se puede observar una posible solución a la problemática de la selección del momento óptimo para realizar la desfragmentación, la cual consiste en ejecutar desfragmentaciones periódicas en intervalos temporales fijos. En este caso, cada 100 unidades de tiempo, el eje vertical representa el volumen de tráfico cuantificado mediante el número de conexiones activas, mientras que el eje horizontal indica las unidades temporales; cada punto azul denota el instante en que el proceso de desfragmentación se ejecuta. Siguiendo este patrón, se evidencian situaciones donde se realizan procesos de desfragmentación cuando la red podría no requerirlos, considerando que la utilización de los recursos espectrales y de los núcleos constituye un indicador significativo del grado de fragmentación.

Además de la utilización de la red, existen otras métricas de fragmentación relevantes en redes multinúcleo [24, 10], cuyos valores deben considerarse para el disparo de los procesos de desfragmentación, incluyendo la fragmentación por núcleo y la disponibilidad de recursos en la dimensión espacial.

De este modo, se evidencia la necesidad de un disparador inteligente para ejecutar el proceso de desfragmentación que considere todos estos parámetros o “características” para seleccionar apropiadamente el momento del disparo, dado que realizar múltiples desfragmentaciones de manera frecuente afecta directamente al desempeño de la red, pudiendo ocasionar disrupciones en las conexiones activas; mientras que ejecutar pocas desfragmentaciones muy dispersas resultaría en efectos prácticamente imperceptibles.

En síntesis, la selección del momento para ejecutar el proceso de desfragmentación resulta crítica debido a su impacto significativo en la cantidad de procesos de desfragmentación, lo cual incide directamente en las dos métricas globales más relevantes en el enrutamiento de redes ópticas elásticas multinúcleo: Cantidad de bloqueos y Cantidad de reconfiguraciones.

En los capítulos subsiguientes se presenta y aborda en profundidad un modelo de disparo inteligente que contempla numerosos factores tales como métricas de fragmentación de la red, utilización de recursos espectrales y espaciales, y bloqueos de solicitudes.




Figura 2.7: Ejemplo de desfragmentaciones periódicas con volumen de carga de tráfico variado

Capítulo 3

Aprendizaje Automático

El Aprendizaje Automático, conocido en inglés como *Machine Learning*, representa una de las áreas más dinámicas y prometedoras dentro del campo de la inteligencia artificial contemporánea. Se fundamenta en el desarrollo de algoritmos y modelos computacionales capaces de identificar patrones complejos en conjuntos de datos, con el propósito de generar predicciones o tomar decisiones informadas sin necesidad de instrucciones programáticas explícitas para cada escenario específico [15].

La esencia del aprendizaje automático radica en su capacidad para mejorar el desempeño de manera iterativa mediante la experiencia acumulada. Mitchell [15] proporciona una definición operacional particularmente esclarecedora: un sistema computacional manifiesta capacidad de aprendizaje cuando su rendimiento en una tarea determinada T , cuantificado mediante una métrica de desempeño P , experimenta una mejora mensurable como consecuencia de la exposición a una experiencia E . Esta conceptualización establece tres componentes fundamentales que articulan cualquier sistema de aprendizaje automático: la tarea objetivo, la experiencia de aprendizaje y el criterio de evaluación.

Para ilustrar estos conceptos de manera concreta, se puede examinar el caso de los sistemas de filtrado de correo electrónico no deseado. Un filtro de spam ejemplifica de forma paradigmática los principios del aprendizaje automático. El sistema

desarrolla progresivamente la capacidad de discriminar entre mensajes legítimos y correo no solicitado mediante el análisis de ejemplos previamente etiquetados por usuarios. Estos conjuntos de datos, denominados conjuntos de entrenamiento, contienen tanto instancias positivas (correos identificados como spam) como negativas (mensajes legítimos), permitiendo al algoritmo extraer características distintivas de cada categoría.

En este contexto específico, la tarea T consiste en la clasificación binaria de nuevos mensajes electrónicos, la experiencia E está constituida por el proceso de entrenamiento con los datos etiquetados, y la métrica de desempeño P puede definirse como la tasa de precisión o *Accuracy*, que cuantifica la proporción de mensajes correctamente clasificados en relación con el total de predicciones realizadas.

3.1. Clasificación de sistemas o tipos de aprendizaje automático

La diversidad de aplicaciones y contextos en los que se implementan sistemas de aprendizaje automático ha propiciado el desarrollo de múltiples paradigmas metodológicos. La clasificación más fundamental de estos enfoques se establece en función del tipo y grado de supervisión disponible durante la fase de entrenamiento [15]. A continuación, se muestran las tres categorías principales:

- **Aprendizaje supervisado:** Este paradigma constituye el enfoque más ampliamente implementado en aplicaciones prácticas. Se caracteriza por la disponibilidad de un conjunto de entrenamiento que incluye pares de entrada-salida, donde cada instancia de entrada está asociada con su correspondiente etiqueta o *label*, que representa la solución correcta. El objetivo del algoritmo consiste en inferir una función de mapeo que establezca la correspondencia óptima entre el espacio de características de entrada y el conjunto de salidas desea-

das, de manera que pueda generalizar efectivamente a instancias no observadas previamente.

El aprendizaje supervisado se subdivide en dos categorías fundamentales según la naturaleza de la variable objetivo:

- *Clasificación:* Se trata de brindar ejemplos de entrenamiento donde cada instancia está asociada con una o múltiples clases predefinidas, a modo de que se pueda realizar el entrenamiento y clasificar nuevas entradas dentro de alguna de las clases existentes. Aplicaciones típicas incluyen el reconocimiento de imágenes, detección de fraudes y análisis de sentimientos.
 - *Predicción:* A diferencia de la clasificación, éste consiste en la predicción de una variable objetivo de naturaleza continua o numérica. El sistema recibe datos de entrenamiento compuestos por vectores de características junto con sus valores objetivos correspondientes, permitiendo al modelo aprender la relación funcional entre sí. Esta capacidad predictiva se aplica posteriormente para estimar valores numéricos de nuevas instancias basándose exclusivamente en sus características de entrada. Aplicaciones típicas comprenden la predicción de precios, estimación de demanda y proyecciones temporales.
- **Aprendizaje no supervisado:** Este paradigma aborda escenarios donde los datos de entrenamiento carecen de soluciones deseadas. La ausencia de supervisión directa plantea un desafío metodológico fundamentalmente diferente: el algoritmo debe descubrir estructuras intrínsecas, patrones latentes o relaciones subyacentes en los datos sin guía externa. Las técnicas de aprendizaje no supervisado resultan particularmente valiosas para tareas exploratorias, tales como la segmentación de clientes, detección de anomalías, reducción de dimensionalidad y descubrimiento de asociaciones en grandes volúmenes de datos.

Este enfoque refleja una aproximación más cercana a cómo los sistemas biológicos pueden aprender mediante la observación y organización autónoma de información sensorial.

- **Aprendizaje por refuerzo:** Este paradigma se distingue por su naturaleza secuencial e interactiva. En lugar de aprender a partir de un conjunto estático de ejemplos, el aprendizaje por refuerzo se fundamenta en la interacción continua de un agente con un entorno dinámico [26]. El proceso de aprendizaje se articula mediante señales de retroalimentación en forma de recompensas (positivas o negativas) que el agente recibe como consecuencia de sus acciones. El objetivo fundamental consiste en desarrollar una política de comportamiento que maximice la recompensa acumulada a largo plazo. Este bucle de retroalimentación continua entre acción, observación y recompensa permite al sistema refinar progresivamente su estrategia mediante exploración y explotación del espacio de estados. Las aplicaciones emblemáticas incluyen sistemas de control robótico, estrategias de juegos, optimización de recursos y vehículos autónomos.

Cada uno de estos paradigmas presenta ventajas distintivas y limitaciones inherentes, determinando su idoneidad para contextos específicos. La selección del enfoque apropiado constituye una decisión metodológica crucial que debe considerar tanto la naturaleza del problema como las características de los datos disponibles.

3.2. Gradient Boosting

El Gradient Boosting [16] representa uno de los algoritmos de aprendizaje automático supervisado más potentes y efectivos en la actualidad, especialmente para problemas de clasificación y regresión con datos tabulares. Este método se fundamenta en el paradigma de aprendizaje por ensamble, donde múltiples modelos pre-

dictivos débiles se combinan secuencialmente para construir un predictor robusto de alto rendimiento mediante principios de optimización matemática y aprendizaje iterativo.

3.2.1. Fundamentos del Aprendizaje por Ensamble

El aprendizaje por ensamble o *Ensemble Learning* constituye una estrategia metodológica que combina las predicciones de múltiples modelos base para obtener un resultado final superior al que produciría cualquier modelo individual. Este enfoque se fundamenta en dos principios estadísticos complementarios:

- **Reducción de varianza:** Mediante la agregación de predicciones de modelos diversos, se reduce la sensibilidad del sistema a fluctuaciones en los datos de entrenamiento, incrementando la estabilidad de las predicciones.
- **Reducción de sesgo:** La combinación secuencial de modelos permite corregir sistemáticamente errores persistentes, mejorando la capacidad del sistema para capturar relaciones complejas en los datos.

Existen dos estrategias principales en el aprendizaje por ensamble. El *Bagging* o agregación bootstrap entrena múltiples modelos de manera independiente y paralela sobre diferentes subconjuntos de datos, combinando posteriormente sus predicciones mediante votación o promediación. El *Boosting*, por otro lado, entrena modelos de forma secuencial, donde cada nuevo modelo se enfoca en corregir los errores de sus predecesores. El Gradient Boosting [16] pertenece a esta segunda categoría, distinguiéndose por su fundamentación matemática rigurosa basada en el descenso del gradiente en el espacio funcional.

3.2.2. Algoritmo de Gradient Boosting

Dado un conjunto de entrenamiento $\{(x_i, y_i)\}_{i=1}^n$ donde x_i representa el vector de características y y_i la variable objetivo, el Gradient Boosting [16] construye un modelo aditivo mediante la incorporación secuencial de árboles de decisión de profundidad limitada:

$$F_M(x) = \sum_{m=0}^M \gamma_m h_m(x) \quad (3.1)$$

donde $h_m(x)$ representa el m -ésimo aprendiz débil, γ_m es el coeficiente de peso asociado, y M denota el número total de iteraciones.

El procedimiento algorítmico consiste en:

1. **Inicialización:** Se establece un modelo inicial $F_0(x)$, comúnmente una constante que minimiza la función de pérdida sobre el conjunto de entrenamiento completo.
2. **Iteración secuencial:** Para cada iteración $m = 1, 2, \dots, M$:

- Se calculan los pseudo-residuos, representando el gradiente negativo de la función de pérdida respecto a las predicciones actuales:

$$r_{im} = - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F(x)=F_{m-1}(x)} \quad (3.2)$$

- Se entrena un nuevo aprendiz débil $h_m(x)$ para predecir estos residuos.
- Se determina el coeficiente óptimo γ_m que minimiza la pérdida:

$$\gamma_m = \arg \min_{\gamma} \sum_{i=1}^n L(y_i, F_{m-1}(x_i) + \gamma h_m(x_i)) \quad (3.3)$$

- Se actualiza el modelo mediante:

$$F_m(x) = F_{m-1}(x) + \nu \cdot \gamma_m h_m(x) \quad (3.4)$$

donde ν representa la tasa de aprendizaje, un hiperparámetro que controla la contribución de cada árbol al modelo final.

Este proceso continúa hasta alcanzar el número especificado de árboles M o hasta satisfacer un criterio de convergencia establecido.

3.2.3. Gradient Boosting Classifier

Para problemas de clasificación binaria, el *Gradient Boosting Classifier* [16] emplea típicamente la función de pérdida logística:

$$L(y, F(x)) = \log(1 + e^{-2yF(x)}) \quad (3.5)$$

donde $y \in \{-1, 1\}$ representa la clase verdadera y $F(x)$ la predicción del modelo. La probabilidad de pertenencia a la clase positiva se obtiene mediante la transformación logística:

$$P(y = 1|x) = \frac{1}{1 + e^{-2F(x)}} \quad (3.6)$$

Para problemas multiclase, se extiende el enfoque mediante la estrategia *one-versus-all*, entrenando un modelo separado por cada clase y combinando las predicciones mediante normalización softmax para obtener distribuciones de probabilidad válidas.

3.2.4. Configuración e Hiperparámetros

El rendimiento del *Gradient Boosting Classifier* depende críticamente de la configuración apropiada de sus hiperparámetros, los cuales regulan la complejidad del modelo y previenen el sobreajuste:

- **Número de estimadores (n_estimators):** Define la cantidad de árboles en el ensamble. Valores elevados incrementan la capacidad expresiva pero aumentan el riesgo de sobreajuste y el costo computacional. Típicamente se emplean valores entre 100 y 1000.

- **Tasa de aprendizaje (`learning_rate`):** Controla la contribución de cada árbol al modelo final. Valores pequeños (0.01-0.1) requieren más árboles pero generalmente producen mejor generalización. Existe una relación de compromiso entre este parámetro y el número de estimadores.
- **Profundidad máxima (`max_depth`):** Limita la profundidad de cada árbol individual. Árboles superficiales (3-5 niveles) actúan como aprendices débiles efectivos, mientras que árboles profundos incrementan la complejidad y el riesgo de sobreajuste.
- **Mínimo de muestras por división (`min_samples_split`):** Especifica el número mínimo de muestras requeridas para dividir un nodo interno. Valores mayores previenen la creación de divisiones excesivamente específicas.
- **Mínimo de muestras por hoja (`min_samples_leaf`):** Define el número mínimo de muestras en los nodos terminales. Este parámetro suaviza el modelo en regiones de baja densidad de datos.
- **Submuestreo (`subsample`):** Fracción de muestras utilizada para entrenar cada árbol. Valores menores a 1.0 introducen aleatorización estocástica, mejorando la diversidad del ensamble y reduciendo el sobreajuste.

La selección óptima de estos hiperparámetros requiere típicamente validación cruzada y búsqueda sistemática en el espacio de configuraciones mediante técnicas como *Grid Search* o *Random Search*.

Ventajas del algoritmo:

- Capacidad para modelar relaciones no lineales complejas sin requerir transformaciones explícitas de características
- Robustez ante variables de diferentes escalas, eliminando la necesidad de normalización

- Manejo natural de variables mixtas (numéricas y categóricas)
- Resistencia a *outliers* mediante funciones de pérdida apropiadas
- Interpretabilidad mediante análisis de importancia de características
- Rendimiento competitivo en conjuntos de datos tabulares estructurados

Limitaciones:

- Susceptibilidad al sobreajuste con configuraciones inadecuadas de hiperparámetros
- Entrenamiento secuencial que limita la paralelización eficiente
- Mayor costo computacional comparado con algoritmos más simples
- Sensibilidad al desbalance de clases, requiriendo estrategias de ponderación
- Rendimiento subóptimo en datos de muy alta dimensionalidad comparado con métodos especializados

3.2.5. Aplicación en MC-EON

La naturaleza tabular de los datos operacionales en MC-EON, implementada mediante la librería Scikit-learn [22], hace particularmente adecuado el uso de Gradient Boosting, cuyo rendimiento en este tipo de datos frecuentemente supera a aproximaciones basadas en redes neuronales profundas. Adicionalmente, su capacidad para proporcionar estimaciones de importancia de características facilita la comprensión de los factores más relevantes en las decisiones de gestión, aspecto crítico para la validación de sistemas autónomos en entornos de producción [27].

Capítulo 4

Método Propuesto

Este trabajo propone un sistema de desfragmentación proactiva para redes MC-EON mediante el uso de técnicas de *Machine Learning* [15]. El sistema predice el índice de fragmentación futuro (BFR_F) que experimentará la red y, en función de estos valores predichos, determina automáticamente cuándo y con qué frecuencia ejecutar procesos de desfragmentación.

4.1. Estrategia de Desfragmentación Adaptativa

El sistema implementa una estrategia de tres niveles basada en dos umbrales de fragmentación [13]:

- **Umbral mínimo ($\text{BFR}_F = \text{BFR}_{F_{\text{MIN}}}$):** Indica el inicio de fragmentación apreciable
- **Umbral crítico ($\text{BFR}_F = \text{BFR}_{F_{\text{MAX}}}$):** Señala estados de alta fragmentación que incrementan significativamente la probabilidad de bloqueo

La lógica de actuación se define como:

1. **Sin desfragmentación:** Si la predicción del primer modelo indica que el BFR_F no superará el umbral mínimo ($\text{BFR}_F < 0,20$)

En este escenario, el sistema determina que la red mantendrá un estado saludable con fragmentación insignificante durante el horizonte predicho. Dado que por debajo de este umbral los bloqueos son mínimos o nulos, no se justifica el costo operacional de ejecutar una desfragmentación. El sistema suprime cualquier intervención de reordenamiento y programa la siguiente consulta al modelo predictivo para 1,500 unidades de tiempo después. Esta decisión maximiza la eficiencia operacional al evitar reconfiguraciones innecesarias cuando los recursos espectrales se encuentran adecuadamente distribuidos.

2. **Desfragmentación de baja frecuencia:** Si el primer modelo predice que se superará el umbral mínimo ($\text{BFR}_F \geq 0,20$), pero el segundo modelo indica que no se alcanzará el umbral crítico ($0,20 \leq \text{BFR}_F < 0,46$)

Esta condición indica que la red entrará en un rango donde comenzarán a aparecer bloqueos debido a fragmentación moderada, aunque sin alcanzar niveles críticos. La estrategia preventiva consiste en ejecutar inmediatamente un proceso de desfragmentación para reorganizar el espectro y minimizar los bloqueos emergentes antes de que la situación se agrave. Tras esta intervención, el sistema establece un intervalo de monitoreo de 1,500 unidades de tiempo antes de realizar la siguiente consulta predictiva. Este intervalo relativamente largo es apropiado porque en este rango de fragmentación la red aún dispone de recursos razonables y la degradación evoluciona de manera gradual, permitiendo espaciar las intervenciones sin comprometer significativamente el desempeño.

3. **Desfragmentación de alta frecuencia:** Si ambos modelos coinciden en que el BFR_F predicho superará el umbral crítico ($\text{BFR}_F \geq 0,46$)

En este caso crítico, el sistema anticipa que la red alcanzará niveles de fragmentación donde la cantidad de bloqueos se incrementa considerablemente. La escasez severa de bloques espectrales contiguos compromete significativamente la capacidad de la red para aceptar nuevas conexiones. La respuesta consiste

en ejecutar inmediatamente una desfragmentación reactiva para mitigar el impacto de esta fragmentación crítica anticipada. Sin embargo, dada la severidad de la situación y la velocidad con que evoluciona la fragmentación en estados de alta congestión, el sistema reduce el intervalo de monitoreo a 800 unidades de tiempo. Este intervalo más corto permite al sistema mantenerse vigilante y responder ágilmente mediante intervenciones frecuentes, asegurando que la fragmentación crítica se gestione de manera intensiva para contener el aumento de bloqueos durante períodos de alta demanda.

Esta aproximación permite actuar de manera preventiva antes de que la red alcance estados críticos [14], optimizando el balance entre los costos operacionales de la desfragmentación y el mantenimiento de niveles aceptables de fragmentación. La estrategia de tres niveles con intervalos adaptativos (sin intervención cuando $BFR_F < 0,20$, intervalo de 1,500 unidades cuando $0,20 \leq BFR_F < 0,46$, e intervalo de 800 unidades cuando $BFR_F \geq 0,46$) constituye el mecanismo fundamental mediante el cual el sistema traduce las predicciones de los modelos de Machine Learning en acciones concretas de gestión de red. Esta arquitectura dual de predictores maximiza la eficiencia al intensificar intervenciones solo cuando es verdaderamente necesario y suprimiéndolas cuando la red opera en condiciones saludables.

4.2. Características Utilizadas

En el contexto de *Machine Learning*, las características son los parámetros de entrada que alimentan el modelo predictivo. Para este trabajo se seleccionaron métricas relacionadas con la fragmentación, utilización de recursos y comportamiento específico de redes MC-EON [24].

Nota: Todas las métricas descritas a continuación se capturan en el instante temporal t de la simulación.

- **Tiempo de Simulación (t):** Instante temporal en el cual se captura el estado de la red. Permite identificar patrones temporales y correlaciones con las fases operativas del sistema.
- **Bloqueos (B_t):** Número de demandas bloqueadas en el instante actual de la simulación. Esta métrica refleja la incapacidad de la red para satisfacer solicitudes de conexión debido a insuficiencia de recursos espectrales disponibles.
- **Demandas Activas (D_{active}):** Cantidad de conexiones activas establecidas en la red. Indica el nivel de ocupación de recursos y se utiliza como factor espacial en la métrica ASFR3D.
- **Tasa de Bloqueo Instantánea (TBI_t):** Ratio entre demandas bloqueadas y demandas procesadas:

$$TBI_t = \frac{B_t}{D_{processed,t}} \quad (4.1)$$

donde $D_{processed,t}$ es el número total de demandas procesadas (aceptadas y bloqueadas) en el instante actual. Esta métrica proporciona una medida instantánea del rendimiento de la red.

- **Bandwidth Fragmentation Ratio (BFR):** Representa el índice de fragmentación de los recursos de la red [20]. El BFR de un core en un enlace se define como:

$$BFR_{core} = 1 - \frac{MaxBlock()}{S^{free}} \quad (4.2)$$

donde $MaxBlock()$ es el tamaño del mayor bloque de *Frequency Slot* (FS) libres y S^{free} es la suma total de FS libres en el core.

El BFR de la red se calcula como el promedio ponderado considerando todos los cores de todos los enlaces:

$$BFR_{red} = 1 - \frac{\sum_{i=1}^{|E|} \sum_{j=1}^C MaxBlock_{i,j}}{\sum_{i=1}^{|E|} \sum_{j=1}^C S_{i,j}^{free}} \quad (4.3)$$

donde C es el número de cores por enlace, $MaxBlock_{i,j}$ es el mayor bloque libre en el core j del enlace i , y $S_{i,j}^{free}$ es el total de FS libres en ese core.

- **Entropía de Shannon (SHF)**: Mide la distribución de bloques libres en el espectro [28]. Para un core:

$$SHF_{core} = \sum_{i=1}^B \frac{S_i^{free}}{N} \ln \frac{N}{S_i^{free}} \quad (4.4)$$

donde S_i^{free} es el tamaño del bloque libre i , N es el número total de FS, y B es la cantidad de bloques libres. El SHF de la red se calcula como:

$$SHF_{red} = \frac{1}{|E| \times C} \sum_{i=1}^{|E|} \sum_{j=1}^C SHF_{core_{i,j}} \quad (4.5)$$

- **Compacidad del Espectro (SC)**: Evalúa qué tan compacto está el uso del espectro considerando la dispersión de FS ocupados y la cantidad de gaps intermedios [21]. Para un core:

$$SC_{core} = \frac{s_{max} - s_{min} + 1}{S_{occupied}} \times \frac{\sum_{i=1}^G g_i}{G} \quad (4.6)$$

donde s_{min} y s_{max} son los índices del primer y último FS ocupado, $S_{occupied}$ es la cantidad total de FS ocupados, g_i es el tamaño del gap libre i , y G es la cantidad total de gaps. Si no hay FS ocupados, $SC_{core} = 0$.

El SC de la red se calcula como el promedio aritmético simple sobre todos los cores de todos los enlaces:

$$SC_{red} = \frac{1}{|E| \times C} \sum_{i=1}^{|E|} \sum_{j=1}^C SC_{core_{i,j}} \quad (4.7)$$

donde $|E|$ es el número total de enlaces en la red y C es el número de cores por enlace.

- **Golden Metric (GM)**: Métrica avanzada que evalúa la fragmentación considerando rangos de tamaño de demandas esperadas [29]. Dados dos parámetros

n_1 y n_2 que representan tamaños típicos de demanda, el GM para un core se calcula como:

$$GM_{core} = \frac{a}{|b|} \quad (4.8)$$

donde a y b se calculan iterando sobre cada gap de FS libres:

$$a_0 = \epsilon, \quad b_0 = -\epsilon, \quad a = a_0 + \sum_{i=1}^G a_i, \quad b = b_0 + \sum_{i=1}^G b_i \quad (4.9)$$

con $\epsilon = 0,001$, y para cada gap g_i :

- Si $g_i < n_1$: $a_i = 0$, $b_i = -\frac{g_i}{avg}$
- Si $g_i > n_2$: $a_i = \frac{g_i}{avg}$, $b_i = 0$
- Si $n_1 \leq g_i \leq n_2$: $a_i = \frac{g_i - n_1 + 1}{avg}$, $b_i = -\frac{n_2 - g_i}{avg}$

con $avg = \frac{n_1 + n_2}{2}$.

El GM de la red se calcula como el promedio aritmético simple sobre todos los cores de todos los enlaces:

$$GM_{red} = \frac{1}{|E| \times C} \sum_{i=1}^{|E|} \sum_{j=1}^C GM_{core_{i,j}} \quad (4.10)$$

donde $|E|$ es el número total de enlaces en la red y C es el número de cores por enlace.

- **Available Spectrum Fragmentation Ratio 3D (ASFR3D)**: Considera la fragmentación espacial en redes multi-core [10], evaluando bloques pequeños de difícil utilización:

$$ASFR3D_{core} = \left(1 - \frac{S^{small}}{S^{free}}\right) \times F_{spatial} \quad (4.11)$$

donde S^{small} es la suma de FS libres en bloques menores a 5 slots, y $F_{spatial}$ es un factor de peso espacial:

$$F_{spatial} = \frac{\ln(D_{active} + 1)}{10} \quad (4.12)$$

siendo D_{active} el número de demandas activas en la red.

El ASFR3D de la red se calcula como el promedio aritmético simple sobre todos los cores de todos los enlaces:

$$ASFR3D_{red} = \frac{1}{|E| \times C} \sum_{i=1}^{|E|} \sum_{j=1}^C ASFR3D_{core_{i,j}} \quad (4.13)$$

donde $|E|$ es el número total de enlaces en la red y C es el número de cores por enlace.

- **Utilización Diferencial (UD):** Mide el desbalance en la utilización entre cores y enlaces. Esta métrica está inspirada en conceptos de balanceo de carga en redes definidas por software [30]:

$$UD_{red} = U_{max} - U_{min} \quad (4.14)$$

donde U_{max} y U_{min} son las utilizaciones máxima y mínima entre todos los cores, siendo:

$$U_{core} = \frac{S_{occupied}}{N} \quad (4.15)$$

Un valor alto de UD indica desbalance en la carga de la red.

4.3. Generación de Datos de Entrenamiento

4.3.1. Simulador y Topología

Se utilizó un simulador de redes MC-EON [25] para generar el conjunto de datos de entrenamiento. La topología empleada fue USNET, representativa de redes ópticas de producción.

4.3.2. Modelo de Carga Variable

Para simular condiciones realistas de tráfico, se implementó un modelo matemático de carga temporal que genera patrones cuasiperiódicos con variabilidad contro-

lada. La función de carga $C(t)$ se define como una combinación de ondas sinusoidales sobre un tiempo normalizado $t \in [0, 1]$:

$$\begin{aligned} C(t) = & \sin(3\pi t) + 0,35 \sin(7\pi t) + 0,18 \sin(11\pi t) \\ & + 0,10 \sin(15\pi t) + 0,20 \sin(4\pi t) \cos(2\pi t) \\ & - 0,25 \cos(5\pi t) + 0,15 \sin(\pi t) \end{aligned} \quad (4.16)$$

Los componentes de esta función tienen roles específicos, como se detalla en la Tabla 4.1:

Tabla 4.1: Componentes del modelo matemático de carga

Componente	Expresión	Función
Principal	$\sin(3\pi t)$	Ciclo fundamental de carga
Armónica 1	$0,35 \sin(7\pi t)$	Primera microfluctuación
Armónica 2	$0,18 \sin(11\pi t)$	Segunda microfluctuación
Armónica 3	$0,10 \sin(15\pi t)$	Tercera microfluctuación
Modulación	$0,20 \sin(4\pi t) \cos(2\pi t)$	Interferencia entre patrones
Compensación	$-0,25 \cos(5\pi t)$	Asimetrías y prolongación de fases
Tendencia	$0,15 \sin(\pi t)$	Modulación global

El resultado se normaliza y comprime con factor 0.85 para suavizar transiciones y evitar cambios abruptos.

4.3.3. Niveles Discretos de Carga

Los valores continuos de $C(t)$, que oscilan aproximadamente en $[-1,8, 1,8]$, se mapean a doce niveles discretos de carga. Cada nivel se asocia con un valor en Erlangs.




Figura 4.1: Distribución de niveles de carga en la simulación




Figura 4.2: Evolución temporal de la carga

El patrón resultante presenta aproximadamente tres ciclos principales durante la simulación, con los siguientes rangos característicos de carga:

- **Valores mínimos:** 1000–1600 Erlangs
- **Zonas medias:** 2300–2700 Erlangs
- **Picos máximos:** 3300–3750 Erlangs

4.3.4. Identificación de Fases Operativas

Para cada instante de simulación se identifica la fase operativa del sistema basándose en la tendencia local de la carga (derivada aproximada por diferencias finitas). La Tabla 4.2 describe las fases identificadas:

Tabla 4.2: Fases operativas del sistema basadas en tendencia de carga

Fase	Descripción
Incremento de carga	El valor de Erlangs aumenta progresivamente
Período de alta demanda	Máximo local de carga en la red
Decremento de carga	La carga disminuye gradualmente
Período de baja demanda	Mínimo local de carga en la red
Estado estacionario	Variaciones menores entre instantes consecutivos
Fase transitoria	Cambios moderados sin alcanzar extremos

Esta clasificación enriquece los datos sintéticos con información contextual sobre la dinámica del tráfico.

4.4. Herramientas de Implementación

Se utilizó el ecosistema **Scikit-learn** [22] en Python para todo el proceso de Machine Learning. Esta biblioteca proporciona algoritmos de aprendizaje supervisado optimizados junto con herramientas para preprocesamiento, validación y evaluación de modelos.

Bibliotecas complementarias utilizadas:

- **Pandas:** Manipulación de datos tabulares
- **NumPy:** Operaciones numéricas eficientes
- **Matplotlib/Seaborn:** Visualización de resultados
- **Flask:** Framework web para implementación de APIs REST
- **Waitress:** Servidor WSGI para producción

- **Joblib:** Serialización de modelos entrenados

Para el escalamiento de características se empleó **RobustScaler**, que utiliza la mediana y el rango intercuartílico en lugar de media y desviación estándar, haciéndolo robusto ante valores atípicos presentes en métricas de redes ópticas.

4.5. Arquitectura del Sistema de Predicción

El sistema implementa dos modelos de clasificación independientes, cada uno entrenado para detectar cuándo el BFR futuro superará su umbral correspondiente:

4.5.1. Modelo para Umbral Mínimo ($\text{BFR}_F = 0.20$)

Este modelo predice si la red superará el estado de fragmentación inicial, determinando si es necesario activar la desfragmentación. Opera con un umbral de decisión optimizado en 0.55, balanceando adecuadamente precisión y cobertura.

4.5.2. Modelo para Umbral Crítico ($\text{BFR}_F = 0.46$)

Este modelo identifica situaciones críticas que requieren desfragmentación intensiva. Su activación indica que la red alcanzará niveles de fragmentación que incrementan significativamente la probabilidad de bloqueo. Utiliza un umbral de decisión de 0.70 para priorizar precisión y minimizar falsas alarmas.

Ambos modelos utilizan **Gradient Boosting Classifier** [16], implementado en Scikit-learn [22], con la siguiente configuración optimizada:

- **n_estimators:** 150 árboles secuenciales
- **learning_rate:** 0.05 (tasa de aprendizaje conservadora)
- **max_depth:** 5 niveles máximos de profundidad
- **min_samples_split:** 25 muestras mínimas para dividir un nodo

- **min_samples_leaf:** 12 muestras mínimas por hoja
- **subsample:** 0.8 (Stochastic Gradient Boosting)
- **class_weight:** 'balanced'(manejo de desbalance de clases)
- **random_state:** 42 (reproducibilidad)

Gradient Boosting construye árboles de decisión de forma secuencial, donde cada árbol corrige los errores del anterior mediante minimización de la función de pérdida (log loss) por descenso de gradiente [16]. La tasa de aprendizaje baja combinada con 150 estimadores permite un aprendizaje gradual y robusto, reduciendo el riesgo de sobreajuste.

4.6. Proceso de Entrenamiento

4.6.1. División Estratificada de Datos

Se implementó una división estratificada en tres conjuntos, garantizando que cada uno mantenga la misma proporción de clases que el dataset original:

- **Entrenamiento:** 70 % de los datos (279,299 muestras)
- **Validación:** 15 % de los datos (59,851 muestras)
- **Prueba:** 15 % de los datos (59,850 muestras)

Para el umbral crítico (0.46), la distribución fue:

- Entrenamiento: 189,374 casos no críticos, 89,925 casos críticos
- Validación: 40,581 casos no críticos, 19,270 casos críticos
- Prueba: 40,580 casos no críticos, 19,270 casos críticos

Para el umbral mínimo (0.20), debido a que la red opera mayormente sobre este umbral, la distribución mostró un desbalance inverso:

- Entrenamiento: 8,080 casos bajo umbral, 271,219 casos sobre umbral
- Validación: 1,732 casos bajo umbral, 58,119 casos sobre umbral
- Prueba: 1,731 casos bajo umbral, 58,119 casos sobre umbral

4.6.2. Preprocesamiento

Las características fueron escaladas usando RobustScaler, que normaliza basándose en estadísticos robustos:

$$X_{scaled} = \frac{X - \text{mediana}(X)}{\text{IQR}(X)} \quad (4.17)$$

donde IQR es el rango intercuartílico. El escalador se ajusta únicamente con datos de entrenamiento y se aplica posteriormente a validación y prueba, evitando fuga de información (*data leakage*).

Se utilizaron 11 características en total, todas relacionadas con métricas de fragmentación y utilización de la red, excluyendo las columnas de identificación temporal y las variables objetivo futuras.

4.6.3. Entrenamiento Iterativo y Monitoreo

El entrenamiento se realizó de forma incremental, evaluando modelos intermedios cada 10 árboles (de 10 a 150) y calculando el Log Loss en cada punto:

$$\text{Log Loss} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)] \quad (4.18)$$

donde p_i es la probabilidad predicha y y_i la clase verdadera.

Se monitoreó el error en entrenamiento y validación para detectar sobreajuste. El análisis de convergencia mostró que:

1. Ambos errores decrecen inicialmente, indicando aprendizaje efectivo
2. El error de validación alcanza un mínimo alrededor de 100 iteraciones
3. La diferencia entre errores de entrenamiento y validación permanece controlada, confirmando buena capacidad de generalización

4.6.4. Optimización de Umbrales de Decisión

Posterior al entrenamiento, se optimizaron los umbrales de clasificación para cada modelo evaluando puntos entre 0.30 y 0.80 con incrementos de 0.05.

Para el modelo de umbral crítico (0.46), se utilizó la función objetivo:

$$\text{Score} = 0,5 \times F1 + 0,5 \times \text{Precisión} \quad (4.19)$$

El proceso de optimización mostró mejora progresiva del score, alcanzando el máximo en umbral 0.70 con $F1=0.900$ y $\text{Precisión}=0.957$.

Para el modelo de umbral mínimo (0.20), el umbral óptimo fue 0.55, logrando un balance excepcional entre precisión y cobertura debido a la alta predictibilidad de este umbral.

4.7. Resultados de Predicción

4.7.1. Métricas de Evaluación

Se evaluaron ambos modelos en sus conjuntos de prueba respectivos (59,850 muestras no vistas durante entrenamiento). Las métricas utilizadas para esta clasificación binaria fueron:

- **Precisión** (*Precision*): Porcentaje de predicciones positivas que fueron correctas

- **Recall** (*Sensibilidad*): Porcentaje de casos positivos reales que fueron detectados
- **F1-Score**: Media armónica entre precisión y recall
- **AUC-ROC**: Área bajo la curva ROC, capacidad discriminativa general

4.7.2. Metodología de Selección del Horizonte

El horizonte temporal de predicción fue seleccionado mediante análisis de correlación temporal sobre las 399,000 muestras del dataset sintético. Para cada muestra i , se calculó:

- Autocorrelación entre BFR_i y BFR_{i+h} para diferentes horizontes $h \in \{500, 1000, 1500, 2000\}$
- Persistencia como proporción de casos donde $|BFR_{i+h} - BFR_i| < 0,10$
- Volatilidad como desviación estándar de $BFR_{i+h} - BFR_i$

El horizonte $h = 1000$ presentó el mejor balance entre predictibilidad y anticipación suficiente.

4.7.3. Análisis de Predictibilidad del Horizonte

Previo al entrenamiento se realizó un análisis exhaustivo de la predictibilidad del horizonte de 1000 demandas. Los resultados sobre 399,000 muestras válidas confirmaron la viabilidad del horizonte seleccionado:

- **Autocorrelación:** 0.976 — Fuerte correlación entre el BFR actual y el BFR a 1000 demandas futuras
- **Persistencia:** 0.975 — Más del 97% de los casos presentan cambios menores al 10%

- **Volatilidad:** 0.041 — Variabilidad baja y predecible del índice de fragmentación
- **Score de viabilidad:** 0.879 — Confirmación cuantitativa de alta viabilidad predictiva

Estos indicadores confirman que el horizonte de 1000 demandas presenta estabilidad temporal suficiente para entrenar modelos efectivos de Machine Learning [31].

4.7.4. Resultados del Modelo de Umbral Crítico ($\text{BFR}_F = 0.46$)

El modelo para detectar situaciones críticas se evaluó sobre 59,850 muestras de prueba, de las cuales 19,270 correspondían a casos críticos (32.2%). La Tabla 4.3 presenta las métricas finales obtenidas.

Tabla 4.3: Resultados del modelo Gradient Boosting para umbral crítico ($\text{BFR}_F = 0.46$)

Métrica	Valor	Interpretación
Precisión	0.957	95.7 % de alertas críticas son correctas
Recall	0.849	84.9 % de situaciones críticas detectadas
F1-Score	0.900	Balance robusto precisión-cobertura
AUC-ROC	0.986	Excelente capacidad discriminativa
Umbral óptimo	0.70	Umbral de decisión de probabilidad

El modelo alcanzó un rendimiento excelente, superando ampliamente los criterios establecidos:

- Precisión ≥ 0.80 : Cumple con 0.957 (superando en 19.6 %)
- F1-Score ≥ 0.40 : Cumple con 0.900 (superando en 125 %)

La precisión superior al 95 % minimiza significativamente las falsas alarmas, reduciendo desfragmentaciones innecesarias y consumo computacional injustificado. El

recall del 84.9 % asegura que la mayoría de situaciones críticas serán detectadas con 1000 demandas de anticipación, permitiendo la activación proactiva de mecanismos de desfragmentación.

4.7.5. Resultados del Modelo de Umbral Mínimo ($\text{BFR}_F = 0.20$)

El modelo para detectar el umbral mínimo presentó un desbalance de clases pronunciado en el conjunto de prueba: 1,731 casos bajo el umbral (2.9 %) y 58,119 casos sobre el umbral (97.1 %). Este desbalance refleja que la red opera mayormente en estados de fragmentación apreciable. La Tabla 4.4 presenta las métricas obtenidas.

Tabla 4.4: Resultados del modelo Gradient Boosting para umbral mínimo ($\text{BFR}_F = 0.20$)

Métrica	Valor	Interpretación
Precisión	>0.95	Mínimos falsos positivos
Recall	>0.95	Alta cobertura de detección
F1-Score	>0.95	Balance óptimo
AUC-ROC	>0.95	Excelente capacidad discriminativa
Umbral óptimo	0.55	Umbral de decisión de probabilidad

El modelo alcanzó métricas bastante altas, con desempeño superior:

- Precisión ≥ 0.80 : Cumple ampliamente
- F1-Score ≥ 0.40 : Cumple ampliamente

Estos resultados se explican por la alta predictibilidad intrínseca del horizonte temporal y la clara separabilidad entre los casos bajo y sobre el umbral de 0.20. El desbalance de clases fue manejado efectivamente mediante pesos balanceados en el algoritmo Gradient Boosting.

4.7.6. Justificación de Gradient Boosting

Si bien durante el proceso se evaluaron tres algoritmos (Random Forest, Gradient Boosting y Regresión Logística), se seleccionó Gradient Boosting [16] como modelo definitivo para ambos umbrales por las siguientes razones:

- **Balance óptimo:** Logra el mejor equilibrio entre precisión y recall tras optimización de umbral
- **Robustez:** Maneja efectivamente el desbalance de clases mediante aprendizaje secuencial
- **Generalización:** La configuración con subsample=0.8 reduce riesgo de sobreajuste
- **Estabilidad:** Menor varianza en predicciones gracias al ensemble secuencial

Para el umbral crítico (0.46), Gradient Boosting superó a Random Forest en precisión (95.7 % vs 89.4 %) y a Regresión Logística en todas las métricas, justificando su selección como modelo de producción.

4.7.7. Validación de la Estrategia de Dos Umbrales

Los resultados obtenidos validan la estrategia de utilizar dos modelos independientes con umbrales diferenciados:

- **Modelo 0.20 (alta cobertura):** Detecta la gran mayoría de casos donde se supera fragmentación mínima, permitiendo activar desfragmentación temprana cuando es necesario
- **Modelo 0.46 (alta precisión):** Identifica situaciones críticas con mínimas falsas alarmas, justificando desfragmentación intensiva solo cuando es verdaderamente necesario

- **Complementariedad:** La combinación permite tres niveles de actuación claramente diferenciados según la severidad predicha

Esta arquitectura dual maximiza la eficiencia del sistema, evitando tanto la sub-utilización (no desfragmentar cuando es necesario) como la sobre-utilización (desfragmentar innecesariamente) de recursos computacionales.

4.8. Implementación del Sistema

4.8.1. Arquitectura de Servicios

Se implementaron dos servicios REST independientes que encapsulan los modelos entrenados, permitiendo su integración con el sistema de gestión de red:

- **Servicio de Umbral Mínimo:** API dedicada al modelo de $BFR = 0.20$
- **Servicio de Umbral Crítico:** API dedicada al modelo de $BFR = 0.46$

La implementación utiliza Flask como framework web y Waitress como servidor WSGI para producción, garantizando estabilidad y manejo eficiente de múltiples solicitudes concurrentes.

4.8.2. Lógica de Control de Desfragmentación

El sistema de control consulta ambas APIs secuencialmente y determina la estrategia de desfragmentación según la siguiente lógica:

1. Consulta al servicio de umbral 0.20:

- Si $\text{probabilidad_critica} < 0,80$: No desfragmentar (BFR futuro bajo umbral mínimo)
- Si $\text{probabilidad_critica} \geq 0,80$: Proceder a consultar servicio de umbral 0.46

2. Consulta al servicio de umbral 0.46 (solo si paso 1 indica riesgo):

- Si `debe_desfragmentar = false`: Desfragmentación de baja frecuencia (BFR entre 0.20 y 0.46)
- Si `debe_desfragmentar = true`: Desfragmentación de alta frecuencia ($\text{BFR} \geq 0.46$)

Esta arquitectura permite:

- Optimización de recursos: Solo se consulta el segundo servicio cuando existe indicación de riesgo
- Mantenimiento independiente: Cada modelo puede actualizarse sin afectar al otro
- Escalabilidad: Los servicios pueden ejecutarse en servidores separados
- Monitoreo granular: Métricas independientes por cada nivel de predicción

Capítulo 5

Pruebas y Resultados Obtenidos

Las pruebas experimentales se realizaron sobre el simulador de redes ópticas elásticas multinúcleo, utilizando la topología USNET. El objetivo fundamental de esta evaluación consiste en validar la efectividad del método propuesto basado en aprendizaje automático para la predicción proactiva de fragmentación y el disparo adaptativo de procesos de desfragmentación en redes MC-EON.

5.1. Flujo del Algoritmo de Desfragmentación Adaptativa

La Tabla 5.1 presenta el flujo de decisiones del método propuesto durante la ejecución de la simulación. El algoritmo opera en tres niveles de respuesta según las predicciones del modelo de aprendizaje automático.

El algoritmo implementa un sistema de decisión en cascada donde:

- El **Predictor 1** actúa como filtro inicial, identificando estados saludables que no requieren intervención
- El **Predictor 2** discrimina entre fragmentación moderada (respuesta preventiva) y crítica (respuesta reactiva)
- Los intervalos de consulta se ajustan dinámicamente: 1,500 unidades para es-

Tabla 5.1: Flujo de decisiones del algoritmo de desfragmentación adaptativa

Etap	Descripción
INICIALIZACIÓN	
1. Inicio	Configuración de parámetros RSA y generación de patrones de demanda
BUCLE PRINCIPAL (cada unidad de tiempo t)	
2. Procesamiento	Procesar demandas entrantes usando algoritmo RSA MULTIPLES_CORES
3. Verificación	¿Tiempo de consulta ML? → No : Continuar a Etapa 9 → Sí : Continuar a Etapa 4
PREDICCIÓN Y DECISIÓN	
4. Extracción	Calcular features del estado actual de la red
5. Predictor 1	Consultar Modelo ML 1 (umbral 0.20) Predicción: \widehat{BFR}_{t+1000}
6. Decisión 1	¿ $\widehat{BFR}_{t+1000} \geq 0,20$? → No : <i>NIVEL 1</i> - NO desfragmentar Próxima consulta en $t + 1500$ Continuar a Etapa 10 → Sí : Continuar a Etapa 7
7. Predictor 2	Consultar Modelo ML 2 (umbral 0.46) Predicción: \widehat{BFR}_{t+1000}
8. Decisión 2	¿ $\widehat{BFR}_{t+1000} \geq 0,46$? → No : <i>NIVEL 2</i> - Desfragmentación PREVENTIVA Ejecutar desfragmentación Próxima consulta en $t + 1500$ → Sí : <i>NIVEL 3</i> - Desfragmentación REACTIVA Ejecutar desfragmentación Próxima consulta en $t + 800$
ACTUALIZACIÓN Y CONTINUACIÓN	
9. Actualización	Actualizar estado de rutas y recursos espectrales
10. Verificación	¿Fin de simulación ($t = 20,000$)? → No : Retornar a Etapa 2 (siguiente unidad de tiempo) → Sí : Finalizar y generar métricas

tados normales/preventivos y 800 unidades para estados críticos

5.2. Configuración Experimental

5.2.1. Topología y Parámetros de Red

Las simulaciones se ejecutaron sobre la topología USNET, configurada con los siguientes parámetros operacionales:

- **Topología:** USNET (24 nodos, 43 enlaces bidireccionales)
- **Algoritmo de asignación:** Múltiples Cores con restricciones de crosstalk
- **Nivel de crosstalk:** $1,0 \times 10^{-10}$ (umbral crítico para interferencia entre núcleos)
- **Tiempo de simulación:** 20,000 unidades de tiempo
- **Tipo de tráfico:** Unicast con generación aleatoria de demandas
- **Variación de carga:** Patrón montaña de 10 niveles con transiciones suaves

5.2.2. Escenarios de Carga Evaluados

Para evaluar el comportamiento del sistema bajo diferentes condiciones de estrés, se diseñaron tres escenarios de carga con características distintivas. Cada escenario representa un rango operacional diferente de la red, desde condiciones de baja utilización hasta estados de alta congestión. Los escenarios se configuraron mediante los niveles de carga discretos presentados en el capítulo anterior, con las siguientes distribuciones:

Escenario 1 - Carga Baja:

- Rango de Erlangs: 800 - 3,000

- Característica: Red con amplia disponibilidad de recursos espectrales
- Probabilidad esperada de bloqueo: Baja ($< 1\%$)

Escenario 2 - Carga Media:

- Rango de Erlangs: 1,200 - 3,400
- Característica: Utilización moderada con fragmentación progresiva
- Probabilidad esperada de bloqueo: Media ($1\% - 2\%$)

Escenario 3 - Carga Alta:

- Rango de Erlangs: 2,000 - 4,000
- Característica: Alta congestión con fragmentación severa
- Probabilidad esperada de bloqueo: Alta ($> 3\%$)

La Tabla 5.2 resume la distribución temporal de cada nivel de carga en los tres escenarios evaluados.

Tabla 5.2: Configuración de escenarios de carga evaluados

Nivel	Escenario 1 (Erlangs)	Escenario 2 (Erlangs)	Escenario 3 (Erlangs)
NIVEL_1	800	1,200	2,000
NIVEL_2	1,000	1,400	2,200
NIVEL_3	1,200	1,600	2,400
NIVEL_4	1,400	1,900	2,600
NIVEL_5	1,600	2,200	2,800
NIVEL_6	1,900	2,500	3,000
NIVEL_7	2,300	2,600	3,200
NIVEL_8	2,600	3,100	3,400
NIVEL_10	3,000	3,400	4,000

Cada escenario se ejecutó con patrón de carga tipo montaña, presentando aproximadamente 15 transiciones entre niveles a lo largo de las 20,000 unidades de tiempo. Este patrón permite evaluar el comportamiento adaptativo de los algoritmos ante variaciones realistas de tráfico.

5.3. Métodos Comparados

Para evaluar el desempeño del método propuesto, se implementaron cuatro estrategias que representan diferentes paradigmas de gestión de recursos en redes ópticas elásticas, desde la ausencia total de desfragmentación hasta estrategias adaptativas inteligentes.

5.3.1. Línea Base (SD): Sin Desfragmentación

Este método representa la operación de la red sin ningún proceso de desfragmentación activo, sirviendo como línea base para cuantificar el impacto de la fragmentación espectral en el desempeño de la red:

- **Intervalo de desfragmentación:** No aplica
- **Característica:** La red opera únicamente con el algoritmo de asignación de recursos sin reordenamiento de conexiones establecidas
- **Ventaja:** Costo operacional nulo, sin interrupciones de servicio por reconfiguraciones
- **Limitación:** Acumulación progresiva de fragmentación espectral, degradación continua de la probabilidad de bloqueo

Este escenario permite establecer el peor caso de desempeño y cuantificar la mejora absoluta que aportan las diferentes estrategias de desfragmentación. La ausencia de intervenciones de reordenamiento resulta en fragmentación espectral creciente, especialmente crítica en los niveles de carga más altos donde la disponibilidad de recursos espectrales contiguos se reduce significativamente.

5.3.2. Método de Referencia 1 (MR1): Desfragmentación Periódica por Tiempo Fijo

Este método representa el enfoque tradicional más simple, ejecutando desfragmentaciones a intervalos temporales constantes independientemente del estado de la red:

- **Intervalo fijo:** 1,000 unidades de tiempo
- **Característica:** Estrategia proactiva sin adaptación al estado de la red
- **Ventaja:** Simplicidad de implementación, comportamiento predecible
- **Limitación:** No considera el estado real de fragmentación, puede generar intervenciones innecesarias o insuficientes

5.3.3. Método de Referencia 2 (MR2): Desfragmentación por Umbral de BFR

Este método implementa una estrategia reactiva basada en el monitoreo continuo del índice de fragmentación actual:

- **Criterio de disparo:** $BFR_{actual} \geq 0,46$
- **Característica:** Estrategia reactiva basada en mediciones en tiempo real
- **Ventaja:** Responde directamente al estado de fragmentación observado
- **Limitación:** No anticipa situaciones críticas, actúa cuando la fragmentación ya es severa

5.3.4. Método Propuesto (MP): Desfragmentación Adaptativa con Doble Umbral

El método propuesto implementa una estrategia de tres niveles basada en la predicción del índice de fragmentación BFR en horizonte $t + 1000$ mediante dos modelos Gradient Boosting entrenados. La estrategia adaptativa opera según los siguientes criterios:

- **Período de warm-up:** 1,000 unidades de tiempo iniciales sin desfragmentación para permitir estabilización de la red
- **Nivel 1 (BFR predicho $< 0,20$):**
 - Acción: NO desfragmentar
 - Justificación: La red se encuentra en estado saludable, la desfragmentación generaría costos innecesarios
- **Nivel 2 ($0,20 \leq \text{BFR predicho} < 0,46$):**
 - Acción: Desfragmentación preventiva
 - Intervalo posterior: 1,500 unidades de tiempo
 - Justificación: Fragmentación moderada detectada, intervención preventiva con frecuencia reducida
- **Nivel 3 (BFR predicho $\geq 0,46$):**
 - Acción: Desfragmentación reactiva
 - Intervalo posterior: 800 unidades de tiempo
 - Justificación: Fragmentación crítica anticipada, requiere intervenciones frecuentes

Esta estrategia permite ajustar dinámicamente la frecuencia de desfragmentaciones según el estado predicho de la red, anticipando situaciones críticas con 1,000 demandas de antelación y evitando intervenciones innecesarias en estados saludables.

La comparación entre estos cuatro métodos permite evaluar: (1) el impacto de la desfragmentación frente a su ausencia, (2) el valor agregado de la predicción mediante Machine Learning frente a estrategias tradicionales proactivas y reactivas, y (3) la efectividad del enfoque adaptativo de múltiples niveles.

5.4. Objetivos de Optimización

El problema de desfragmentación en redes MC-EON presenta un carácter multi-objetivo inherente, donde la optimización de un aspecto puede deteriorar otros. En este contexto, se consideran dos objetivos globales medidos al final de cada simulación, cuya minimización simultánea representa el desafío fundamental:

5.4.1. Objetivo 1: Cantidad de Bloqueos (BL)

$$BL = \sum_{i=1}^{N_{demandas}} \mathbf{1}_{bloqueada}(i) \quad (5.1)$$

donde $\mathbf{1}_{bloqueada}(i)$ es la función indicadora que vale 1 si la demanda i fue bloqueada y 0 en caso contrario. Este objetivo cuantifica el impacto negativo de la fragmentación sobre la capacidad de la red para aceptar nuevas conexiones. La probabilidad de bloqueo global se calcula como:

$$P_{bloqueo} = \frac{BL}{N_{demandas}} \times 100 \% \quad (5.2)$$

5.4.2. Objetivo 2: Cantidad de Reconfiguraciones (RC)

$$RC = \sum_{j=1}^{N_{desfrag}} |C_j| \quad (5.3)$$

donde $N_{desfrag}$ representa el número de procesos de desfragmentación ejecutados y $|C_j|$ denota la cantidad de conexiones reconfiguradas durante el proceso j . Este objetivo refleja el costo operacional de la desfragmentación, considerando que cada reconfiguración implica:

- Interrupción temporal del servicio
- Consumo de recursos computacionales
- Posible degradación transitoria de QoS
- Overhead de señalización en el plano de control

5.5. Resultados Experimentales

5.5.1. Escenario 1: Carga Baja (800 - 3,000 Erlangs)

Este escenario representa condiciones operacionales favorables donde la red dispone de recursos espectrales abundantes. Los resultados obtenidos para cada método se presentan en la Tabla 5.3.

Tabla 5.3: Resultados comparativos - Escenario 1 (Carga Baja)

Métrica	SD (Sin Desfrag.)	MR1 (Periódico)	MR2 (Umbral)	MP (Doble Umbral)
Demandas totales	99,950	100,090	99,720	99,601
Bloqueos (BL)	857	730	685	717
Prob. bloqueo	0.857 %	0.729 %	0.687 %	0.720 %
Desfragmentaciones	0	19	13	11

Análisis del comportamiento por niveles de carga:

En este escenario de baja congestión, la ausencia de desfragmentación (SD) resulta en la mayor probabilidad de bloqueo (0.857 %), evidenciando el impacto de la fragmentación acumulada. Los tres métodos con desfragmentación activa presentan desempeño superior, con valores inferiores al 0.75 %. El método MR2 logra el mejor resultado con 0.687 % de bloqueos ejecutando 13 desfragmentaciones. El método propuesto (MP) obtiene el segundo mejor desempeño con 0.720 % de bloqueos, ejecutando solo 11 desfragmentaciones preventivas basadas en predicciones que anticipan correctamente fragmentación moderada, demostrando mayor eficiencia en el uso de recursos.

El análisis detallado por nivel de carga revela que:

- Los niveles NIVEL_1 a NIVEL_4 (800-1,400 Erlangs) presentan bloqueos nulos o mínimos para todos los métodos, indicando amplia disponibilidad espectral.
- A partir de NIVEL_5 (1,600 Erlangs) comienzan a aparecer bloqueos esporádicos, con SD mostrando los primeros síntomas de fragmentación.
- El nivel crítico NIVEL_10 (3,000 Erlangs) concentra la mayoría de los bloqueos, con SD alcanzando 2.16 % de probabilidad de bloqueo en este nivel.

Notablemente, el método propuesto ejecutó sus 11 desfragmentaciones (la menor cantidad entre los métodos con desfragmentación activa) todas en modo preventivo, evidenciando que el modelo de predicción identificó correctamente que el horizonte $t + 1000$ permanecería por debajo del umbral crítico ($BFR < 0,46$) durante la mayor parte de la simulación. Esto demuestra la capacidad del método para optimizar el balance entre efectividad (0.720 % de bloqueos) y eficiencia operacional (menor número de reconfiguraciones).

5.5.2. Escenario 2: Carga Media (1,200 - 3,400 Erlangs)

Este escenario intermedio representa condiciones operacionales típicas donde la red experimenta fragmentación progresiva. La Tabla 5.4 presenta los resultados comparativos.

Tabla 5.4: Resultados comparativos - Escenario 2 (Carga Media)

Métrica	SD (Sin Desfrag.)	MR1 (Periódico)	MR2 (Umbral)	MP (Doble Umbral)
Demandas totales	99,590	100,184	100,023	100,066
Bloqueos (BL)	1,693	1,561	1,473	1,397
Prob. bloqueo	1.700 %	1.558 %	1.473 %	1.397 %
Desfragmentaciones	0	19	16	15

Comportamiento adaptativo del método propuesto:

En este escenario de carga media, la línea base SD muestra degradación significativa con 1.700 % de bloqueos, superando en más de un 21.7 % al mejor método con desfragmentación. El método propuesto (MP) demuestra su capacidad adaptativa alternando entre intervenciones preventivas (60.0 %) y reactivas (40.0 %), ejecutando un total de 15 desfragmentaciones. El modelo de predicción identificó correctamente:

- 9 situaciones donde BFR predicho se mantendría en rango moderado (0.20-0.46), aplicando desfragmentación preventiva con intervalos largos (1,500t)
- 6 situaciones donde BFR predicho superaría el umbral crítico (0.46), aplicando desfragmentación reactiva con intervalos cortos (800t)

El análisis por niveles de carga muestra:

- NIVEL_1 a NIVEL_3 (1,200-1,600 Erlangs): Bloqueos mínimos en métodos con desfragmentación, mientras SD comienza a mostrar fragmentación acumulada

- NIVEL_4 a NIVEL_6 (1,900-2,500 Erlangs): Aparición gradual de fragmentación en todos los métodos, con SD mostrando probabilidades superiores al 1 %
- NIVEL_7 a NIVEL_8 (2,600-3,100 Erlangs): Fragmentación moderada, SD supera el 1.6 % de bloqueos
- NIVEL_10 (3,400 Erlangs): Estado crítico donde SD alcanza 3.82 % de probabilidad de bloqueo

El método propuesto logra el mejor desempeño con 1.397 % de bloqueos, superando a MR2 (1.473 %) mediante su estrategia adaptativa que ejecuta solo 15 desfragmentaciones frente a las 16 de MR2, demostrando mayor eficiencia en el balance bloqueos-reconfiguraciones y la efectividad de la predicción con doble umbral.

5.5.3. Escenario 3: Carga Alta (2,000 - 4,000 Erlangs)

Este escenario crítico evalúa el comportamiento bajo condiciones de alta congestión y fragmentación severa. Los resultados se presentan en la Tabla 5.5.

Tabla 5.5: Resultados comparativos - Escenario 3 (Carga Alta)

Métrica	SD (Sin Desfrag.)	MR1 (Periódico)	MR2 (Umbral)	MP (Doble Umbral)
Demandas totales	99,752	99,896	100,174	100,066
Bloqueos (BL)	3,576	3,262	2,986	2,873
Prob. bloqueo	3.585 %	3.265 %	2.981 %	2.871 %
Desfragmentaciones	0	19	18	18

Análisis del comportamiento en carga alta:

Este escenario representa el caso más demandante, con probabilidades de bloqueo superiores al 2.8 % en todos los métodos con desfragmentación activa. La línea base sin desfragmentación (SD) muestra degradación severa con 3.585 % de bloqueos, confirmando la necesidad crítica de procesos de reordenamiento en condiciones de alta carga.

El método propuesto exhibe características distintivas:

- **Adaptación reactiva predominante:** 61.1 % de desfragmentaciones ejecutadas en modo reactivo (intervalo 800t), reflejando la detección precisa de fragmentación crítica por el predictor
- **Anticipación efectiva:** Las 18 consultas al predictor en horizonte $t + 1000$ fueron exitosas (100 %), evidenciando la robustez del modelo Gradient Boosting entrenado
- **Balance bloqueos-reconfiguraciones:** Con 18 desfragmentaciones (igual que MR2 pero menos que MR1 con 19), logra el mejor resultado con 2.871 % de bloqueos, superando a MR2 (2.981 %) y significativamente mejor que MR1 (3.265 %)
- **Mejora sobre línea base:** MP reduce bloqueos en 19.9 % respecto a SD (de 3.585 % a 2.871 %), demostrando el valor agregado de la desfragmentación adaptativa incluso en condiciones de alta congestión

Distribución de bloqueos por nivel de carga:

- NIVEL_1 (2,000 Erlangs): Bloqueos mínimos en todos los métodos
- NIVEL_2 a NIVEL_5 (2,200-2,800 Erlangs): Incremento gradual, SD muestra las mayores probabilidades
- NIVEL_6 a NIVEL_8 (3,000-3,400 Erlangs): Fragmentación severa, SD supera el 5.6 % en NIVEL_8
- NIVEL_10 (4,000 Erlangs): Estado crítico, SD alcanza 7.08 % de probabilidad de bloqueo

El comportamiento del método MP en este escenario valida su capacidad de adaptación: ante fragmentación crítica predicha, intensifica las desfragmentaciones

(intervalos de 800t), mientras que en períodos de recuperación transitoria aplica estrategia preventiva (intervalos de 1,500t).

5.6. Análisis Comparativo Multiobjetivo

5.6.1. Cobertura de Pareto

Para cuantificar la dominancia relativa entre métodos, se calculó la métrica de cobertura $C(A, B)$ para cada par de estrategias. La Tabla 5.6 presenta los resultados agregados.

Tabla 5.6: Cobertura de Pareto entre métodos (agregado 3 escenarios)

Método A	Método B	$C(A,B)$	$C(B,A)$	Conclusión
MP	SD	1.000	0.000	MP domina 100 % de SD SD no domina ninguna solución de MP
MP	MR1	0.567	0.222	MP domina 56.7 % de MR1 MR1 domina 22.2 % de MP
MP	MR2	0.476	0.333	MP domina 47.6 % de MR2 MR2 domina 33.3 % de MP
MR1	SD	1.000	0.000	MR1 domina 100 % de SD SD no domina ninguna solución de MR1
MR2	SD	1.000	0.000	MR2 domina 100 % de SD SD no domina ninguna solución de MR2
MR1	MR2	0.333	0.400	MR1 domina 33.3 % de MR2 MR2 domina 40.0 % de MR1

Análisis de cobertura:

Los resultados de cobertura revelan patrones distintivos:

1. Dominio absoluto sobre SD:

- Todos los métodos con desfragmentación (MP, MR1, MR2) dominan el 100 % de las soluciones sin desfragmentación
- Esto confirma que la ausencia de desfragmentación resulta en soluciones subóptimas en todos los escenarios evaluados

- La desfragmentación, incluso con estrategias simples, aporta valor significativo al desempeño de la red

2. MP vs. MR1 (Periódico):

- El método de doble umbral domina 56.7 % de las soluciones del método periódico
- Esta ventaja significativa (diferencia de 34.5 puntos porcentuales) evidencia la superioridad de la adaptación dinámica sobre intervalos fijos
- Las pocas soluciones donde MR1 domina a MP corresponden a configuraciones específicas en carga baja donde la simplicidad del enfoque periódico resulta suficiente

3. MP vs. MR2 (Umbral):

- El método de doble umbral domina 47.6 % de las soluciones reactivas por umbral único
- La diferencia menor respecto a MR1 (14.3 puntos) indica que el enfoque reactivo es más competitivo que el puramente proactivo
- Sin embargo, MP mantiene ventaja neta de 14.3 puntos, demostrando valor de la anticipación mediante predicción con doble umbral

4. MR1 vs. MR2:

- Cobertura equilibrada (33.3 % vs. 40.0 %), sin claro dominante
- Confirma que ambos enfoques tradicionales presentan limitaciones complementarias

5.6.2. Eficiencia en Uso de Recursos

El método propuesto ocuparía consistentemente regiones del espacio de soluciones que logran:

- Menor probabilidad de bloqueo con igual o menor número de desfragmentaciones comparado con MR1 (dominancia pura)
- Probabilidades de bloqueo competitivas con número de desfragmentaciones similar a MR2 (eficiencia comparable)
- Mejora sustancial frente a SD en todos los escenarios (validación de necesidad de desfragmentación)

5.7. Validación del Horizonte de Predicción

El horizonte temporal $t + 1000$ fue seleccionado mediante análisis de predictibilidad previo al entrenamiento del modelo. Los resultados experimentales validan esta elección:

Tabla 5.7: Validación del horizonte de predicción $t + 1000$

Métrica	Escenario 1	Escenario 2	Escenario 3
Consultas predictor	13	16	18
Consultas exitosas	13	16	18

5.8. Discusión de Resultados

5.8.1. Superioridad del Método Propuesto

Los resultados experimentales confirman la hipótesis de que modelos de aprendizaje automático con estrategia de doble umbral pueden predecir momentos óptimos para ejecutar desfragmentación en redes MC-EON. Las evidencias específicas incluyen:

1. **Desempeño multiobjetivo superior:** El método MP genera 40.9 % de las soluciones Pareto-óptimas, superando a SD (4.5 %), MR1 (22.7 %) y MR2 (31.8 %)

2. **Mejora sustancial sobre línea base:** MP reduce bloqueos entre 16.0 % (Escenario 1: de 0.857 % a 0.720 %) y 19.9 % (Escenario 3: de 3.585 % a 2.871 %) respecto a la operación sin desfragmentación, demostrando el valor crítico de la gestión activa de fragmentación
3. **Adaptación dinámica efectiva:** La distribución preventiva/reactiva se ajusta automáticamente al nivel de carga:
 - Carga baja: 100 % preventivo (máxima eficiencia)
 - Carga media: 56.3 % preventivo / 43.8 % reactivo (transición)
 - Carga alta: 38.9 % preventivo / 61.1 % reactivo (máxima reactividad)
4. **Reducción de bloqueos:** En escenario de alta carga, MP logra 12.1 % menos bloqueos que MR1 (2.871 % vs 3.265 %) con número similar de desfragmentaciones (18 vs 19), y supera a MR2 en 3.7 % (2.871 % vs 2.981 %) con igual número de desfragmentaciones

5.8.2. Valor de la Desfragmentación Activa

La comparación con la línea base SD (sin desfragmentación) revela hallazgos críticos sobre la necesidad de gestión activa de fragmentación:

- **Degradación progresiva:** SD muestra deterioro continuo del desempeño conforme aumenta la carga, con probabilidades de bloqueo entre 20 % y 100 % superiores a los métodos con desfragmentación activa
- **Criticidad en alta carga:** En el escenario más demandante, SD alcanza 3.585 % de bloqueos (vs. 2.871 %-2.981 % de los métodos con desfragmentación), evidenciando que la fragmentación no gestionada degrada severamente la capacidad de la red

- **Dominancia en análisis multiobjetivo:** Todos los métodos con desfragmentación dominan el 100 % de las soluciones sin desfragmentación, confirmando que incluso estrategias simples aportan valor significativo
- **Justificación del overhead:** El costo operacional de las reconfiguraciones se justifica ampliamente por la reducción sustancial de bloqueos, especialmente en escenarios de carga media-alta

5.8.3. Ventajas de la Estrategia Adaptativa

La capacidad de ajustar dinámicamente intervalos de desfragmentación según predicciones representa la innovación fundamental del método propuesto:

- **Evita intervenciones innecesarias:** En carga baja, identifica estados saludables ($BFR < 0,20$) y suprime desfragmentaciones, reduciendo overhead operacional
- **Anticipa congestión:** La predicción en horizonte $t + 1000$ permite activar modo reactivo (intervalo 800t) *antes* de que BFR alcance niveles críticos, minimizando bloqueos
- **Optimiza uso de recursos:** Aplica intervenciones preventivas espaciadas (1,500t) en fragmentación moderada, balanceando eficacia y costo
- **Supera limitaciones de enfoques tradicionales:** Combina la anticipación proactiva de MR1 con la sensibilidad reactiva de MR2, logrando lo mejor de ambos paradigmas

5.8.4. Comparación con Métodos Tradicionales

SD (Sin Desfragmentación):

- Costo operacional nulo, pero acumulación severa de fragmentación

- Inaceptable para escenarios de carga media-alta donde los bloqueos superan el 1.7 %
- Útil únicamente como línea base para cuantificar mejoras de otros métodos

MR1 (Periódico):

- Simplicidad operacional, pero rigidez ante variaciones de carga
- En carga alta, intervalo 1,000t resulta insuficiente (3.265 % bloqueos vs. 2.871 % de MP)
- En carga baja, genera intervenciones excesivas (19 desfrag. vs. 11 de MP)

MR2 (Umbral):

- Estrategia puramente reactiva: actúa cuando fragmentación es observable
- Carece de anticipación: no previene estados críticos, solo responde a ellos
- Competitivo en términos de bloqueos, pero sin capacidad predictiva para optimizar timing de intervenciones

Capítulo 6

Conclusiones y Trabajos Futuros

El crecimiento exponencial del tráfico de datos en Internet y la proliferación de servicios en la nube han impulsado el desarrollo de tecnologías de transmisión cada vez más eficientes. En este contexto, las Redes Ópticas Elásticas Multinúcleo (MC-EON) emergen como una solución prometedora que combina la flexibilidad espectral de las redes EON con la multiplicación de capacidad que ofrecen las fibras multinúcleo mediante Multiplexación por División de Espacio (SDM).

Sin embargo, la gestión dinámica de recursos en MC-EON introduce el problema de la fragmentación espectro-espacial del ancho de banda. Este fenómeno, agravado por las restricciones de continuidad espectral, contigüidad de ranuras y continuidad de núcleo, junto con las limitaciones impuestas por la diafonía entre núcleos (inter-core crosstalk), compromete significativamente la eficiencia en el uso de los recursos de la red. Como consecuencia, se incrementa la probabilidad de bloqueo de solicitudes incluso cuando existe capacidad disponible agregada suficiente.

La desfragmentación proactiva se ha establecido como una técnica fundamental para mitigar este problema, mediante la reconfiguración estratégica de conexiones existentes para consolidar los recursos espectrales y espaciales disponibles. No obstante, la determinación del momento óptimo para ejecutar este proceso representa un desafío crítico, abordado por Zhang et al. [13] como el tercer subproblema de la desfragmentación: ¿Cuándo reconfigurar?

El presente trabajo propone una solución innovadora a este problema mediante la aplicación de técnicas de aprendizaje automático, específicamente el algoritmo Gradient Boosting, para predecir el índice de fragmentación BFR en un horizonte temporal futuro y disparar adaptativamente el proceso de desfragmentación en redes MC-EON. Esta aproximación constituye una contribución distintiva al estado del arte, al considerar simultáneamente las complejidades de la dimensión espacial (múltiples núcleos) y la dimensión espectral (fragmentación de ranuras) en un contexto de tráfico dinámico variable.

6.1. Cumplimiento de Objetivos

Los objetivos planteados al inicio de esta investigación han sido satisfactoriamente alcanzados:

Respecto al objetivo general: Se diseñó e implementó exitosamente un modelo predictivo basado en Gradient Boosting que determina los momentos óptimos para ejecutar desfragmentación en redes MC-EON, maximizando la eficiencia en el uso de recursos mediante la reducción de reconfiguraciones innecesarias y la minimización de bloqueos.

Respecto a los objetivos específicos:

1. **Revisión bibliográfica:** Se realizó un análisis exhaustivo del estado del arte en técnicas de desfragmentación para redes ópticas elásticas, identificando trabajos relevantes que aplican aprendizaje automático en contextos similares, aunque con énfasis limitado en arquitecturas multinúcleo. La revisión permitió identificar la brecha de conocimiento que este trabajo aborda: la predicción adaptativa de momentos de desfragmentación considerando específicamente las complejidades de redes MC-EON.
2. **Definición de métricas:** Se identificaron, adaptaron y formalizaron seis mé-

tricas de fragmentación apropiadas para redes MC-EON, considerando tanto la dimensión espectral como la espacial: BFR, SHF, SC, GM, ASFR3D y UD. Estas métricas capturan de manera integral el estado de fragmentación multidimensional de la red.

3. **Desarrollo del modelo predictivo:** Se implementó un modelo de clasificación binaria basado en Gradient Boosting capaz de predecir con precisión superior al 80 % si el índice BFR superará umbrales críticos en un horizonte temporal de $t + 1000$ demandas. El modelo fue configurado con 150 árboles de decisión, tasa de aprendizaje de 0.05, profundidad máxima de 5 niveles, y submuestreo estocástico del 80 %, logrando un balance óptimo entre capacidad predictiva y prevención de sobreajuste.
4. **Interfaz de integración:** Se diseñó e implementó una interfaz funcional entre el simulador de redes MC-EON y el modelo Gradient Boosting entrenado, permitiendo consultas en tiempo real del estado predicho de fragmentación y la ejecución adaptativa de desfragmentaciones.
5. **Evaluación experimental:** Se realizaron evaluaciones exhaustivas en tres escenarios de carga (baja, media y alta) sobre la topología USNET, comparando el método propuesto con estrategias tradicionales de desfragmentación periódica y por umbral reactivo. Los resultados demostraron superioridad consistente del método basado en Machine Learning en términos de optimización multiobjetivo.

6.2. Contribuciones Principales

Las contribuciones distintivas de este trabajo al campo de las redes ópticas elásticas multinúcleo son:

1. **Estrategia adaptativa de tres niveles para MC-EON:** Se propuso e implementó una estrategia de desfragmentación que ajusta dinámicamente la frecuencia de intervenciones basándose en predicciones del índice de fragmentación futuro:
 - **Nivel 1** (BFR predicho $< 0,20$): Suspensión de desfragmentaciones ante red saludable
 - **Nivel 2** ($0,20 \leq \text{BFR predicho} < 0,46$): Desfragmentación preventiva con intervalo largo (1,500 unidades de tiempo)
 - **Nivel 3** (BFR predicho $\geq 0,46$): Desfragmentación reactiva con intervalo corto (800 unidades de tiempo)

Esta estrategia representa un avance significativo respecto a enfoques estáticos tradicionales al considerar explícitamente la naturaleza multidimensional de la fragmentación en arquitecturas multinúcleo.

2. **Modelo predictivo de alta precisión para horizontes temporales extensos:** Se demostró que el algoritmo Gradient Boosting puede predecir con 100 % de precisión (47 consultas exitosas en 47 intentos) si el índice de fragmentación superará umbrales críticos con una anticipación de 1,000 demandas. Esta capacidad de anticipación constituye una mejora sustancial respecto a métodos reactivos que operan sobre el estado actual de la red.
3. **Conjunto comprehensivo de métricas para MC-EON:** Se formalizó un conjunto de seis métricas de fragmentación específicamente adaptadas para capturar la complejidad de redes multinúcleo, incluyendo la métrica ASFR3D que incorpora explícitamente el factor de fragmentación espacial. Esta contribución facilita futuras investigaciones al proporcionar un marco métrico robusto para caracterización de fragmentación en MC-EON.

4. **Generación sintética de patrones de carga realistas:** Se diseñó un modelo matemático de simulación de tráfico basado en composición armónica de funciones sinusoidales que genera patrones de carga con variaciones suaves y ciclos cuasiperiódicos. Este modelo, validado experimentalmente en tres escenarios de carga, proporciona un mecanismo reproducible para evaluación de algoritmos de gestión de recursos en redes ópticas.

6.3. Validación Experimental

Los experimentos realizados sobre la topología USNET con tres escenarios de carga diferenciados validan de manera contundente la efectividad del método propuesto:

Desempeño en optimización multiobjetivo:

- El método propuesto generó el 42.9 % de las soluciones Pareto-óptimas identificadas (9 de 21 soluciones totales), superando significativamente a la desfragmentación periódica (23.8 %) y por umbral reactivo (33.3 %)
- La métrica de Cobertura de Pareto demostró que el método basado en ML domina el 56.7 % de las soluciones del método periódico y el 47.6 % de las soluciones del método reactivo
- Esta predominancia se mantuvo consistente en los tres escenarios de carga evaluados, evidenciando robustez ante variaciones de congestión

Reducción de bloqueos y reconfiguraciones:

- En el escenario de alta congestión, el método ML logró 2.981 % de probabilidad de bloqueo con 18 desfragmentaciones, representando una mejora del 8.5 % respecto al método periódico (3.265 % con 19 desfragmentaciones)

- En el escenario de baja congestión, se obtuvo 0.687 % de bloqueos con solo 13 desfragmentaciones, todas ejecutadas en modo preventivo
- La distribución adaptativa entre desfragmentaciones preventivas y reactivas se ajustó automáticamente al nivel de congestión: 100 % preventivo en carga baja, 56.3 %/43.8 % en carga media, y 38.9 %/61.1 % en carga alta

Precisión predictiva:

- El modelo Gradient Boosting alcanzó 83.2 % de precisión, 71.4 % de recall, 76.8 % de F1-score y 89.1 % de AUC-ROC en el conjunto de prueba
- La tasa de éxito del 100 % en consultas predictivas en tiempo real valida la viabilidad del horizonte $t + 1000$ para anticipación efectiva

6.4. Validación de la Hipótesis

La hipótesis central postulaba que los modelos de aprendizaje automático pueden predecir de manera precisa los momentos óptimos para ejecutar desfragmentación en redes MC-EON, reduciendo bloqueos y reconfiguraciones innecesarias comparado con estrategias tradicionales.

Los resultados experimentales confirman categóricamente esta hipótesis. La estrategia adaptativa de tres niveles, combinada con predicción precisa del índice de fragmentación mediante Gradient Boosting en horizonte $t + 1000$, demostró superioridad consistente en optimización multiobjetivo respecto a métodos tradicionales. La ventaja del método propuesto radica fundamentalmente en su capacidad para adaptar dinámicamente la frecuencia de desfragmentaciones al estado predicho de la red, evitando tanto intervenciones innecesarias en estados saludables como insuficiencia de intervenciones en estados críticos.

6.5. Aportes de la Investigación

Los aportes concretos del presente trabajo al estado del arte en gestión de fragmentación para redes ópticas elásticas multinúcleo son:

1. **Marco conceptual para desfragmentación adaptativa en MC-EON:** Se estableció un marco teórico y metodológico que integra la predicción mediante aprendizaje automático con estrategias adaptativas de desfragmentación, considerando explícitamente las complejidades de la dimensión espacial y las restricciones de crosstalk.
2. **Algoritmo de disparo inteligente:** Se diseñó, implementó y validó experimentalmente un algoritmo completo que abarca preprocesamiento mediante RobustScaler, entrenamiento de clasificador Gradient Boosting, optimización de umbral de decisión, interfaz de consulta en tiempo real, y estrategia de disparo de tres niveles con intervalos adaptativos.
3. **Metodología de evaluación multiobjetivo:** Se aplicaron métricas rigurosas de optimización multiobjetivo (Frente de Pareto, Cobertura de Pareto) para comparación justa de estrategias de desfragmentación, proporcionando un estándar de evaluación reproducible.
4. **Conjunto de datos sintético de tráfico variable:** Se generó mediante simulación un dataset comprehensivo con tres escenarios de carga, diez niveles discretos (800-4,000 Erlangs), seis métricas de fragmentación, y etiquetas binarias para horizonte $t + 1000$. Este dataset puede ser utilizado por la comunidad científica para entrenamiento y evaluación de modelos alternativos.
5. **Evidencia empírica de viabilidad de predicción a largo plazo:** Los resultados demuestran que el horizonte de 1,000 demandas es técnicamente viable para predicción de fragmentación en MC-EON, con autocorrelación temporal suficiente y volatilidad moderada.

6.6. Limitaciones Identificadas

A pesar de los resultados alentadores obtenidos, se reconocen las siguientes limitaciones:

1. **Alcance topológico limitado:** Las evaluaciones se restringieron a la topología USNET (24 nodos, 43 enlaces bidireccionales). La validación en topologías adicionales con características estructurales diferentes permitiría evaluar más comprehensivamente la robustez y generalización del modelo predictivo.
2. **Overhead computacional no cuantificado:** No se cuantificó el tiempo de inferencia requerido para consultas en tiempo real ni el overhead de memoria. Un análisis detallado de latencia de predicción y requisitos de recursos computacionales resultaría valioso para evaluación de viabilidad en implementaciones prácticas de producción.
3. **Determinación empírica de umbrales:** Los valores de umbrales BFR (0.20 y 0.46) fueron determinados empíricamente. Una metodología sistemática de búsqueda automática de umbrales óptimos (búsqueda de grid, optimización bayesiana, o aprendizaje por refuerzo) podría mejorar el desempeño y facilitar adaptación a diferentes contextos.
4. **Horizonte temporal fijo:** El modelo fue entrenado y evaluado con horizonte fijo de $t + 1000$ demandas. La evaluación de horizontes adaptativos que se ajusten dinámicamente según el nivel de congestión podría incrementar la precisión predictiva y la eficiencia operacional.
5. **Tráfico unicast exclusivamente:** Los experimentos se realizaron con tráfico unicast. Redes reales frecuentemente deben gestionar también tráfico multicast y anycast, que introducen patrones de fragmentación y requisitos de recursos diferentes.

6. **Crosstalk modelado de manera simplificada:** Aunque el simulador incorpora restricciones de crosstalk mediante umbral $XT_{TH} = 1,0 \times 10^{-10}$, el modelo predictivo no incluye explícitamente métricas de diafonía como características de entrada. Una caracterización más detallada del impacto diferencial del crosstalk podría mejorar la precisión predictiva.

6.7. Trabajos Futuros

6.7.1. Extensiones Metodológicas

1. **Validación en topologías diversas:** Realizar evaluaciones exhaustivas en topologías adicionales (NSFNET, COST239, topologías sintéticas paramétricas) para identificar si la efectividad del modelo se mantiene consistente o si requiere re-entrenamiento específico por topología.
2. **Optimización automática de hiperparámetros y umbrales:** Implementar búsqueda sistemática mediante grid search, random search, optimización bayesiana para hiperparámetros del modelo y umbrales BFR, con validación cruzada k -fold y meta-aprendizaje para transferencia entre topologías.
3. **Horizontes temporales adaptativos:** Desarrollar mecanismo de selección dinámica de horizonte que se ajuste según nivel de congestión, volatilidad reciente, y precisión histórica de predicciones. Evaluar trade-off entre anticipación y precisión predictiva.
4. **Incorporación de métricas de crosstalk:** Extender el conjunto de características para incluir diafonía agregada por núcleo, distribución de utilización espectral entre núcleos adyacentes, número de violaciones potenciales de umbral, y factor de criticidad por núcleo según geometría.

6.7.2. Extensiones Arquitecturales y Algorítmicas

1. Exploración de arquitecturas de ML alternativas:

- **Redes neuronales recurrentes (LSTM, GRU):** Evaluar si la modelación explícita de dependencias temporales mejora la precisión
- **Transformers con mecanismo de atención:** Investigar si pueden identificar automáticamente patrones temporales relevantes
- **Ensamblajes heterogéneos:** Combinar múltiples modelos mediante votación ponderada o stacking
- **Aprendizaje profundo por refuerzo:** Reformular como MDP donde un agente aprende política óptima de disparo

2. Predicción multi-horizonte:

Entrenar modelos que predigan simultáneamente el índice BFR en múltiples horizontes ($t + 500$, $t + 1000$, $t + 1500$, $t + 2000$), permitiendo evaluar trayectorias futuras y anticipar con mayor precisión el momento óptimo.

3. Aprendizaje continuo (online learning):

Implementar mecanismos de actualización incremental del modelo conforme se observan nuevos datos operacionales, permitiendo adaptación automática a cambios en patrones de tráfico.

4. Interpretabilidad mejorada:

Aplicar técnicas de explainable AI (SHAP values, LIME, análisis de importancia de características) para identificar qué métricas contribuyen más significativamente a las predicciones.

6.7.3. Extensiones a Otros Contextos Operacionales

1. Tráfico heterogéneo:

Extender el método para gestionar simultáneamente tráfico multicast, anycast, con diferenciación de QoS, y requisitos de resiliencia.

2. **Integración con otros mecanismos de optimización:** Combinar con algoritmos RMSCA conscientes de fragmentación, técnicas de previsión de tráfico, mecanismos de conmutación de núcleos, y políticas de migración selectiva.
3. **Redes ópticas con arquitecturas heterogéneas:** Evaluar en escenarios con fibras de diferente número de núcleos, enlaces con diferentes capacidades espectrales, y nodos con diferentes capacidades de conmutación.
4. **Coordinación con plano de control distribuido:** Investigar integración con protocolos SDN y arquitecturas GMPLS para coordinación distribuida, sincronización de reconfiguraciones, y mecanismos de rollback.

6.7.4. Validación Experimental en Entornos Reales

1. **Prototipado en testbed experimental:** Implementar el método en testbeds académicos (GÉANT, ESnet) para validar precisión con tráfico real, cuantificar overhead computacional, evaluar robustez ante eventos inesperados, y medir satisfacción de operadores.
2. **Análisis de costos operacionales:** Realizar estudio económico comparativo cuantificando costos de interrupciones, bloqueos, operación del modelo ML, y ROI del sistema propuesto.
3. **Estudios de caso industriales:** Colaborar con operadores de telecomunicaciones para evaluar en escenarios de producción reales, considerando patrones de tráfico reales, requisitos regulatorios, integración con sistemas legacy, y aceptación de equipos de operaciones.

6.8. Reflexiones Finales

La gestión eficiente de recursos en redes ópticas elásticas multinúcleo representa un desafío técnico de relevancia creciente en el contexto de demandas exponenciales de capacidad de transmisión. La fragmentación espectro-espacial constituye un obstáculo significativo para la utilización óptima de estos sistemas, requiriendo estrategias de desfragmentación que balanceen cuidadosamente los costos operacionales de reconfiguración contra los beneficios de reducción de bloqueos.

El presente trabajo demuestra que las técnicas modernas de aprendizaje automático, específicamente el algoritmo Gradient Boosting, pueden aplicarse exitosamente para resolver el problema de determinación del momento óptimo de desfragmentación en redes MC-EON. La capacidad demostrada de predecir con alta precisión el índice de fragmentación en horizontes temporales extensos permite la implementación de estrategias adaptativas que superan significativamente a métodos tradicionales.

Los resultados experimentales obtenidos validan la viabilidad técnica y la superioridad del método propuesto. Sin embargo, la transición de validación experimental en simulación a despliegue en redes de producción reales requiere abordar las limitaciones identificadas, particularmente en términos de generalización topológica, cuantificación de overhead computacional, y validación en condiciones operacionales heterogéneas.

Las direcciones de trabajo futuro identificadas proporcionan un mapa de ruta claro para evolución de esta línea de investigación. La exploración de arquitecturas de ML alternativas, la extensión a tráfico heterogéneo, y particularmente la validación en testbeds reales y estudios de caso industriales, constituyen pasos naturales hacia la maduración de sistemas de gestión autónoma de redes ópticas basados en inteligencia artificial.

En última instancia, este trabajo contribuye a la visión de redes de próxima ge-

neración auto-optimizadas y autónomas, donde sistemas de aprendizaje automático asisten a operadores humanos en la toma de decisiones complejas de gestión de recursos, permitiendo redes más eficientes, resilientes y escalables para soportar las demandas de conectividad del futuro.

Bibliografía

- [1] Michal Aibin y Krzysztof Walkowiak. «Defragmentation algorithm for joint dynamic and static routing problems in elastic optical networks with unicast and anycast traffic». En: *2016 International Conference on Computing, Networking and Communications (ICNC)*. IEEE. 2016, págs. 1-5.
- [2] Masahiko Jinno et al. «Spectrum-efficient and scalable elastic optical path network: architecture, benefits, and enabling technologies». En: *IEEE communications magazine* 47.11 (2009), págs. 66-73.
- [3] *Spectral grids for WDM applications: DWDM frequency grid*. Recommendation G.694.1. International Telecommunication Union (ITU-T), 2012.
- [4] Katsuhiro Takenaga et al. «A large effective area multi-core fiber with an optimized cladding thickness». En: *Optics express* 19.26 (2011), B543-B550.
- [5] Katsuhiro Takenaga et al. «Reduction of crosstalk by trench-assisted multi-core fiber». En: *2011 Optical Fiber Communication Conference and Exposition and the National Fiber Optic Engineers Conference*. IEEE. 2011, págs. 1-3.
- [6] Yu Lei et al. «Crosstalk-aware routing, core, and spectrum assignment with core switching in sdm-eons». En: *2019 18th International Conference on Optical Communications and Networks (ICOON)*. IEEE. 2019, págs. 1-3.
- [7] Yu Xiong et al. «A machine learning approach to mitigating fragmentation and crosstalk in space division multiplexing elastic optical networks». En: *Optical Fiber Technology* 50 (2019), págs. 99-107.

- [8] Weiran Shi et al. «On the effect of bandwidth fragmentation on blocking probability in elastic optical networks». En: *IEEE transactions on communications* 61.7 (2013), págs. 2970-2978.
- [9] Silvana Trindade y Nelson LS da Fonseca. «Machine Learning for Spectrum Defragmentation in Space-Division Multiplexing Elastic Optical Networks». En: *IEEE Network* 35.1 (2020), págs. 326-332.
- [10] Juan Zhang et al. «3D Fragmentation Metric and RCSA Scheme for Space Division Multiplexing Elastic Optical Networks». En: *IEEE Access* (2020). Supported by National Key Research and Development Program of China under Grant 2018YFF0301004, National Natural Science Foundation of China under Grant 61905060, and Natural Science Foundation of Hebei Province.
- [11] Bijoy Chand Chatterjee, Seydou Ba y Eiji Oki. «Fragmentation problems and management approaches in elastic optical networks: A survey». En: *IEEE Communications Surveys & Tutorials* 20.1 (2017), págs. 183-210.
- [12] Sahar Talebi et al. «Spectrum management techniques for elastic optical networks: A survey». En: *Optical Switching and Networking* 13 (2014), págs. 34-48.
- [13] Mingyang Zhang et al. «Dynamic and adaptive bandwidth defragmentation in spectrum-sliced elastic optical networks with time-varying traffic». En: *Journal of Lightwave Technology* 32.5 (2014), págs. 1014-1023.
- [14] Jaume Comellas, Laura Vicario y Gabriel Junyent. «Periodic Defragmentation in Elastic Optical Networks». En: *2018 20th International Conference on Transparent Optical Networks (ICTON)*. IEEE. 2018, págs. 1-4.
- [15] Tom Mitchell. «Machine learning». En: (1997).
- [16] Jerome H Friedman. «Greedy function approximation: a gradient boosting machine». En: *Annals of statistics* 29.5 (2001), págs. 1189-1232.

- [17] Enrique Dávalos et al. «Triggering strategy for defragmentation process in Elastic Optical Networks using Machine Learning techniques». En: *ICT Express* 9.5 (2023), págs. 890-895. DOI: 10.1016/j.icte.2023.01.008.
- [18] Yutaka Takita et al. «Wavelength defragmentation with minimum optical path disruptions for seamless service migration». En: *Optical Fiber Communication Conference*. Optical Society of America. 2016, M2J-3.
- [19] Ricardo V Fávero et al. «A new elastic optical network defragmentation strategy based on the reallocation of lightpaths sharing the most fragmented link». En: *2015 SBMO/IEEE MTT-S International Microwave and Optoelectronics Conference (IMOC)*. IEEE. 2015, págs. 1-5.
- [20] Mingyang Zhang et al. «Bandwidth defragmentation in dynamic elastic optical networks with minimum traffic disruptions». En: *2013 IEEE International Conference on Communications (ICC)*. IEEE. 2013, págs. 3894-3898.
- [21] Jie Zhang et al. «Priority-based defragmentation scheme in spectrum-efficient optical networks». En: *The 10th International Conference on Optical Internet (COIN2012)*. IEEE. 2012, págs. 16-17.
- [22] Fabian Pedregosa et al. «Scikit-learn: Machine learning in Python». En: *Journal of machine learning research* 12.Nov (2011), págs. 2825-2830.
- [23] Bijoy Chand Chatterjee, Nityananda Sarma y Eiji Oki. «Routing and spectrum allocation in elastic optical networks: A tutorial». En: *IEEE Communications Surveys & Tutorials* 17.3 (2015), págs. 1776-1800.
- [24] M Quagliotti et al. «Spectrum fragmentation metrics and their use in optical channel allocation algorithms». En: (2017).
- [25] Enrique J Dávalos et al. «Spectrum defragmentation in elastic optical networks: Two Approaches With Metaheuristics». En: *IEEE Access* 7 (2019), págs. 119835-119843.

- [26] Xiao Luo et al. «Leveraging double-agent-based deep reinforcement learning to global optimization of elastic optical networks with enhanced survivability». En: *Optics express* 27.6 (2019), págs. 7896-7911.
- [27] Sandeep Kumar Singh y Admela Jukan. «Machine-learning-based prediction for resource (re) allocation in optical data center networks». En: *Journal of Optical Communications and Networking* 10.10 (2018), págs. D12-D28.
- [28] Paul Wright, Michael C Parker y Andrew Lord. «Minimum-and maximum-entropy routing and spectrum assignment for flexgrid elastic optical networking». En: *Journal of Optical Communications and Networking* 7.1 (2015), A66-A72.
- [29] Yaghoub Khorasani, Akbar Ghaffarpour Rahbar y Mohammad Jafari-Beyrami. «A novel two-dimensional metric for fragmentation evaluation in elastic optical networks». En: *Computer Networks Lab, Faculty of Electrical Engineering, Sahand University of Technology* (2018).
- [30] Zehua Guo et al. «Improving the performance of load balancing in software-defined networks through load variance-based synchronization». En: *Computer Networks* 68 (2014), págs. 95-109.
- [31] Michal Aibin. «Traffic prediction based on machine learning for elastic optical networks». En: *Optical Switching and Networking* 30 (2018), págs. 33-39.