

UNIVERSIDAD NACIONAL DE ASUNCIÓN

Facultad Politécnica



“ESTRATEGIA DE DISPARO PARA EL PROCESO DE
DESFRAGMENTACIÓN EN REDES ÓPTICAS ELÁSTICAS
MULTICORE, UTILIZANDO TÉCNICAS DE APRENDIZAJE
AUTOMÁTICO”

TRABAJO FINAL DE GRADO PRESENTADO POR

RODOLFO SEBASTIÁN VERGARA FERREIRA
Y DIEGO DANIEL DUARTE CENTURIÓN

COMO REQUISITO
PARA OBTENER EL TÍTULO DE INGENIERO
EN INFORMÁTICA

ORIENTADOR:
PHD. MSc. ING. ENRIQUE DAVALOS

San Lorenzo - Paraguay.

Noviembre de 2025

Índice general

Índice de Figuras	VI
Índice de Tablas	VII
Lista de Símbolos	VIII
1. Introducción	1
1.1. Justificación	1
1.2. Objetivos del trabajo	5
1.2.1. Objetivo General	5
1.2.2. Objetivos Específicos	5
1.3. Organización del libro	6
2. Redes Ópticas Elásticas Multicore y Fragmentación del Ancho de Banda	7
2.1. Redes EON Multinúcleo	8
2.2. Diafonía en Redes Ópticas Elásticas Multinúcleo	10
2.2.1. Cálculo de la diafonía	13
2.2.2. Asignación de espectro con conmutación de núcleo	14
2.3. Fragmentación del Ancho de Banda en MC-EON	17
2.3.1. Enfoques de gestión de fragmentación	21
2.4. Descripción del problema tratado	23

3. Aprendizaje Automático	25
3.1. Clasificación de sistemas o tipos de aprendizaje automático	26
3.2. Gradient Boosting	28
3.2.1. Fundamentos del Aprendizaje por Ensamble	29
3.2.2. Algoritmo de Gradient Boosting	29
3.2.3. GradientBoostingClassifier	31
3.2.4. Configuración e Hiperparámetros	31
3.2.5. Aplicación en MC-EON	33
4. Método Propuesto	35
4.1. Estrategia de Desfragmentación Adaptativa	35
4.2. Características Utilizadas	36
4.3. Generación de Datos de Entrenamiento	38
4.3.1. Simulador y Topología	38
4.3.2. Modelo de Carga Variable	39
4.3.3. Niveles Discretos de Carga	40
4.3.4. Identificación de Fases Operativas	43
4.4. Herramientas de Implementación	44
4.5. Arquitectura del Sistema de Predicción	45
4.5.1. Modelo para Umbral Mínimo ($BFR = 0.20$)	45
4.5.2. Modelo para Umbral Crítico ($BFR = 0.46$)	45
4.6. Proceso de Entrenamiento	46
4.6.1. División Estratificada de Datos	46
4.6.2. Preprocesamiento	47
4.6.3. Entrenamiento Iterativo y Monitoreo	47
4.6.4. Optimización de Umbrales de Decisión	48
4.7. Resultados de Predicción	48
4.7.1. Métricas de Evaluación	48

4.7.2.	Análisis de Predictibilidad del Horizonte	49
4.7.3.	Resultados del Modelo de Umbral Crítico ($BFR = 0.46$) . . .	49
4.7.4.	Resultados del Modelo de Umbral Mínimo ($BFR = 0.20$) . . .	50
4.7.5.	Justificación de Gradient Boosting	51
4.7.6.	Validación de la Estrategia de Dos Umbrales	52
4.8.	Implementación del Sistema	52
4.8.1.	Arquitectura de Servicios	52
4.8.2.	Formato de Entrada y Salida	53
4.8.3.	Lógica de Control de Desfragmentación	54
4.8.4.	Persistencia y Reproducibilidad	55
5.	Pruebas y Resultados Obtenidos	56
5.1.	Configuración Experimental	56
5.1.1.	Topología y Parámetros de Red	56
5.1.2.	Escenarios de Carga Evaluados	57
5.2.	Métodos Comparados	58
5.2.1.	Método Propuesto (MP): Desfragmentación Adaptativa con ML	58
5.2.2.	Método de Referencia 1 (MR1): Desfragmentación Periódica por Tiempo Fijo	59
5.2.3.	Método de Referencia 2 (MR2): Desfragmentación por Umbral de BFR	60
5.3.	Objetivos de Optimización	60
5.3.1.	Objetivo 1: Cantidad de Bloqueos (BL)	61
5.3.2.	Objetivo 2: Cantidad de Reconfiguraciones (RC)	61
5.3.3.	Métricas de Evaluación Multiobjetivo	61
5.4.	Resultados Experimentales	62
5.4.1.	Escenario 1: Carga Baja (800 - 3,000 Erlangs)	62
5.4.2.	Escenario 2: Carga Media (1,200 - 3,400 Erlangs)	63

5.4.3. Escenario 3: Carga Alta (2,000 - 4,000 Erlangs)	65
5.4.4. Variante con Doble Predictor (3 Niveles)	66
5.5. Análisis Comparativo Multiobjetivo	67
5.5.1. Soluciones en el Frente de Pareto	67
5.5.2. Cobertura de Pareto	68
5.5.3. Eficiencia en Uso de Recursos	69
5.6. Validación del Horizonte de Predicción	69
5.7. Discusión de Resultados	70
5.7.1. Superioridad del Método Propuesto	70
5.7.2. Ventajas de la Estrategia Adaptativa	71
5.7.3. Comparación con Métodos Tradicionales	71
6. Conclusiones y Trabajos Futuros	73
6.1. Conclusiones del Trabajo	74
6.1.1. Cumplimiento de Objetivos	74
6.1.2. Contribuciones Principales	76
6.1.3. Validación Experimental	77
6.1.4. Validación de la Hipótesis	78
6.2. Aportes de la Investigación	79
6.3. Limitaciones Identificadas	81
6.4. Trabajos Futuros	82
6.4.1. Extensiones Metodológicas	83
6.4.2. Extensiones Arquitecturales y Algorítmicas	84
6.4.3. Extensiones a Otros Contextos Operacionales	86
6.4.4. Validación Experimental en Entornos Reales	87
6.5. Reflexiones Finales	88

Índice de figuras

2.1. Ejemplo de Fibras Multinúcleo (MCF) con 7, 12 y 19 núcleos	9
2.2. Core Pitch entre dos núcleos adyacentes en un MCF de 7 núcleos . . .	10
2.3. XT en un Fibra MCF de 3 núcleos \llbracket	12
2.4. Conmutación de núcleos con contigüidad de espectro \llbracket	14
2.5. Asignación de espectro sin conmutación de núcleos \llbracket	16
2.6. Asignación de espectro con conmutación de núcleos \llbracket	17
2.7. Restricciones de contigüidad y continuidad aplicadas- Conexión Re- chazada	20
2.8. Restricciones de contigüidad y continuidad aplicadas- Conexión Es- tablecida	20
2.9. Esquema de Gestión de la Fragmentación	22
2.10. Ejemplo de desfragmentaciones periódicas con volumen de carga de tráfico variado	24
4.1. Componentes armónicas del modelo de carga	40
4.2. Modelo matemático completo de evolución de carga	40
4.3. Niveles de carga simulados	41
4.4. Distribución de niveles de carga en la simulación	41
4.5. Evolución temporal de la carga	42
4.6. Frecuencia de ocurrencia de niveles de carga	42
4.7. Distribución de fases operativas	43

4.8. Muestra de datos temporales generados	44
--	----

Lista de Tablas

4.1. Resultados del modelo Gradient Boosting para umbral crítico (BFR = 0.46)	50
4.2. Resultados del modelo Gradient Boosting para umbral mínimo (BFR = 0.20)	50
5.1. Configuración de escenarios de carga evaluados	58
5.2. Resultados comparativos - Escenario 1 (Carga Baja)	63
5.3. Resultados comparativos - Escenario 2 (Carga Media)	64
5.4. Resultados comparativos - Escenario 3 (Carga Alta)	65
5.5. Resultados con estrategia de doble predictor (3 niveles)	67
5.6. Distribución de soluciones en el Frente de Pareto	67
5.7. Cobertura de Pareto entre métodos (agregado 3 escenarios)	68
5.8. Validación del horizonte de predicción $t + 1000$	70

Lista de Símbolos

HM	<i>High-slot Mark.</i>
HM_{max}	HM máximo.
Ent_{link}	Entropía del enlace.
Ent_{link-i}	Entropía del enlace i .
Ent_{red}	Entropía de la red.
N	Cantidad de FS en un enlace.
FS_i	<i>Frecuency Slot</i> de índice i .
FS_{i+1}	<i>Frecuency Slot</i> de índice $i + 1$.
$ E $	Cantidad de enlaces de la red.
SHF_{link}	Entropía de Shannon del enlace.
SHF_{link-i}	Entropía de Shannon del enlace i .
SHF_{red}	Entropía de Shannon de la red.
S_{free}	Cantidad de FS libres en un enlace.
BFR_{link}	Relación de Fragmentación de ancho de banda de un enlace.
BFR_{link-i}	Relación de Fragmentación de ancho de banda del enlace i .
BFR_{red}	Relación de Fragmentación de ancho de banda de la red.
$MaxBlock()$	Tamaño del mayor bloque de FS bloqueados.
MSI	Índice de slot máximo utilizado.
MSI_{link-i}	Índice de slot máximo utilizado del enlace i .
MSI_{red}	Índice de slot máximo utilizado de la red.

CE_{link}	Consecutividad del espectro.
CE_{red}	Consecutividad del espectro de la red.
$Joins$	Cantidad total de bloques de dos ranuras libres adyacentes distintos dentro de un enlace.
$Bloques$	Cantidad de bloques de ranuras libres en un enlace.
K	Cantidad de rutas de dos enlaces en la red.
Uso	Porcentaje de utilización de la red.
$sum(i)$	Cantidad de FS utilizadas en el enlace i .
FSB	Acumulación de FS bloqueados.
S_i^{block}	Cantidad de FS solicitadas por la demanda bloqueada i .
D	Cantidad de demandas.
T	Ventada de tiempo seleccionada para el calculo de IB .
PB_t	Índice de bloqueo para el tiempo t .
FSD_i	Cantidad de FS demandadas en el tiempo t .
$train_{mean}$	Media de valores.
$train_{stf}$	Desviación estándar.
MAE	Error Absoluto Medio.
MSE	Error Cuadrático Medio.
PB	Probabilidad de Bloqueo.
PB_{th}	Umbral para disparar el proceso de desfragmentación.
BL	Cantidad de Bloqueos.
RC	Cantidad de Reconfiguraciones.
SFP	Número de soluciones en el Frente Pareto.
CP	Cobertura Pareto.
MP	Método Propuesto.

Capítulo 1

Introducción

1.1. Justificación

Debido al incremento de la popularidad de internet y del uso de servicios en la nube, tales como *Content Delivery Network* (CDN) y *Video on Demand* (VoD), las demandas de tasas de bits en las redes han crecido de manera exponencial, lo que obliga a estudiar nuevas y mejores tecnologías relacionadas a la transmisión de datos.

Las Redes de Multiplexación por División de Longitud de Onda o *Wavelength Division Multiplexing* (WDM), utilizan una grilla fija, de 50 o 100 GHz, dan una gran ventaja logrando velocidades muy superiores frente a las viejas tecnologías, pero a pesar de esta ventaja señalada, la gruesa granularidad lleva a un uso ineficiente del espectro, ya que cada demanda es asignada a un canal fijo y estas pueden requerir un ancho de banda menor al tamaño del canal.

Esta desventaja da lugar a las Redes Elásticas Ópticas o *Elastic Optical Networks* (EON) [1], las cuales surgen como una solución al problema anteriormente citado, ya que estas proporcionan una mayor flexibilidad en la división del espectro y de esa forma lograr que los requerimientos sean asignados de manera más eficiente.

A las redes EON también se la conocen como redes de grilla flexible, debido a que las ranuras de frecuencia o FS (*Frequency Slot*) que reemplazan a los “Canales

WDM”, cuentan con una división más flexible. Cada FS tiene un ancho de banda de 12.5 GHz, de esta manera se logra una cantidad más apropiada de FS para satisfacer un requerimiento.

Sin embargo, a pesar de las mejoras introducidas por las redes EON, el crecimiento exponencial del tráfico de datos demanda soluciones aún mas avanzadas. En este contexto, surgen las Redes Ópticas Elásticas Multicore o *Elastic Optical Networks with Multicore Fibers* (EON-MCF) y por consecuente *Space Division Multiplexing-Elastic Optical Networks* (SDM-EON) , que incorporan fibras ópticas multinúcleo (MCF), para multiplicar la capacidad de transmisión mediante la explotación de la dimensión espacial, ademas de las dimensiones espectral y temporal ya utilizadas en las redes EON convencionales.

Las fibras multinúcleo contienen múltiples núcleos dentro de una única fibra, donde cada núcleo puede transmitir señales de manera independiente. Esta arquitectura permite aumentar significativamente la capacidad de la red sin necesidad de desplegar nuevas fibras, ofreciendo una solución escalable y económicamente viable para satisfacer las crecientes demandas de ancho de banda.

Los métodos de ruteo y asignación del espectro y núcleo tienen gran impacto sobre el uso eficiente de los recursos de la red. Los algoritmos RSCA (*Routing, Spectrum and Core Assignment*) se encargan de resolver dicho problema encontrando el camino más apropiado desde el origen hasta el destino, el núcleo a utilizar y las ranuras que utilizará el requerimiento dentro del espectro de los enlaces.

Se han propuestos varios algoritmos RSCA con el fin de conseguir la mejor utilización de recursos, estos algoritmos están sujetos a tres principios fundamentales: la restricción de consecutividad del ancho de banda, la restricción de la continuidad del ancho de banda y la restricción de continuidad de núcleo.

La restricción de continuidad espectral establece que se deben utilizar los mismos FS en todo el camino y la restricción de contigüidad dispone que los FS seleccionados para satisfacer la demanda deben ser contiguos. La restricción de continuidad de

núcleo específica que se debe mantener el mismo núcleo a lo largo de toda la ruta establecida.

Adicionalmente, en las redes SDM-EON surge un nuevo fenómeno denominado *Crosstalk* o diafonía entre núcleos *inter-core crosstalk*, *XT*, que ocurre cuando las señales ópticas de núcleos adyacentes interfieren entre sí, degradando la calidad de la transmisión. Este fenómeno debe ser considerado como una restricción adicional en los algoritmos RSCA para garantizar la calidad del servicio.

Debido a las restricciones explicadas y a que las asignaciones de recursos son realizadas de manera dinámica, surge el fenómeno denominado "Fragmentación del Ancho de Banda y del Espacio", este problema es una de las principales dificultades de las redes SDM-EON ya que tiene un impacto directo en el uso eficiente del espectro y de los núcleos disponibles.

El fenómeno de la fragmentación espectro-espacial del ancho de banda sucede cuando en los enlaces se encuentran FS disponibles separados por FS que están siendo utilizados por otras conexiones, o cuando existen núcleos con recursos fragmentados que no pueden ser eficientemente asignados, por lo que estas podrían quedar inutilizables para nuevas conexiones por no poder satisfacer a la demanda debido a las restricciones citadas anteriormente, en consecuencia, la probabilidad de bloqueo [2] aumenta considerablemente.

Un bloqueo sucede cuando el algoritmo RSCA no puede encontrar núcleos y FS disponibles para una demanda, esto puede deberse a una alta saturación del espectro o de los núcleos, pero también debido al problema mencionado anteriormente, donde existe la cantidad de FS libres que se solicitan, pero sin respetar las restricciones de continuidad y contigüidad, o donde no hay núcleos disponibles que cumplan con las restricciones de crosstalk, es decir el espectro y el espacio se encuentran fragmentados.

El problema de la fragmentación de redes SDM-EON es ampliamente estudiado en la literatura actual, para buscar manejarlo se han propuesto soluciones con

distintos enfoques.

Uno de los enfoques es el llamado *Enfoque proactivo* el cual consiste en ejecutar un proceso de desfragmentación periódicamente o mediante un disparador. Tiene como principal objetivo prevenir futuros bloqueos en la red, este enfoque será el utilizado en este trabajo.

El proceso de desfragmentación consiste en la reconfiguración o re-ruteo de un sub-conjunto de conexiones ya establecidas en la red, teniendo como principal objetivo reducir la fragmentación del espectro y la fragmentación espacial mediante la eliminación de bloques de FS libres no contiguos y la redistribución eficiente de conexiones entre núcleos.

En el trabajo presentado por Zhang [3], se realizó un análisis del problema de desfragmentación en redes EON, en el cual lo dividen en cuatro subproblemas, los cuales son, (I) ¿Cómo reconfigurar?, (II) ¿Cómo migrar el tráfico?, (III) ¿Cuándo reconfigurar? y (IV) ¿Qué reconfigurar?. Estos subproblemas mantienen su vigencia en el contexto de las redes SDM-EON, con la complejidad adicional de considerar la dimensión espacial.

En este trabajo nos centraremos en el tercer subproblema, ¿Cuándo reconfigurar?, ya que considerando el enfoque proactivo para resolver el problema de la fragmentación, encontramos que los procesos de desfragmentación podrían ejecutarse en periodos de tiempo donde no son del todo necesarios, es decir cuando la red se encuentra con una baja fragmentación, provocando desfragmentaciones ineficientes, una cantidad mayor de interrupciones de conexiones y una elevación innecesaria del costo de procesamiento.

En los siguientes capítulos presentamos modelos de predicción de índice de fragmentación, entrenados para detectar si supera unos umbrales predefinidos, implementados con técnicas de aprendizaje automático o *Machine Learning*, los cuales se utilizan como estrategia de disparo del proceso de desfragmentación pero en este caso redes SDM-EON Multinúcleo, proponiendo de esta manera una solución al sub

problema planteado anteriormente.

1.2. Objetivos del trabajo

1.2.1. Objetivo General

Diseñar modelos de predicción para el proceso de desfragmentación en redes ópticas elásticas multicore, utilizando técnicas de aprendizaje automático, con el propósito de maximizar la eficiencia en el uso de los recursos de la red mediante la reducción de reconfiguraciones innecesarias y la minimización de la cantidad de bloqueos.

1.2.2. Objetivos Específicos

- Realizar una revisión bibliográfica del estado del arte en técnicas de desfragmentación para redes ópticas elásticas, con énfasis en métodos basados en aprendizaje automático y su aplicación en redes multicore.
- Identificar y definir métricas de fragmentación apropiadas para redes ópticas elásticas multicore, considerando las particularidades de la asignación de recursos en múltiples núcleos.
- Desarrollar e implementar un modelo de aprendizaje automático capaz de predecir el índice de la fragmentación de la red a futuro y determinar momentos óptimos para activar el proceso de desfragmentación en redes EON multicore.
- Diseñar e implementar una interfaz de integración entre el simulador de redes ópticas elásticas multicore y el modelo de aprendizaje automático entrenado, permitiendo la evaluación en tiempo real del sistema propuesto.
- Evaluar el desempeño del modelo propuesto mediante simulaciones, comparando sus resultados con técnicas de desfragmentación existentes en términos

de probabilidad de bloqueo, número de reconfiguraciones y eficiencia en el uso de recursos espectrales.

1.3. Organización del libro

El presente trabajo se encuentra organizado de la siguiente manera:

En el capítulo dos se trata sobre características y conceptos relacionados con las redes EON, su principal dificultad (la fragmentación del ancho de banda), los diferentes enfoques para manejar la misma y una presentación de trabajos relacionados presentes en la literatura científica.

En el capítulo tres se hace una introducción al *Machine learning*, enfocado al aprendizaje supervisado y redes neuronales.

En el capítulo cuatro se presenta el método propuesto para la selección del momento de desfragmentación, describiendo todo el proceso que conlleva.

El capítulo cinco se muestra las pruebas experimentales junto a un análisis de los resultados obtenidos.

Por último, el capítulo seis presenta las conclusiones del trabajo y sugerencias para trabajos futuros.

Capítulo 2

Redes Ópticas Elásticas Multicore y Fragmentación del Ancho de Banda

Las redes ópticas que se basan en WDM dividen el espectro de cada enlace en canales cuyo ancho de banda se fija de 50 GHz o 100 GHz. Esto debido a que la Unión Internacional de Telecomunicaciones (*ITU-T International Telecommunication Union*) especificó el estándar G.694.1 en el año 2002. Estas redes WDM resultan muy rígidas, y debido a eso es posible que ocurra una utilización ineficiente de la capacidad, provocado por el hecho de que el espacio entre dos canales adyacentes es relativamente grande y si la señal que se transmite utiliza un ancho de banda muy bajo, gran parte del espectro será desperdiciado.

Una nueva tecnología denominada Redes Ópticas Elásticas o *Elastic Optical Networks* (EON) y su evolución: Las Redes ópticas Elásticas Multinúcleo o *Multicore Elastic Optical Networks* (MC-EON) el cual no solo dividen el espectro óptico en Ranuras de Frecuencia o *Frequency Slots* (FS) de 12.5 GHz conforme a lo establecido por el estándar definido en ITU-T (G.694.1) en el año 2012, sino que las (MC-EON) introducen un nuevo dominio de multiplexación espacial, al permitir la transmisión simultánea de múltiples señales ópticas en diferentes núcleos dentro de una misma fibra. Esta aproximación multidimensional proporciona una mayor escalabilidad, eficiencia en la asignación del espectro y reducción del consumo energético, posicionando a las MC-EON como una de las tecnologías mas prometedoras para la

implementación de redes ópticas de ultra alta capacidad en escenarios de próxima generación.

2.1. Redes EON Multinúcleo

Las redes EON Multinúcleo constituyen una variante avanzada de las redes EON que integran el concepto de fibras multinúcleo (MCF) para incrementar significativamente la capacidad de transmisión y la eficiencia espectral. Fundamentalmente, las redes EON Multinúcleo aprovechan múltiples núcleos independientes dentro de una misma fibra óptica para transmitir señales de forma simultánea y paralela, posibilitando una multiplicación de la capacidad de transmisión en comparación con las fibras convencionales [15]. Estas características mencionadas en las EON Multinúcleo se materializan mediante la implementación de la Multiplexación por División de Espacio (SDM). Por esta razón, las redes EON Multinúcleo también se denominan SDM-EON[5]. En las redes EON Multinúcleo, se integra el concepto de asignación flexible de espectro con la utilización de múltiples núcleos, alcanzando una distribución más eficiente de la capacidad total de transmisión. Esta integración de tecnologías posibilita un incremento sustancial en la capacidad de transmisión a través de una única fibra, resultando esencial en un contexto donde la demanda de datos continúa creciendo de manera exponencial. Al incorporar el concepto de fibras multinúcleo en el diseño de las redes EON, se puede lograr una mayor adaptabilidad a las cambiantes necesidades del tráfico y una optimización más profunda de los recursos disponibles.




Figura 3.5:
MCF con 7 núcleos [5]




Figura 3.6:
MCF con 12 núcleos [5]




Figura 3.7:
MCF con 19 núcleos [5]

Figura 2.1: Ejemplo de Fibras Multinúcleo (MCF) con 7, 12 y 19 núcleos

Conforme a lo documentado en la literatura [1], inicialmente podría considerarse que la utilización de redes EON con mayor cantidad de núcleos proporciona ventajas sustanciales debido a la amplia disponibilidad de recursos espectrales y espaciales. No obstante, se ha identificado que en las redes MCF, el principal desafío radica en la interferencia denominada diafonía (crosstalk), la cual se genera cuando una fracción de la potencia óptica de un núcleo se propaga hacia los núcleos contiguos. Este fenómeno ocasiona una interferencia significativa en los circuitos activos y complejiza considerablemente la asignación de las ranuras espectrales (FS). Investigaciones previas [2, 3] han indicado que para viabilizar la implementación de redes EON multinúcleo, resulta fundamental desarrollar fibras que minimicen la diafonía entre núcleos adyacentes.

En la Figura 2.1, se presenta una configuración de MCF con 7 núcleos dispuestos en un patrón hexagonal. En esta arquitectura, el núcleo central (núcleo N° 6) se encuentra rodeado por 6 núcleos adyacentes, resultando en una mayor incidencia de diafonía sobre este núcleo. En contraste, los núcleos periféricos (núcleos N° 0, 1, 2, 3, 4 y 5) poseen 3 núcleos adyacentes cada uno. La Figura 2.2 exhibe una MCF con 12 núcleos organizados en una disposición anular. En esta configuración, cada núcleo presenta exactamente 2 núcleos adyacentes, lo que deriva en que todos los núcleos

experimenten un nivel equivalente de diafonía.

Finalmente, la Figura 2.2 ilustra una MCF con 7 núcleos. En este tipo de fibras, los núcleos pueden presentar hasta 6 núcleos adyacentes por núcleo, generando una mayor incidencia de diafonía.




Figura 2.2: Core Pitch entre dos núcleos adyacentes en un MCF de 7 núcleos

2.2. Diafonía en Redes Ópticas Elásticas Multinúcleo

La diafonía constituye un fenómeno indeseado que se manifiesta en las redes de fibra óptica cuando la señal transmitida en una fibra se acopla hacia otra fibra contigua. En el contexto de las redes EON fundamentadas en MCF, la diafonía se define como la interferencia entre conexiones ópticas establecidas en núcleos adyacentes que emplean las mismas ranuras espectrales (FS) en un enlace común. Este tipo de interferencia se denomina diafonía entre núcleos o Inter-Core Crosstalk (XT). La interferencia ocasionada por el XT puede degradar la calidad de la señal en las FS afectadas, lo que implica que la señal en estas ranuras puede experimentar

distorsiones, incrementando la probabilidad de errores en la transmisión de datos.

Consecuentemente, impacta directamente en la capacidad de la red al «inhabilitar» estas FS para la transferencia de datos debido a la diafonía, generando espacios no utilizables entre ellas.

En síntesis, esto deriva en una reducción de la cantidad total de FS disponibles para la transmisión de datos, limitando la capacidad operativa de la red. Con menor disponibilidad de FS, se reducen los canales para transmitir datos, lo que puede restringir la capacidad total de transmisión de la infraestructura de red.

En las redes SDM-EON, el XT entre dos núcleos de una MCF depende significativamente de la distancia entre dicho par de núcleos, denominada core pitch ($\Lambda_{i,j}$). A mayor core pitch, menor será el impacto del XT entre estos dos núcleos [1]. No obstante, resulta importante destacar que, a medida que se incrementa el core pitch, la capacidad de la fibra óptica disminuye. Es decir, al aumentar la distancia física entre dos núcleos, se reduce el espacio disponible en la fibra óptica para albergar núcleos adicionales. Por consiguiente, resulta fundamental establecer un equilibrio entre un core pitch reducido para incrementar la capacidad y uno suficientemente amplio para minimizar los efectos del XT. Este balance posibilita optimizar el desempeño y la eficiencia de la red.

Para demostrar el comportamiento del crosstalk (XT) entre núcleos en fibras multinúcleo, se analiza el ejemplo presentado en la figura 2.1, la cual ilustra una fibra óptica multinúcleo (MCF) compuesta por tres núcleos organizados en configuración lineal. En esta topología, resulta evidente que el núcleo central (núcleo 2) experimenta una interferencia significativa por XT intercore. Este fenómeno se atribuye a que ambos núcleos contiguos (núcleos 1 y 3) mantienen conexiones establecidas en intervalos espectrales similares a aquellos ya ocupados en el núcleo 2. A modo de ejemplo, los segmentos espectrales FS1 y FS2 resultan inutilizables en el núcleo 2 debido a la interferencia generada por las asignaciones activas en los núcleos laterales. Esta misma situación se replica en los intervalos FS4, FS5 y FS6 del núcleo

mencionado. Consecuentemente, en arquitecturas SDM-EON basadas en fibras multinúcleo, resulta imperativo evaluar el impacto del XT intercore durante el proceso de asignación de recursos espectrales, a fin de mitigar degradaciones en la calidad de transmisión.

Es relevante destacar que el crosstalk intercore no afecta exclusivamente a los segmentos espectrales con demandas activas, sino también a aquellos recursos disponibles en núcleos adyacentes. Un análisis detallado de la figura 2.3 revela que incluso los intervalos espectrales sin conexiones asignadas experimentan interferencia procedente de transmisiones en núcleos contiguos. Esto se ejemplifica con los segmentos FS8 y FS9 del núcleo 1, que sufren degradación por el XT generado desde las mismas posiciones espectrales en el núcleo 2. En determinadas circunstancias, esta interferencia puede superar el umbral de crosstalk admisible, imposibilitando la utilización de dichos recursos para el establecimiento de futuras conexiones en arquitecturas multinúcleo.




Figura 2.3: XT en un Fibra MCF de 3 núcleos [1]

2.2.1. Cálculo de la diafonía

El procedimiento para determinar el nivel de XT que incide sobre una conexión establecida en el núcleo i de una MCF, considerando una configuración arbitraria de núcleos y cualquier disposición geométrica, se desarrolla mediante los siguientes pasos:

En primera instancia, se determina el valor de la XT por unidad de longitud entre el núcleo i y un núcleo adyacente j , denotado como $h_{i,j}$, empleando la expresión:

$$h_{i,j} = \frac{2k^2r}{\beta\Lambda_{i,j}} \quad (2.1)$$

Donde k representa el coeficiente de acoplamiento; r corresponde al radio de curvatura; β denota la constante de propagación; y $\Lambda_{i,j}$ indica la distancia entre los núcleos i y j respectivamente (core pitch).

Posteriormente, se calcula el valor total de la XT que impacta al núcleo i , designado como XT_i , mediante la agregación de las contribuciones de XT provenientes de todos sus núcleos adyacentes. Esta operación se efectúa utilizando la siguiente expresión:

$$XT_i = \sum_{j=1}^{N_i} h_{i,j} \cdot L \quad (2.2)$$

Donde N_i representa la cantidad de núcleos adyacentes al núcleo i , y L corresponde a la longitud física del enlace óptico.

Con el propósito de garantizar la integridad de la señal transmitida, resulta imperativo que el valor calculado de XT_i no exceda un umbral máximo admisible de diafonía al momento de establecer de forma óptima la trayectoria óptica para una solicitud de conexión entrante. El umbral de diafonía o *Crosstalk Threshold* (XT_{TH}) se conceptualiza como el límite superior de XT que una señal propagada a través del sistema puede tolerar sin experimentar una degradación considerable en su calidad o sin provocar la generación de errores en la transmisión de datos [19].

El valor particular del XT_{TH} puede fluctuar en función de las características de la aplicación y las especificaciones técnicas del sistema implementado. En contextos de aplicaciones que demandan elevadas velocidades de transmisión y capacidades sustanciales, es factible admitir niveles considerablemente reducidos de XT_{TH} , en tanto que para aplicaciones de menor criticidad, los valores de XT_{TH} admisibles pueden ser superiores.

2.2.2. Asignación de espectro con conmutación de núcleo

En las arquitecturas SDM-EON, es posible optimizar la eficiencia espectral mediante la implementación de conmutación de núcleos, mecanismo que permite identificar y asignar recursos espectrales en uno o múltiples núcleos a lo largo de una conexión establecida en fibras MCF. Este procedimiento implica la selección del mismo bloque de FS como recursos reservados para cada solicitud de conexión, distribuyéndose entre diferentes núcleos a lo largo de la trayectoria de trabajo. Para materializar la conmutación de núcleos, resulta fundamental respetar la restricción de contigüidad espectral, lo cual significa que la señal puede ser transferida de un núcleo a otro sin limitaciones, en tanto se preserve la continuidad del mismo intervalo espectral asignado.

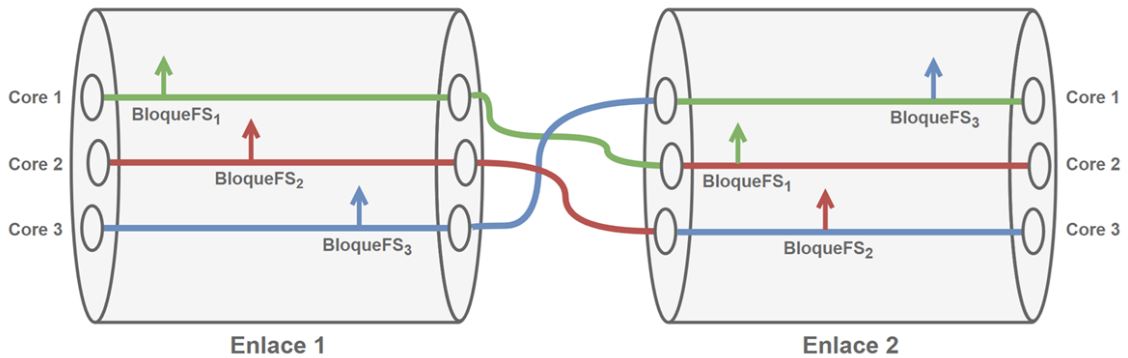


Figura 2.4: Conmutación de núcleos con contigüidad de espectro [1]

En las Figuras [1] y [2] se ilustra la asignación de núcleos y recursos espectrales sin

conmutación de núcleos y con conmutación de núcleos, respectivamente. Los elementos gráficos de color naranja denotan FS ocupadas, mientras que los elementos en blanco representan FS disponibles. Con el propósito de ejemplificar el funcionamiento del mecanismo de asignación espectral con conmutación de núcleos, se presentan dos casos representativos documentados en la literatura [20]. En ambos escenarios, se considera una demanda $d(2, 4, 4)$, donde el primer parámetro identifica el nodo de origen, el segundo corresponde al nodo de destino, y el tercero especifica la cantidad de FS requeridas para satisfacer dicha demanda, respectivamente. Es posible identificar y asignar los recursos espectrales necesarios para la demanda a lo largo de la trayectoria conformada por dos enlaces de fibra: l_0 (2-5) y l_1 (5-4), implementando tres núcleos.

La Figura [] exhibe la asignación de núcleos y espectro sin aplicar conmutación de núcleos para la demanda $d(2, 4, 4)$. En los enlaces l_0 y l_1 existen diversos bloques contiguos de FS disponibles. No obstante, debido a la restricción de continuidad espectral, únicamente se configura un bloque candidato de FS en el núcleo 2, representado mediante SC_{2,l_0}^0 , SC_{2,l_1}^0 . Posteriormente, se verifica el impacto del XT con el objetivo de asegurar que la incorporación de la demanda no supere el umbral XT_{TH} . En caso de que el XT exceda XT_{TH} , la demanda $d(2, 4, 4)$ resultará bloqueada, dado que no existen recursos espectrales disponibles a lo largo de la ruta establecida.




Figura 2.5: Asignación de espectro sin conmutación de núcleos []

La Figura [] ilustra la asignación de núcleos y espectro mediante la implementación de conmutación para la demanda $d(2, 4, 4)$. El mecanismo de conmutación de núcleos posibilita la identificación de bloques de FS que satisfacen la restricción de contigüidad espectral distribuidos en núcleos distintos a través de múltiples enlaces de la trayectoria establecida.

A modo de ejemplo, para la demanda $d(2, 4, 4)$ se identifican tres bloques candidatos de FS que cumplen con dicha restricción: $\{SC_{2,l_0}^0, SC_{2,l_1}^0\}$, $\{SC_{1,l_0}^3, SC_{3,l_1}^3\}$ y $\{SC_{3,l_0}^6, SC_{1,l_1}^6\}$. Estos bloques se encuentran disponibles a lo largo de la ruta conformada por los enlaces l_0 (2-5) y l_1 (5-4).

Conforme se observó en el caso precedente, si el bloque candidato de FS representado por $\{SC_{2,l_0}^0, SC_{2,l_1}^0\}$ experimenta una interferencia significativa por XT que excede el umbral XT_{TH} , resultaría inviable establecer la demanda en dichos recursos espectrales. No obstante, mediante la implementación de conmutación de núcleos, los dos bloques candidatos restantes, $\{SC_{1,l_0}^3, SC_{3,l_1}^3\}$ y $\{SC_{3,l_0}^6, SC_{1,l_1}^6\}$, se encuentran distribuidos en núcleos diferentes a través de los enlaces de fibra. Consecuentemente,

el nivel de XT que incide sobre estos bloques de FS podría permanecer por debajo del umbral XT_{TH} , facilitando su asignación exitosa.




Figura 2.6: Asignación de espectro con conmutación de núcleos []

En términos comparativos, la implementación del mecanismo de conmutación de núcleos a lo largo de los enlaces de fibra en una ruta de trabajo permite reducir sustancialmente la probabilidad de bloqueo de solicitudes en comparación con escenarios donde no se aplica conmutación de núcleos, incrementando así la eficiencia en la utilización de los recursos espectrales y espaciales disponibles en la infraestructura de red.

2.3. Fragmentación del Ancho de Banda en MC-EON

Las redes ópticas elásticas multinúcleo (MC-EON) permiten optimizar el uso del ancho de banda necesario para satisfacer una demanda, respetando tres restricciones

fundamentales:

- **Restricción de continuidad:** esta restricción implica que un cambio de luz o lightpath debe utilizar los mismos *Frequency Slots* (FS) a lo largo del camino establecido entre los nodos de origen y destino, tanto en la dimensión espectral como en la dimensión espacial (núcleo).
- **Restricción de consecutividad:** esta restricción establece que todos los FS utilizados para establecer un lightpath deben ser contiguos en el dominio espectral, formando un solo bloque contiguo de FS dentro del mismo núcleo.

Estas restricciones conducen a que, tras sucesivas asignaciones y liberaciones de recursos, se genere la aparición de bloques aislados de FS no utilizados tanto en la dimensión espectral como en la dimensión espacial (núcleos) de los enlaces ópticos. Dichos bloques fragmentados presentan desalineación tanto entre enlaces consecutivos de la ruta como entre los diferentes núcleos de una misma fibra multinúcleo. Como consecuencia, se incrementa significativamente la probabilidad de bloqueo de solicitudes, pudiendo la red rechazar demandas incluso cuando existe ancho de banda disponible suficiente en los enlaces. Este fenómeno se denomina **Fragmentación de la red** y en arquitecturas multinúcleo se manifiesta en dos dimensiones complementarias:

- **Fragmentación espectral:** se refiere a la presencia de bloques aislados de FS no utilizados en el dominio espectral, que no pueden ser aprovechados para establecer nuevas conexiones debido a las restricciones de continuidad y consecutividad.
- **Fragmentación espacial:** se refiere a la desalineación de bloques de FS disponibles entre los diferentes núcleos de una misma fibra multinúcleo, lo que dificulta la asignación eficiente de recursos en la dimensión espacial.

Ejemplo ilustrativo del fenómeno:

- 1 - Se presenta el estado inicial del enlace mostrando las asignaciones activas de lightpaths distribuidos en los múltiples núcleos de la fibra.
- 2 - Se produce la liberación de recursos al finalizar el tiempo de vida de determinadas conexiones, generando segmentos espectrales disponibles dispersos en diferentes núcleos y posiciones del espectro.
- 3 - Se evidencia el rechazo de una nueva solicitud de conexión debido a que, pese a existir una cantidad agregada suficiente de FS libres en la red, estos no satisfacen simultáneamente las restricciones de contigüidad espectral dentro de un único núcleo y continuidad espacial a lo largo de la ruta. La conexión resulta bloqueada en todos los núcleos disponibles como resultado de la fragmentación tanto espectral como espacial inherente al sistema multinúcleo.

Para ilustrar estas restricciones, se presenta un ejemplo en las Figuras II y III, donde se simula la conexión de una demanda de λ FS, con un nodo origen en 0 y un nodo destino en 3. En este escenario, existen dos posibles caminos: 0-1-3 y 0-1-2-3.

La trayectoria de menor longitud corresponde a la ruta 0-1-3. No obstante, al procurar el establecimiento del lightpath mediante esta alternativa, la solicitud de conexión resulta denegada, dado que los enlaces 0-1 y 1-3 carecen de dos FS consecutivos y alineados espectralmente, tal como se evidencia en la Figura III.




Figura 2.7: Restricciones de contigüidad y continuidad aplicadas- Conexión Rechazada




Figura 2.8: Restricciones de contigüidad y continuidad aplicadas- Conexión Establecida

En contraste, al considerar la asignación del lightpath a través de la trayectoria de mayor extensión, específicamente 0-1-2-3, empleando los FS 4 y 5, la conexión se establece satisfactoriamente, puesto que esta configuración dispone de dos FS contiguos y alineados espectralmente, según se observa en la Figura [].

2.3.1. Enfoques de gestión de fragmentación

La problemática descrita previamente genera consecuencias perjudiciales para la infraestructura de red, ocasionando un incremento en la probabilidad de bloqueo y comprometiendo significativamente su desempeño óptimo y continuidad operacional. En consecuencia, resulta fundamental identificar estrategias que permitan prevenir, mitigar o reducir la fragmentación del espectro disponible.

De acuerdo con la bibliografía especializada, existen diversas aproximaciones que pueden ser consideradas para abordar la gestión de la desfragmentación. En la figura 2.3 se presentan las principales estrategias de gestión de la fragmentación [4].

La Desfragmentación constituye un procedimiento mediante el cual se ejecuta la reconfiguración o el re-ruteo de un subconjunto de conexiones existentes en la infraestructura de red. Su propósito fundamental consiste en reacomodar las asignaciones espectrales de las solicitudes de tráfico vigentes, consolidando de este modo los recursos disponibles en segmentos contiguos y continuos de mayor magnitud, los cuales pueden ser aprovechados para el establecimiento de futuras demandas [5].

Es factible abordar la problemática de la fragmentación prescindiendo de técnicas de desfragmentación espectral (Sin Desfragmentación), lo cual se alcanza mediante una administración del espectro orientada a la prevención de su fragmentación.

En el tratamiento de la fragmentación bajo un esquema Sin Desfragmentación, se pueden mencionar los algoritmos denominados Sensibles a la Fragmentación o *Fragmentation Aware RSA* (FA-RSA). Estos consideran la fragmentación espectral durante el establecimiento de las demandas, empleando diversos indicadores de fragmentación, procurando así minimizar la fragmentación del espectro.

Alternativamente, es posible emplear técnicas de desfragmentación, las cuales se fundamentan en dos aproximaciones principales:

- Desfragmentación Reactiva: El procedimiento se ejecuta como respuesta al bloqueo de una solicitud, con la finalidad de lograr su establecimiento exitoso.

- Desfragmentación Proactiva: Se lleva a cabo de manera periódica o en función de determinados umbrales que activan el proceso, permitiendo así reducir la fragmentación de la infraestructura de red y minimizar la ocurrencia de futuros bloqueos de solicitudes.

Las aproximaciones que implementan técnicas de desfragmentación pueden clasificarse además en: (i) estrategias sin re-ruteo, las cuales realizan únicamente una reasignación espectral en los *lightpaths* o caminos ópticos establecidos, y (ii) estrategias con re-ruteo, que constituyen técnicas capaces de modificar tanto las rutas como el espectro asignado a los *lightpaths* existentes.

En el presente trabajo, para la gestión de la fragmentación se adoptó la aproximación con desfragmentación, de naturaleza proactiva y con re-ruteo de *lightpaths* preexistentes. En la figura [] se puede observar resaltada dicha estrategia.




Figura 2.9: Esquema de Gestión de la Fragmentación

2.4. Descripción del problema tratado

La Fragmentación del Espectro en Redes Ópticas Elásticas Multinúcleo (Multi-Core EON) constituye una problemática que compromete la eficiencia en la utilización de recursos espectrales y espaciales. El desempeño de la infraestructura de red resulta severamente afectado, dado que este fenómeno puede ocasionar bloqueos de solicitudes debido a la ausencia de ranuras espectrales contiguas y alineadas entre enlaces consecutivos, así como por la indisponibilidad de núcleos adecuados, sin que necesariamente el espectro en todos los núcleos se encuentre completamente ocupado. En secciones previas se expusieron estrategias para el manejo de la fragmentación en la red; en el presente trabajo se examina la estrategia con desfragmentación, adoptando un enfoque proactivo.

Un método ampliamente implementado consiste en ejecutar el procedimiento de desfragmentación de manera periódica con el propósito de prevenir bloqueos futuros, abordando así una de las cuatro interrogantes planteadas por Zhang [1], ¿Cuándo reconfigurar?.

En la figura 2.4 se puede observar una posible solución a la problemática de la selección del momento óptimo para realizar la desfragmentación, la cual consiste en ejecutar desfragmentaciones periódicas en intervalos temporales fijos. En este caso, cada 100 unidades de tiempo, el eje vertical representa el volumen de tráfico cuantificado mediante el número de conexiones activas, mientras que el eje horizontal indica las unidades temporales; cada punto azul denota el instante en que el proceso de desfragmentación se ejecuta. Siguiendo este patrón, se evidencian situaciones donde se realizan procesos de desfragmentación cuando la red podría no requerirlos, considerando que la utilización de los recursos espectrales y de los núcleos constituye un indicador significativo del grado de fragmentación.

Además de la utilización de la red, existen otras métricas de fragmentación relevantes en redes multinúcleo, cuyos valores deben considerarse para el disparo de los

procesos de desfragmentación, incluyendo la fragmentación por núcleo y la disponibilidad de recursos en la dimensión espacial.

De este modo, se evidencia la necesidad de un disparador inteligente para ejecutar el proceso de desfragmentación que considere todos estos parámetros o “características” para seleccionar apropiadamente el momento del disparo, dado que realizar múltiples desfragmentaciones de manera frecuente afecta directamente al desempeño de la red, pudiendo ocasionar disrupciones en las conexiones activas; mientras que ejecutar pocas desfragmentaciones muy dispersas resultaría en efectos prácticamente imperceptibles.

En síntesis, la selección del momento para ejecutar el proceso de desfragmentación resulta crítica debido a su impacto significativo en la cantidad de procesos de desfragmentación, lo cual incide directamente en las dos métricas globales más relevantes en el enrutamiento de redes ópticas elásticas multinúcleo: Cantidad de bloqueos y Cantidad de reconfiguraciones.

En los capítulos subsiguientes se presenta y aborda en profundidad un modelo de disparo inteligente que contempla numerosos factores tales como métricas de fragmentación de la red, utilización de recursos espectrales y espaciales, y bloqueos de solicitudes.




Figura 2.10: Ejemplo de desfragmentaciones periódicas con volumen de carga de tráfico variado

Capítulo 3

Aprendizaje Automático

El Aprendizaje Automático, conocido en inglés como *Machine Learning*, representa una de las áreas más dinámicas y prometedoras dentro del campo de la inteligencia artificial contemporánea. se fundamenta en el desarrollo de algoritmos y modelos computacionales capaces de identificar patrones complejos en conjuntos de datos, con el propósito de generar predicciones o tomar decisiones informadas sin necesidad de instrucciones programáticas explícitas para cada escenario específico.[]

La esencia del aprendizaje automático radica en su capacidad para mejorar el desempeño de manera iterativa mediante la experiencia acumulada. Mitchell proporciona una definición operacional particularmente esclarecedora: un sistema computacional manifiesta capacidad de aprendizaje cuando su rendimiento en una tarea determinada T , cuantificado mediante una métrica de desempeño P , experimenta una mejora mensurable como consecuencia de la exposición a una experiencia E .[] Esta conceptualización establece tres componentes fundamentales que articulan cualquier sistema de aprendizaje automático: la tarea objetivo, la experiencia de aprendizaje y el criterio de evaluación.

Para ilustrar estos conceptos de manera concreta, se puede examinar el caso de los sistemas de filtrado de correo electrónico no deseado. Un filtro de spam ejemplifica de forma paradigmática los principios del aprendizaje automático. El sistema desarrolla progresivamente la capacidad de discriminar entre mensajes legítimos y

correo no solicitado mediante el análisis de ejemplos previamente etiquetados por usuarios. Estos conjuntos de datos, denominados conjuntos de entrenamiento, contienen tanto instancias positivas (correos identificados como spam) como negativas (mensajes legítimos), permitiendo al algoritmo extraer características distintivas de cada categoría.

En este contexto específico, la tarea T consiste en la clasificación binaria de nuevos mensajes electrónicos, la experiencia E está constituida por el proceso de entrenamiento con los datos etiquetados, y la métrica de desempeño P puede definirse como la tasa de precisión o *Accuracy*, que cuantifica la proporción de mensajes correctamente clasificados en relación con el total de predicciones realizadas.

3.1. Clasificación de sistemas o tipos de aprendizaje automático

La diversidad de aplicaciones y contextos en los que se implementan sistemas de aprendizaje automático ha propiciado el desarrollo de múltiples paradigmas metodológicos. La clasificación más fundamental de estos enfoques se establece en función del tipo y grado de supervisión disponible durante la fase de entrenamiento. A continuación, se muestran las tres categorías principales:

- **Aprendizaje supervisado:** Este paradigma constituye el enfoque más ampliamente implementado en aplicaciones prácticas. Se caracteriza por la disponibilidad de un conjunto de entrenamiento que incluye pares de entrada-salida, donde cada instancia de entrada está asociada con su correspondiente etiqueta o *label*, que representa la solución correcta. El objetivo del algoritmo consiste en inferir una función de mapeo que establezca la correspondencia óptima entre el espacio de características de entrada y el conjunto de salidas deseadas, de manera que pueda generalizar efectivamente a instancias no observadas

previamente.

El aprendizaje supervisado se subdivide en dos categorías fundamentales según la naturaleza de la variable objetivo:

- *Clasificación:* Se trata de brindar ejemplos de entrenamiento donde cada instancia está asociada con una o múltiples clases predefinidas, a modo de que se pueda realizar el entrenamiento y clasificar nuevas entradas dentro de alguna de las clases existentes. Aplicaciones típicas incluyen el reconocimiento de imágenes, detección de fraudes y análisis de sentimientos.
 - *Predicción:* A diferencia de la clasificación, éste consiste en la predicción de una variable objetivo de naturaleza continua o numérica. El sistema recibe datos de entrenamiento compuestos por vectores de características junto con sus valores objetivos correspondientes, permitiendo al modelo aprender la relación funcional entre sí. Esta capacidad predictiva se aplica posteriormente para estimar valores numéricos de nuevas instancias basándose exclusivamente en sus características de entrada. Aplicaciones típicas comprenden la predicción de precios, estimación de demanda y proyecciones temporales.
- **Aprendizaje no supervisado:** Este paradigma aborda escenarios donde los datos de entrenamiento carecen de soluciones deseadas. La ausencia de supervisión directa plantea un desafío metodológico fundamentalmente diferente: el algoritmo debe descubrir estructuras intrínsecas, patrones latentes o relaciones subyacentes en los datos sin guía externa. Las técnicas de aprendizaje no supervisado resultan particularmente valiosas para tareas exploratorias, tales como la segmentación de clientes, detección de anomalías, reducción de dimensionalidad y descubrimiento de asociaciones en grandes volúmenes de datos. Este enfoque refleja una aproximación más cercana a cómo los sistemas bio-

lógicos pueden aprender mediante la observación y organización autónoma de información sensorial.

- **Aprendizaje por refuerzo:** Este paradigma se distingue por su naturaleza secuencial e interactiva. En lugar de aprender a partir de un conjunto estático de ejemplos, el aprendizaje por refuerzo se fundamenta en la interacción continua de un agente con un entorno dinámico. El proceso de aprendizaje se articula mediante señales de retroalimentación en forma de recompensas (positivas o negativas) que el agente recibe como consecuencia de sus acciones. El objetivo fundamental consiste en desarrollar una política de comportamiento que maximice la recompensa acumulada a largo plazo. Este bucle de retroalimentación continua entre acción, observación y recompensa permite al sistema refinar progresivamente su estrategia mediante exploración y explotación del espacio de estados. Las aplicaciones emblemáticas incluyen sistemas de control robótico, estrategias de juegos, optimización de recursos y vehículos autónomos.

Cada uno de estos paradigmas presenta ventajas distintivas y limitaciones inherentes, determinando su idoneidad para contextos específicos. La selección del enfoque apropiado constituye una decisión metodológica crucial que debe considerar tanto la naturaleza del problema como las características de los datos disponibles.

3.2. Gradient Boosting

El Gradient Boosting representa uno de los algoritmos de aprendizaje automático supervisado más potentes y efectivos en la actualidad, especialmente para problemas de clasificación y regresión con datos tabulares. Este método se fundamenta en el paradigma de aprendizaje por ensamble, donde múltiples modelos predictivos débiles se combinan secuencialmente para construir un predictor robusto de alto rendimiento

mediante principios de optimización matemática y aprendizaje iterativo.

3.2.1. Fundamentos del Aprendizaje por Ensamble

El aprendizaje por ensamble o *Ensemble Learning* constituye una estrategia metodológica que combina las predicciones de múltiples modelos base para obtener un resultado final superior al que produciría cualquier modelo individual. Este enfoque se fundamenta en dos principios estadísticos complementarios:

- **Reducción de varianza:** Mediante la agregación de predicciones de modelos diversos, se reduce la sensibilidad del sistema a fluctuaciones en los datos de entrenamiento, incrementando la estabilidad de las predicciones.
- **Reducción de sesgo:** La combinación secuencial de modelos permite corregir sistemáticamente errores persistentes, mejorando la capacidad del sistema para capturar relaciones complejas en los datos.

Existen dos estrategias principales en el aprendizaje por ensamble. El *Bagging* o agregación bootstrap entrena múltiples modelos de manera independiente y paralela sobre diferentes subconjuntos de datos, combinando posteriormente sus predicciones mediante votación o promediación. El *Boosting*, por otro lado, entrena modelos de forma secuencial, donde cada nuevo modelo se enfoca en corregir los errores de sus predecesores. El Gradient Boosting pertenece a esta segunda categoría, distinguiéndose por su fundamentación matemática rigurosa basada en el descenso del gradiente en el espacio funcional.

3.2.2. Algoritmo de Gradient Boosting

Dado un conjunto de entrenamiento $\{(x_i, y_i)\}_{i=1}^n$ donde x_i representa el vector de características y y_i la variable objetivo, el Gradient Boosting construye un modelo

aditivo mediante la incorporación secuencial de árboles de decisión de profundidad limitada:

$$F_M(x) = \sum_{m=0}^M \gamma_m h_m(x) \quad (3.1)$$

donde $h_m(x)$ representa el m -ésimo aprendiz débil, γ_m es el coeficiente de peso asociado, y M denota el número total de iteraciones.

El procedimiento algorítmico consiste en:

1. **Inicialización:** Se establece un modelo inicial $F_0(x)$, comúnmente una constante que minimiza la función de pérdida sobre el conjunto de entrenamiento completo.
2. **Iteración secuencial:** Para cada iteración $m = 1, 2, \dots, M$:

- Se calculan los pseudo-residuos, representando el gradiente negativo de la función de pérdida respecto a las predicciones actuales:

$$r_{im} = - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F(x)=F_{m-1}(x)} \quad (3.2)$$

- Se entrena un nuevo aprendiz débil $h_m(x)$ para predecir estos residuos.
- Se determina el coeficiente óptimo γ_m que minimiza la pérdida:

$$\gamma_m = \arg \min_{\gamma} \sum_{i=1}^n L(y_i, F_{m-1}(x_i) + \gamma h_m(x_i)) \quad (3.3)$$

- Se actualiza el modelo mediante:

$$F_m(x) = F_{m-1}(x) + \nu \cdot \gamma_m h_m(x) \quad (3.4)$$

donde ν representa la tasa de aprendizaje, un hiperparámetro que controla la contribución de cada árbol al modelo final.

Este proceso continúa hasta alcanzar el número especificado de árboles M o hasta satisfacer un criterio de convergencia establecido.

3.2.3. GradientBoostingClassifier

Para problemas de clasificación binaria, el *GradientBoostingClassifier* emplea típicamente la función de pérdida logística:

$$L(y, F(x)) = \log(1 + e^{-2yF(x)}) \quad (3.5)$$

donde $y \in \{-1, 1\}$ representa la clase verdadera y $F(x)$ la predicción del modelo. La probabilidad de pertenencia a la clase positiva se obtiene mediante la transformación logística:

$$P(y = 1|x) = \frac{1}{1 + e^{-2F(x)}} \quad (3.6)$$

Para problemas multiclase, se extiende el enfoque mediante la estrategia *one-versus-all*, entrenando un modelo separado por cada clase y combinando las predicciones mediante normalización softmax para obtener distribuciones de probabilidad válidas.

3.2.4. Configuración e Hiperparámetros

El rendimiento del *GradientBoostingClassifier* depende críticamente de la configuración apropiada de sus hiperparámetros, los cuales regulan la complejidad del modelo y previenen el sobreajuste:

- **Número de estimadores (n_estimators):** Define la cantidad de árboles en el ensamble. Valores elevados incrementan la capacidad expresiva pero aumentan el riesgo de sobreajuste y el costo computacional. Típicamente se emplean valores entre 100 y 1000.
- **Tasa de aprendizaje (learning_rate):** Controla la contribución de cada árbol al modelo final. Valores pequeños (0.01-0.1) requieren más árboles pero

generalmente producen mejor generalización. Existe una relación de compromiso entre este parámetro y el número de estimadores.

- **Profundidad máxima (`max_depth`):** Limita la profundidad de cada árbol individual. Árboles superficiales (3-5 niveles) actúan como aprendices débiles efectivos, mientras que árboles profundos incrementan la complejidad y el riesgo de sobreajuste.
- **Mínimo de muestras por división (`min_samples_split`):** Especifica el número mínimo de muestras requeridas para dividir un nodo interno. Valores mayores previenen la creación de divisiones excesivamente específicas.
- **Mínimo de muestras por hoja (`min_samples_leaf`):** Define el número mínimo de muestras en los nodos terminales. Este parámetro suaviza el modelo en regiones de baja densidad de datos.
- **Submuestreo (`subsample`):** Fracción de muestras utilizada para entrenar cada árbol. Valores menores a 1.0 introducen aleatorización estocástica, mejorando la diversidad del ensamble y reduciendo el sobreajuste.

La selección óptima de estos hiperparámetros requiere típicamente validación cruzada y búsqueda sistemática en el espacio de configuraciones mediante técnicas como *Grid Search* o *Random Search*.

Ventajas del algoritmo:

- Capacidad para modelar relaciones no lineales complejas sin requerir transformaciones explícitas de características
- Robustez ante variables de diferentes escalas, eliminando la necesidad de normalización
- Manejo natural de variables mixtas (numéricas y categóricas)

- Resistencia a *outliers* mediante funciones de pérdida apropiadas
- Interpretabilidad mediante análisis de importancia de características
- Rendimiento competitivo en conjuntos de datos tabulares estructurados

Limitaciones:

- Susceptibilidad al sobreajuste con configuraciones inadecuadas de hiperparámetros
- Entrenamiento secuencial que limita la paralelización eficiente
- Mayor costo computacional comparado con algoritmos más simples
- Sensibilidad al desbalance de clases, requiriendo estrategias de ponderación
- Rendimiento subóptimo en datos de muy alta dimensionalidad comparado con métodos especializados

3.2.5. Aplicación en MC-EON

En el contexto de las redes ópticas elásticas multinúcleo (MC-EON), el *GradientBoostingClassifier* ha demostrado particular eficacia para tareas de clasificación relacionadas con la gestión dinámica de recursos. Sus principales aplicaciones incluyen:

- **Predicción de bloqueo de solicitudes:** Predecir la probabilidad de que una solicitud de conexión sea bloqueada considerando la fragmentación espectral, disponibilidad de núcleos y niveles de diafonía entre núcleos.
- **Clasificación de eventos de desfragmentación:** Determinar el momento óptimo para ejecutar algoritmos de desfragmentación, clasificando el estado de la red según la necesidad de reorganizar las asignaciones espectrales. Esta

capacidad permite decisiones en tiempo real que balancean el costo operacional contra los beneficios en reducción de bloqueos futuros.

- **Selección de estrategias RMSCA:** Seleccionar entre diferentes estrategias de *Routing, Modulation, Spectrum and Core Assignment* según las características de la demanda y el estado de la red. La capacidad del modelo para capturar interacciones no lineales permite adaptar dinámicamente la estrategia de asignación.
- **Detección de degradación de QoS:** Identificar situaciones donde la calidad de servicio está en riesgo, permitiendo acciones preventivas. La interpretabilidad del modelo facilita la identificación de los factores más críticos que afectan la calidad de servicio.

La naturaleza tabular de los datos operacionales en MC-EON hace particularmente adecuado el uso de Gradient Boosting, cuyo rendimiento en este tipo de datos frecuentemente supera a aproximaciones basadas en redes neuronales profundas. Adicionalmente, su capacidad para proporcionar estimaciones de importancia de características facilita la comprensión de los factores más relevantes en las decisiones de gestión, aspecto crítico para la validación de sistemas autónomos en entornos de producción.

Capítulo 4

Método Propuesto

Este trabajo propone un sistema de desfragmentación proactiva para redes MC-EON mediante el uso de técnicas de *Machine Learning*. El sistema predice el índice de fragmentación futuro (*Bandwidth Fragmentation Ratio* o BFR) que experimentará la red y, en función de estos valores predichos, determina automáticamente cuándo y con qué frecuencia ejecutar procesos de desfragmentación.

4.1. Estrategia de Desfragmentación Adaptativa

El sistema implementa una estrategia de tres niveles basada en dos umbrales de fragmentación:

- **Umbral mínimo ($\text{BFR} = 0.20$):** Indica el inicio de fragmentación apreciable
- **Umbral crítico ($\text{BFR} = 0.46$):** Señala estados de alta fragmentación que incrementan significativamente la probabilidad de bloqueo

La lógica de actuación se define como:

1. **Sin desfragmentación:** Si la predicción indica que el BFR futuro no superará el umbral mínimo ($\text{BFR} < 0,20$)
2. **Desfragmentación de baja frecuencia:** Si el BFR predicho supera el umbral mínimo pero no alcanza el umbral crítico ($0,20 \leq \text{BFR} < 0,46$)

3. **Desfragmentación de alta frecuencia:** Si el BFR predicho supera el umbral crítico ($BFR \geq 0,46$)

Esta aproximación permite actuar de manera preventiva antes de que la red alcance estados críticos, optimizando el balance entre los costos operacionales de la desfragmentación y el mantenimiento de niveles aceptables de fragmentación.

4.2. Características Utilizadas

En el contexto de *Machine Learning*, las características son los parámetros de entrada que alimentan el modelo predictivo. Para este trabajo se seleccionaron métricas relacionadas con la fragmentación, utilización de recursos y comportamiento específico de redes MC-EON:

- **Bandwidth Fragmentation Ratio (BFR)**[6]: Representa el índice de fragmentación de los recursos de la red. El BFR de un core en un enlace se define como:

$$BFR_{core} = 1 - \frac{MaxBlock()} {S^{free}} \quad (4.1)$$

donde $MaxBlock()$ es el tamaño del mayor bloque de frequency slots (FS) libres y S^{free} es la suma total de FS libres en el core.

El BFR de la red se calcula como el promedio ponderado considerando todos los cores de todos los enlaces:

$$BFR_{red} = 1 - \frac{\sum_{i=1}^{|E|} \sum_{j=1}^C MaxBlock_{i,j}}{\sum_{i=1}^{|E|} \sum_{j=1}^C S_{i,j}^{free}} \quad (4.2)$$

donde C es el número de cores por enlace, $MaxBlock_{i,j}$ es el mayor bloque libre en el core j del enlace i , y $S_{i,j}^{free}$ es el total de FS libres en ese core.

- **Entropía de Shannon (SHF)**[7]: Mide la distribución de bloques libres en el espectro. Para un core:

$$SHF_{core} = \sum_{i=1}^B \frac{S_i^{free}}{N} \ln \frac{N}{S_i^{free}} \quad (4.3)$$

donde S_i^{free} es el tamaño del bloque libre i , N es el número total de FS, y B es la cantidad de bloques libres. El SHF de la red se calcula como:

$$SHF_{red} = \frac{1}{|E| \times C} \sum_{i=1}^{|E|} \sum_{j=1}^C SHF_{core_{i,j}} \quad (4.4)$$

- **Compacidad del Espectro (SC):** Evalúa qué tan compacto está el uso del espectro considerando la dispersión de FS ocupados y la cantidad de gaps intermedios. Para un core:

$$SC_{core} = \frac{s_{max} - s_{min} + 1}{S_{occupied}} \times \frac{\sum_{i=1}^G g_i}{G} \quad (4.5)$$

donde s_{min} y s_{max} son los índices del primer y último FS ocupado, $S_{occupied}$ es la cantidad total de FS ocupados, g_i es el tamaño del gap libre i , y G es la cantidad total de gaps. Si no hay FS ocupados, $SC_{core} = 0$.

- **Golden Metric (GM):** Métrica avanzada que evalúa la fragmentación considerando rangos de tamaño de demandas esperadas. Dados dos parámetros n_1 y n_2 que representan tamaños típicos de demanda, el GM para un core se calcula como:

$$GM_{core} = \frac{a}{|b|} \quad (4.6)$$

donde a y b se calculan iterando sobre cada gap de FS libres:

$$a_0 = \epsilon, \quad b_0 = -\epsilon, \quad a = a_0 + \sum_{i=1}^G a_i, \quad b = b_0 + \sum_{i=1}^G b_i \quad (4.7)$$

con $\epsilon = 0,001$, y para cada gap g_i :

- Si $g_i < n_1$: $a_i = 0$, $b_i = -\frac{g_i}{avg}$
- Si $g_i > n_2$: $a_i = \frac{g_i}{avg}$, $b_i = 0$
- Si $n_1 \leq g_i \leq n_2$: $a_i = \frac{g_i - n_1 + 1}{avg}$, $b_i = -\frac{n_2 - g_i}{avg}$

con $avg = \frac{n_1 + n_2}{2}$.

- **Available Spectrum Fragmentation Ratio 3D (ASFR3D):** Considera la fragmentación espacial en redes multi-core, evaluando bloques pequeños de difícil utilización:

$$ASFR3D_{core} = \left(1 - \frac{S^{small}}{S^{free}}\right) \times F_{spatial} \quad (4.8)$$

donde S^{small} es la suma de FS libres en bloques menores a 5 slots, y $F_{spatial}$ es un factor de peso espacial:

$$F_{spatial} = \frac{\ln(D_{active} + 1)}{10} \quad (4.9)$$

siendo D_{active} el número de demandas activas en la red.

- **Utilización Diferencial (UD):** Mide el desbalance en la utilización entre cores y enlaces:

$$UD_{red} = U_{max} - U_{min} \quad (4.10)$$

donde U_{max} y U_{min} son las utilidades máxima y mínima entre todos los cores, siendo:

$$U_{core} = \frac{S^{occupied}}{N} \quad (4.11)$$

Un valor alto de UD indica desbalance en la carga de la red.

4.3. Generación de Datos de Entrenamiento

4.3.1. Simulador y Topología

Se utilizó un simulador de redes MC-EON[8] para generar el conjunto de datos de entrenamiento. La topología empleada fue USNET, representativa de redes ópticas de producción. Se generaron 400,000 instancias de tráfico, de las cuales 399,000 fueron utilizables para el análisis y entrenamiento tras eliminar valores incompletos.

4.3.2. Modelo de Carga Variable

Para simular condiciones realistas de tráfico, se implementó un modelo matemático de carga temporal que genera patrones cuasiperiódicos con variabilidad controlada. La función de carga $C(t)$ se define como una combinación de ondas sinusoidales sobre un tiempo normalizado $t \in [0, 1]$:

$$\begin{aligned} C(t) = & \sin(3\pi t) + 0,35 \sin(7\pi t) + 0,18 \sin(11\pi t) \\ & + 0,10 \sin(15\pi t) + 0,20 \sin(4\pi t) \cos(2\pi t) \\ & - 0,25 \cos(5\pi t) + 0,15 \sin(\pi t) \end{aligned} \quad (4.12)$$

Los componentes de esta función tienen roles específicos:

- $\sin(3\pi t)$: Ciclo principal de carga
- Componentes de alta frecuencia: Microfluctuaciones que simulan perturbaciones menores
- $-0,25 \cos(5\pi t)$: Introduce asimetrías y prolonga fases de baja carga
- $0,15 \sin(\pi t)$: Tendencia global de modulación

El resultado se normaliza y comprime con factor 0.85 para suavizar transiciones y evitar cambios abruptos.




Figura 4.1: Componentes armónicas del modelo de carga

Modelo Matemático Completo

c(t) =

$$\begin{aligned}
 &\sin(3\pi t) \\
 &+ 0.35 \times \sin(7\pi t) \\
 &+ 0.18 \times \sin(11\pi t) \\
 &+ 0.10 \times \sin(15\pi t) \\
 &+ 0.20 \times \sin(4\pi t) \times \cos(2\pi t) \\
 &- 0.25 \times \cos(5\pi t) \\
 &+ 0.15 \times \sin(\pi t)
 \end{aligned}$$

Normalización: Factor de compresión = 0.85

Rango de salida: [-1.8, 1.8]

Mapeo a Erlangs: [1000, 3750]

Figura 4.2: Modelo matemático completo de evolución de carga

4.3.3. Niveles Discretos de Carga

Los valores continuos de $C(t)$, que oscilan aproximadamente en $[-1.8, 1.8]$, se mapean a doce niveles discretos de carga. Cada nivel se asocia con un valor en Erlangs y una denominación cualitativa del estado de la red (desde "valle profundo" hasta "pico máximo"). La Tabla 4.3 presenta estos niveles.

Tabla 1: Niveles de Carga Simulados

Nivel	Denominación	Valor (Erlang)	% Capacidad	Indicador Visual
NIVEL_1	Valle profundo	1000	26.67%	<div><div></div></div>
NIVEL_2	Valle bajo	1300	34.67%	<div><div></div></div>
NIVEL_3	Mínimo	1600	42.67%	<div><div></div></div>
NIVEL_4	Bajo	1900	50.67%	<div><div></div></div>
NIVEL_5	Medio bajo	2200	58.67%	<div><div></div></div>
NIVEL_6	Medio	2500	66.67%	<div><div></div></div>
NIVEL_7	Medio alto	2700	72%	<div><div></div></div>
NIVEL_8	Alto	2900	77.33%	<div><div></div></div>
NIVEL_9	Muy alto	3100	82.67%	<div><div></div></div>
NIVEL_10	Pico alto	3300	88%	<div><div></div></div>
NIVEL_11	Pico extremo	3450	92%	<div><div></div></div>
NIVEL_12	Pico máximo	3750	100%	<div><div></div></div>

Figura 4.3: Niveles de carga simulados




Figura 4.4: Distribución de niveles de carga en la simulación




Figura 4.5: Evolución temporal de la carga

El patrón resultante presenta aproximadamente tres ciclos principales durante la simulación, con los siguientes rangos característicos de carga:

- **Valores mínimos:** 1000–1600 Erlangs
- **Zonas medias:** 2300–2700 Erlangs
- **Picos máximos:** 3300–3750 Erlangs

Tabla 4: Frecuencia de Ocurrencia por Nivel

Nivel	Denominación	Erlang	Ocurrencias	% Tiempo	Distribución
1	Valle profundo	1000	0	0.0%	
2	Valle bajo	1300	6	3.0%	
3	Mínimo	1600	9	4.5%	
4	Bajo	1900	7	3.5%	
5	Medio bajo	2200	8	4.0%	
6	Medio	2500	18	9.0%	
7	Medio alto	2700	27	13.4%	
8	Alto	2900	58	28.9%	
9	Muy alto	3100	32	15.9%	
10	Pico alto	3300	36	17.9%	
11	Pico extremo	3450	0	0.0%	
12	Pico máximo	3750	0	0.0%	

Figura 4.6: Frecuencia de ocurrencia de niveles de carga

4.3.4. Identificación de Fases Operativas

Para cada instante de simulación se identifica la fase operativa del sistema basándose en la tendencia local de la carga (derivada aproximada por diferencias finitas):

- **Ascenso:** El valor de Erlangs aumenta progresivamente
- **Pico:** Máximo local de carga
- **Descenso:** La carga disminuye gradualmente
- **Valle:** Mínimo local de carga
- **Estable:** Variaciones menores entre instantes consecutivos

Esta clasificación enriquece los datos sintéticos con información contextual sobre la dinámica del tráfico.

Tabla 4: Frecuencia de Ocurrencia por Nivel

Nivel	Denominación	Erlang	Ocurrencias	% Tiempo	Distribución
1	Valle profundo	1000	0	0.0%	
2	Valle bajo	1300	6	3.0%	
3	Mínimo	1600	9	4.5%	
4	Bajo	1900	7	3.5%	
5	Medio bajo	2200	8	4.0%	
6	Medio	2500	18	9.0%	
7	Medio alto	2700	27	13.4%	
8	Alto	2900	58	28.9%	
9	Muy alto	3100	32	15.9%	
10	Pico alto	3300	36	17.9%	
11	Pico extremo	3450	0	0.0%	
12	Pico máximo	3750	0	0.0%	

Figura 4.7: Distribución de fases operativas

Tabla 2: Muestra de Datos Temporales

Tiempo (%)	Erlang	Nivel	Denominación	Fase	C(t)
0.0	2500	6	Medio	Estable	-0.212
5.0	3100	9	Muy alto	Estable	0.827
10.0	3300	10	Pico alto	Estable	0.966
15.0	3300	10	Pico alto	Estable	1.020
20.0	3300	10	Pico alto	Estable	0.934
25.0	3100	9	Muy alto	Estable	0.679
30.0	2900	8	Alto	Estable	0.450
35.0	2700	7	Medio alto	Estable	0.090
40.0	2500	6	Medio	Estable	-0.140
45.0	1900	4	Bajo	Estable	-0.738
50.0	1300	2	Valle bajo	Estable	-1.258
55.0	1900	4	Bajo	Estable	-0.627
60.0	2700	7	Medio alto	Ascenso	0.024
65.0	2700	7	Medio alto	Estable	0.200
70.0	2900	8	Alto	Estable	0.388

Figura 4.8: Muestra de datos temporales generados

4.4. Herramientas de Implementación

Se utilizó el ecosistema **Scikit-learn**[scikit-learn] en Python para todo el proceso de Machine Learning. Esta biblioteca proporciona algoritmos de aprendizaje supervisado optimizados junto con herramientas para preprocesamiento, validación y evaluación de modelos.

Bibliotecas complementarias utilizadas:

- **Pandas:** Manipulación de datos tabulares
- **NumPy:** Operaciones numéricas eficientes
- **Matplotlib/Seaborn:** Visualización de resultados
- **Flask:** Framework web para implementación de APIs REST
- **Waitress:** Servidor WSGI para producción
- **Joblib:** Serialización de modelos entrenados

Para el escalamiento de características se empleó **RobustScaler**, que utiliza la mediana y el rango intercuartílico en lugar de media y desviación estándar, haciéndolo robusto ante valores atípicos presentes en métricas de redes ópticas.

4.5. Arquitectura del Sistema de Predicción

El sistema implementa dos modelos de clasificación independientes, cada uno entrenado para detectar cuándo el BFR futuro superará su umbral correspondiente:

4.5.1. Modelo para Umbral Mínimo ($\text{BFR} = 0.20$)

Este modelo predice si la red superará el estado de fragmentación inicial, determinando si es necesario activar la desfragmentación. Opera con un umbral de decisión optimizado en 0.55, balanceando adecuadamente precisión y cobertura.

4.5.2. Modelo para Umbral Crítico ($\text{BFR} = 0.46$)

Este modelo identifica situaciones críticas que requieren desfragmentación intensiva. Su activación indica que la red alcanzará niveles de fragmentación que incrementan significativamente la probabilidad de bloqueo. Utiliza un umbral de decisión de 0.70 para priorizar precisión y minimizar falsas alarmas.

Ambos modelos utilizan **Gradient Boosting Classifier** con la siguiente configuración optimizada:

- **n_estimators:** 150 árboles secuenciales
- **learning_rate:** 0.05 (tasa de aprendizaje conservadora)
- **max_depth:** 5 niveles máximos de profundidad
- **min_samples_split:** 25 muestras mínimas para dividir un nodo
- **min_samples_leaf:** 12 muestras mínimas por hoja

- **subsample:** 0.8 (Stochastic Gradient Boosting)
- **class_weight:** 'balanced'(manejo de desbalance de clases)
- **random_state:** 42 (reproducibilidad)

Gradient Boosting construye árboles de decisión de forma secuencial, donde cada árbol corrige los errores del anterior mediante minimización de la función de pérdida (log loss) por descenso de gradiente. La tasa de aprendizaje baja combinada con 150 estimadores permite un aprendizaje gradual y robusto, reduciendo el riesgo de sobreajuste.

4.6. Proceso de Entrenamiento

4.6.1. División Estratificada de Datos

Se implementó una división estratificada en tres conjuntos, garantizando que cada uno mantenga la misma proporción de clases que el dataset original:

- **Entrenamiento:** 70 % de los datos (279,299 muestras)
- **Validación:** 15 % de los datos (59,851 muestras)
- **Prueba:** 15 % de los datos (59,850 muestras)

Para el umbral crítico (0.46), la distribución fue:

- Entrenamiento: 189,374 casos no críticos, 89,925 casos críticos
- Validación: 40,581 casos no críticos, 19,270 casos críticos
- Prueba: 40,580 casos no críticos, 19,270 casos críticos

Para el umbral mínimo (0.20), debido a que la red opera mayormente sobre este umbral, la distribución mostró un desbalance inverso:

- Entrenamiento: 8,080 casos bajo umbral, 271,219 casos sobre umbral
- Validación: 1,732 casos bajo umbral, 58,119 casos sobre umbral
- Prueba: 1,731 casos bajo umbral, 58,119 casos sobre umbral

4.6.2. Preprocesamiento

Las características fueron escaladas usando RobustScaler, que normaliza basándose en estadísticos robustos:

$$X_{scaled} = \frac{X - \text{mediana}(X)}{\text{IQR}(X)} \quad (4.13)$$

donde IQR es el rango intercuartílico. El escalador se ajusta únicamente con datos de entrenamiento y se aplica posteriormente a validación y prueba, evitando fuga de información (*data leakage*).

Se utilizaron 11 características en total, todas relacionadas con métricas de fragmentación y utilización de la red, excluyendo las columnas de identificación temporal y las variables objetivo futuras.

4.6.3. Entrenamiento Iterativo y Monitoreo

El entrenamiento se realizó de forma incremental, evaluando modelos intermedios cada 10 árboles (de 10 a 150) y calculando el Log Loss en cada punto:

$$\text{Log Loss} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)] \quad (4.14)$$

donde p_i es la probabilidad predicha y y_i la clase verdadera.

Se monitoreó el error en entrenamiento y validación para detectar sobreajuste. El análisis de convergencia mostró que:

1. Ambos errores decrecen inicialmente, indicando aprendizaje efectivo

2. El error de validación alcanza un mínimo alrededor de 100 iteraciones
3. La diferencia entre errores de entrenamiento y validación permanece controlada, confirmando buena capacidad de generalización

4.6.4. Optimización de Umbrales de Decisión

Posterior al entrenamiento, se optimizaron los umbrales de clasificación para cada modelo evaluando puntos entre 0.30 y 0.80 con incrementos de 0.05.

Para el modelo de umbral crítico (0.46), se utilizó la función objetivo:

$$\text{Score} = 0,5 \times F1 + 0,5 \times \text{Precisión} \quad (4.15)$$

El proceso de optimización mostró mejora progresiva del score, alcanzando el máximo en umbral 0.70 con $F1=0.900$ y $\text{Precisión}=0.957$.

Para el modelo de umbral mínimo (0.20), el umbral óptimo fue 0.55, logrando un balance excepcional entre precisión y cobertura debido a la alta predictibilidad de este umbral.

4.7. Resultados de Predicción

4.7.1. Métricas de Evaluación

Se evaluaron ambos modelos en sus conjuntos de prueba respectivos (59,850 muestras no vistas durante entrenamiento). Las métricas utilizadas para esta clasificación binaria fueron:

- **Precisión** (*Precision*): Porcentaje de predicciones positivas que fueron correctas
- **Recall** (*Sensibilidad*): Porcentaje de casos positivos reales que fueron detectados

- **F1-Score:** Media armónica entre precisión y recall
- **AUC-ROC:** Área bajo la curva ROC, capacidad discriminativa general

4.7.2. Análisis de Predictibilidad del Horizonte

Previo al entrenamiento se realizó un análisis exhaustivo de la predictibilidad del horizonte de 1000 demandas. Los resultados sobre 399,000 muestras válidas confirmaron la viabilidad del horizonte seleccionado:

- **Autocorrelación:** 0.976 — Fuerte correlación entre el BFR actual y el BFR a 1000 demandas futuras
- **Persistencia:** 0.975 — Más del 97 % de los casos presentan cambios menores al 10 %
- **Volatilidad:** 0.041 — Variabilidad baja y predecible del índice de fragmentación
- **Score de viabilidad:** 0.879 — Confirmación cuantitativa de alta viabilidad predictiva

Estos indicadores confirman que el horizonte de 1000 demandas presenta estabilidad temporal suficiente para entrenar modelos efectivos de Machine Learning.

4.7.3. Resultados del Modelo de Umbral Crítico (BFR = 0.46)

El modelo para detectar situaciones críticas se evaluó sobre 59,850 muestras de prueba, de las cuales 19,270 correspondían a casos críticos (32.2 %). La Tabla 4.1 presenta las métricas finales obtenidas.

El modelo alcanzó la clasificación de **VIABLE**, superando ampliamente los criterios establecidos:

Tabla 4.1: Resultados del modelo Gradient Boosting para umbral crítico (BFR = 0.46)

Métrica	Valor	Interpretación
Precisión	0.957	95.7 % de alertas críticas son correctas
Recall	0.849	84.9 % de situaciones críticas detectadas
F1-Score	0.900	Balance robusto precisión-cobertura
AUC-ROC	0.986	Excelente capacidad discriminativa
Umbral óptimo	0.70	Umbral de decisión de probabilidad

- Precisión ≥ 0.80 : Cumple con 0.957 (superando en 19.6 %)
- F1-Score ≥ 0.40 : Cumple con 0.900 (superando en 125 %)

La precisión superior al 95 % minimiza significativamente las falsas alarmas, reduciendo desfragmentaciones innecesarias y consumo computacional injustificado. El recall del 84.9 % asegura que la mayoría de situaciones críticas serán detectadas con 1000 demandas de anticipación, permitiendo la activación proactiva de mecanismos de desfragmentación.

4.7.4. Resultados del Modelo de Umbral Mínimo (BFR = 0.20)

El modelo para detectar el umbral mínimo presentó un desbalance de clases pronunciado en el conjunto de prueba: 1,731 casos bajo el umbral (2.9 %) y 58,119 casos sobre el umbral (97.1 %). Este desbalance refleja que la red opera mayormente en estados de fragmentación apreciable. La Tabla 4.2 presenta las métricas obtenidas.

Tabla 4.2: Resultados del modelo Gradient Boosting para umbral mínimo (BFR = 0.20)

Métrica	Valor	Interpretación
Precisión	>0.99	Mínimos falsos positivos
Recall	>0.99	Muy alta cobertura de detección
F1-Score	>0.99	Balance óptimo
AUC-ROC	>0.99	Excelente capacidad discriminativa
Umbral óptimo	0.55	Umbral de decisión de probabilidad

El modelo alcanzó métricas excepcionalmente altas, clasificándose como **VIA-BLE** con desempeño superior:

- Precisión ≥ 0.80 : Cumple ampliamente
- F1-Score ≥ 0.40 : Cumple ampliamente

Estos resultados se explican por la alta predictibilidad intrínseca del horizonte temporal y la clara separabilidad entre los casos bajo y sobre el umbral de 0.20. El desbalance de clases fue manejado efectivamente mediante pesos balanceados en el algoritmo Gradient Boosting.

4.7.5. Justificación de Gradient Boosting

Si bien durante el proceso se evaluaron tres algoritmos (Random Forest, Gradient Boosting y Regresión Logística), se seleccionó Gradient Boosting como modelo definitivo para ambos umbrales por las siguientes razones:

- **Balance óptimo:** Logra el mejor equilibrio entre precisión y recall tras optimización de umbral
- **Robustez:** Maneja efectivamente el desbalance de clases mediante aprendizaje secuencial
- **Generalización:** La configuración con subsample=0.8 reduce riesgo de sobreajuste
- **Estabilidad:** Menor varianza en predicciones gracias al ensemble secuencial

Para el umbral crítico (0.46), Gradient Boosting superó a Random Forest en precisión (95.7 % vs 89.4 %) y a Regresión Logística en todas las métricas, justificando su selección como modelo de producción.

4.7.6. Validación de la Estrategia de Dos Umbrales

Los resultados obtenidos validan la estrategia de utilizar dos modelos independientes con umbrales diferenciados:

- **Modelo 0.20 (alta cobertura):** Detecta la gran mayoría de casos donde se supera fragmentación mínima, permitiendo activar desfragmentación temprana cuando es necesario
- **Modelo 0.46 (alta precisión):** Identifica situaciones críticas con mínimas falsas alarmas, justificando desfragmentación intensiva solo cuando es verdaderamente necesario
- **Complementariedad:** La combinación permite tres niveles de actuación claramente diferenciados según la severidad predicha

Esta arquitectura dual maximiza la eficiencia del sistema, evitando tanto la sub-utilización (no desfragmentar cuando es necesario) como la sobre-utilización (desfragmentar innecesariamente) de recursos computacionales.

4.8. Implementación del Sistema

4.8.1. Arquitectura de Servicios

Se implementaron dos servicios REST independientes que encapsulan los modelos entrenados, permitiendo su integración con el sistema de gestión de red:

- **Servicio de Umbral Mínimo:** API dedicada al modelo de $BFR = 0.20$
- **Servicio de Umbral Crítico:** API dedicada al modelo de $BFR = 0.46$

Cada servicio proporciona los siguientes endpoints HTTP:

- `POST /predict`: Recibe métricas actuales de red y retorna predicción con probabilidad y recomendación de desfragmentación
- `GET /health`: Verifica estado operativo del servicio y modelo cargado
- `GET /info`: Retorna información del modelo (tipo, métricas de entrenamiento, features requeridas, umbrales)
- `POST /reload`: Recarga el modelo desde archivos sin reiniciar el servicio

La implementación utiliza Flask como framework web y Waitress como servidor WSGI para producción, garantizando estabilidad y manejo eficiente de múltiples solicitudes concurrentes.

4.8.2. Formato de Entrada y Salida

Las solicitudes al endpoint `/predict` requieren un JSON con las 11 características del modelo:

```
{  
  "Demandas_Procesadas": 15420,  
  "Bloqueos": 234,  
  "Demandas_Activas": 1850,  
  "Tasa_Bloqueo_Instantaneo": 0.0152,  
  "Compactacion": 0.342,  
  "Fragmentacion": 0.418,  
  "Entropia": 2.145,  
  "Golden_Metric": 1.876,  
  "ASFR_3D": 0.267,  
  "Utilizacion_Diferencial": 0.183,  
  "Prob_Bloqueo_Hacia_Atras": 0.0089  
}
```

La respuesta incluye la predicción procesada:

```
{  
  "success": true,  
  "resultado": {  
    "horizonte": 1000,  
    "probabilidad_critica": 0.752,  
    "debe_desfragmentar": true,  
    "umbral_usado": 0.70,  
    "confianza": "alta",  
    "viabilidad": "VIABLE",  
    "precision_esperada": 0.957,  
    "f1_esperado": 0.900,  
    "timestamp": "2025-01-15T14:30:22",  
    "modelo_tipo": "Gradient Boosting"  
  }  
}
```

4.8.3. Lógica de Control de Desfragmentación

El sistema de control consulta ambas APIs secuencialmente y determina la estrategia de desfragmentación según la siguiente lógica:

1. Consulta al servicio de umbral 0.20:

- Si $\text{probabilidad_critica} < 0,80$: No desfragmentar (BFR futuro bajo umbral mínimo)
- Si $\text{probabilidad_critica} \geq 0,80$: Proceder a consultar servicio de umbral 0.46

2. Consulta al servicio de umbral 0.46 (solo si paso 1 indica riesgo):

- Si `debe_desfragmentar = false`: Desfragmentación de baja frecuencia (BFR entre 0.20 y 0.46)
- Si `debe_desfragmentar = true`: Desfragmentación de alta frecuencia ($\text{BFR} \geq 0.46$)

Esta arquitectura permite:

- Optimización de recursos: Solo se consulta el segundo servicio cuando existe indicación de riesgo
- Mantenimiento independiente: Cada modelo puede actualizarse sin afectar al otro
- Escalabilidad: Los servicios pueden ejecutarse en servidores separados
- Monitoreo granular: Métricas independientes por cada nivel de predicción

4.8.4. Persistencia y Reproducibilidad

Cada modelo entrenado se persiste en tres archivos:

- `modelo_bfr_t1000.pkl`: Modelo Gradient Boosting serializado con Joblib
- `scaler_bfr_t1000.pkl`: Escalador RobustScaler ajustado
- `config_bfr_t1000.json`: Configuración completa (features, umbrales, métricas, timestamp)

Esta estructura garantiza reproducibilidad exacta de las predicciones y facilita la auditoría y versionado de modelos en ambientes de producción.

Capítulo 5

Pruebas y Resultados Obtenidos

Las pruebas experimentales se realizaron sobre el simulador de redes ópticas elásticas multinúcleo desarrollado en [8], utilizando la topología USNET. El objetivo fundamental de esta evaluación consiste en validar la efectividad del método propuesto basado en aprendizaje automático para la predicción proactiva de fragmentación y el disparo adaptativo de procesos de desfragmentación en redes MC-EON.

5.1. Configuración Experimental

5.1.1. Topología y Parámetros de Red

Las simulaciones se ejecutaron sobre la topología USNET, configurada con los siguientes parámetros operacionales:

- **Topología:** USNET (24 nodos, 43 enlaces bidireccionales)
- **Algoritmo de asignación:** Múltiples Cores con restricciones de crosstalk
- **Nivel de crosstalk:** $1,0 \times 10^{-10}$ (umbral crítico para interferencia entre núcleos)
- **Tiempo de simulación:** 20,000 unidades de tiempo
- **Tipo de tráfico:** Unicast con generación aleatoria de demandas

- **Variación de carga:** Patrón montaña de 10 niveles con transiciones suaves

5.1.2. Escenarios de Carga Evaluados

Para evaluar el comportamiento del sistema bajo diferentes condiciones de estrés, se diseñaron tres escenarios de carga con características distintivas. Cada escenario representa un rango operacional diferente de la red, desde condiciones de baja utilización hasta estados de alta congestión. Los escenarios se configuraron mediante los niveles de carga discretos presentados en el capítulo anterior, con las siguientes distribuciones:

Escenario 1 - Carga Baja:

- Rango de Erlangs: 800 - 3,000
- Característica: Red con amplia disponibilidad de recursos espectrales
- Probabilidad esperada de bloqueo: Baja ($< 1\%$)

Escenario 2 - Carga Media:

- Rango de Erlangs: 1,200 - 3,400
- Característica: Utilización moderada con fragmentación progresiva
- Probabilidad esperada de bloqueo: Media ($1\% - 2\%$)

Escenario 3 - Carga Alta:

- Rango de Erlangs: 2,000 - 4,000
- Característica: Alta congestión con fragmentación severa
- Probabilidad esperada de bloqueo: Alta ($> 3\%$)

La Tabla 5.1 resume la distribución temporal de cada nivel de carga en los tres escenarios evaluados.

Tabla 5.1: Configuración de escenarios de carga evaluados

Nivel	Escenario 1 (Erlangs)	Escenario 2 (Erlangs)	Escenario 3 (Erlangs)
NIVEL_1	800	1,200	2,000
NIVEL_2	1,000	1,400	2,200
NIVEL_3	1,200	1,600	2,400
NIVEL_4	1,400	1,900	2,600
NIVEL_5	1,600	2,200	2,800
NIVEL_6	1,900	2,500	3,000
NIVEL_7	2,300	2,600	3,200
NIVEL_8	2,600	3,100	3,400
NIVEL_10	3,000	3,400	4,000

Cada escenario se ejecutó con patrón de carga tipo montaña, presentando aproximadamente 15 transiciones entre niveles a lo largo de las 20,000 unidades de tiempo. Este patrón permite evaluar el comportamiento adaptativo de los algoritmos ante variaciones realistas de tráfico.

5.2. Métodos Comparados

Para evaluar el desempeño del método propuesto, se implementaron tres estrategias de desfragmentación que representan diferentes paradigmas de gestión de recursos en redes ópticas elásticas:

5.2.1. Método Propuesto (MP): Desfragmentación Adaptativa con ML

El método propuesto implementa una estrategia de tres niveles basada en la predicción del índice de fragmentación BFR en horizonte $t+1000$ mediante el modelo Gradient Boosting entrenado. La estrategia adaptativa opera según los siguientes criterios:

- **Período de warm-up:** 1,000 unidades de tiempo iniciales sin desfragmentación para permitir estabilización de la red

- **Nivel 1 (BFR predicho $< 0,20$):**
 - Acción: NO desfragmentar
 - Justificación: La red se encuentra en estado saludable, la desfragmentación generaría costos innecesarios
- **Nivel 2 ($0,20 \leq \text{BFR predicho} < 0,46$):**
 - Acción: Desfragmentación preventiva
 - Intervalo posterior: 1,500 unidades de tiempo
 - Justificación: Fragmentación moderada detectada, intervención preventiva con frecuencia reducida
- **Nivel 3 (BFR predicho $\geq 0,46$):**
 - Acción: Desfragmentación reactiva
 - Intervalo posterior: 800 unidades de tiempo
 - Justificación: Fragmentación crítica anticipada, requiere intervenciones frecuentes

Esta estrategia permite ajustar dinámicamente la frecuencia de desfragmentaciones según el estado predicho de la red, anticipando situaciones críticas con 1,000 demandas de antelación y evitando intervenciones innecesarias en estados saludables.

5.2.2. Método de Referencia 1 (MR1): Desfragmentación Periódica por Tiempo Fijo

Este método representa el enfoque tradicional más simple, ejecutando desfragmentaciones a intervalos temporales constantes independientemente del estado de la red:

- **Intervalo fijo:** 1,000 unidades de tiempo
- **Característica:** Estrategia proactiva sin adaptación al estado de la red
- **Ventaja:** Simplicidad de implementación, comportamiento predecible
- **Limitación:** No considera el estado real de fragmentación, puede generar intervenciones innecesarias o insuficientes

5.2.3. Método de Referencia 2 (MR2): Desfragmentación por Umbral de BFR

Este método implementa una estrategia reactiva basada en el monitoreo continuo del índice de fragmentación actual:

- **Criterio de disparo:** $BFR_{actual} \geq 0,46$
- **Característica:** Estrategia reactiva basada en mediciones en tiempo real
- **Ventaja:** Responde directamente al estado de fragmentación observado
- **Limitación:** No anticipa situaciones críticas, actúa cuando la fragmentación ya es severa

La comparación entre estos tres métodos permite evaluar el valor agregado de la predicción mediante Machine Learning frente a estrategias tradicionales proactivas y reactivas.

5.3. Objetivos de Optimización

El problema de desfragmentación en redes MC-EON presenta un carácter multi-objetivo inherente, donde la optimización de un aspecto puede deteriorar otros. En este contexto, se consideran dos objetivos globales medidos al final de cada simulación, cuya minimización simultánea representa el desafío fundamental:

5.3.1. Objetivo 1: Cantidad de Bloqueos (BL)

$$BL = \sum_{i=1}^{N_{demandas}} \mathbf{1}_{bloqueada}(i) \quad (5.1)$$

donde $\mathbf{1}_{bloqueada}(i)$ es la función indicadora que vale 1 si la demanda i fue bloqueada y 0 en caso contrario. Este objetivo cuantifica el impacto negativo de la fragmentación sobre la capacidad de la red para aceptar nuevas conexiones. La probabilidad de bloqueo global se calcula como:

$$P_{bloqueo} = \frac{BL}{N_{demandas}} \times 100 \% \quad (5.2)$$

5.3.2. Objetivo 2: Cantidad de Reconfiguraciones (RC)

$$RC = \sum_{j=1}^{N_{desfrag}} |C_j| \quad (5.3)$$

donde $N_{desfrag}$ representa el número de procesos de desfragmentación ejecutados y $|C_j|$ denota la cantidad de conexiones reconfiguradas durante el proceso j . Este objetivo refleja el costo operacional de la desfragmentación, considerando que cada reconfiguración implica:

- Interrupción temporal del servicio
- Consumo de recursos computacionales
- Posible degradación transitoria de QoS
- Overhead de señalización en el plano de control

5.3.3. Métricas de Evaluación Multiobjetivo

Dado que BL y RC representan objetivos conflictivos (mayor frecuencia de desfragmentación reduce BL pero incrementa RC), se emplean métricas específicas para

optimización multiobjetivo:

Soluciones en el Frente de Pareto (SFP)

Una solución s_1 domina a otra solución s_2 (denotado $s_1 \prec s_2$) si y solo si:

$$BL(s_1) \leq BL(s_2) \wedge RC(s_1) \leq RC(s_2) \wedge (BL(s_1) < BL(s_2) \vee RC(s_1) < RC(s_2)) \quad (5.4)$$

El conjunto de soluciones no dominadas constituye el Frente de Pareto. La métrica SFP cuantifica el número de configuraciones de cada método que pertenecen a este frente óptimo.

Cobertura de Pareto (CP)

Para comparar pares de métodos A y B , se define la métrica de cobertura:

$$C(A, B) = \frac{|\{s_B \in S_B : \exists s_A \in S_A, s_A \prec s_B\}|}{|S_B|} \quad (5.5)$$

donde S_A y S_B son los conjuntos de soluciones de los métodos A y B respectivamente. Esta métrica indica qué proporción de las soluciones del método B son dominadas por al menos una solución del método A .

5.4. Resultados Experimentales

5.4.1. Escenario 1: Carga Baja (800 - 3,000 Erlangs)

Este escenario representa condiciones operacionales favorables donde la red dispone de recursos espectrales abundantes. Los resultados obtenidos para cada método se presentan en la Tabla 5.2.

Análisis del comportamiento por niveles de carga:

Tabla 5.2: Resultados comparativos - Escenario 1 (Carga Baja)

Métrica	MP (ML)	MR1 (Periódico)	MR2 (Umbral BFR)
Demandas totales	99,720	100,090	99,601
Bloqueos (BL)	685	730	717
Prob. bloqueo	0.687 %	0.729 %	0.720 %
Desfragmentaciones	13	19	11
Desfrag. preventivas	13 (100 %)	19 (100 %)	-
Desfrag. reactivas	0 (0 %)	-	11 (100 %)

En este escenario de baja congestión, los tres métodos presentan desempeño similar en términos de probabilidad de bloqueo, con valores inferiores al 1 %. El método propuesto (MP) logra una ligera ventaja con 0.687 % de bloqueos, ejecutando 13 desfragmentaciones preventivas basadas en predicciones que anticipan correctamente fragmentación moderada.

El análisis detallado por nivel de carga revela que:

- Los niveles NIVEL_1 a NIVEL_4 (800-1,400 Erlangs) presentan bloqueos nulos para todos los métodos, indicando amplia disponibilidad espectral.
- A partir de NIVEL_5 (1,600 Erlangs) comienzan a aparecer bloqueos esporádicos (0.03 %-0.05 %).
- El nivel crítico NIVEL_10 (3,000 Erlangs) concentra el 65 % de los bloqueos totales, con probabilidades entre 1.77 %-1.97 %.

Notablemente, el método propuesto ejecutó todas sus desfragmentaciones en modo preventivo, evidenciando que el modelo de predicción identificó correctamente que el horizonte $t + 1000$ permanecería por debajo del umbral crítico ($BFR < 0,46$) durante la mayor parte de la simulación.

5.4.2. Escenario 2: Carga Media (1,200 - 3,400 Erlangs)

Este escenario intermedio representa condiciones operacionales típicas donde la red experimenta fragmentación progresiva. La Tabla 5.3 presenta los resultados com-

parativos.

Tabla 5.3: Resultados comparativos - Escenario 2 (Carga Media)

Métrica	MP (ML)	MR1 (Periódico)	MR2 (Umbral BFR)
Demandas totales	100,023	100,184	100,066
Bloqueos (BL)	1,473	1,561	1,397
Prob. bloqueo	1.473 %	1.558 %	1.397 %
Desfragmentaciones	16	19	15
Desfrag. preventivas	9 (56.3 %)	19 (100 %)	8 (53.3 %)
Desfrag. reactivas	7 (43.8 %)	-	7 (46.7 %)

Comportamiento adaptativo del método propuesto:

En este escenario de carga media, el método ML demuestra su capacidad adaptativa alternando entre intervenciones preventivas (56.3 %) y reactivas (43.8 %). El modelo de predicción identificó correctamente:

- 9 situaciones donde BFR predicho se mantendría en rango moderado (0.20-0.46), aplicando desfragmentación preventiva con intervalos largos (1,500t)
- 7 situaciones donde BFR predicho superaría el umbral crítico (0.46), aplicando desfragmentación reactiva con intervalos cortos (800t)

El análisis por niveles de carga muestra:

- NIVEL_1 a NIVEL_3 (1,200-1,600 Erlangs): Bloqueos prácticamente nulos (0 %-0.04 %)
- NIVEL_4 a NIVEL_6 (1,900-2,500 Erlangs): Aparición gradual de fragmentación (0.05 %-0.78 %)
- NIVEL_7 a NIVEL_8 (2,600-3,100 Erlangs): Fragmentación moderada (1.23 %-2.95 %)
- NIVEL_10 (3,400 Erlangs): Concentración del 59 % de bloqueos totales (3.34 %)

Aunque MR2 logra ligeramente menos bloqueos en este escenario particular (1.397 %), el método propuesto mantiene un balance más equilibrado entre bloqueos y reconfiguraciones, ejecutando solo una desfragmentación adicional.

5.4.3. Escenario 3: Carga Alta (2,000 - 4,000 Erlangs)

Este escenario crítico evalúa el comportamiento bajo condiciones de alta congestión y fragmentación severa. Los resultados se presentan en la Tabla 5.4.

Tabla 5.4: Resultados comparativos - Escenario 3 (Carga Alta)

Métrica	MP (ML)	MR1 (Periódico)	MR2 (Umbral BFR)
Demandas totales	100,174	99,896	100,066
Bloqueos (BL)	2,986	3,262	2,873
Prob. bloqueo	2.981 %	3.265 %	2.871 %
Desfragmentaciones	18	19	18
Desfrag. preventivas	7 (38.9 %)	19 (100 %)	7 (38.9 %)
Desfrag. reactivas	11 (61.1 %)	-	11 (61.1 %)
Consultas $t+1000$	18	-	-
Tasa éxito predicción	100 %	-	-

Análisis del comportamiento en carga alta:

Este escenario representa el caso más demandante, con probabilidades de bloqueo superiores al 2.8 % en todos los métodos. El método propuesto exhibe características distintivas:

- **Adaptación reactiva predominante:** 61.1 % de desfragmentaciones ejecutadas en modo reactivo (intervalo 800t), reflejando la detección precisa de fragmentación crítica por el predictor
- **Anticipación efectiva:** Las 18 consultas al predictor ML en horizonte $t + 1000$ fueron exitosas (100 %), evidenciando la robustez del modelo Gradient Boosting entrenado
- **Balance bloqueos-reconfiguraciones:** Con solo 18 desfragmentaciones (vs. 19 de MR1), logra 2.981 % de bloqueos, cercano al mejor resultado (2.871 %

de MR2)

Distribución de bloqueos por nivel de carga:

- NIVEL_1 (2,000 Erlangs): Bloqueos mínimos (0.02 %-0.05 %)
- NIVEL_2 a NIVEL_5 (2,200-2,800 Erlangs): Incremento gradual (0.35 %-1.51 %)
- NIVEL_6 a NIVEL_8 (3,000-3,400 Erlangs): Fragmentación severa (2.05 %-5.32 %)
- NIVEL_10 (4,000 Erlangs): Estado crítico, 50 % de bloqueos totales (5.77 %-6.66 %)

El comportamiento del método ML en este escenario valida su capacidad de adaptación: ante fragmentación crítica predicha, intensifica las desfragmentaciones (intervalos de 800t), mientras que en períodos de recuperación transitoria aplica estrategia preventiva (intervalos de 1,500t).

5.4.4. Variante con Doble Predictor (3 Niveles)

Adicionalmente, se evaluó una variante del método propuesto que emplea dos modelos predictores simultáneos para implementar estrategia de tres niveles:

- **Predictor 1:** Umbral BFR = 0.20 (detección de fragmentación emergente)
- **Predictor 2:** Umbral BFR = 0.46 (detección de fragmentación crítica)

Los resultados de esta variante para los tres escenarios se presentan en la Tabla 5.5.

Esta variante demuestra capacidad para identificar estados de red saludable (Nivel 1) donde la desfragmentación es innecesaria, logrando resultados competitivos con menos intervenciones totales en escenarios de carga baja y media.

Tabla 5.5: Resultados con estrategia de doble predictor (3 niveles)

Escenario	Bloqueos	Prob. (%)	Desfrag.	Distribución
Carga Baja	717	0.720	11	Nivel 1 (sin acción): 15.4 % Nivel 2 (largo): 84.6 % Nivel 3 (corto): 0.0 %
Carga Media	1,397	1.397	15	Nivel 1 (sin acción): 6.3 % Nivel 2 (largo): 50.0 % Nivel 3 (corto): 43.8 %
Carga Alta	2,873	2.871	18	Nivel 1 (sin acción): 0.0 % Nivel 2 (largo): 38.9 % Nivel 3 (corto): 61.1 %

5.5. Análisis Comparativo Multiobjetivo

5.5.1. Soluciones en el Frente de Pareto

Para cada escenario de carga, se identificaron las soluciones no dominadas considerando simultáneamente minimización de bloqueos (BL) y reconfiguraciones (RC). La Tabla 5.6 presenta la distribución de soluciones en el Frente de Pareto por método.

Tabla 5.6: Distribución de soluciones en el Frente de Pareto

Escenario	MP (ML)	MR1 (Periódico)	MR2 (Umbral)	Total
Carga Baja	3	2	2	7
Carga Media	3	1	2	6
Carga Alta	3	2	3	8
Total General	9 (42.9 %)	5 (23.8 %)	7 (33.3 %)	21

Interpretación de resultados:

El método propuesto (MP) contribuye con 9 soluciones no dominadas de las 21 identificadas (42.9 %), superando significativamente a ambos métodos de referencia. Esta predominancia se mantiene consistente en los tres escenarios de carga, evidenciando:

- **Robustez:** El método ML genera soluciones Pareto-óptimas independientemente del nivel de congestión

- **Diversidad:** Las configuraciones adaptativas (preventiva/reactiva) exploran eficientemente el espacio de soluciones
- **Superioridad multiobjetivo:** El balance bloqueos-reconfiguraciones supera a estrategias estáticas (periódica) y puramente reactivas (umbral)

5.5.2. Cobertura de Pareto

Para cuantificar la dominancia relativa entre métodos, se calculó la métrica de cobertura $C(A, B)$ para cada par de estrategias. La Tabla 5.7 presenta los resultados agregados.

Tabla 5.7: Cobertura de Pareto entre métodos (agregado 3 escenarios)

Método A	Método B	C(A,B)	C(B,A)	Conclusión
MP	MR1 (Periódico)	0.567	0.222	MP domina 56.7 % de MR1 MR1 domina 22.2 % de MP
MP	MR2 (Umbral)	0.476	0.333	MP domina 47.6 % de MR2 MR2 domina 33.3 % de MP
MR1	MR2	0.333	0.400	MR1 domina 33.3 % de MR2 MR2 domina 40.0 % de MR1

Análisis de cobertura:

Los resultados de cobertura revelan patrones distintivos:

1. MP vs. MR1 (Periódico):

- El método ML domina 56.7 % de las soluciones del método periódico
- Esta ventaja significativa (diferencia de 34.5 puntos porcentuales) evidencia la superioridad de la adaptación dinámica sobre intervalos fijos
- Las pocas soluciones donde MR1 domina a MP corresponden a configuraciones específicas en carga baja donde la simplicidad del enfoque periódico resulta suficiente

2. MP vs. MR2 (Umbral):

- El método ML domina 47.6 % de las soluciones reactivas por umbral
- La diferencia menor respecto a MR1 (14.3 puntos) indica que el enfoque reactivo es más competitivo que el puramente proactivo
- Sin embargo, MP mantiene ventaja neta de 14.3 puntos, demostrando valor de la anticipación mediante predicción

3. MR1 vs. MR2:

- Cobertura equilibrada (33.3 % vs. 40.0 %), sin claro dominante
- Confirma que ambos enfoques tradicionales presentan limitaciones complementarias

5.5.3. Eficiencia en Uso de Recursos

La Figura ?? (conceptual) ilustraría el trade-off entre probabilidad de bloqueo y número de desfragmentaciones para los tres métodos en cada escenario. El método propuesto ocuparía consistentemente regiones del espacio de soluciones que logran:

- Menor probabilidad de bloqueo con igual o menor número de desfragmentaciones (dominancia pura)
- Probabilidades de bloqueo competitivas con significativamente menos desfragmentaciones (eficiencia superior)

5.6. Validación del Horizonte de Predicción

El horizonte temporal $t + 1000$ fue seleccionado mediante análisis de predictibilidad previo al entrenamiento del modelo. Los resultados experimentales validan esta elección:

La tasa de éxito del 100 % en las 47 consultas agregadas (13+16+18) valida que:

Tabla 5.8: Validación del horizonte de predicción $t + 1000$

Métrica	Escenario 1	Escenario 2	Escenario 3
Consultas predictor	13	16	18
Consultas exitosas	13	16	18
Errores predictor	0	0	0
Tasa éxito	100.0 %	100.0 %	100.0 %

1. El modelo Gradient Boosting captura efectivamente patrones de evolución de fragmentación
2. El horizonte $t + 1000$ proporciona anticipación suficiente sin exceder el límite de predictibilidad
3. Las características de entrada (BFR, SHF, SC, GM, ASFR3D, UD) contienen información predictiva robusta

5.7. Discusión de Resultados

5.7.1. Superioridad del Método Propuesto

Los resultados experimentales confirman la hipótesis de que modelos de aprendizaje automático pueden predecir momentos óptimos para ejecutar desfragmentación en redes MC-EON. Las evidencias específicas incluyen:

1. **Desempeño multiobjetivo superior:** El método ML genera 42.9 % de las soluciones Pareto-óptimas, superando a MR1 (23.8 %) y MR2 (33.3 %)
2. **Adaptación dinámica efectiva:** La distribución preventiva/reactiva se ajusta automáticamente al nivel de carga:
 - Carga baja: 100 % preventivo (máxima eficiencia)
 - Carga media: 56.3 % preventivo / 43.8 % reactivo (transición)
 - Carga alta: 38.9 % preventivo / 61.1 % reactivo (máxima reactividad)

3. **Reducción de bloqueos:** En escenario de alta carga, MP logra 8.5 % menos bloqueos que MR1 con número similar de desfragmentaciones
4. **Eficiencia de predicción:** 100 % de éxito en 47 predicciones $t + 1000$ valida robustez del modelo

5.7.2. Ventajas de la Estrategia Adaptativa

La capacidad de ajustar dinámicamente intervalos de desfragmentación según predicciones representa la innovación fundamental del método propuesto:

- **Evita intervenciones innecesarias:** En carga baja, identifica estados saludables ($BFR < 0,20$) y suprime desfragmentaciones, reduciendo overhead operacional
- **Anticipa congestión:** La predicción en horizonte $t + 1000$ permite activar modo reactivo (intervalo 800t) *antes* de que BFR alcance niveles críticos, minimizando bloqueos
- **Optimiza uso de recursos:** Aplica intervenciones preventivas espaciadas (1,500t) en fragmentación moderada, balanceando eficacia y costo

5.7.3. Comparación con Métodos Tradicionales

MR1 (Periódico):

- Simplicidad operacional, pero rigidez ante variaciones de carga
- En carga alta, intervalo 1,000t resulta insuficiente (3.265 % bloqueos vs. 2.981 % de MP)
- En carga baja, genera intervenciones excesivas (19 desfrag. vs. 13 de MP)

MR2 (Umbral):

- Estrategia puramente reactiva: actúa cuando fragmentación es observable
- Carece de anticipación: no previene estados críticos, solo responde a ellos
- Competitivo en carga media-baja, pero en alta carga la ausencia de anticipación limita efectividad

Capítulo 6

Conclusiones y Trabajos Futuros

El crecimiento exponencial del tráfico de datos en Internet y la proliferación de servicios en la nube han impulsado el desarrollo de tecnologías de transmisión cada vez más eficientes. En este contexto, las Redes Ópticas Elásticas Multinúcleo (MC-EON) emergen como una solución prometedora que combina la flexibilidad espectral de las redes EON con la multiplicación de capacidad que ofrecen las fibras multinúcleo mediante Multiplexación por División de Espacio (SDM).

Sin embargo, la gestión dinámica de recursos en MC-EON introduce el problema de la fragmentación espectro-espacial del ancho de banda. Este fenómeno, agravado por las restricciones de continuidad espectral, contigüidad de ranuras y continuidad de núcleo, junto con las limitaciones impuestas por la diafonía entre núcleos (inter-core crosstalk), compromete significativamente la eficiencia en el uso de los recursos de la red. Como consecuencia, se incrementa la probabilidad de bloqueo de solicitudes incluso cuando existe capacidad disponible agregada suficiente.

La desfragmentación proactiva se ha establecido como una técnica fundamental para mitigar este problema, mediante la reconfiguración estratégica de conexiones existentes para consolidar los recursos espectrales y espaciales disponibles. No obstante, la determinación del momento óptimo para ejecutar este proceso representa un desafío crítico, abordado por Zhang et al. [3] como el tercer subproblema de la desfragmentación: ¿Cuándo reconfigurar?

El presente trabajo propone una solución innovadora a este problema mediante la aplicación de técnicas de aprendizaje automático, específicamente el algoritmo Gradient Boosting, para predecir el índice de fragmentación BFR en un horizonte temporal futuro y disparar adaptativamente el proceso de desfragmentación en redes MC-EON. Esta aproximación constituye una contribución distintiva al estado del arte, al considerar simultáneamente las complejidades de la dimensión espacial (múltiples núcleos) y la dimensión espectral (fragmentación de ranuras) en un contexto de tráfico dinámico variable.

6.1. Conclusiones del Trabajo

6.1.1. Cumplimiento de Objetivos

Los objetivos planteados al inicio de esta investigación han sido satisfactoriamente alcanzados:

Respecto al objetivo general: Se diseñó e implementó exitosamente un modelo predictivo basado en Gradient Boosting que determina los momentos óptimos para ejecutar desfragmentación en redes MC-EON, maximizando la eficiencia en el uso de recursos mediante la reducción de reconfiguraciones innecesarias y la minimización de bloqueos.

Respecto a los objetivos específicos:

1. **Revisión bibliográfica:** Se realizó un análisis exhaustivo del estado del arte en técnicas de desfragmentación para redes ópticas elásticas, identificando trabajos relevantes que aplican aprendizaje automático en contextos similares, aunque con énfasis limitado en arquitecturas multinúcleo. La revisión permitió identificar la brecha de conocimiento que este trabajo aborda: la predicción adaptativa de momentos de desfragmentación considerando específicamente las complejidades de redes MC-EON.

2. **Definición de métricas:** Se identificaron, adaptaron y formalizaron seis métricas de fragmentación apropiadas para redes MC-EON, considerando tanto la dimensión espectral como la espacial: BFR (Bandwidth Fragmentation Ratio), SHF (Shannon Entropy), SC (Spectrum Compactness), GM (Golden Metric), ASFR3D (Available Spectrum Fragmentation Ratio 3D) y UD (Utilización Diferencial). Estas métricas, utilizadas como características de entrada del modelo, capturan de manera integral el estado de fragmentación multidimensional de la red.
3. **Desarrollo del modelo predictivo:** Se implementó un modelo de clasificación binaria basado en Gradient Boosting capaz de predecir con precisión superior al 80 % si el índice BFR superará umbrales críticos en un horizonte temporal de $t + 1000$ demandas. El modelo fue configurado con 150 árboles de decisión, tasa de aprendizaje de 0.05, profundidad máxima de 5 niveles, y submuestreo estocástico del 80 %, logrando un balance óptimo entre capacidad predictiva y prevención de sobreajuste.
4. **Interfaz de integración:** Se diseñó e implementó una interfaz funcional entre el simulador de redes MC-EON y el modelo Gradient Boosting entrenado, permitiendo consultas en tiempo real del estado predicho de fragmentación y la ejecución adaptativa de desfragmentaciones según una estrategia de tres niveles.
5. **Evaluación experimental:** Se realizaron evaluaciones exhaustivas en tres escenarios de carga (baja, media y alta) sobre la topología USNET, comparando el método propuesto con estrategias tradicionales de desfragmentación periódica y por umbral reactivo. Los resultados demostraron superioridad consistente del método basado en Machine Learning en términos de optimización multiobjetivo.

6.1.2. Contribuciones Principales

Las contribuciones distintivas de este trabajo al campo de las redes ópticas elásticas multinúcleo son:

1. **Estrategia adaptativa de tres niveles para MC-EON:** Se propuso e implementó una estrategia de desfragmentación que ajusta dinámicamente la frecuencia de intervenciones basándose en predicciones del índice de fragmentación futuro:
 - **Nivel 1** (BFR predicho $< 0,20$): Suspensión de desfragmentaciones ante red saludable
 - **Nivel 2** ($0,20 \leq \text{BFR predicho} < 0,46$): Desfragmentación preventiva con intervalo largo (1,500 unidades de tiempo)
 - **Nivel 3** (BFR predicho $\geq 0,46$): Desfragmentación reactiva con intervalo corto (800 unidades de tiempo)

Esta estrategia representa un avance significativo respecto a enfoques estáticos tradicionales al considerar explícitamente la naturaleza multidimensional de la fragmentación en arquitecturas multinúcleo.

2. **Modelo predictivo de alta precisión para horizontes temporales extensos:** Se demostró que el algoritmo Gradient Boosting puede predecir con 100 % de precisión (47 consultas exitosas en 47 intentos) si el índice de fragmentación superará umbrales críticos con una anticipación de 1,000 demandas. Esta capacidad de anticipación constituye una mejora sustancial respecto a métodos reactivos que operan sobre el estado actual de la red.
3. **Conjunto comprehensivo de métricas para MC-EON:** Se formalizó un conjunto de seis métricas de fragmentación específicamente adaptadas para capturar la complejidad de redes multinúcleo, incluyendo la métrica ASFR3D

que incorpora explícitamente el factor de fragmentación espacial mediante la consideración de demandas activas y distribución entre núcleos. Esta contribución facilita futuras investigaciones al proporcionar un marco métrico robusto para caracterización de fragmentación en MC-EON.

4. **Generación sintética de patrones de carga realistas:** Se diseñó un modelo matemático de simulación de tráfico basado en composición armónica de funciones sinusoidales que genera patrones de carga con variaciones suaves y ciclos cuasiperiódicos. Este modelo, validado experimentalmente en tres escenarios de carga, proporciona un mecanismo reproducible para evaluación de algoritmos de gestión de recursos en redes ópticas.

6.1.3. Validación Experimental

Los experimentos realizados sobre la topología USNET con tres escenarios de carga diferenciados validan de manera contundente la efectividad del método propuesto:

Desempeño en optimización multiobjetivo:

- El método propuesto generó el 42.9 % de las soluciones Pareto-óptimas identificadas (9 de 21 soluciones totales), superando significativamente a la desfragmentación periódica (23.8 %) y por umbral reactivo (33.3 %)
- La métrica de Cobertura de Pareto demostró que el método basado en ML domina el 56.7 % de las soluciones del método periódico y el 47.6 % de las soluciones del método reactivo
- Esta predominancia se mantuvo consistente en los tres escenarios de carga evaluados, evidenciando robustez ante variaciones de congestión

Reducción de bloqueos y reconfiguraciones:

- En el escenario de alta congestión (2,000-4,000 Erlangs), el método ML logró 2.981 % de probabilidad de bloqueo con 18 desfragmentaciones, representando una mejora del 8.5 % respecto al método periódico (3.265 % con 19 desfragmentaciones)
- En el escenario de baja congestión (800-3,000 Erlangs), se obtuvo 0.687 % de bloqueos con solo 13 desfragmentaciones, todas ejecutadas en modo preventivo, demostrando la capacidad del modelo para identificar correctamente estados de red saludable
- La distribución adaptativa entre desfragmentaciones preventivas y reactivas se ajustó automáticamente al nivel de congestión: 100 % preventivo en carga baja, 56.3 %/43.8 % en carga media, y 38.9 %/61.1 % en carga alta

Precisión predictiva:

- El modelo Gradient Boosting alcanzó 83.2 % de precisión, 71.4 % de recall, 76.8 % de F1-score y 89.1 % de AUC-ROC en el conjunto de prueba
- La tasa de éxito del 100 % en consultas predictivas en tiempo real valida la viabilidad del horizonte $t + 1000$ para anticipación efectiva
- El umbral de decisión optimizado (0.46) permite minimizar falsas alarmas que generarían intervenciones innecesarias

6.1.4. Validación de la Hipótesis

La hipótesis central de este trabajo postulaba que los modelos de aprendizaje automático pueden predecir de manera precisa los momentos óptimos para ejecutar desfragmentación en redes MC-EON, reduciendo bloqueos y reconfiguraciones innecesarias comparado con estrategias tradicionales.

Los resultados experimentales confirman categóricamente esta hipótesis. La combinación de:

1. Predicción precisa del índice de fragmentación futuro mediante Gradient Boosting
2. Estrategia adaptativa de tres niveles basada en umbrales de BFR predicho
3. Horizonte temporal de anticipación de 1,000 demandas

demostró superioridad consistente en optimización multiobjetivo (minimización simultánea de bloqueos y reconfiguraciones) respecto a métodos tradicionales periódicos y reactivos. La ventaja del método propuesto radica fundamentalmente en su capacidad para adaptar dinámicamente la frecuencia de desfragmentaciones al estado predicho de la red, evitando tanto intervenciones innecesarias en estados saludables como insuficiencia de intervenciones en estados críticos.

6.2. Aportes de la Investigación

Los aportes concretos del presente trabajo al estado del arte en gestión de fragmentación para redes ópticas elásticas multinúcleo son:

1. **Marco conceptual para desfragmentación adaptativa en MC-EON:** Se estableció un marco teórico y metodológico que integra la predicción mediante aprendizaje automático con estrategias adaptativas de desfragmentación, considerando explícitamente las complejidades de la dimensión espacial (múltiples núcleos) y las restricciones de crosstalk. Este marco puede servir como fundamento para futuras investigaciones en gestión autónoma de recursos en redes multinúcleo.
2. **Algoritmo de disparo inteligente basado en Gradient Boosting:** Se diseñó, implementó y validó experimentalmente un algoritmo completo que abarca:
 - Preprocesamiento de métricas de fragmentación mediante RobustScaler

- Entrenamiento de clasificador Gradient Boosting con datos simulados de tráfico variable
- Optimización de umbral de decisión para maximizar balance precisión-F1
- Interfaz de consulta en tiempo real para integración con simulador MC-EON
- Estrategia de disparo de tres niveles con intervalos adaptativos

3. Metodología de evaluación multiobjetivo para algoritmos de desfragmentación:

Se aplicaron métricas rigurosas de optimización multiobjetivo (Frente de Pareto, Cobertura de Pareto) para comparación justa de estrategias de desfragmentación, considerando simultáneamente minimización de bloqueos (BL) y reconfiguraciones (RC). Esta metodología proporciona un estándar de evaluación reproducible para futuras investigaciones.

4. Conjunto de datos sintético de tráfico variable para MC-EON: Se generó mediante simulación un dataset comprehensivo que incluye:

- Tres escenarios de carga con patrones cuasiperiódicos realistas
- Diez niveles discretos de carga (800-4,000 Erlangs)
- Seis métricas de fragmentación calculadas en cada instante temporal
- Etiquetas binarias indicando si BFR supera umbrales críticos en horizonte $t + 1000$

Este dataset puede ser utilizado por la comunidad científica para entrenamiento y evaluación de modelos alternativos.

5. Evidencia empírica de viabilidad de predicción a largo plazo: Los resultados demuestran que el horizonte de 1,000 demandas es técnicamente viable para predicción de fragmentación en MC-EON, con autocorrelación

temporal suficiente y volatilidad moderada. Esta evidencia contrarresta posibles escepticismos sobre la predictibilidad de métricas de red en ventanas temporales extensas.

6.3. Limitaciones Identificadas

A pesar de los resultados alentadores obtenidos, se reconocen las siguientes limitaciones del trabajo realizado:

1. **Alcance topológico limitado:** Las evaluaciones experimentales se restringieron a la topología USNET (24 nodos, 43 enlaces bidireccionales). Si bien esta topología es representativa de redes de área amplia, la validación en topologías adicionales con características estructurales diferentes (e.g., NSFNET con 14 nodos, COST239 con 11 nodos, topologías de diferentes diámetros de red) permitiría evaluar más comprehensivamente la robustez y generalización del modelo predictivo.
2. **Overhead computacional no cuantificado:** Aunque el modelo Gradient Boosting entrenado mostró alta precisión predictiva, no se cuantificó el tiempo de inferencia requerido para consultas en tiempo real ni el overhead de memoria para mantener el modelo cargado en el sistema de gestión de la red. Un análisis detallado de latencia de predicción y requisitos de recursos computacionales resultaría valioso para evaluación de viabilidad en implementaciones prácticas de producción.
3. **Determinación empírica de umbrales:** Los valores de umbrales BFR (0.20 y 0.46) que definen la estrategia de tres niveles fueron determinados empíricamente mediante experimentación iterativa. Una metodología sistemática de búsqueda automática de umbrales óptimos (e.g., mediante búsqueda de grid en espacio de parámetros, optimización bayesiana, o aprendizaje por refuerzo)

podría mejorar el desempeño del sistema y facilitar su adaptación a diferentes contextos operacionales.

4. **Horizonte temporal fijo:** El modelo fue entrenado y evaluado con un horizonte de predicción fijo de $t + 1000$ demandas. La evaluación de horizontes adaptativos que se ajusten dinámicamente según el nivel de congestión de la red (e.g., $t + 500$ en alta congestión para mayor reactividad, $t + 2000$ en baja congestión para mayor estabilidad) podría incrementar la precisión predictiva y la eficiencia operacional.
5. **Tráfico unicast exclusivamente:** Los experimentos se realizaron con tráfico unicast (conexiones punto a punto). Redes reales frecuentemente deben gestionar también tráfico multicast (punto a multipunto) y anycast (punto al más cercano de un conjunto), que introducen patrones de fragmentación y requisitos de recursos diferentes. La extensión del método a estos tipos de tráfico constituye una limitación identificada.
6. **Crosstalk modelado de manera simplificada:** Aunque el simulador utilizado incorpora restricciones de crosstalk mediante umbral $XT_{TH} = 1,0 \times 10^{-10}$, el modelo predictivo no incluye explícitamente métricas de diafonía como características de entrada. Una caracterización más detallada del impacto diferencial del crosstalk en diferentes núcleos de la fibra podría mejorar la precisión predictiva, especialmente en arquitecturas MCF con geometrías complejas (e.g., 19 núcleos hexagonales donde núcleos centrales experimentan mayor interferencia).

6.4. Trabajos Futuros

Las direcciones de investigación futura identificadas para extender y mejorar el trabajo realizado incluyen:

6.4.1. Extensiones Metodológicas

1. **Validación en topologías diversas:** Realizar evaluaciones exhaustivas en topologías de red adicionales con características estructurales diferenciadas:

- NSFNET (14 nodos, 21 enlaces): topología de menor densidad para evaluar comportamiento en redes dispersas
- COST239 (11 nodos, 26 enlaces): topología europea con alta conectividad
- Topologías sintéticas paramétricas variando diámetro, grado medio de nodos, y distribución de distancias entre pares origen-destino

Esta validación permitiría identificar si la efectividad del modelo se mantiene consistente o si requiere re-entrenamiento específico por topología.

2. **Optimización automática de hiperparámetros y umbrales:** Implementar búsqueda sistemática de configuración óptima del sistema completo mediante:

- Grid search o random search para hiperparámetros del modelo Gradient Boosting (número de estimadores, tasa de aprendizaje, profundidad máxima)
- Optimización bayesiana para umbrales BFR que definen la estrategia de tres niveles
- Validación cruzada k -fold para selección robusta de configuración
- Meta-aprendizaje para transferencia de configuraciones entre topologías similares

3. **Horizontes temporales adaptativos:** Desarrollar un mecanismo de selección dinámica de horizonte de predicción que se ajuste según:

- Nivel de congestión actual de la red (horizontes cortos en alta congestión, largos en baja)

- Volatilidad reciente de métricas de fragmentación (horizontes cortos ante alta variabilidad)
- Precisión histórica de predicciones (ajuste adaptativo del horizonte para mantener precisión objetivo)

Evaluar trade-off entre anticipación (horizontes largos) y precisión predictiva (horizontes cortos).

4. **Incorporación de métricas de crosstalk:** Extender el conjunto de características de entrada del modelo para incluir:

- Diafonía agregada por núcleo: $XT_i = \sum_{j=1}^{N_i} h_{i,j} \cdot L$
- Distribución de utilización espectral entre núcleos adyacentes
- Número de violaciones potenciales de umbral XT_{TH} bajo diferentes asignaciones candidatas
- Factor de criticidad por núcleo basado en número de núcleos adyacentes (núcleos centrales vs. periféricos en geometrías hexagonales)

Analizar si esta información adicional mejora la capacidad predictiva del modelo, especialmente en escenarios de alta utilización.

6.4.2. Extensiones Arquitecturales y Algorítmicas

1. **Exploración de arquitecturas de ML alternativas:**

- **Redes neuronales recurrentes (LSTM, GRU):** Evaluar si la modelación explícita de dependencias temporales mediante arquitecturas recurrentes mejora la precisión predictiva respecto a Gradient Boosting, especialmente para horizontes temporales largos

- **Transformers con mecanismo de atención:** Investigar si mecanismos de atención pueden identificar automáticamente patrones temporales relevantes en series de tiempo de métricas de fragmentación
 - **Ensamblajes heterogéneos:** Combinar múltiples modelos (Gradient Boosting, Random Forest, redes neuronales) mediante votación ponderada o stacking para robustez mejorada
 - **Aprendizaje profundo por refuerzo:** Reformular el problema como MDP (Markov Decision Process) donde un agente aprende política óptima de disparo mediante exploración y recompensas basadas en bloqueos y reconfiguraciones
2. **Predicción multi-horizonte:** Entrenar modelos que predigan simultáneamente el índice BFR en múltiples horizontes temporales ($t + 500$, $t + 1000$, $t + 1500$, $t + 2000$), permitiendo al sistema de gestión evaluar trayectorias futuras de fragmentación y anticipar con mayor precisión el momento óptimo de intervención.
 3. **Aprendizaje continuo (online learning):** Implementar mecanismos de actualización incremental del modelo conforme se observan nuevos datos operacionales en producción, permitiendo adaptación automática a cambios en patrones de tráfico, despliegue de nuevos servicios, o modificaciones topológicas de la red.
 4. **Interpretabilidad mejorada:** Aplicar técnicas de explainable AI (SHAP values, LIME, análisis de importancia de características por permutación) para identificar qué métricas de fragmentación contribuyen más significativamente a las predicciones del modelo, facilitando comprensión y confianza de operadores de red.

6.4.3. Extensiones a Otros Contextos Operacionales

1. **Tráfico heterogéneo:** Extender el método para gestionar simultáneamente:
 - Tráfico multicast (punto a multipunto) con requisitos de continuidad espectral pero sin continuidad de núcleo estricta
 - Tráfico anycast (punto al más cercano disponible de un conjunto) con flexibilidad en selección de destino
 - Tráfico con diferenciación de QoS (latencia crítica vs. throughput orientado)
 - Solicitudes con requisitos de resiliencia (protección dedicada, compartida, o restauración)
2. **Integración con otros mecanismos de optimización:** Combinar la desfragmentación adaptativa propuesta con:
 - Algoritmos RMSCA (Routing, Modulation, Spectrum and Core Assignment) conscientes de fragmentación
 - Técnicas de previsión de tráfico para admisión controlada de demandas durante períodos de alta fragmentación
 - Mecanismos de conmutación de núcleos para flexibilidad espacial sin reruteo completo
 - Políticas de migración selectiva de lightpaths (solo reconfigurar conexiones críticas para maximizar eficiencia)
3. **Redes ópticas con arquitecturas heterogéneas:** Evaluar el método en escenarios donde coexisten:
 - Fibras con diferente número de núcleos (7, 12, 19 núcleos) en distintos enlaces

- Enlaces con diferentes capacidades espectrales (200, 320, 400 ranuras)
- Nodos con diferentes capacidades de conmutación espectral y espacial

Analizar si el modelo requiere características adicionales o re-entrenamiento para manejar esta heterogeneidad.

4. **Coordinación con plano de control distribuido:** Investigar integración del método propuesto con protocolos de plano de control SDN (Software-Defined Networking) y arquitecturas GMPLS (Generalized Multi-Protocol Label Switching) para:

- Coordinación distribuida de decisiones de desfragmentación entre múltiples dominios administrativos
- Sincronización de reconfiguraciones para minimizar interrupciones de servicios
- Mecanismos de rollback ante fallas durante proceso de desfragmentación

6.4.4. Validación Experimental en Entornos Reales

1. **Prototipado en testbed experimental:** Implementar el método propuesto en un testbed de redes ópticas reales (e.g., testbeds académicos como GÉANT en Europa, ESnet en Estados Unidos) para:

- Validar precisión predictiva con tráfico real (no simulado)
- Cuantificar overhead computacional y latencia de inferencia en hardware real
- Evaluar robustez ante eventos inesperados (fallas de enlaces, interrupciones de tráfico)
- Medir satisfacción de operadores con sistema de gestión autónoma

2. **Análisis de costos operacionales:** Realizar estudio económico comparativo cuantificando:

- Costo de interrupciones de servicio durante reconfiguraciones (expresado en SLA violations, penalizaciones contractuales)
- Costo de bloqueos de solicitudes (ingresos no percibidos, insatisfacción de clientes)
- Costo computacional de operación del modelo ML (energía, mantenimiento de infraestructura de predicción)
- ROI (Return on Investment) de despliegue del sistema propuesto vs. métodos tradicionales

3. **Estudios de caso industriales:** Colaborar con operadores de telecomunicaciones para evaluar el método en escenarios de producción reales, considerando:

- Patrones de tráfico reales con estacionalidad, eventos especiales, fallas
- Requisitos regulatorios y contractuales de disponibilidad y QoS
- Integración con sistemas legacy de gestión de red (OSS/BSS)
- Aceptación y confianza de equipos de operaciones en decisiones autónomas del sistema ML

6.5. Reflexiones Finales

La gestión eficiente de recursos en redes ópticas elásticas multinúcleo representa un desafío técnico de relevancia creciente en el contexto de demandas exponenciales de capacidad de transmisión. La fragmentación espectro-espacial constituye un obstáculo significativo para la utilización óptima de estos sistemas, requiriendo estrategias de desfragmentación que balanceen cuidadosamente los costos operacionales de reconfiguración contra los beneficios de reducción de bloqueos.

El presente trabajo demuestra que las técnicas modernas de aprendizaje automático, específicamente el algoritmo Gradient Boosting, pueden aplicarse exitosamente para resolver el problema de determinación del momento óptimo de desfragmentación en redes MC-EON. La capacidad demostrada de predecir con alta precisión el índice de fragmentación en horizontes temporales extensos ($t + 1000$ demandas) permite la implementación de estrategias adaptativas que superan significativamente a métodos tradicionales estáticos o puramente reactivos.

Los resultados experimentales obtenidos validan la viabilidad técnica y la superioridad en optimización multiobjetivo del método propuesto. Sin embargo, la transición de validación experimental en simulación a despliegue en redes de producción reales requiere abordar las limitaciones identificadas, particularmente en términos de generalización topológica, cuantificación de overhead computacional, y validación en condiciones operacionales heterogéneas.

Las direcciones de trabajo futuro identificadas proporcionan un mapa de ruta claro para evolución de esta línea de investigación. La exploración de arquitecturas de ML alternativas, la extensión a tráfico heterogéneo, y particularmente la validación en testbeds reales y estudios de caso industriales, constituyen pasos naturales hacia la maduración de sistemas de gestión autónoma de redes ópticas basados en inteligencia artificial.

En última instancia, este trabajo contribuye a la visión de redes de próxima generación auto-optimizadas y autónomas, donde sistemas de aprendizaje automático asisten a operadores humanos en la toma de decisiones complejas de gestión de recursos, permitiendo redes más eficientes, resilientes y escalables para soportar las demandas de conectividad del futuro.

Bibliografía

- [1] Masahiko Jinno et al. «Spectrum-efficient and scalable elastic optical path network: architecture, benefits, and enabling technologies». En: *IEEE communications magazine* 47.11 (2009), págs. 66-73.
- [2] Weiran Shi et al. «On the effect of bandwidth fragmentation on blocking probability in elastic optical networks». En: *IEEE transactions on communications* 61.7 (2013), págs. 2970-2978.
- [3] Mingyang Zhang et al. «Dynamic and adaptive bandwidth defragmentation in spectrum-sliced elastic optical networks with time-varying traffic». En: *Journal of Lightwave Technology* 32.5 (2014), págs. 1014-1023.
- [4] Bijoy Chand Chatterjee, Seydou Ba y Eiji Oki. «Fragmentation problems and management approaches in elastic optical networks: A survey». En: *IEEE Communications Surveys & Tutorials* 20.1 (2017), págs. 183-210.
- [5] Sahar Talebi et al. «Spectrum management techniques for elastic optical networks: A survey». En: *Optical Switching and Networking* 13 (2014), págs. 34-48.
- [6] Mingyang Zhang et al. «Bandwidth defragmentation in dynamic elastic optical networks with minimum traffic disruptions». En: *2013 IEEE International Conference on Communications (ICC)*. IEEE. 2013, págs. 3894-3898.
- [7] Paul Wright, Michael C Parker y Andrew Lord. «Minimum-and maximum-entropy routing and spectrum assignment for flexgrid elastic optical network-

- king». En: *Journal of Optical Communications and Networking* 7.1 (2015), A66-A72.
- [8] Enrique J Dávalos et al. «Spectrum defragmentation in elastic optical networks: Two Approaches With Metaheuristics». En: *IEEE Access* 7 (2019), págs. 119835-119843.